

Gabarito — Lista de Exercícios 01

Princípios do delineamento de experimentos (Capítulo 1 / Aula 01)

Questão 1. (Psicologia — identificação de unidades)*Solução.*

- (a) A **unidade experimental** é o participante: é nele que o programa de meditação (o tratamento) é sorteado e aplicado. A **unidade amostral** é cada aplicação do questionário — há três medições (submuestras) por participante.
- (b) Há **8 réplicas legítimas por programa** (8 participantes por grupo). As três respostas de um mesmo participante são submuestras, não réplicas independentes: elas compartilham a mesma unidade experimental e, portanto, tendem a ser correlacionadas entre si (um participante mais ansioso tende a responder "mais ansioso" nas três aplicações).
- (c) Ele comete **pseudorrepliação**: ao tratar 72 observações correlacionadas como se fossem 72 réplicas independentes, infla artificialmente o tamanho amostral efetivo, reduz o erro-padrão das médias estimadas de forma ilegítima e, com isso, aumenta a taxa de falsos positivos (rejeita H_0 com mais frequência do que o nível de significância nominal permitiria). O procedimento correto — formalizado no Capítulo 3 (DCA com submuestreo) — é primeiro resumir as submuestras por unidade experimental (por exemplo, pela média) e só então comparar os 24 valores resultantes (8 por grupo).

Questão 2. (Agricultura — fator, nível, tratamento)*Solução.*

- (a) Dois fatores: **Variedade** (níveis: V1, V2, V3) e **Densidade de plantio** (níveis: baixa, alta).
- (b) $3 \times 2 = 6$ **tratamentos**: (V1,baixa), (V1,alta), (V2,baixa), (V2,alta), (V3,baixa), (V3,alta).
- (c) É um **desenho fatorial**, porque todas as combinações dos níveis dos dois fatores são usadas simultaneamente (arranjo cruzado), em vez de estudar cada fator isoladamente em experimentos separados. Isso permite estimar não só os efeitos principais da variedade e da densidade, mas também se o efeito de uma depende do nível da outra (*interação*) — tema dos Capítulos 5 e 6.

Questão 3. (Ciência de dados — os três pilares)*Solução.*

- (a) **Não**. A atribuição ao "novo algoritmo" foi determinada por uma escolha do próprio usuário (atualizar ou não o aplicativo), não por sorteio do pesquisador.

- (b) Por exemplo: (i) usuários que atualizam o aplicativo tendem a ser mais engajados ou mais familiarizados com tecnologia, o que por si só pode aumentar o tempo de sessão, independentemente do algoritmo; (ii) a atualização pode ter trazido outras mudanças simultâneas (correções de bugs, nova interface) que também afetam o tempo de sessão, confundindo o efeito específico do algoritmo de recomendação.
- (c) Desenho sugerido: **Fator** = algoritmo de recomendação (2 níveis: antigo, novo); **unidade experimental** = usuário; **aleatorização** = cada usuário elegível é sorteado, de forma independente, para receber o algoritmo antigo ou o novo (um teste A/B clássico), mantendo os dois grupos idênticos em todas as outras características do aplicativo durante o período do teste; **resposta** = tempo de sessão médio no período.

Questão 4. (Fontes de variação)

Solução.

- (a) (i) **Efeito do tratamento** — é exatamente a comparação que o experimento foi desenhado para detectar.
- (b) (ii) **Variação sistemática entre unidades experimentais** — existia antes de qualquer tratamento ser aplicado, então não pode ser efeito da razão.
- (c) (iii) **Erro experimental** — variação residual entre unidades que receberam o *mesmo* tratamento e tinham a *mesma* origem conhecida (ninhada); é o que resta depois de contabilizar tratamento e a fonte de variação sistemática conhecida.

Questão 5. (Controle local / blocagem)

Solução.

- (a) Cada uma das 4 turmas é um **bloco**. Dentro de cada turma, os alunos são sorteados aleatoriamente entre os dois métodos (por exemplo, metade da turma para expositivo, metade para baseado em projetos), repetindo esse sorteio independentemente em cada uma das 4 turmas.
- (b) Parte da variação na nota final se deve a diferenças *entre turmas* que nada têm a ver com o método de ensino (turma mais forte, horário, professor auxiliar etc.). Ao comparar os métodos *dentro* de cada turma e só depois combinar essas comparações, essa fonte de variação conhecida é removida do erro experimental antes da análise — o que sobra para comparar os métodos é mais "limpo", tornando a comparação mais precisa (erro-padrão menor) do que sortear os métodos ignorando a turma, que misturaria variação entre turmas com o efeito do método.
- (c) **Não**. A blocagem organiza *onde* a aleatorização acontece (dentro de cada bloco), mas não a substitui: sem sortear os métodos dentro de cada turma, ainda haveria risco de viés de seleção dentro de cada bloco (por exemplo, se o professor colocasse os alunos mais motivados no método que prefere). Blocagem e aleatorização resolvem problemas diferentes e são usadas em conjunto.

Questão 6. (Dedução — resultados potenciais)*Solução.*

- (a) O conjunto de índices $\{i : Z_i = 1\}$ é, por construção do mecanismo de aleatorização, um subconjunto de tamanho n_1 sorteado uniformemente entre os $\binom{N}{n_1}$ subconjuntos de $\{1, \dots, N\}$ — exatamente a definição de uma amostra aleatória simples (AAS) sem reposição de tamanho n_1 retirada dos índices $1, \dots, N$. Como $\bar{Y}_1^{obs} = \frac{1}{n_1} \sum_{i: Z_i=1} Y_i(1)$ é a média dos valores $Y_i(1)$ correspondentes a esses índices sorteados, e os valores $Y_1(1), \dots, Y_N(1)$ são tratados como constantes fixas (não aleatórias), $\bar{Y}_1^{obs}$ é, por definição, a média de uma AAS sem reposição de tamanho n_1 do conjunto finito $\{Y_1(1), \dots, Y_N(1)\}$.
- (b) Um resultado clássico de amostragem (válido para qualquer população finita, qualquer que seja sua distribuição) diz que a média de uma AAS sem reposição é um estimador não-viesado da média populacional: $E[\bar{Y}_1^{obs}] = \frac{1}{N} \sum_{i=1}^N Y_i(1) = \bar{Y}(1)$. Pelo item (a), essa propriedade se aplica diretamente. Pelo mesmo argumento aplicado ao complemento — as n_0 unidades com $Z_i = 0$ formam a AAS complementar de tamanho n_0 do conjunto $\{Y_1(0), \dots, Y_N(0)\}$ — temos $E[\bar{Y}_0^{obs}] = \bar{Y}(0)$. Por linearidade da esperança,

$$E[\widehat{ATE}] = E[\bar{Y}_1^{obs}] - E[\bar{Y}_0^{obs}] = \bar{Y}(1) - \bar{Y}(0) = ATE. \quad \blacksquare$$

- (c) Porque a única fonte de aleatoriedade explorada na demonstração é o *mecanismo de aleatorização* (qual subconjunto de unidades é sorteado para tratamento) — os $2N$ valores $Y_i(0), Y_i(1)$ são tratados como constantes fixas do início ao fim. O argumento é inteiramente combinatório/de amostragem finita (a mesma lógica que garante que a média de uma enquete por amostragem aleatória estima sem viés a média da população, sem qualquer suposição sobre a forma da distribuição dos valores populacionais). É por isso que a aleatorização, e não a normalidade dos erros, é o que fundamenta a validade causal do experimento — a normalidade entra depois, apenas para viabilizar fórmulas fechadas de teste/IC, como já visto na comparação entre o teste F e o teste de aleatorização.

Questão 7. (Método científico — falseabilidade e validade externa)*Solução.*

- (a) Garante apenas **validade interna**. A aleatorização impecável assegura que, dentro do grupo de testadores beta, a diferença observada entre "recomendação antiga" e "recomendação nova" é uma estimativa não-viesada do efeito causal *nessa amostra* (nenhuma variável, medida ou não, fica sistematicamente desbalanceada entre os dois braços). Isso nada diz sobre se esse efeito se generaliza a usuários fora do grupo beta — essa é uma pergunta de validade externa, logicamente separada, e a aleatorização por si só não a responde.
- (b) Uma formulação falseável precisa apontar uma observação que a contradiria caso a alegação seja falsa — por exemplo: "entre os usuários do grupo beta sorteados para a recomendação nova, a taxa média de conversão será pelo menos 12% maior do que entre os sorteados para a recomendação antiga, com essa diferença estatisticamente significativa a um nível pré-registrado (ex. $\alpha = 0,05$)". Se o experimento (já desenhado e executado) resultar numa diferença nula, negativa, ou não significativa, a alegação é refutada por essa evidência — ao contrário de

uma alegação vaga como "a recomendação nova é melhor", que nenhum resultado numérico conseguiria contradizer de forma inequívoca.

- (c) Exige uma suposição de **representatividade**: que o efeito do algoritmo de recomendação sobre testadores beta (usuários auto-selecionados, mais engajados, motivados por recompensa) seja o mesmo — ou ao menos comparável — ao efeito sobre a população geral de usuários do site. Essa suposição não é garantida por nenhuma propriedade do desenho experimental usado (a aleatorização só protege contra confusão *dentro* do grupo estudado); ela é uma alegação substantiva sobre o domínio, que precisaria ser justificada separadamente (por exemplo, comparando características observáveis dos testadores beta com as da população geral) ou testada diretamente, expandindo o teste para uma amostra aleatória de todos os usuários.

Nota de apoio (questão 1c) — a pseudorreplicação em código:

```
# Simulação simplificada: mesma logica da Aula 01 (Aulas2026/MATD48-01.Rmd)
# 24 participantes, 3 medidas cada (submuestras) -- efeito de tratamento nulo
set.seed(1)
participante <- rep(1:24, each = 3)
efeito_individual <- rep(rnorm(24, 0, 5), each = 3)
grupo <- rep(rep(c("10min", "20min", "30min"), each = 8), each = 3)
resposta <- 50 + efeito_individual + rnorm(72, 0, 2) # tratamento sem efeito real

# Errado: ignora que ha so 24 UEs -> 72 "réplicas"
summary(aov(resposta ~ grupo))[[1]][["Pr(>F)"]][1]

# Certo: agrega por participante antes de comparar -> 24 UEs
media_part <- tapply(resposta, participante, mean)
grupo_part <- tapply(grupo, participante, unique)
summary(aov(media_part ~ grupo_part))[[1]][["Pr(>F)"]][1]
```

Rodando este código, o p-valor do modelo "errado" tende a ser bem menor que o do modelo "correto" mesmo quando, por construção, não há efeito real de tratamento — evidência direta do custo de ignorar a distinção entre unidade experimental e unidade amostral.