

Gabarito — Lista de Exercícios 02

Modelo linear, mínimos quadrados e estimabilidade (Capítulo 2 / Aula 02)

Questão 1. (Ciência de dados — mínimos quadrados na mão)*Solução.*

(a)

$$\mathbf{X} = \begin{bmatrix} 1 & 2 \\ 1 & 4 \\ 1 & 6 \\ 1 & 8 \\ 1 & 10 \end{bmatrix}, \quad \mathbf{Y} = \begin{bmatrix} 15 \\ 22 \\ 25 \\ 33 \\ 38 \end{bmatrix}.$$

(b)

$$\mathbf{X}'\mathbf{X} = \begin{bmatrix} 5 & 30 \\ 30 & 220 \end{bmatrix}, \quad \mathbf{X}'\mathbf{Y} = \begin{bmatrix} 133 \\ 912 \end{bmatrix}.$$

(c) Com $a = 5$, $b = 30$, $c = 220$: $ac - b^2 = 1100 - 900 = 200$, então

$$(\mathbf{X}'\mathbf{X})^{-1} = \frac{1}{200} \begin{bmatrix} 220 & -30 \\ -30 & 5 \end{bmatrix},$$

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y} = \frac{1}{200} \begin{bmatrix} 220(133) - 30(912) \\ -30(133) + 5(912) \end{bmatrix} = \frac{1}{200} \begin{bmatrix} 1900 \\ 570 \end{bmatrix} = \begin{bmatrix} 9.5 \\ 2.85 \end{bmatrix}.$$

Logo $\hat{\beta}_0 = 9.5$ e $\hat{\beta}_1 = 2.85$.(d) Cada script adicional carregado está associado a um aumento estimado de **2,85 décimos de segundo** (0,285 s) no tempo de carregamento da página, mantendo tudo o mais igual.(e) A soma dos resíduos deve ser **zero**. Das equações normais, $\mathbf{X}'\mathbf{e} = \mathbf{X}'(\mathbf{Y} - \mathbf{X}\hat{\beta}) = \mathbf{0}$. A primeira linha de $\mathbf{X}'$ é um vetor de 1's (porque a primeira coluna de $\mathbf{X}$ é o intercepto), então a primeira componente de $\mathbf{X}'\mathbf{e}$ é exatamente $\sum_i e_i$, que portanto é zero — sem precisar recalculer os resíduos individualmente. (Conferindo: $\hat{\mathbf{Y}} = (15.2, 20.9, 26.6, 32.3, 38.0)$, $\mathbf{e} = (-0.2, 1.1, -1.6, 0.7, 0.0)$, soma = 0.)**Questão 2. (Psicologia — estimabilidade)***Solução.*

(a)

$$\mathbf{X} = \begin{bmatrix} 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \end{bmatrix}.$$

- (b) O posto é **3**, não 4. A coluna de μ é exatamente a soma das colunas de α_1 , α_2 e α_3 (cada linha tem um único α_j igual a 1, então a soma das três colunas de α é uma coluna de 1's, idêntica à coluna de μ) — uma dependência linear exata que reduz o posto em 1.
- (c) Usando o critério $\lambda'\beta$ estimável $\iff \lambda'$ no espaço-linha de $\mathbf{X}$ (equivalentemente, existe $\mathbf{a}$ com $\mathbf{a}'\mathbf{X} = \lambda'$):
- (i) μ : **não estimável**. Não há combinação das seis linhas de $\mathbf{X}$ que produza $(1, 0, 0, 0)$ — toda linha de $\mathbf{X}$ tem um μ e um α_j simultaneamente "ligados"; isolar μ exigiria cancelar todos os α_j 's ao mesmo tempo em que se mantém o coeficiente de μ em 1, o que não é possível dado o posto 3 da matriz.
 - (ii) $\mu + \alpha_1$: **estimável**. Tome $\mathbf{a} = (\frac{1}{2}, \frac{1}{2}, 0, 0, 0, 0)$ (a média das duas observações do grupo 1): $\mathbf{a}'\mathbf{X} = (1, 1, 0, 0)$, que é exatamente λ' para $\mu + \alpha_1$. É a média populacional do grupo 1.
 - (iii) $\alpha_1 - \alpha_2$: **estimável**. Tome $\mathbf{a} = (\frac{1}{2}, \frac{1}{2}, -\frac{1}{2}, -\frac{1}{2}, 0, 0)$: $\mathbf{a}'\mathbf{X} = (0, 1, -1, 0)$, a diferença entre as médias dos grupos 1 e 2 — um contraste, sempre estimável independentemente da parametrização.
 - (iv) $\alpha_1 + \alpha_2 + \alpha_3$: **não estimável**. Não existe $\mathbf{a}$ com $\mathbf{a}'\mathbf{X} = (0, 1, 1, 1)$: qualquer combinação das linhas que dê coeficiente 1 em cada α_j necessariamente também carrega um coeficiente não nulo em μ (soma dos pesos $\mathbf{a}$), então essa função particular não pode ser isolada.

Questão 3. (Agricultura — especificação do modelo)

Solução.

- (a) Ordenando as parcelas (baixa,V1), (baixa,V2), (alta,V1), (alta,V2):

$$\mathbf{X} = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \\ 1 & 1 & 1 \end{bmatrix}.$$

- (b) Sim, $\mathbf{X}$ tem posto coluna completo (posto 3 = número de colunas). As quatro linhas são distintas e, tomando três delas — por exemplo, as linhas 1, 2 e 3 — obtém-se uma submatriz 3×3 triangular inferior com diagonal $(1, 1, 1)$ e determinante não nulo, o que já basta para garantir posto 3 completo em $\mathbf{X}$.
- (c) β_0 é a produtividade média esperada da combinação de referência (dose baixa, V1). β_1 é a diferença esperada na produtividade média entre dose alta e dose baixa, mantendo a variedade fixa (em V1). β_2 é a diferença esperada entre V2 e V1, mantendo a dose fixa (em baixa). Como não há termo de interação neste modelo, assume-se que essas duas diferenças são as mesmas independentemente do nível do outro fator.

Questão 4. (Ciência de dados — geometria dos mínimos quadrados)

Solução.

- (a) Das equações normais, $\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}'\mathbf{Y}$, logo $\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} - \mathbf{X}'\mathbf{Y} = \mathbf{0}$, ou seja, $-\mathbf{X}'(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}) = \mathbf{0}$. Como $\mathbf{e} = \mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}$, isso é exatamente $\mathbf{X}'\mathbf{e} = \mathbf{0}$.
- (b) Se a primeira coluna de $\mathbf{X}$ é $\mathbf{1}$ (vetor de 1's), a primeira linha de $\mathbf{X}'$ também é $\mathbf{1}'$, e a primeira componente de $\mathbf{X}'\mathbf{e}$ é $\mathbf{1}'\mathbf{e} = \sum_i e_i$. Pelo item (a), essa componente é zero, logo $\sum_i e_i = 0$.
- (c) Não. $\sum_i e_i = 0$ é uma restrição *global* (média dos resíduos zero); ela não impede padrões *locais* sistemáticos. Por exemplo, os resíduos poderiam ser sistematicamente positivos para valores pequenos de x e sistematicamente negativos para valores grandes de x (indicando uma relação não linear que um modelo linear não capturou) e ainda assim somar exatamente zero. A propriedade garante apenas ausência de viés *médio*, não ausência de má especificação do modelo — por isso sempre inspecionamos o gráfico de resíduos, não só sua soma.

Questão 5. (Ciência de dados — exercício computacional em R)

Solução.

(a)

```
x <- c(2, 4, 6, 8, 10)
y <- c(15, 22, 25, 33, 38)
X <- cbind(1, x)

beta_hat <- solve(t(X) %*% X) %*% t(X) %*% y

y_hat <- X %*% beta_hat
residuos <- y - y_hat

sum(residuos)
```

- (b) Rodando o código, `beta_hat` retorna (9.5, 2.85) — coincide exatamente com o resultado manual da Questão 1(c), e `sum(residuos)` retorna um valor numericamente igual a zero (algo como $-2.1\text{e-}13$, um artefato de precisão de ponto flutuante).

(c)

```
coef(lm(y ~ x))
```

As duas estimativas coincidem porque `lm()` resolve exatamente as mesmas equações normais $\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}'\mathbf{Y}$ (internamente via decomposição QR, por estabilidade numérica, mas o resultado algébrico é idêntico ao da inversão direta de $\mathbf{X}'\mathbf{X}$).

Questão 6. (Dedução — equações normais)

Solução.

(a)

$$S(\boldsymbol{\beta}) = (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})'(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) = \mathbf{Y}'\mathbf{Y} - \mathbf{Y}'\mathbf{X}\boldsymbol{\beta} - \boldsymbol{\beta}'\mathbf{X}'\mathbf{Y} + \boldsymbol{\beta}'\mathbf{X}'\mathbf{X}\boldsymbol{\beta}.$$

Como $\mathbf{Y}'\mathbf{X}\boldsymbol{\beta}$ é um escalar, ele é igual à sua própria transposta $\boldsymbol{\beta}'\mathbf{X}'\mathbf{Y}$, então os dois termos do meio se combinam:

$$S(\boldsymbol{\beta}) = \mathbf{Y}'\mathbf{Y} - 2\boldsymbol{\beta}'\mathbf{X}'\mathbf{Y} + \boldsymbol{\beta}'\mathbf{X}'\mathbf{X}\boldsymbol{\beta}.$$

- (b) Aplicando as duas regras de derivação termo a termo, com $\mathbf{a} = \mathbf{X}'\mathbf{Y}$ no termo linear e $\mathbf{A} = \mathbf{X}'\mathbf{X}$ (simétrica) no termo quadrático:

$$\frac{\partial S(\boldsymbol{\beta})}{\partial \boldsymbol{\beta}} = -2\mathbf{X}'\mathbf{Y} + 2\mathbf{X}'\mathbf{X}\boldsymbol{\beta}.$$

- (c) Igualando a $\mathbf{0}$:

$$-2\mathbf{X}'\mathbf{Y} + 2\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{0} \implies \mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}'\mathbf{Y}.$$

- (d) A Hessiana de $S(\boldsymbol{\beta})$ é a matriz de segundas derivadas, $\partial^2 S / \partial \boldsymbol{\beta} \partial \boldsymbol{\beta}' = 2\mathbf{X}'\mathbf{X}$. Para qualquer vetor $\mathbf{v}$, $\mathbf{v}'(2\mathbf{X}'\mathbf{X})\mathbf{v} = 2(\mathbf{X}\mathbf{v})'(\mathbf{X}\mathbf{v}) = 2\|\mathbf{X}\mathbf{v}\|^2 \geq 0$, logo a Hessiana é semidefinida positiva em qualquer ponto do domínio (não depende de $\boldsymbol{\beta}$). Uma função cuja Hessiana é semidefinida positiva em todo o domínio é **convexa**; para uma função convexa, todo ponto crítico (derivada primeira nula) é um **mínimo global**, nunca um máximo ou ponto de sela. Isso garante que qualquer solução das equações normais realmente minimiza $S(\boldsymbol{\beta})$, e não apenas anula sua derivada.

Questão 7. (Dedução/computacional — pseudoinversa de Moore-Penrose via SVD)

Solução.

- (a)

$$\mathbf{A}\mathbf{v}_3 = \begin{bmatrix} 4 & 2 & 2 \\ 2 & 2 & 0 \\ 2 & 0 & 2 \end{bmatrix} \frac{1}{\sqrt{3}} \begin{bmatrix} 1 \\ -1 \\ -1 \end{bmatrix} = \frac{1}{\sqrt{3}} \begin{bmatrix} 4-2-2 \\ 2-2-0 \\ 2-0-2 \end{bmatrix} = \frac{1}{\sqrt{3}} \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} = \mathbf{0}.$$

Confirmado: $\mathbf{v}_3$ é autovetor de autovalor 0. Isso já era esperado porque $\mathbf{X}$ (a matriz de delineamento original) tem posto 2 (a coluna de μ é a soma das colunas de τ_1, τ_2), então $\mathbf{A} = \mathbf{X}'\mathbf{X}$ também tem posto 2 (o posto de $\mathbf{X}'\mathbf{X}$ é sempre igual ao posto de $\mathbf{X}$) — uma matriz 3×3 de posto 2 é singular e tem exatamente um autovalor nulo.

- (b)

$$\mathbf{D}^+ = \begin{bmatrix} 1/6 & 0 & 0 \\ 0 & 1/2 & 0 \\ 0 & 0 & 0 \end{bmatrix}.$$

- (c) Como o termo em $\mathbf{v}_3$ é multiplicado por 0 em $\mathbf{D}^+$,

$$\mathbf{A}^+ = \frac{1}{6}\mathbf{v}_1\mathbf{v}_1' + \frac{1}{2}\mathbf{v}_2\mathbf{v}_2'.$$

A entrada (1,1) usa só as primeiras componentes: $v_{1,1} = 2/\sqrt{6}$, $v_{2,1} = 0$. Logo

$$[\mathbf{A}^+]_{11} = \frac{1}{6}(2/\sqrt{6})^2 + \frac{1}{2}(0)^2 = \frac{1}{6} \cdot \frac{4}{6} = \frac{4}{36} = \frac{1}{9} \approx 0,1111,$$

que bate exatamente com a entrada (1,1) de `MASS::ginv(A)`.

- (d)

```
A <- matrix(c(4,2,2, 2,2,0, 2,0,2), ncol = 3, byrow = TRUE)
sv <- svd(A)
D_mais <- diag(ifelse(sv$d > 1e-8, 1 / sv$d, 0))
A_mais <- sv$v %*% D_mais %*% t(sv$u)
max(abs(A_mais - MASS::ginv(A)))
```

Rodando o código, a diferença máxima é numericamente zero: a construção manual via SVD e `MASS::ginv()` produzem a mesma matriz.

(e)

$$\mathbf{b} = \mathbf{A}^+ \mathbf{X}' \mathbf{y} \approx (9,5833, 5,1667, 4,4167)',$$

e as funções estimáveis:

$$\mu + \tau_1 = 9,5833 + 5,1667 = 14,75, \quad \mu + \tau_2 = 9,5833 + 4,4167 = 14,00, \quad \tau_1 - \tau_2 = 5,1667 - 4,4167 = 0,75.$$

Esses três valores coincidem com os que qualquer outra inversa generalizada de $\mathbf{A}$ produziria (mesmo que o vetor $\mathbf{b}$ intermediário seja diferente), porque $\mu + \tau_1$, $\mu + \tau_2$ e $\tau_1 - \tau_2$ são funções **estimáveis** — e o texto do Capítulo 2 do livro mostra que o valor de uma função estimável $\mathbf{X}'\mathbf{b}$ não depende de qual inversa generalizada $(\mathbf{X}'\mathbf{X})^-$ foi usada para obter $\mathbf{b}$, só o próprio $\mathbf{b}$ depende dessa escolha.