

**Gabarito — Lista de Exercícios 04**

Delineamento completamente aleatorizado: modelo, ANOVA, intervalos de confiança e tamanho amostral (Capítulo 3 / Aula 04)

**Questão 1. (Psicologia — ANOVA a partir de somas de quadrados)**

*Solução.*

- (a) Com  $t = 3$ ,  $N = 30$ :  $g.l._{Trat} = 2$ ,  $g.l._E = 27$ ,  $g.l._{Total} = 29$ .  $SQ_E = 402,6 - 148,2 = 254,4$ .  $MS_{Trat} = 148,2/2 = 74,1$ ;  $MS_E = 254,4/27 \approx 9,42$ .  $F = 74,1/9,42 \approx \mathbf{7,86}$ .

| Fonte   | g.l. | SQ    | QM    | $F$  |
|---------|------|-------|-------|------|
| Técnica | 2    | 148,2 | 74,10 | 7,86 |
| Erro    | 27   | 254,4 | 9,42  |      |
| Total   | 29   | 402,6 |       |      |

- (b) Sim, diferem:  $F = 7,86 > F_{2,27;0,05} \approx 3,35$ , logo rejeitamos  $H_0 : \mu_1 = \mu_2 = \mu_3$  a  $\alpha = 0,05$ . Há evidência de que ao menos uma técnica difere das demais quanto à redução média de cortisol.
- (c) A ANOVA global só permite afirmar que *existe* alguma diferença entre as três médias — **não** identifica quais pares diferem, nem a direção ou magnitude de cada diferença específica. Para isso são necessários procedimentos de comparação múltipla (contrastes, Tukey, etc.), fora do escopo desta lista.

**Questão 2. (Agricultura — intervalos de confiança)**

*Solução.* Com  $MS_E = 18,4$ ,  $df_E = 28$ ,  $n = 8$  por dose,  $t_{28;0,025} \approx 2,048$ .

- (a)  $\bar{Y}_{80} \pm t_{28;0,025} \sqrt{MS_E/8} = 74,3 \pm 2,048 \sqrt{2,3} = 74,3 \pm 3,11$ , ou seja,  $\mathbf{IC}_{95\%} \approx (71,19; 77,41)$  sc/ha.
- (b)  $(\bar{Y}_{80} - \bar{Y}_{40}) \pm t_{28;0,025} \sqrt{MS_E(1/8 + 1/8)} = 5,6 \pm 2,048 \sqrt{4,6} = 5,6 \pm 4,39$ , ou seja,  $\mathbf{IC}_{95\%} \approx (1,21; 9,99)$  sc/ha — como o intervalo não contém zero, há evidência de que a dose de 80 kg/ha produz maior produtividade média que a de 40 kg/ha.
- (c) Porque a ANOVA assume variância comum  $\sigma^2$  entre todos os  $t$  tratamentos (homocedasticidade); combinar (*pool*) a variabilidade das quatro doses em uma única estimativa  $MS_E$ , com 28 graus de liberdade em vez de apenas 7 por dose, produz uma estimativa de  $\sigma^2$  mais precisa e, portanto, intervalos mais estreitos — desde que a suposição de variância comum seja razoável (Aula 06).

**Questão 3. (Ciência de dados — notação matricial do DCA)**

*Solução.*

- (a)  $\mathbf{X}$  é  $12 \times 3$ . Como as três colunas de  $\mathbf{X}$  são indicadoras de grupos disjuntos,  $\mathbf{X}'\mathbf{X} = \text{diag}(n_1, n_2, n_3) = \text{diag}(4, 3, 5)$  (uma matriz  $3 \times 3$ ), e portanto  $(\mathbf{X}'\mathbf{X})^{-1} = \text{diag}(1/4, 1/3, 1/5)$ .
- (b) Porque  $\mathbf{X}$  tem posto coluna completo ( $\text{posto}(\mathbf{X}) = 3 = \text{número de colunas}$ ): não há combinação linear não trivial das colunas de  $\mathbf{X}$  que seja o vetor nulo, logo  $\mathbf{X}'\mathbf{X}$  é invertível e *toda* função linear de  $\boldsymbol{\beta}$  — em particular cada  $\mu_i$  isoladamente — é estimável de forma única. Isso contrasta com a parametrização sobreparametrizada  $\mu + \tau_i$  (posto  $t - 1$  para os  $\tau_i$  dado  $\mu$ ), em que só contrastes (como  $\mu_i - \mu_k$ ) são estimáveis, não  $\mu$  e  $\tau_i$  isoladamente.
- (c)  $\text{Var}(\hat{\mu}_2 - \hat{\mu}_3) = \text{Var}(\hat{\mu}_2) + \text{Var}(\hat{\mu}_3) - 2 \text{Cov}(\hat{\mu}_2, \hat{\mu}_3) = \sigma^2/n_2 + \sigma^2/n_3 - 0 = \sigma^2 \left( \frac{1}{3} + \frac{1}{5} \right) = \frac{8}{15} \sigma^2$ , já que  $(\mathbf{X}'\mathbf{X})^{-1}$  diagonal implica  $\text{Cov}(\hat{\mu}_2, \hat{\mu}_3) = 0$ .

#### Questão 4. (Dedução — $\hat{\boldsymbol{\beta}}$ é BLUE no DCA)

*Solução.*

- (a)  $E[\hat{\boldsymbol{\beta}}] = E[(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}] = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'E[\mathbf{Y}] = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}\boldsymbol{\beta} = \boldsymbol{\beta}$ , usando  $E[\mathbf{Y}] = \mathbf{X}\boldsymbol{\beta}$  (pois  $E[\boldsymbol{\varepsilon}] = \mathbf{0}$ ) e que  $(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X} = \mathbf{I}_t$ . Logo  $\hat{\boldsymbol{\beta}}$  é não viesado.
- (b)  $\text{Cov}(\hat{\boldsymbol{\beta}}) = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' \text{Cov}(\mathbf{Y}) \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\sigma^2\mathbf{I}_N)\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} = \sigma^2(\mathbf{X}'\mathbf{X})^{-1} \underbrace{\mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}}_{=\mathbf{I}_t} = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}$ . Como  $\mathbf{X}'\mathbf{X} = \text{diag}(n_1, \dots, n_t)$  para a matriz de indicadoras (colunas ortogonais entre si), sua inversa é  $\text{diag}(1/n_1, \dots, 1/n_t)$ , logo  $\text{Cov}(\hat{\boldsymbol{\beta}}) = \text{diag}(\sigma^2/n_1, \dots, \sigma^2/n_t)$ : diagonal,  $i$ -ésimo elemento  $\sigma^2/n_i$ .
- (c) **Teorema (Gauss-Markov).** Sob  $E[\boldsymbol{\varepsilon}] = \mathbf{0}$  e  $\text{Cov}(\boldsymbol{\varepsilon}) = \sigma^2\mathbf{I}_N$  (sem exigir normalidade), se  $\boldsymbol{\lambda}'\boldsymbol{\beta}$  é estimável, então  $\boldsymbol{\lambda}'\hat{\boldsymbol{\beta}}$  é o BLUE de  $\boldsymbol{\lambda}'\boldsymbol{\beta}$ : entre todos os estimadores lineares  $\mathbf{c}'\mathbf{Y}$  não viesados para  $\boldsymbol{\lambda}'\boldsymbol{\beta}$ , ele tem a menor variância. As hipóteses do teorema — média zero e covariância  $\sigma^2\mathbf{I}_N$  dos erros — são exatamente as assumidas no enunciado, e  $\mathbf{X}$  tem posto completo, o que torna *toda*  $\boldsymbol{\lambda}'\boldsymbol{\beta}$  estimável (item b). Em particular, tomando  $\boldsymbol{\lambda} = \mathbf{e}_i$  (o  $i$ -ésimo vetor canônico),  $\mu_i = \mathbf{e}_i'\boldsymbol{\beta}$  é estimável e  $\hat{\mu}_i = \mathbf{e}_i'\hat{\boldsymbol{\beta}} = \bar{Y}_i$ . é o BLUE de  $\mu_i$ : nenhum outro estimador linear não viesado de  $\mu_i$  tem variância menor que  $\sigma^2/n_i$ .

#### Questão 5. (Número de réplicas — ciência de dados)

*Solução.*

- (a) O menor  $n$  tabelado com poder  $\geq 0,80$  é  $\mathbf{n=40}$  por grupo (poder 0,80 exatamente), totalizando  $3 \times 40 = \mathbf{120}$  observações.
- (b) Com  $n = 20$ , o poder tabelado é 0,50: se a diferença real entre as estratégias de *cache* for de fato do tamanho assumido no piloto ( $f \approx 0,30$ ), a equipe teria apenas cerca de 50% de chance de detectá-la como estatisticamente significativa — ou seja, quase a mesma chance de um "cara ou coroa" de o experimento terminar inconclusivo mesmo havendo efeito real (erro Tipo II de  $\beta \approx 0,50$ ).

- (c) **Subestimar**  $\sigma$  tornaria o planejamento otimista demais: um  $\sigma$  menor do que o real infla artificialmente o  $f$  de Cohen calculado a partir das médias piloto (pois  $f = \sigma_\mu/\sigma$ ), fazendo a tabela superestimar o poder alcançado para um dado  $n$  — na prática, o poder real seria menor que o nominal, e o experimento ficaria subdimensionado. Por isso pilotos muito pequenos, que tendem a estimar  $\sigma$  de forma instável, pedem cautela (ou uma margem de segurança) no planejamento amostral.