

Gabarito — Lista de Exercícios 09

Delineamento em blocos completos aleatorizados (Capítulo 4 / Aula 09)

Questão 1. (Agricultura — tabela de ANOVA do DBCA)*Solução.*

- (a) $SQ_{Erro} = SQ_{Total} - SQ_{Trat} - SQ_{Bloco} = 850 - 320 - 210 = \mathbf{320}$. Graus de liberdade: $gl_{Trat} = t - 1 = 3$, $gl_{Bloco} = b - 1 = 4$, $gl_{Erro} = (t - 1)(b - 1) = 12$, $gl_{Total} = tb - 1 = 19$. Quadrados médios: $QM_{Trat} = 320/3 = 106,67$, $QM_{Bloco} = 210/4 = 52,5$, $QM_{Erro} = 320/12 = 26,67$.
- (b) $F_0 = QM_{Trat}/QM_{Erro} = 106,67/26,67 \approx \mathbf{4,00}$.
- (c) Como $F_0 = 4,00 > F_{0,05;3;12} = 3,49$, **rejeita-se** H_0 : há evidência, ao nível de 5%, de que pelo menos uma variedade difere das demais quanto à produtividade média.

Questão 2. (Dedução — decomposição ortogonal da soma de quadrados)*Solução.*

- (a) $\sum_i a_i = \sum_i (\bar{Y}_{i.} - \bar{Y}_{..}) = \left(\sum_i \bar{Y}_{i.} \right) - t\bar{Y}_{..}$. Como $\bar{Y}_{..}$ é, por definição, a média das médias de tratamento $\bar{Y}_{i.}$ (o desenho é balanceado, cada tratamento com b observações), $\sum_i \bar{Y}_{i.} = t\bar{Y}_{..}$, logo $\sum_i a_i = 0$. O argumento para $\sum_j b_j = 0$ é idêntico, trocando tratamento por bloco.
- (b) Para i fixo,

$$\sum_j e_{ij} = \sum_j Y_{ij} - b\bar{Y}_{i.} - \sum_j \bar{Y}_{.j} + b\bar{Y}_{..}$$

Mas $\sum_j Y_{ij} = b\bar{Y}_{i.}$ (soma das b observações do tratamento i) e $\sum_j \bar{Y}_{.j} = b\bar{Y}_{..}$ (pelo item (a), aplicado aos blocos). Logo $\sum_j e_{ij} = b\bar{Y}_{i.} - b\bar{Y}_{i.} - b\bar{Y}_{..} + b\bar{Y}_{..} = 0$. O argumento para $\sum_i e_{ij} = 0$ (com j fixo) é análogo, trocando os papéis de i e j .

- (c) Elevando ao quadrado e somando,

$$\sum_{i,j} (Y_{ij} - \bar{Y}_{..})^2 = \sum_{i,j} (a_i + b_j + e_{ij})^2 = \sum_{i,j} a_i^2 + \sum_{i,j} b_j^2 + \sum_{i,j} e_{ij}^2 + 2 \sum_{i,j} a_i b_j + 2 \sum_{i,j} a_i e_{ij} + 2 \sum_{i,j} b_j e_{ij}.$$

O primeiro termo cruzado se anula porque a_i não depende de j nem b_j de i : $\sum_{i,j} a_i b_j = (\sum_i a_i)(\sum_j b_j) = 0 \times 0 = 0$ pelo item (a). O segundo se anula porque, para cada i , a_i é constante em j e $\sum_j e_{ij} = 0$ (item b): $\sum_{i,j} a_i e_{ij} = \sum_i a_i (\sum_j e_{ij}) = \sum_i a_i \times 0 = 0$. Analogamente, $\sum_{i,j} b_j e_{ij} = \sum_j b_j (\sum_i e_{ij}) = 0$. Restam apenas os três termos quadráticos:

$$\sum_{i,j} (Y_{ij} - \bar{Y}_{..})^2 = b \sum_i a_i^2 + t \sum_j b_j^2 + \sum_{i,j} e_{ij}^2 = SQ_{Trat} + SQ_{Bloco} + SQ_{Erro},$$

em que o fator b multiplicando $\sum_i a_i^2$ (e t multiplicando $\sum_j b_j^2$) surge porque a_i^2 (resp. b_j^2) é somado b vezes (resp. t vezes) — uma vez para cada valor do índice do qual não depende.

Nota: este é o mesmo fato que, na Seção de notação matricial do Capítulo 4, aparece como ortogonalidade entre as colunas (centralizadas) de X_{trat} e X_{bloco} na matriz de delineamento $X = [\mathbf{1} \mid X_{trat} \mid X_{bloco}]$ — a prova algébrica acima é a mesma ortogonalidade, escrita sem notação matricial.

Questão 3. (Psicologia — blocagem como aleatorização restrita)

Solução.

- Sejam $Y_u(1)$ e $Y_u(3)$ os resultados potenciais do paciente u sob respiração guiada e sob mindfulness breve, respectivamente. O efeito causal médio de interesse é $\tau_{13} = \mathbb{E}[Y_u(1) - Y_u(3)]$, tomado sobre a população dos pacientes recrutados.
- A aleatorização — mesmo restrita a cada bloco de gravidade — garante que, *dentro de cada bloco*, os pacientes que efetivamente receberam a técnica i são uma amostra representativa de como todos os pacientes *daquele bloco* responderiam à técnica i : o sorteio não depende de nenhuma característica do paciente (observada ou não) que também afete a resposta, então não há confusão entre "recebeu a técnica i " e "teria respondido melhor de qualquer forma". Como isso vale bloco a bloco, e o efeito causal médio geral é uma combinação ponderada (pelo tamanho de cada bloco) dos efeitos médios dentro de cada bloco, o estimador permanece não viesado para τ_{13} — a blocagem apenas organiza *onde* a aleatorização acontece, sem comprometer a comparabilidade que ela garante.
- A blocagem reduz o erro-padrão quando a gravidade basal está de fato correlacionada com a resposta (redução de ansiedade) — por exemplo, se pacientes com ansiedade grave tendem a ter reduções absolutas maiores (ou menores) do que os leves, independentemente da técnica. Nesse caso, parte da variabilidade total da resposta é "explicada" pelo bloco antes mesmo de comparar as técnicas, reduzindo o quadrado médio do erro. Se a gravidade basal *não* estiver correlacionada com a resposta, bloquear não introduz viés, mas também não reduz a variância — apenas consome $b - 1 = 2$ graus de liberdade do erro sem retorno, exatamente como no exemplo do viveiro de pepineiros ($ER \approx 1,02$) visto em aula.

Questão 4. (Agricultura — dado faltante, fórmula de Yates)

Solução.

- Com $t = 5$, $b = 4$, $T' = 58$, $B' = 78$, $G' = 380$:

$$\hat{y} = \frac{tT' + bB' - G'}{(t-1)(b-1)} = \frac{5(58) + 4(78) - 380}{(4)(3)} = \frac{290 + 312 - 380}{12} = \frac{222}{12} = \mathbf{18,5}.$$

- O DBCA completo (sem dado faltante) teria $gl_{Erro} = (t-1)(b-1) = (4)(3) = 12$. Como o valor foi estimado (não observado), perde-se 1 grau de liberdade adicional: $gl_{Erro}^{ajustado} = 12 - 1 = \mathbf{11}$.

Questão 5. (Eficiência relativa)

Solução.

- (a) $gl_{Bloco} = b - 1 = 4$. $gl_{Erro}(DBCA) = (t - 1)(b - 1) = (5)(4) = 20$. $gl_{Erro}(DCA) = gl_{Erro}(DBCA) + gl_{Bloco} = 20 + 4 = \mathbf{24}$.

(b)

$$ER = \frac{(gl_B + 1)(gl_{E,DCA} + 3) QM_{Bloco} + gl_{E,DCA}(gl_B + 3) QM_{Erro}}{(gl_{E,DCA} + 1)(gl_B + 3) QM_{Erro}} = \frac{(5)(27)(45) + (24)(7)(15)}{(25)(7)(15)} = \frac{6075 + 2520}{2625} = \mathbf{3,27}$$

- (c) Um DCA precisaria de aproximadamente 3,27 vezes mais repetições por tratamento para atingir a mesma precisão deste DBCA — um ganho substancial, bem maior do que o $ER \approx 1,02$ observado no experimento do viveiro de pepineiros. A diferença reflete o fato de que, aqui, $QM_{Bloco} = 45$ é três vezes maior que $QM_{Erro} = 15$ (os blocos capturam heterogeneidade real e considerável), enquanto no exemplo do pepino QM_{Bloco} era menor que QM_{Erro} — os blocos mal capturaram heterogeneidade alguma.

Questão 6. (Dissertativa — matriz de delineamento)

Solução.

- (a) A ausência de colunas de produto entre X_{trat} e X_{bloco} é, em termos do modelo, a suposição de **aditividade tratamento-bloco**: o efeito esperado de um tratamento não depende do bloco em que ele é observado (e vice-versa). Se houvesse uma interação real entre tratamento e bloco, o modelo $Y = X\beta + \varepsilon$ com essa matriz X estaria mal especificado, e a diferença ficaria absorvida (incorretamente) no termo de erro.
- (b) Como as colunas de X_{bloco} apenas identificam a qual bloco cada unidade pertence, e não carregam nenhuma informação de interesse por si — o "efeito de bloco" existe no modelo apenas para **absorver variação** que, de outra forma, cairia no erro —, testar se essa variação é "estatisticamente significativa" responde a uma pergunta diferente da que motivou incluir X_{bloco} em X . Os blocos foram escolhidos pelo delineamento (não sorteados) com base em conhecimento prévio de heterogeneidade; removê-los do modelo por causa de um p-valor não significativo devolveria essa variação conhecida ao erro, sem nenhum ganho, e poderia até invalidar a estrutura de aleatorização restrita sob a qual os dados foram coletados.

Questão 7. (Ciência de dados — fatores confundidos vs. blocagem)

Solução.

- (a) O fator confundido é a **data de cadastro do usuário** (ou, mais amplamente, qualquer característica correlacionada a ela — tempo de uso do site, familiaridade com a interface, sazonalidade de quando o usuário chegou). Todo usuário cadastrado após 1º de janeiro de 2026 recebe *sempre* o algoritmo novo, e todo usuário cadastrado antes recebe *sempre* o antigo — as duas variáveis variam em perfeita sincronia.
- (b) Como **Algoritmo** é uma função determinística da data de cadastro (um implica o outro sem exceção), as colunas indicadoras dessas duas variáveis em X são idênticas a menos de uma constante — a matriz de delineamento não tem posto completo nessas duas colunas. **1m()**

reportaria coeficiente NA para uma delas (tipicamente a última incluída na fórmula): não é possível separar estatisticamente o efeito do algoritmo do efeito de ser um usuário mais novo, **não importa quantos usuários adicionais sejam observados** sob essa mesma regra de atribuição — o problema é de delineamento, não de tamanho de amostra.

- (c) Uma reformulação correta blocaria por **coorte de cadastro** (por exemplo, faixas de data de cadastro: usuários de 2023, 2024, 2025, 2026) — cada coorte funcionando como um bloco que agrupa usuários com veteranaria semelhante. **Dentro de cada bloco/coorte**, os usuários seriam então **sorteados** aleatoriamente entre algoritmo novo e antigo (um teste A/B tradicional restrito a cada coorte), de modo que ambos os algoritmos sejam observados em todo nível de veteranaria — quebrando a sincronia perfeita que causava a confusão no desenho original.