Lista de Exercícios 02

Modelo linear, mínimos quadrados e estimabilidade (Capítulo 2 / Aula 02)

© 2026 Raydonal Ospina Martínez, Departamento de Estatística, UFBA. Material de uso exclusivo dos estudantes de MATD48; é proibida a reprodução ou distribuição, total ou parcial, sem autorização do autor (Lei nº 9.610/1998). Versão preliminar.

Entrega: até a próxima aula. Justifique todas as respostas — nestas listas, a justificativa vale mais que a resposta final. O gabarito completo está em `Gabarito02.pdf`.

Questão 1. (Ciência de dados — mínimos quadrados na mão)

Uma pequena amostra de 5 medições relaciona o número de *scripts* carregados por uma página web (x) ao tempo de carregamento em décimos de segundo (y):

x	2	4	6	8	10
y	15	22	25	33	38

Considere o modelo $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$.

(a) Escreva explicitamente a matriz de delineamento $\mathbf{X}$ (5×2) e o vetor $\mathbf{Y}$ para este conjunto de dados.

(b) Calcule $\mathbf{X}'\mathbf{X}$ e $\mathbf{X}'\mathbf{Y}$.

(c) Resolva as equações normais $\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}'\mathbf{Y}$ para obter $\hat{\beta}_0$ e $\hat{\beta}_1$. (Dica: $(\mathbf{X}'\mathbf{X})^{-1}$ para uma matriz 2×2 $\begin{bmatrix} a & b \\ b & c \end{bmatrix}$ é $\frac{1}{ac-b^2}\begin{bmatrix} c & -b \\ -b & a \end{bmatrix}$.)

(d) Interprete $\hat{\beta}_1$ no contexto do problema.

(e) Sem recalcular tudo: qual deveria ser a soma dos resíduos $\sum_i (y_i - \hat{y}_i)$? Justifique sua resposta a partir das equações normais, sem apenas calcular os resíduos.

Questão 2. (Psicologia — estimabilidade)

Um estudo mede o tempo de reação (ms) de 6 participantes, 2 em cada um de três grupos experimentais (G_1, G_2, G_3). O modelo utilizado, na parametrização *sobreparametrizada* usual de um fator, é

$$y_{ij} = \mu + \alpha_j + \varepsilon_{ij}, \qquad j = 1, 2, 3, \quad i = 1, 2,$$

com $\mathbf{X}$ formada por uma coluna de 1's (para μ) e uma coluna indicadora para cada grupo (para α_1, α_2, α_3).

(a) Escreva a matriz $\mathbf{X}$ (6×4) explicitamente, com colunas na ordem $(\mu, \alpha_1, \alpha_2, \alpha_3)$.

(b) Qual é o posto de $\mathbf{X}$? Explique por que ele é menor do que o número de colunas.

© 2026 R. Ospina Martínez — UFBA · Uso exclusivo dos alunos de MATD48 · Reprodução proibida sem autorização (Lei 9.610/1998)

(c) Para cada função a seguir, diga se é **estimável** e justifique usando a definição (existe $\mathbf{a}$ tal que $\mathbf{a}'\mathbf{X} = \boldsymbol{\lambda}'$?):

(i) μ

(ii) $\mu + \alpha_1$

(iii) $\alpha_1 - \alpha_2$

(iv) $\alpha_1 + \alpha_2 + \alpha_3$

Questão 3. (Agricultura — especificação do modelo)

Uma equipe agronômica testa o efeito de dois fatores sobre a produtividade do milho: dose de fertilizante (baixa, alta) e variedade (V1, V2), com uma repetição de cada combinação (4 parcelas no total). Usando a codificação padrão do `R` (contrastes de tratamento, que descartam o nível de referência de cada fator), o modelo é

$$y_i = \beta_0 + \beta_1 \, \mathbf{1}\{\text{dose alta}\} + \beta_2 \, \mathbf{1}\{\text{V2}\} + \varepsilon_i.$$

(a) Escreva $\mathbf{X}$ (4×3) para as quatro parcelas (uma de cada combinação dose×variedade).

(b) $\mathbf{X}$ tem posto coluna completo? Justifique calculando (ou argumentando sobre) o posto.

(c) Interprete β_0, β_1 e β_2 em termos das médias esperadas das quatro combinações de tratamento.

Questão 4. (Ciência de dados — geometria dos mínimos quadrados)

Mostre, a partir das equações normais $\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}'\mathbf{Y}$, que:

(a) $\mathbf{X}'\mathbf{e} = \mathbf{0}$, em que $\mathbf{e} = \mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}$ é o vetor de resíduos. (Dica: reescreva as equações normais isolando $\mathbf{X}'(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}})$.)

(b) Se a primeira coluna de $\mathbf{X}$ é um vetor de 1's (intercepto), conclua a partir do item (a) que $\sum_i e_i = 0$.

(c) Isso significa que o modelo "acerta em média"no sentido de não haver nenhum padrão sistemático não capturado nos resíduos? Justifique com um contraexemplo conceitual (não precisa ser numérico).

Questão 5. (Ciência de dados — exercício computacional em R)

Considere novamente os dados da Questão 1. O código abaixo está incompleto.

```
x <- c(2, 4, 6, 8, 10)
y <- c(15, 22, 25, 33, 38)
X <- cbind(1, x)

# (a) complete a linha abaixo para obter beta_hat via algebra de matrizes
beta_hat <- ______________________

# (b) obtenha os valores ajustados e os residuos
```


© 2026 R. Ospina Martínez — UFBA · Uso exclusivo dos alunos de MATD48 · Reprodução proibida sem autorização (Lei 9.610/1998)

```r
y_hat <- X %*% beta_hat
residuos <- ______________________

# (c) confirme a Questao 1(e): a soma dos residuos deve ser (numericamente) zero
sum(residuos)
```

(a) Complete as duas linhas indicadas.

(b) Rode o código (mentalmente ou em sua máquina) e confirme que os valores de $\hat{\boldsymbol{\beta}}$ batem com os obtidos manualmente na Questão 1.

(c) Modifique o código para comparar sua estimativa com a saída de `lm(y ~ x)`. As duas devem coincidir — explique, em uma frase, por quê.

Questão 6. (Dedução — equações normais)

Considere o modelo linear geral $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ e a soma de quadrados dos resíduos $S(\boldsymbol{\beta}) = (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})'(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})$.

(a) Expanda $S(\boldsymbol{\beta})$ em termos de $\mathbf{Y}'\mathbf{Y}$, $\boldsymbol{\beta}'\mathbf{X}'\mathbf{Y}$ e $\boldsymbol{\beta}'\mathbf{X}'\mathbf{X}\boldsymbol{\beta}$.

(b) Usando as regras de derivação matricial $\partial(\mathbf{a}'\boldsymbol{\beta})/\partial\boldsymbol{\beta} = \mathbf{a}$ e $\partial(\boldsymbol{\beta}'\mathbf{A}\boldsymbol{\beta})/\partial\boldsymbol{\beta} = 2\mathbf{A}\boldsymbol{\beta}$ (para $\mathbf{A}$ simétrica), calcule $\partial S(\boldsymbol{\beta})/\partial\boldsymbol{\beta}$.

(c) Iguale a derivada a $\mathbf{0}$ e obtenha as equações normais $\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}'\mathbf{Y}$.

(d) Explique por que a matriz Hessiana ($2\mathbf{X}'\mathbf{X}$) sendo semidefinida positiva garante que a solução das equações normais é um *mínimo* de $S(\boldsymbol{\beta})$, e não um máximo ou ponto de sela.

Questão 7. (Dedução/computacional — pseudoinversa de Moore-Penrose via SVD)

Um experimento com dois tratamentos, cada um com 2 réplicas, produz o modelo sobreparametrizado $y_{ij} = \mu + \tau_i + \varepsilon_{ij}$ $(i = 1, 2)$, com

$$\mathbf{X} = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 0 & 1 \end{bmatrix}, \qquad \mathbf{y} = \begin{bmatrix} 15{,}2 \\ 14{,}3 \\ 13{,}5 \\ 14{,}5 \end{bmatrix}, \qquad \mathbf{A} := \mathbf{X}'\mathbf{X} = \begin{bmatrix} 4 & 2 & 2 \\ 2 & 2 & 0 \\ 2 & 0 & 2 \end{bmatrix}.$$

Como $\mathbf{A}$ é simétrica, sua decomposição em valores singulares coincide com sua decomposição espectral, $\mathbf{A} = \mathbf{V}\mathbf{D}\mathbf{V}'$, com autovalores/autovetores

$$\lambda_1 = 6,\ \mathbf{v}_1 = \tfrac{1}{\sqrt{6}}(2,1,1)'; \qquad \lambda_2 = 2,\ \mathbf{v}_2 = \tfrac{1}{\sqrt{2}}(0,-1,1)'; \qquad \lambda_3 = 0,\ \mathbf{v}_3 = \tfrac{1}{\sqrt{3}}(1,-1,-1)'.$$

(a) Verifique, multiplicando $\mathbf{A}\mathbf{v}_3$, que $\mathbf{v}_3$ é de fato um autovetor de autovalor 0 (isto é, $\mathbf{A}\mathbf{v}_3 = \mathbf{0}$) — e explique por que a existência de um autovalor nulo já era esperada, dado o posto incompleto de $\mathbf{X}$.

© 2026 R. Ospina Martínez — UFBA · Uso exclusivo dos alunos de MATD48 · Reprodução proibida sem autorização (Lei 9.610/1998)

(b) Escreva a matriz $\mathbf{D}^+$ (pseudoinversa de Moore-Penrose de $\mathbf{D} = \text{diag}(6, 2, 0)$): inverta apenas os valores singulares não nulos e mantenha 0 na posição correspondente a λ_3.

(c) A pseudoinversa é $\mathbf{A}^+ = \mathbf{V}\mathbf{D}^+\mathbf{V}'$, com $\mathbf{V} = [\mathbf{v}_1\ \mathbf{v}_2\ \mathbf{v}_3]$. Calcule explicitamente a entrada $(1,1)$ de $\mathbf{A}^+$ (isto é, $\mathbf{e}_1'\mathbf{A}^+\mathbf{e}_1$), mostrando as contas com $\mathbf{v}_1, \mathbf{v}_2$ (o termo em $\mathbf{v}_3$ some, porque é multiplicado por 0 em $\mathbf{D}^+$). Confira que sua resposta bate com $1/9 \approx 0{,}1111$.

(d) Complete o código abaixo, que calcula $\mathbf{A}^+$ inteira via `svd()` e a compara com `MASS::ginv(A)`:

```
A <- matrix(c(4,2,2, 2,2,0, 2,0,2), ncol = 3, byrow = TRUE)
sv <- svd(A)
D_mais <- diag(_____________________) # (i) inverta so os valores singulares > 1e-8
A_mais <- _____________________ # (ii) V %*% D+ %*% t(U)
max(abs(A_mais - MASS::ginv(A)))
```

(e) Use $\mathbf{A}^+$ para obter $\mathbf{b} = \mathbf{A}^+\mathbf{X}'\mathbf{y}$ e, a partir de $\mathbf{b}$, as funções estimáveis $\mu + \tau_1$, $\mu + \tau_2$ e $\tau_1 - \tau_2$ (multiplicando $\mathbf{b}$ pelos vetores $\boldsymbol{\lambda}'$ apropriados, como na Questão 2). Se algum colega usar uma inversa generalizada *diferente* de $\mathbf{A}^+$ para resolver as equações normais, seu $\mathbf{b}$ será diferente do seu — mas os três valores estimáveis calculados devem coincidir. Explique, em uma frase, por que a teoria garante essa coincidência mesmo sem saber qual inversa generalizada o colega usou.

© 2026 R. Ospina Martínez — UFBA · Uso exclusivo dos alunos de MATD48 · Reprodução proibida sem autorização (Lei 9.610/1998)