

Lista de Exercícios 02

Modelo linear, mínimos quadrados e estimabilidade (Capítulo 2 / Aula 02)

Entrega: até a próxima aula. Justifique todas as respostas — nestas listas, a justificativa vale mais que a resposta final. O gabarito completo está em [Gabarito02.pdf](#).

Questão 1. (Ciência de dados — mínimos quadrados na mão)

Uma pequena amostra de 5 medições relaciona o número de *scripts* carregados por uma página web (x) ao tempo de carregamento em décimos de segundo (y):

x	2	4	6	8	10
y	15	22	25	33	38

Considere o modelo $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$.

- Escreva explicitamente a matriz de delineamento $\mathbf{X}$ (5×2) e o vetor $\mathbf{Y}$ para este conjunto de dados.
- Calcule $\mathbf{X}'\mathbf{X}$ e $\mathbf{X}'\mathbf{Y}$.
- Resolva as equações normais $\mathbf{X}'\mathbf{X}\hat{\beta} = \mathbf{X}'\mathbf{Y}$ para obter $\hat{\beta}_0$ e $\hat{\beta}_1$. (Dica: $(\mathbf{X}'\mathbf{X})^{-1}$ para uma matriz 2×2 $\begin{bmatrix} a & b \\ b & c \end{bmatrix}$ é $\frac{1}{ac-b^2} \begin{bmatrix} c & -b \\ -b & a \end{bmatrix}$.)
- Interprete $\hat{\beta}_1$ no contexto do problema.
- Sem recalcular tudo: qual deveria ser a soma dos resíduos $\sum_i (y_i - \hat{y}_i)$? Justifique sua resposta a partir das equações normais, sem apenas calcular os resíduos.

Questão 2. (Psicologia — estimabilidade)

Um estudo mede o tempo de reação (ms) de 6 participantes, 2 em cada um de três grupos experimentais (G_1, G_2, G_3). O modelo utilizado, na parametrização *sobreparametrizada* usual de um fator, é

$$y_{ij} = \mu + \alpha_j + \varepsilon_{ij}, \quad j = 1, 2, 3, \quad i = 1, 2,$$

com $\mathbf{X}$ formada por uma coluna de 1's (para μ) e uma coluna indicadora para cada grupo (para $\alpha_1, \alpha_2, \alpha_3$).

- Escreva a matriz $\mathbf{X}$ (6×4) explicitamente, com colunas na ordem $(\mu, \alpha_1, \alpha_2, \alpha_3)$.
- Qual é o posto de $\mathbf{X}$? Explique por que ele é menor do que o número de colunas.
- Para cada função a seguir, diga se é **estimável** e justifique usando a definição (existe $\mathbf{a}$ tal que $\mathbf{a}'\mathbf{X} = \lambda'$):
 - μ

- (ii) $\mu + \alpha_1$
- (iii) $\alpha_1 - \alpha_2$
- (iv) $\alpha_1 + \alpha_2 + \alpha_3$

Questão 3. (Agricultura — especificação do modelo)

Uma equipe agrônômica testa o efeito de dois fatores sobre a produtividade do milho: dose de fertilizante (baixa, alta) e variedade (V1, V2), com uma repetição de cada combinação (4 parcelas no total). Usando a codificação padrão do R (contrastes de tratamento, que descartam o nível de referência de cada fator), o modelo é

$$y_i = \beta_0 + \beta_1 \mathbf{1}\{\text{dose alta}\} + \beta_2 \mathbf{1}\{\text{V2}\} + \varepsilon_i.$$

- (a) Escreva $\mathbf{X}$ (4×3) para as quatro parcelas (uma de cada combinação dose $\times$ variedade).
- (b) $\mathbf{X}$ tem posto coluna completo? Justifique calculando (ou argumentando sobre) o posto.
- (c) Interprete β_0 , β_1 e β_2 em termos das médias esperadas das quatro combinações de tratamento.

Questão 4. (Ciência de dados — geometria dos mínimos quadrados)

Mostre, a partir das equações normais $\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}'\mathbf{Y}$, que:

- (a) $\mathbf{X}'\mathbf{e} = \mathbf{0}$, em que $\mathbf{e} = \mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}$ é o vetor de resíduos. (Dica: reescreva as equações normais isolando $\mathbf{X}'(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}})$.)
- (b) Se a primeira coluna de $\mathbf{X}$ é um vetor de 1's (intercepto), conclua a partir do item (a) que $\sum_i e_i = 0$.
- (c) Isso significa que o modelo "acerta em média" no sentido de não haver nenhum padrão sistemático não capturado nos resíduos? Justifique com um contraexemplo conceitual (não precisa ser numérico).

Questão 5. (Ciência de dados — exercício computacional em R)

Considere novamente os dados da Questão 1. O código abaixo está incompleto.

```
x <- c(2, 4, 6, 8, 10)
y <- c(15, 22, 25, 33, 38)
X <- cbind(1, x)

# (a) complete a linha abaixo para obter beta_hat via algebra de matrizes
beta_hat <- -----

# (b) obtenha os valores ajustados e os residuos
y_hat <- X %*% beta_hat
residuos <- -----

# (c) confirme a Questao 1(e): a soma dos residuos deve ser (numericamente) zero
sum(residuos)
```

- (a) Complete as duas linhas indicadas.
- (b) Rode o código (mentalmente ou em sua máquina) e confirme que os valores de $\hat{\beta}$ batem com os obtidos manualmente na Questão 1.
- (c) Modifique o código para comparar sua estimativa com a saída de `lm(y ~ x)`. As duas devem coincidir — explique, em uma frase, por quê.

Questão 6. (Dedução — equações normais)

Considere o modelo linear geral $\mathbf{Y} = \mathbf{X}\beta + \varepsilon$ e a soma de quadrados dos resíduos $S(\beta) = (\mathbf{Y} - \mathbf{X}\beta)'(\mathbf{Y} - \mathbf{X}\beta)$.

- (a) Expanda $S(\beta)$ em termos de $\mathbf{Y}'\mathbf{Y}$, $\beta'\mathbf{X}'\mathbf{Y}$ e $\beta'\mathbf{X}'\mathbf{X}\beta$.
- (b) Usando as regras de derivação matricial $\partial(\mathbf{a}'\beta)/\partial\beta = \mathbf{a}$ e $\partial(\beta'\mathbf{A}\beta)/\partial\beta = 2\mathbf{A}\beta$ (para $\mathbf{A}$ simétrica), calcule $\partial S(\beta)/\partial\beta$.
- (c) Iguale a derivada a $\mathbf{0}$ e obtenha as equações normais $\mathbf{X}'\mathbf{X}\hat{\beta} = \mathbf{X}'\mathbf{Y}$.
- (d) Explique por que a matriz Hessiana ($2\mathbf{X}'\mathbf{X}$) sendo semidefinida positiva garante que a solução das equações normais é um *mínimo* de $S(\beta)$, e não um máximo ou ponto de sela.

Questão 7. (Dedução/computacional — pseudoinversa de Moore-Penrose via SVD)

Um experimento com dois tratamentos, cada um com 2 réplicas, produz o modelo sobreparametrizado $y_{ij} = \mu + \tau_i + \varepsilon_{ij}$ ($i = 1, 2$), com

$$\mathbf{X} = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 0 & 1 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 15,2 \\ 14,3 \\ 13,5 \\ 14,5 \end{bmatrix}, \quad \mathbf{A} := \mathbf{X}'\mathbf{X} = \begin{bmatrix} 4 & 2 & 2 \\ 2 & 2 & 0 \\ 2 & 0 & 2 \end{bmatrix}.$$

Como $\mathbf{A}$ é simétrica, sua decomposição em valores singulares coincide com sua decomposição espectral, $\mathbf{A} = \mathbf{V}\mathbf{D}\mathbf{V}'$, com autovalores/autovetores

$$\lambda_1 = 6, \mathbf{v}_1 = \frac{1}{\sqrt{6}}(2, 1, 1)'; \quad \lambda_2 = 2, \mathbf{v}_2 = \frac{1}{\sqrt{2}}(0, -1, 1)'; \quad \lambda_3 = 0, \mathbf{v}_3 = \frac{1}{\sqrt{3}}(1, -1, -1)'.$$

- (a) Verifique, multiplicando $\mathbf{A}\mathbf{v}_3$, que $\mathbf{v}_3$ é de fato um autovetor de autovalor 0 (isto é, $\mathbf{A}\mathbf{v}_3 = \mathbf{0}$) — e explique por que a existência de um autovalor nulo já era esperada, dado o posto incompleto de $\mathbf{X}$.
- (b) Escreva a matriz $\mathbf{D}^+$ (pseudoinversa de Moore-Penrose de $\mathbf{D} = \text{diag}(6, 2, 0)$): inverta apenas os valores singulares não nulos e mantenha 0 na posição correspondente a λ_3 .
- (c) A pseudoinversa é $\mathbf{A}^+ = \mathbf{V}\mathbf{D}^+\mathbf{V}'$, com $\mathbf{V} = [\mathbf{v}_1 \ \mathbf{v}_2 \ \mathbf{v}_3]$. Calcule explicitamente a entrada (1,1) de $\mathbf{A}^+$ (isto é, $\mathbf{e}_1'\mathbf{A}^+\mathbf{e}_1$), mostrando as contas com $\mathbf{v}_1, \mathbf{v}_2$ (o termo em $\mathbf{v}_3$ some, porque é multiplicado por 0 em $\mathbf{D}^+$). Confira que sua resposta bate com $1/9 \approx 0,1111$.

- (d) Complete o código abaixo, que calcula $\mathbf{A}^+$ inteira via `svd()` e a compara com `MASS::ginv(A)`:

```
A <- matrix(c(4,2,2, 2,2,0, 2,0,2), ncol = 3, byrow = TRUE)
sv <- svd(A)
D_mais <- diag(_____) # (i) inverta so os valores singulares > 1e-8
A_mais <- _____ # (ii) V %*% D+ %*% t(U)
max(abs(A_mais - MASS::ginv(A)))
```

- (e) Use $\mathbf{A}^+$ para obter $\mathbf{b} = \mathbf{A}^+ \mathbf{X}' \mathbf{y}$ e, a partir de $\mathbf{b}$, as funções estimáveis $\mu + \tau_1$, $\mu + \tau_2$ e $\tau_1 - \tau_2$ (multiplicando $\mathbf{b}$ pelos vetores $\mathbf{X}'$ apropriados, como na Questão 2). Se algum colega usar uma inversa generalizada *diferente* de $\mathbf{A}^+$ para resolver as equações normais, seu $\mathbf{b}$ será diferente do seu — mas os três valores estimáveis calculados devem coincidir. Explique, em uma frase, por que a teoria garante essa coincidência mesmo sem saber qual inversa generalizada o colega usou.