

Lista de Exercícios 03

Gauss-Markov, matriz de projeção, modelo particionado e formas quadráticas (Capítulo 2 / Aula 03)

Entrega: até a próxima aula. Justifique todas as respostas — nestas listas, a justificativa vale mais que a resposta final. O gabarito completo está em [Gabarito03.pdf](#).

Questão 1. (Dedução — propriedades da matriz de projeção)

Seja $\mathbf{X}$ uma matriz $n \times p$ de posto coluna completo e $\mathbf{P}_X = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$.

- (a) Mostre algebricamente que $\mathbf{P}_X$ é **simétrica**, isto é, $\mathbf{P}_X' = \mathbf{P}_X$. (Use o fato de que $(\mathbf{X}'\mathbf{X})^{-1}$ é simétrica.)
- (b) Mostre algebricamente que $\mathbf{P}_X$ é **idempotente**, isto é, $\mathbf{P}_X\mathbf{P}_X = \mathbf{P}_X$.
- (c) Mostre que $\mathbf{I}_n - \mathbf{P}_X$ também é simétrica e idempotente.
- (d) Use o item (b) para argumentar por que os autovalores de $\mathbf{P}_X$ só podem ser 0 ou 1, e conclua que $\text{tr}(\mathbf{P}_X) = \text{posto}(\mathbf{P}_X)$. (Dica: para uma matriz idempotente $\mathbf{A}$, se $\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$ com $\mathbf{v} \neq \mathbf{0}$, então $\mathbf{A}\mathbf{A}\mathbf{v} = \lambda^2\mathbf{v}$, mas também $\mathbf{A}\mathbf{A}\mathbf{v} = \mathbf{A}\mathbf{v} = \lambda\mathbf{v}$.)

Questão 2. (Dedução — variância de $\hat{\beta}$)

Considere $\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$, com $\text{Cov}(\mathbf{Y}) = \sigma^2\mathbf{I}_n$.

- (a) Escreva $\hat{\beta} = \mathbf{A}\mathbf{Y}$, identificando explicitamente a matriz $\mathbf{A}$.
- (b) Usando a propriedade $\text{Cov}(\mathbf{A}\mathbf{Y}) = \mathbf{A} \text{Cov}(\mathbf{Y}) \mathbf{A}'$ para qualquer matriz fixa $\mathbf{A}$, derive $\text{Cov}(\hat{\beta}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}$. (Lembre-se de que $(\mathbf{X}'\mathbf{X})^{-1}$ é simétrica.)
- (c) A partir do resultado do item (b), escreva a variância de um único coeficiente $\hat{\beta}_j$ em termos do elemento (j, j) de $(\mathbf{X}'\mathbf{X})^{-1}$.

Questão 3. (Psicologia — matriz de projeção numérica)

Um pesquisador ajusta o modelo $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$ a apenas 4 observações: $x = (1, 2, 3, 4)$, $y = (3, 5, 6, 10)$.

- (a) Escreva $\mathbf{X}$ (4×2).
- (b) Calcule $\mathbf{X}'\mathbf{X}$ e, a partir dela, $\mathbf{P}_X = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$. (Pode usar a fórmula da inversa 2×2 da Lista 02, Questão 1.)
- (c) Verifique numericamente que $\mathbf{P}_X\mathbf{P}_X = \mathbf{P}_X$ para pelo menos uma entrada da matriz, e confira que $\text{tr}(\mathbf{P}_X) = 2$.
- (d) Calcule as alavancagens (diagonal de $\mathbf{P}_X$) das quatro observações. Alguma delas se destaca como potencialmente mais influente? Por quê, geometricamente, as observações extremas de x costumam ter alavancagem maior?

(e) Calcule $\hat{\mathbf{Y}} = \mathbf{P}_X \mathbf{Y}$ e a soma de quadrados do erro $\text{SQE} = \mathbf{Y}'(\mathbf{I}_4 - \mathbf{P}_X)\mathbf{Y}$.

Questão 4. (Ciência de dados — soma de quadrados extra)

Um modelo completo (com $p = 3$ parâmetros) e um modelo reduzido, aninhado no completo (com $p_1 = 2$ parâmetros), são ajustados aos mesmos $n = 40$ dados, resultando em $\text{SQE}(\text{reduzido}) = 5000$ e $\text{SQE}(\text{completo}) = 4200$.

- Calcule a soma de quadrados extra, $\text{SQE}(\text{reduzido}) - \text{SQE}(\text{completo})$.
- Calcule os graus de liberdade do numerador e do denominador da estatística F .
- Calcule a estatística F e compare com o valor crítico aproximado $F_{1,37;0,05} \approx 4,11$. O teste rejeita $H_0 : \beta_2 = 0$ ao nível de 5%?
- Em termos de $\mathbf{P}_X$ e $\mathbf{P}_{X_1}$, qual forma quadrática corresponde à soma de quadrados extra calculada no item (a)?

Questão 5. (Distribuição de formas quadráticas)

Seja $\mathbf{A} = \begin{bmatrix} 0,5 & 0,5 \\ 0,5 & 0,5 \end{bmatrix}$ e $\mathbf{Y} \sim N(\boldsymbol{\mu}, \sigma^2 \mathbf{I}_2)$.

- Verifique que $\mathbf{A}$ é idempotente e determine seu posto.
- Se $\boldsymbol{\mu} = (0, 0)'$, qual é a distribuição exata de $\mathbf{Y}'\mathbf{A}\mathbf{Y}/\sigma^2$? Justifique citando o teorema apropriado.
- Se $\boldsymbol{\mu} = (3, -3)'$, calcule $\mathbf{A}\boldsymbol{\mu}$. Isso muda sua resposta ao item (b)? Explique por que um vetor de médias $\boldsymbol{\mu} \neq \mathbf{0}$ pode ainda assim produzir uma forma quadrática *central* qui-quadrado.
- Se $\boldsymbol{\mu} = (2, 2)'$, calcule $\mathbf{A}\boldsymbol{\mu}$ e $\boldsymbol{\mu}'\mathbf{A}\boldsymbol{\mu}$. Que tipo de distribuição resulta agora?

Questão 6. (Ciência de dados — exercício computacional em R)

O código abaixo reproduz, por álgebra de matrizes, o teste de soma de quadrados extra da Aula 03 para os dados de tempo de reação, sono e cafeína — mas duas linhas estão incompletas.

```
X1 <- model.matrix(~ horas_sono, data = dados_sono)
X <- model.matrix(~ horas_sono + cafeina_mg, data = dados_sono)
Y <- dados_sono$tempo_reacao
n <- nrow(dados_sono)

P1 <- X1 %*% solve(t(X1) %*% X1) %*% t(X1)
P <- X %*% solve(t(X) %*% X) %*% t(X)

sqe_reduzido <- as.numeric(t(Y) %*% (diag(n) - P1) %*% Y)
sqe_completo <- as.numeric(t(Y) %*% (diag(n) - P) %*% Y)

gl_extra <- _____ # (a)
gl_residuo <- _____ # (b)
```

```
F_extra <- ((sqe_reduzido - sqe_completo) / gl_extra) / (sqe_completo / gl_residuo)
p_valor <- pf(F_extra, gl_extra, gl_residuo, lower.tail = FALSE)
```

- (a) Complete a linha (a): os graus de liberdade do numerador (posto de $\mathbf{X}$ menos posto de $\mathbf{X}_1$).
- (b) Complete a linha (b): os graus de liberdade do denominador (resíduo do modelo completo).
- (c) Explique, em uma frase, o que mudaria no código se quiséssemos testar, em vez da cafeína isoladamente, um modelo completo com *duas* covariáveis extras (por exemplo, cafeína e temperatura ambiente da sala).

Questão 7. (Dedução — Teorema de Frisch-Waugh-Lovell)

Considere o modelo particionado $\mathbf{Y} = \mathbf{X}_1\beta_1 + \mathbf{X}_2\beta_2 + \boldsymbol{\varepsilon}$ e as equações normais em blocos,

$$\begin{bmatrix} \mathbf{X}_1'\mathbf{X}_1 & \mathbf{X}_1'\mathbf{X}_2 \\ \mathbf{X}_2'\mathbf{X}_1 & \mathbf{X}_2'\mathbf{X}_2 \end{bmatrix} \begin{bmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{bmatrix} = \begin{bmatrix} \mathbf{X}_1'\mathbf{Y} \\ \mathbf{X}_2'\mathbf{Y} \end{bmatrix}.$$

- (a) A partir da primeira linha de blocos, isole $\hat{\beta}_1$ em função de $\hat{\beta}_2$ (suponha $\mathbf{X}_1'\mathbf{X}_1$ invertível).
- (b) Substitua o resultado do item (a) na segunda linha de blocos e mostre que, definindo $\mathbf{P}_{X_1} = \mathbf{X}_1(\mathbf{X}_1'\mathbf{X}_1)^{-1}\mathbf{X}_1'$ e $\mathbf{M}_1 = \mathbf{I}_n - \mathbf{P}_{X_1}$, a equação se reduz a

$$\mathbf{X}_2'\mathbf{M}_1\mathbf{X}_2\hat{\beta}_2 = \mathbf{X}_2'\mathbf{M}_1\mathbf{Y}.$$

- (c) Usando que $\mathbf{M}_1$ é simétrica e idempotente, mostre que $\mathbf{X}_2'\mathbf{M}_1\mathbf{X}_2 = \tilde{\mathbf{X}}_2'\tilde{\mathbf{X}}_2$ e $\mathbf{X}_2'\mathbf{M}_1\mathbf{Y} = \tilde{\mathbf{X}}_2'\tilde{\mathbf{Y}}$, em que $\tilde{\mathbf{X}}_2 = \mathbf{M}_1\mathbf{X}_2$ e $\tilde{\mathbf{Y}} = \mathbf{M}_1\mathbf{Y}$ são os resíduos de regredir $\mathbf{X}_2$ e $\mathbf{Y}$, respectivamente, em $\mathbf{X}_1$. Conclua que $\hat{\beta}_2 = (\tilde{\mathbf{X}}_2'\tilde{\mathbf{X}}_2)^{-1}\tilde{\mathbf{X}}_2'\tilde{\mathbf{Y}}$ — o coeficiente de mínimos quadrados da regressão simples de $\tilde{\mathbf{Y}}$ em $\tilde{\mathbf{X}}_2$.
- (d) O código abaixo verifica numericamente o resultado dos itens (a)–(c) nos dados de sono e cafeína da Aula 03, mas está incompleto:

```
mod_completo <- lm(tempo_reacao ~ horas_sono + cafeina_mg, data = dados_sono)

Y_tilde <- _____ # (i) residuos de tempo_reacao ~ horas_sono
X2_tilde <- _____ # (ii) residuos de cafeina_mg ~ horas_sono
mod_fw1 <- lm(Y_tilde ~ X2_tilde)

c(beta_completo = unname(coef(mod_completo)["cafeina_mg"]),
  beta_fw1 = unname(coef(mod_fw1)[2]))
```

Complete as linhas (i) e (ii) usando `resid(lm(...))`, e explique por que os dois valores no vetor final devem ser (numericamente) idênticos.

- (e) Em um experimento aleatorizado em que `horas_sono` tivesse sido, por desenho, perfeitamente independente de `cafeina_mg` (por exemplo, se a dose de cafeína fosse sorteada, sem relação alguma com o sono de cada participante), o que você esperaria que acontecesse com $\tilde{\mathbf{X}}_2$ em relação a $\mathbf{X}_2$ original? Isso muda a conclusão de que $\hat{\beta}_2$ da regressão múltipla e da regressão residualizada coincidem?