Planejamento e Análise de Experimentos

Notas de curso — MATD48

Raydonal Ospina Martínez

12 de outubro de 2026

Sumário

Prefácio 1
Para quem é este livro 1
Como o material está organizado 1
Convenções tipográficas 2
1 Princípios do delineamento de experimentos 3
1.1 O método científico e o papel do delineamento experimental 3
1.2 Unidades experimentais e unidades amostrais 5
1.3 Fontes de variação 7
1.4 Os três aspectos do delineamento experimental 8
1.5 Resumo do capítulo 16
2 Introdução aos modelos lineares 17
2.1 Da população conceitual de respostas ao modelo linear 17
2.2 Diagramas de Hasse: a estrutura do delineamento antes da álgebra 17
2.3 O modelo linear geral 20
2.4 Estimação por mínimos quadrados 23
2.5 Estimabilidade de funções lineares dos parâmetros 25
2.6 O teorema de Gauss-Markov e o BLUE 29
2.7 A matriz de projeção 30
2.8 O modelo linear particionado 33
2.9 O teorema de Frisch-Waugh-Lovell 35
2.10 Distribuição de formas lineares e quadráticas 37
2.11 Resumo do capítulo 39
3 Delineamento completamente aleatorizado 41
3.1 Princípios de aleatorização: a ideia de um teste de aleatorização 41
3.2 O delineamento completamente aleatorizado a uma via de classificação 48
3.3 Submuestreo em um DCA 57
3.4 O modelo de efeitos aleatórios 64
3.5 Verificação de pressupostos 68
3.6 Contrastes e comparações múltiplas 71
3.7 Procedimentos de comparação múltipla 76
3.8 Polinômios ortogonais 80
3.9 Análise de covariância (ANCOVA) 83
3.10 Teste de Kruskal-Wallis 86
3.11 Resumo do capítulo 87
4 Delineamentos com fontes de bloqueio 89
4.1 O delineamento em blocos completos aleatorizados (DBCA) 89
4.2 Teste de Friedman 101
4.3 Blocos incompletos balanceados 103
4.4 Delineamento em quadrado latino 105
4.5 Delineamento em quadrado greco-latino 119
4.6 Parcelas subdivididas (*split-plot*) 122
4.7 Resumo do capítulo 126
5 Delineamentos com arranjos fatoriais 129
5.1 Por que cruzar fatores? 129
5.2 O fatorial A×B: efeitos principais e interação 130
5.3 Tabela de ANOVA para o fatorial A×B balanceado 131

5.4 Notação matricial do fatorial A×B 135
5.5 Fatoriais A×B×C: interações duplas e tripla 135
5.6 Fatoriais de dois fatores em blocos completos 141
5.7 Resumo do capítulo 142
6 Fatoriais avançados: confusão, fracionamento e superfície de resposta 143
6.1 Fatoriais 2^k: notação e ANOVA 143
6.2 Análise de um fatorial 2^k não replicado 148
6.3 Confusão em 2^k: designação de tratamentos a blocos 150
6.4 Fatoriais 3^k: ideia geral e confusão com AB^2 156
6.5 Fatoriais fracionados de dois níveis: a ideia geral 157
6.6 Rumo à otimização: superfície de resposta 158
6.7 Resumo do capítulo 158
7 Metodologia de superfície de resposta 159
7.1 Introdução à superfície de resposta 159
7.2 O caminho de máxima inclinação: de um fatorial inicial até a região do ótimo 164
7.3 Delineamento composto central (CCD) 165
7.4 Otimização de múltiplas respostas: funções de desejabilidade 166
7.5 Desenho robusto: otimizando a média e a variância ao mesmo tempo 167
7.6 Resumo do capítulo 170
7.7 Fim do programa do semestre 170
8 Experimentação em produtos digitais: testes A/B e bandits 173
8.1 Parte I — Testes A/B como delineamento completamente aleatorizado 173
8.2 Parte II — Bandits: quando explorar e quando explotar 180
8.3 Resumo do capítulo 184
8.4 Encerrando o livro 185
Referências 187

Prefácio

Este livro reúne as notas de curso de **MATD48 — Planejamento de Experimentos A**, disciplina do Departamento de Estatística da Universidade Federal da Bahia (UFBA). Ele acompanha os slides de aula (`Aulas2026/`) e as listas de exercícios semanais (`Listas2026/`), formando um material único de apoio, publicado junto à página do curso (https://raydonal.github.io/matd48/).

Para quem é este livro

Para estudantes que já cursaram inferência estatística e álgebra linear básica e que agora precisam projetar, executar e analisar experimentos — não apenas ajustar um modelo a dados que já existem, mas decidir *como os dados deveriam ser gerados* para responder a uma pergunta causal com confiança. O planejamento de experimentos é, historicamente, um dos poucos ramos da estatística nascidos para resolver problemas reais e urgentes — desde parcelas agrícolas em Rothamsted até testes A/B em produtos digitais — e é tratado aqui como tal.

Como o material está organizado

Este livro é **mais amplo do que a disciplina**: os slides de aula (`Aulas2026/`) e as listas semanais (`Listas2026/`) seguem estritamente o cronograma de um semestre, mas o livro não tem essa restrição — ele cobre, além do programa da disciplina, tópicos modernos de delineamento experimental (Capítulo 8) que não cabem em 14 semanas, mas que são parte do mesmo arcabouço causal apresentado desde o Capítulo 1. O livro é deliberadamente **livre de listas de exercícios**: os exercícios de cada capítulo alinhado ao semestre vivem nas listas semanais correspondentes em `Listas2026/`, com gabarito à parte, para não duplicar conteúdo entre os dois materiais.

Capítulo	Tópico	Aulas correspondentes
1	Princípios do delineamento de experimentos	Aula 01
2	Introdução aos modelos lineares	Aulas 02–03
3	Delineamento completamente aleatorizado (DCA)	Aulas 04–08
4	Delineamentos com fontes de bloqueio (blocos, quadrado latino, greco-latino)	Aulas 09–11
5	Delineamentos com arranjos fatoriais	Aula 12
6	Fatoriais 2^k/3^k, confusão e fracionamento	Aula 13
7	Metodologia de superfície de resposta	Aula 14
8	Testes A/B e bandits em produtos digitais	*(além do programa do semestre)*

Um fio condutor atravessa os oito capítulos: os mesmos três domínios de aplicação — **psicologia experimental**, **agricultura/agroindústria** e **ciência de dados/engenharia** — reaparecem capítulo após capítulo, para que o leitor veja como a mesma estrutura formal (unidades, fatores, blocos, interações) se manifesta em contextos muito diferentes; o Capítulo 8 é onde esse fio se encontra de forma mais direta com a prática atual de experimentação em ciência de dados.

Convenções tipográficas

Aplicação — um exemplo completo, com dados reais ou simulados e a pergunta de pesquisa que motiva a técnica em questão.

Para discutir — perguntas abertas, sem resposta única, pensadas para debate em sala.

Uso do R — código comentado, sempre reprodutível a partir do próprio capítulo.

Todo o código usa o pacote `tidyverse` para manipulação de dados e `ggplot2` para gráficos, na mesma convenção já usada nos slides de aula do curso.

1 Princípios do delineamento de experimentos

Um experimento bem desenhado responde a uma pergunta causal antes mesmo de qualquer dado ser coletado — a análise estatística só formaliza uma conclusão que o desenho já tornou possível. Um experimento mal desenhado, por outro lado, não é salvo por nenhuma técnica de análise, por mais sofisticada que seja (Box et al., 2005; Fisher, 1935b). Este capítulo estabelece o vocabulário e os três princípios estruturais — **repetição**, **aleatorização** e **controle local (blocagem)** — que sustentam todo o resto do curso.

1.1 O método científico e o papel do delineamento experimental

Antes de qualquer definição técnica, vale situar a pergunta que motiva a disciplina inteira: *por que planejar um experimento é, em si, um problema estatístico?* A resposta passa pelo que se entende por **método científico** — e por como a estatística, historicamente, deixou de ser só a ferramenta que resume dados já coletados para se tornar parte do próprio desenho da investigação.

1.1.1 O ciclo empírico: de observação a hipótese testável

Uma forma padrão de descrever a investigação científica é como um ciclo: observação de um fenômeno → formulação de uma hipótese que o explica → dedução de uma **predição testável** a partir dessa hipótese → coleta de dados desenhada para confrontar a predição → confronto (a hipótese sobrevive, é refinada ou é descartada). Popper (1959) insistiu num ponto que orienta todo o curso: uma hipótese só é cientificamente informativa se for **falseável** — se existir, em princípio, algum resultado observável que a contradiga. Uma alegação causal que "explica" qualquer padrão de dados possível não é uma hipótese científica, é uma hipótese vazia.



O ciclo empírico: observação, hipótese, predição testável, coleta de dados desenhada para confrontar a predição, e confronto (a hipótese sobrevive, é refinada ou é descartada). O delineamento de experimentos atua na terceira e na quarta etapas.

Figura 1.1: O ciclo empírico: observação, hipótese, predição testável, coleta de dados desenhada para confrontar a predição, e confronto (a hipótese sobrevive, é refinada ou é descartada). O delineamento de experimentos atua na terceira e na quarta etapas.

O delineamento de experimentos entra exatamente nesse ponto do ciclo: ele é a engenharia de **como coletar dados que de fato têm o poder de contradizer a hipótese**, caso ela seja falsa. Um delineamento fraco (sem repetição, sem aleatorização, com fontes de confusão não controladas) produz dados que "confirmam" a hipótese do pesquisador quase independentemente de ela ser verdadeira — o oposto do que Popper pede. Um delineamento forte é desenhado precisamente para dar à hipótese uma chance real de falhar o teste. Voltaremos a essa ideia de forma operacional na Seção 1.4 (p. 8), onde repetição, aleatorização e controle local aparecem como as três famílias de decisões que tornam um experimento capaz de refutar (ou não) a hipótese que o motivou.

1.1.2 Observação vs. experimentação: por que “controlado” importa

Nem todo estudo empírico é um experimento. Um **estudo observacional** registra o que já aconteceu ou aconteceria de qualquer forma — o pesquisador não decide quem recebe qual tratamento, só observa e mede. Um **estudo experimental** é aquele em que o próprio pesquisador **atribui** o tratamento às unidades, idealmente por sorteio. A diferença parece pequena, mas tem consequências lógicas enormes: em um estudo observacional, qualquer diferença encontrada entre grupos pode ser devida ao tratamento *ou* a alguma outra característica que levou aquelas unidades a receber aquele tratamento (auto-seleção, viés de indicação clínica, tendência histórica). “Correlação não implica causalidade” é o resumo popular desse problema. Em um estudo experimental bem desenhado, a atribuição do tratamento é decidida pelo pesquisador (por sorteio), não pela unidade nem por nenhuma característica dela — e é esse fato, formalizado com rigor na Seção 1.4.3 (p. 9), que permite interpretar uma diferença observada como efeito causal.

1.1.3 Uma nota histórica: quantificar, controlar, e só depois formalizar

Os ingredientes que compõem o delineamento experimental não nasceram juntos. Jan Baptist van Helmont, no século XVII, pesou 90 kg de solo seco, plantou nele um salgueiro de 2,25 kg e o regou apenas com água por cinco anos: ao final, o solo havia perdido pouco mais de 0,1 kg enquanto a árvore ganhara quase 74 kg — evidência de que a massa da planta vinha majoritariamente da água, não do solo (hoje sabemos que vem também do CO_2 do ar; o método de van Helmont, medir em vez de especular, é o que importa reter). Um século depois, Joseph Priestley perguntou se uma planta conseguiria “restaurar” o ar de uma câmara fechada em que uma vela já havia se apagado: sem planta, uma vela nova não voltava a queimar; com planta, dias depois, voltava. A comparação entre os dois cenários — não a simples observação de que “com planta funcionou” — é o que permitiu atribuir o efeito à planta e não a alguma outra mudança concomitante (temperatura, tempo, luz). Van Helmont contribuiu o primeiro ingrediente do delineamento moderno (quantificação precisa); Priestley, o segundo (comparação contra um controle). Faltavam ainda repetição e aleatorização — e é exatamente aí que entra Fisher.

A formalização estatística de repetição, aleatorização e blocagem como resposta metodológica ao problema da causalidade nasce do trabalho de Ronald A. Fisher na estação agrícola experimental de Rothamsted (Inglaterra), entre 1919 e 1933, sistematizado em Fisher (1935b). Antes de Fisher, os ensaios agrícolas comparavam parcelas de terra “parecidas” escolhidas por julgamento do pesquisador — um procedimento vulnerável exatamente ao problema de confusão discutido acima: solo mais fértil, mais exposto ao sol ou mais próximo de uma fonte de água não é escolhido ao acaso, e qualquer diferença de produtividade entre parcelas “tratadas” e “controle” fica misturada com essas diferenças pré-existentes. A contribuição de Fisher foi perceber que a *aleatorização deliberada* resolve o problema de confusão de forma que nenhuma quantidade de julgamento cuidadoso do pesquisador consegue igualar — porque neutraliza inclusive fontes de confusão que o pesquisador nem sabe que existem (formalizaremos isso na Seção 1.4.3 (p. 9)). Dessa origem agrícola, o delineamento experimental se espalhou para a indústria (Box, a partir dos anos 1960, com fatoriais 2^{k-p} — Capítulo 6), para ensaios clínicos, e mais recentemente para testes A/B em produtos digitais (Owen, 2020) — o mesmo arcabouço lógico, aplicado a domínios muito diferentes, é o fio que conecta os exemplos de psicologia, agricultura e ciência de dados usados ao longo deste livro.

1.1.4 Confusão (*confounding*): o problema que a aleatorização resolve

Já que a palavra vai reaparecer com frequência, vale uma definição precisa. Duas variáveis estão **confundidas** quando seus efeitos sobre a resposta não podem ser separados a partir dos dados observados — tipicamente porque uma delas determinou (ou influenciou fortemente) os valores da outra. O exemplo clássico (Owen, 2020): se todas as unidades do grupo tratado são medidas de manhã e todas as do grupo

controle à tarde, qualquer diferença encontrada mistura o efeito do tratamento com o efeito do horário do dia — os dois são **perfeitamente confundidos**, e nenhuma análise estatística, por mais sofisticada, consegue desembaraçá-los a partir desses dados. O mesmo acontece se tratamento e controle são medidos por instrumentos diferentes, em laboratórios diferentes, ou — o caso mais comum em ciência de dados — quando se compara um grupo "tratado agora" com um **controle histórico** ("como era antes"): qualquer tendência de fundo ao longo do tempo (sazonalidade, aprendizado, mudança de público) fica confundida com o efeito do tratamento.

Confusão pode envolver uma variável **conhecida e medida** (nesse caso, ao menos em princípio, ela poderia ser incluída no modelo como covariável — Seção 3.9 (p. 83) do Capítulo 3) ou uma variável **desconhecida ou não medida** — o caso mais perigoso, porque não há como incluí-la em nenhum modelo. É exatamente aqui que a aleatorização mostra sua força: ao sortear a atribuição do tratamento, o pesquisador garante que *nenhuma* variável — medida ou não, conhecida ou não — fica sistematicamente desbalanceada entre os grupos, em expectativa. A prova formal desse fato, via o modelo de resultados potenciais, é o conteúdo da Seção 1.4.3 (p. 9) a seguir.

Para discutir

1. Uma empresa de tecnologia observa que usuários que ativam uma nova funcionalidade têm maior retenção do que os que não ativam, e conclui que a funcionalidade "causa" retenção. Que variável não medida poderia estar confundida com a decisão de ativar a funcionalidade?
2. Em que sentido o critério de falseabilidade de Popper ajuda a distinguir um bom desenho experimental (que arrisca refutar a hipótese do pesquisador) de um desenho "confirmatório" (que tende a produzir evidência favorável à hipótese independentemente dela ser verdadeira)?

1.2 Unidades experimentais e unidades amostrais

Duas ideias que se confundem com frequência, mas que têm papéis estatísticos muito diferentes:

- **Unidade experimental (UE):** a menor entidade a que um tratamento é atribuído de forma independente. É o nível em que a *aleatorização* acontece.
- **Unidade amostral (ou unidade de observação):** a entidade em que a variável resposta é efetivamente medida. Pode coincidir com a unidade experimental ou não.

Quando várias unidades amostrais vêm da mesma unidade experimental, dizemos que há **submuestreo** (ou pseudorreplicação, se isso for ignorado na análise). Tratar submuestras como se fossem repetições independentes do tratamento é um dos erros mais comuns — e mais graves — em análise de experimentos, porque infla artificialmente o tamanho amostral e reduz erros-padrão de forma não legítima.

Aplicação — Psicologia: técnicas de estudo e desempenho em prova
Um professor quer comparar três técnicas de estudo — *releitura*, *flashcards* e *teste-prática* — quanto ao desempenho em uma prova de vocabulário. Ele recruta 30 estudantes e atribui aleatoriamente cada um a uma das três técnicas (10 por grupo). Cada estudante estuda uma lista de 40 palavras e depois responde a **duas provas paralelas** (versões A e B, aplicadas em sequência) sobre o mesmo material.

Aqui, a **unidade experimental é o estudante** — é nele que a técnica de estudo (o tratamento) é aplicada, e é impossível "sortear de novo" a técnica para uma prova sem sortear de novo o estudante. A **unidade**

amostral é cada prova respondida: há duas medições (submuestras) por estudante. Se o pesquisador tratasse as 60 provas como 60 réplicas independentes do experimento, estaria contando cada estudante duas vezes, ignorando que as duas notas de uma mesma pessoa são correlacionadas — um erro clássico de pseudorreplicação (voltaremos a isso formalmente com submuestreo no Capítulo 3, ao tratar do DCA).

> **Uso do R** — simulando a distinção UE vs. unidade amostral

```
set.seed(2026)

tecnica <- c("Releitura", "Flashcards", "Teste-prática")
n_estudantes_por_grupo <- 10

# Nível 1: a unidade experimental (o estudante) recebe um efeito de tratamento + um
# desvio individual fixo (habilidade do estudante) que persiste nas duas provas.
dados_estudantes <- tibble(
  estudante  = 1:(3 * n_estudantes_por_grupo),
  tecnica    = factor(rep(tecnica, each = n_estudantes_por_grupo), levels = tecnica),
  habilidade = rnorm(3 * n_estudantes_por_grupo, mean = 0, sd = 6)
)

efeito_tecnica <- c("Releitura" = 0, "Flashcards" = 4, "Teste-prática" = 9)

# Nível 2: a unidade amostral (cada prova) soma um ruído de medição próprio.
dados_provas <- dados_estudantes %>%
  crossing(prova = c("A", "B")) %>%
  mutate(
    nota = 65 + efeito_tecnica[as.character(tecnica)] + habilidade +
      rnorm(n(), mean = 0, sd = 3)
  )

dados_provas %>%
  group_by(tecnica) %>%
  summarise(
    n_estudantes = n_distinct(estudante),
    n_provas     = n(),
    media_nota   = mean(nota),
    .groups = "drop"
  ) %>%
  kable(digits = 1, caption = "Estudantes (UE) vs. provas (unidade amostral) por
        técnica") %>%
  kable_styling(full_width = FALSE)
```

Tabela 1.1: Estudantes (UE) vs. provas (unidade amostral) por técnica

tecnica	n_estudantes	n_provas	media_nota
Releitura	10	20	61.7
Flashcards	10	20	66.3
Teste-prática	10	20	78.2

O número de réplicas legítimo para inferência sobre o efeito da técnica é **10 por grupo** (o número de estudantes), não 20 (o número de provas) — este é exatamente o ponto que retomaremos com rigor ao estudar o desenho completamente aleatorizado com submuestreo.



Duas notas (provas A e B) por estudante, uma linha ligando as duas submuestras da mesma unidade experimental. Cada cor é uma técnica de estudo; a forma do ponto (círculo vs. triângulo) distingue a prova A da prova B.

Figura 1.2: Duas notas (provas A e B) por estudante, uma linha ligando as duas submuestras da mesma unidade experimental. Cada cor é uma técnica de estudo; a forma do ponto (círculo vs. triângulo) distingue a prova A da prova B.

O gráfico deixa visível, e não só conceitual, o que a distinção UE/unidade amostral significa: as duas notas ligadas pela mesma linha (mesmo estudante) ficam sistematicamente mais próximas entre si do que notas de estudantes diferentes dentro da mesma técnica — a variação *entre* linhas (entre estudantes) é maior do que a variação *dentro* de cada linha (entre as duas provas do mesmo estudante). É exatamente essa correlação dentro da unidade experimental que torna as 60 notas não independentes entre si, e que a análise do Capítulo 3 (DCA com submuestreo) precisa levar em conta para não superestimar o tamanho amostral efetivo.

1.3 Fontes de variação

Toda variável resposta varia por múltiplas razões simultâneas. Organizar essas razões é o primeiro passo do delineamento:

1. **Variação devida ao tratamento** — a diferença que o pesquisador quer detectar (efeito da técnica de estudo, da dose de fertilizante, do layout da página).
2. **Variação sistemática de unidades experimentais** — diferenças pré-existentes entre unidades (habilidade prévia do estudante, fertilidade do talhão, navegador do usuário) que não são o foco da pergunta, mas afetam a resposta.
3. **Erro experimental** — variação residual não explicada por (1) nem (2): tudo aquilo que permanece depois de contabilizarmos tratamento e fontes conhecidas de variação sistemática.

O delineamento experimental é, em essência, uma estratégia para **isolar (1)**, **remover ou controlar (2)** e **estimar honestamente (3)**.

1.3.1 Por que essa decomposição força a forma aditiva do modelo

Vale insistir num ponto que costuma passar despercebido: a separação em três fontes acima **não** é uma conveniência notacional escolhida porque “soma é mais fácil que produto” — é uma consequência direta de o tratamento ter sido *aleatorizado*, e o Capítulo 2 vai construir toda a sua maquinaria (matriz $\mathbf{X}$, modelo $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$) em cima exatamente dessa consequência, não de uma escolha de conveniência.

Comece pela observação puramente algébrica, sem nenhuma suposição estatística: para cada unidade i e cada tratamento t que ela poderia receber, o resultado potencial $Y_i(t)$ (Seção 1.4.3 (p. 9), adiante) pode **sempre** ser reescrito como

$$Y_i(t) = \underbrace{\mu}_{\text{média geral}} + \underbrace{\tau_t}_{\text{desvio médio do tratamento } t} + \underbrace{\delta_i(t)}_{\text{o que sobra}},$$

definindo μ como a média de $Y_i(t)$ sobre todas as unidades e todos os tratamentos, τ_t como o quanto a média do tratamento t se afasta de μ, e $\delta_i(t)$ como o resíduo que sobra depois de subtrair os dois primeiros termos. Até aqui isso é uma tautologia — vale para *qualquer* função $Y_i(t)$, sem nenhuma suposição sobre o mundo — e $\delta_i(t)$ pode, em princípio, depender tanto da unidade i quanto do tratamento t de forma completamente livre (inclusive carregando interações unidade$\times$tratamento arbitrárias). Nada nisso ainda

parece o modelo $Y_{ij} = \mu + \tau_i + \varepsilon_{ij}$ do Capítulo 3 (Seção 3.2.1 (p. 49)), em que o erro ε_{ij} não depende de t e se comporta como ruído aleatório de média zero.

A ponte entre as duas coisas é exatamente a aleatorização. O experimento não observa $\delta_i(t)$ para todo t — só observa $\delta_i(T_i)$, o resíduo do tratamento T_i efetivamente sorteado para i. Se a atribuição T_i fosse decidida por alguma característica da própria unidade (autosseleção, julgamento do pesquisador, conveniência — o problema de confusão já discutido acima), $\delta_i(T_i)$ carregaria, sistematicamente, um pedaço da **variação sistemática de unidades experimentais** (fonte 2): unidades com $\delta_i(t)$ tipicamente maior para um certo t tenderiam a ser justamente as que "escolhem" ou "recebem" aquele tratamento, e a fonte 2 vazaria para dentro da fonte 1 — a diferença de médias entre grupos deixaria de isolar o efeito do tratamento. É precisamente esse vazamento que a Seção 1.4.3 (p. 9) prova, com rigor, que a aleatorização impede: como o mecanismo de sorteio decide T_i *independentemente* dos valores $\{Y_i(t)\}_t$ (e portanto de $\{\delta_i(t)\}_t$), o resíduo observado $\delta_i(T_i)$, olhado através do subconjunto aleatoriamente sorteado para cada grupo, não difere sistematicamente de um grupo para outro — ele se comporta, em relação ao rótulo de tratamento, como uma variável **exógena**, exatamente o papel que ε_{ij} desempenha no modelo linear. É só *depois* dessa garantia que faz sentido escrever $\delta_i(T_i)$ simplesmente como ε_{ij} — sem o argumento t, tratado como ruído aleatório de média zero, não correlacionado com o tratamento recebido.

Em suma: a fonte 1 (tratamento) e a fonte 3 (erro) só permanecem **separáveis** — a fonte 2 só permanece **fora** da fonte 1 — porque a aleatorização garante que a atribuição de tratamento e a heterogeneidade pré-existente das unidades são estatisticamente independentes. Um delineamento sem aleatorização não invalida a *álgebra* da decomposição $Y_i(t) = \mu + \tau_t + \delta_i(t)$ (que, como visto, vale sempre) — invalida a leitura de $\delta_i(T_i)$ como ruído aditivo e não correlacionado com o tratamento, que é exatamente o que torna $Y_{ij} = \mu + \tau_i + \varepsilon_{ij}$ um *modelo* estatístico útil, e não apenas uma reparametrização vazia dos dados. O Capítulo 2 (Seção 2.3 (p. 20)) retoma esse argumento em notação matricial, ao explicar por que $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ — com $\mathbf{X}$ fixo pelo desenho e $\boldsymbol{\varepsilon}$ não correlacionado com $\mathbf{X}$ — é a representação natural, não arbitrária, de "efeito sistemático mais erro aleatório" sob aleatorização (Cochran & Cox, 1957; Fisher, 1935b; Kirk, 2012).

1.3.2 Fatores e níveis

- **Fator:** uma variável controlada (ou pelo menos categorizada) pelo pesquisador, que se hipotetiza afetar a resposta.
- **Níveis:** os valores específicos que um fator assume no experimento.
- **Tratamento:** uma combinação específica de níveis de um ou mais fatores, atribuída a uma unidade experimental.

Esse vocabulário — fator, nível, tratamento — é comum aos principais textos-base da disciplina (Dean et al., 2017; Montgomery, 2017) e será usado sem redefinição nos capítulos seguintes.

Tabela 1.2: Fator, níveis e unidade experimental em três domínios

Domínio	Fator	Níveis	Unidade experimental
Psicologia	Técnica de estudo	Releitura / Flashcards / Teste-prática	Estudante
Agricultura	Dose de fertilizante	0, 50, 100 kg/ha	Parcela de terra
Ciência de dados	Layout da página	Lista / Grade	Usuário do site

Quando dois ou mais fatores são cruzados (todas as combinações de níveis aparecem no experimento), temos um **arranjo fatorial** — assunto dos Capítulos 5 e 6. Por ora, tratamos do caso de um único fator.

1.4 Os três aspectos do delineamento experimental

Seguindo a formalização clássica (Cochran & Cox, 1957; Fisher, 1935b), todo desenho experimental resolve simultaneamente três problemas, correspondentes a três famílias de decisões:

1. **Desenho de tratamentos** — *o quê* comparar: quais fatores, quantos níveis, se são cruzados ou aninhados.
2. **Desenho para controle do erro** — *como* atribuir tratamentos às unidades para que a comparação seja justa: aleatorização, blocagem, uso de covariáveis.
3. **Desenho amostral** — *quantas* unidades e *como* medir a resposta: número de réplicas, submuestragem, esquema de medição repetida.

Os três princípios abaixo pertencem sobretudo ao segundo aspecto, mas condicionam os outros dois.

1.4.1 Repetição (replicação)

Repetir um tratamento em várias unidades experimentais **independentes** permite estimar a variabilidade do erro experimental e, com isso, testar se a diferença observada entre tratamentos é maior do que se esperaria só por acaso. Sem repetição genuína (não confundir com submuestreo — Seção 1.2 (p. 5)), não há como estimar o erro e, portanto, não há inferência válida.

1.4.2 Aleatorização

Atribuir tratamentos às unidades experimentais por sorteio — e não por conveniência, ordem de chegada ou julgamento do pesquisador — garante que, *em expectativa*, os grupos de tratamento sejam comparáveis em todas as variáveis, observadas ou não. É a aleatorização que permite interpretar uma diferença entre médias de grupo como *efeito causal* do tratamento, e não como reflexo de alguma variável de confusão. Sem aleatorização, o grupo controle deixa de ser um substituto crível do contrafactual do grupo tratado.

1.4.3 Por que a aleatorização funciona: o modelo de resultados potenciais

A afirmação “a aleatorização elimina viés de confusão” costuma ser aceita por apelo intuitivo. Ela também admite uma justificativa formal, devida a Neyman (1990) e depois generalizada por Rubin (1974) — o chamado **modelo causal de Neyman-Rubin**, ou modelo de resultados potenciais, que usaremos ao longo de todo o curso sempre que compararmos tratamentos (ver Imbens & Rubin, 2015 para um tratamento completo).

Para cada unidade experimental $i = 1, \dots, N$ e cada tratamento t que ela poderia receber, postulamos a existência de um **resultado potencial** $Y_i(t)$: o valor que a resposta assumiria *se* a unidade i recebesse o tratamento t. Com dois tratamentos ($t \in \{0, 1\}$), cada unidade tem dois resultados potenciais, $Y_i(0)$ e $Y_i(1)$, mas o experimento só revela **um** deles — o correspondente ao tratamento efetivamente sorteado para i. O outro é, por definição, contrafactual: nunca observável. Esse é o *problema fundamental da inferência causal*.

A Tabela 1.3 concretiza a definição: é a chamada **tabela científica** (*science table*), um recurso didático padrão na exposição do modelo de Neyman-Rubin. Ela lista os dois resultados potenciais de cada unidade lado a lado — algo que **nenhum conjunto de dados real exibe**, porque metade da tabela é, por construção, contrafactual. A coluna Y_i^{obs} mostra o que o experimento de fato revela depois que Z_i é sorteado: exatamente uma das duas colunas anteriores, nunca as duas.

Tabela 1.3: Tabela científica (science table): apenas seis unidades ilustrativas. Cada linha tem dois resultados potenciais, mas só um é revelado (‘?’ marca o contrafactual). O ATE é uma média sobre uma coluna que nunca existe inteira nos dados observados.

Unidade	$Y_i(0)$	$Y_i(1)$	Z_i	Y_i^{obs}
$i=1$	18,2	?	0	18,2
$i=2$	?	24,7	1	24,7
$i=3$	21,4	?	0	21,4
$i=4$	?	27,1	1	27,1
$i=5$	16,9	?	0	16,9
$i=6$	?	22,3	1	22,3

Duas suposições tornam o problema tratável:

- **SUTVA** (*Stable Unit Treatment Value Assumption*): o resultado potencial de i depende só do tratamento atribuído a i, não do tratamento atribuído a outras unidades (sem interferência entre unidades) nem de “versões ocultas” do tratamento.
- O **estimando causal** de interesse é tipicamente o **efeito médio do tratamento**,

$$\mathrm{ATE} = \frac{1}{N}\sum_{i=1}^{N}\big[Y_i(1) - Y_i(0)\big] = \bar{Y}(1) - \bar{Y}(0),$$

  uma média sobre unidades de uma quantidade que, para cada unidade individualmente, nunca podemos calcular (porque exigiria observar os dois resultados potenciais da mesma unidade).

Seja $Z_i \in \{0,1\}$ o indicador de qual tratamento a unidade i recebeu. O que o experimento observa é $Y_i = Z_i Y_i(1) + (1-Z_i)Y_i(0)$. O estimador natural do ATE é a diferença de médias observadas entre os grupos,

$$\widehat{\mathrm{ATE}} = \frac{1}{n_1}\sum_{i:\,Z_i=1} Y_i \;-\; \frac{1}{n_0}\sum_{i:\,Z_i=0} Y_i = \bar{Y}_1^{\,obs} - \bar{Y}_0^{\,obs}.$$

Por que a aleatorização garante $E[\widehat{\mathrm{ATE}}] = \mathrm{ATE}$? A chave é que os $2N$ valores $\{Y_i(0), Y_i(1)\}_{i=1}^{N}$ são tratados como **fixos** (características das unidades, não variáveis aleatórias) — a única aleatoriedade no experimento é *qual* subconjunto de n_1 unidades, entre os $\binom{N}{n_1}$ possíveis, recebe $Z_i = 1$. Sob esse mecanismo de aleatorização (cada subconjunto igualmente provável), Z_i é independente dos pares $(Y_i(0), Y_i(1))$ para todo i, o que dá

$$E\Big[\bar{Y}_1^{\,obs}\Big] = E\left[\frac{1}{n_1}\sum_{i:\,Z_i=1} Y_i(1)\right] = \frac{1}{N}\sum_{i=1}^{N} Y_i(1) = \bar{Y}(1),$$

e, simetricamente, $E[\bar{Y}_0^{\,obs}] = \bar{Y}(0)$ — porque, sob aleatorização, o subconjunto sorteado para tratamento é uma amostra aleatória simples (sem reposição) do conjunto de todas as unidades, e a média amostral de uma AAS é não-viesada para a média da população da qual foi extraída, qualquer que seja essa população (aqui, a “população” dos N valores fixos $Y_i(1)$). Logo $E[\widehat{\mathrm{ATE}}] = \bar{Y}(1) - \bar{Y}(0) = \mathrm{ATE}$: a diferença de

médias observadas é não-viesada para o efeito causal médio, **sem nenhuma suposição sobre a distribuição de $Y_i(t)$** — o mesmo espírito, aliás, do teste de aleatorização que retomaremos com rigor no Capítulo 3.

Aplicação — Agricultura: resultados potenciais de duas variedades de semente
$N = 40$ parcelas de terra têm **fertilidade** heterogênea e fixa. Postulamos, para cada parcela i, dois resultados potenciais de produtividade: $Y_i(0)$ sob a variedade V1 e $Y_i(1)$ sob a variedade V2 (com efeito heterogêneo, maior nas parcelas mais férteis). Simulamos os $2N = 80$ valores fixos — nunca observados simultaneamente na prática — só para poder *verificar* a demonstração acima por Monte Carlo.

Uso do R — verificando E[ATE-chapéu] = ATE por simulação

```
set.seed(2026)
N <- 40
fertilidade <- runif(N, 0, 10)
Y0 <- 20 + 1.5 * fertilidade + rexp(N, rate = 0.3)   # potencial sob V1 —
        deliberadamente não normal
Y1 <- Y0 + 4 + 0.3 * fertilidade                     # potencial sob V2 — efeito
        heterogêneo (maior se fértil)

ATE_verdadeiro <- mean(Y1 - Y0)
ATE_verdadeiro
```

```
## [1] 5.12961
```

```
n1 <- 20        # metade das parcelas recebe V2
n_rep <- 5000   # numero de reamostragens do mecanismo de aleatorizacao

ate_hat <- replicate(n_rep, {
  idx_trat <- sample(N, n1)                                  # sorteio de qual
        subconjunto recebe V2
  mean(Y1[idx_trat]) - mean(Y0[-idx_trat])                   # so o potencial
        "revelado" e observado
})

c(ATE_verdadeiro = ATE_verdadeiro, media_simulada = mean(ate_hat),
  diferenca = mean(ate_hat) - ATE_verdadeiro)
```

```
## ATE_verdadeiro media_simulada      diferenca
##     5.12961038     5.11388421    -0.01572617
```


Distribuição de Monte Carlo de ATE-chapéu sob 5.000 reamostragens independentes do mecanismo de aleatorização (quais 20 das 40 parcelas recebem a variedade V2), com o ATE verdadeiro (fixo, calculado sobre os 2N resultados potenciais) marcado pela linha tracejada.

Figura 1.3: Distribuição de Monte Carlo de ATE-chapéu sob 5.000 reamostragens independentes do mecanismo de aleatorização (quais 20 das 40 parcelas recebem a variedade V2), com o ATE verdadeiro (fixo, calculado sobre os 2N resultados potenciais) marcado pela linha tracejada.

Cada uma das 5.000 barras do histograma corresponde a um sorteio *diferente* de quais 20 parcelas recebem V2 — os $2N = 80$ resultados potenciais nunca mudam entre reamostragens, só a atribuição Z_i muda,

exatamente como a prova algébrica pressupõe. A distribuição de $\widehat{\mathrm{ATE}}$ tem alguma dispersão (não é possível saber o ATE exatamente com uma única reamostragem de 40 parcelas), mas está **centrada exatamente na linha tracejada** — o ATE verdadeiro e fixo —, e não em nenhum outro valor. Essa é a confirmação empírica, por simulação, de que $E[\widehat{\mathrm{ATE}}] = \mathrm{ATE}$: nenhuma suposição de normalidade foi usada para gerar $Y_i(0)$ (a distribuição exponencial deslocada foi escolhida de propósito, para deixar claro que o resultado não depende de normalidade), e a média do histograma bate com o ATE verdadeiro de qualquer forma.

Sem aleatorização — por exemplo, se as unidades se autosselecionam para o tratamento — Z_i pode depender de $(Y_i(0), Y_i(1))$ (unidades com $Y_i(1)$ potencialmente maior podem ser justamente as que "escolhem" o tratamento), quebrando a igualdade $E[\bar{Y}_1^{obs}] = \bar{Y}(1)$: a diferença de médias observadas deixa de estimar o ATE e passa a misturar o efeito causal com viés de seleção — exatamente o problema levantado na Questão 3 da caixa de discussão a seguir.

1.4.3.1 Quão dispersa é $\widehat{\mathrm{ATE}}$? A fórmula de variância de Neyman

Não-viés diz que o histograma da Figura 1.3 está centrado no lugar certo, mas nada diz sobre sua largura. Neyman (1990) derivou a variância exata de $\widehat{\mathrm{ATE}}$ sob o mecanismo de aleatorização — tratando, como antes, os $2N$ resultados potenciais como constantes fixas e a única fonte de aleatoriedade sendo *qual* subconjunto de tamanho n_1 recebe $Z_i = 1$ (amostragem sem reposição de um total de N unidades). Sejam

$$S_1^2 = \frac{1}{N-1}\sum_{i=1}^{N}\big(Y_i(1) - \bar{Y}(1)\big)^2, \qquad S_0^2 = \frac{1}{N-1}\sum_{i=1}^{N}\big(Y_i(0) - \bar{Y}(0)\big)^2$$

as variâncias populacionais (finitas, sobre as N unidades) dos dois resultados potenciais, e

$$S_{01}^2 = \frac{1}{N-1}\sum_{i=1}^{N}\Big[\big(Y_i(1) - Y_i(0)\big) - \mathrm{ATE}\Big]^2$$

a variância populacional dos **efeitos individuais de tratamento** $\tau_i = Y_i(1) - Y_i(0)$. O resultado de Neyman é

$$\mathrm{Var}\big(\widehat{\mathrm{ATE}}\big) = \frac{S_1^2}{n_1} + \frac{S_0^2}{n_0} - \frac{S_{01}^2}{N}.$$

A intuição: os dois primeiros termos são exatamente o que se esperaria de duas médias amostrais independentes (como em um teste t de duas amostras usual); o terceiro termo, negativo, é uma correção que só existe porque, aqui, as duas "amostras" (n_1 e n_0) vêm de **particionar a mesma população finita de N unidades** em vez de duas populações infinitas separadas — quanto mais heterogêneo o efeito individual τ_i entre unidades, maior S_{01}^2 e menor a variância do estimador.

O caso extremo é instrutivo e vale explicitar, porque a intuição costuma errar o sinal. Se o efeito for **constante**, $\tau_i \equiv \tau$ para toda unidade, então S_{01}^2 — que é a variância dos τ_i — vale **zero**, não S_1^2; e, como $Y_i(1) = Y_i(0) + \tau$, tem-se $S_1^2 = S_0^2 = S^2$. A fórmula então **não** se reduz, ela atinge seu valor **máximo**:

$$\mathrm{Var}(\widehat{\mathrm{ATE}}) \;=\; S^2\left(\frac{1}{n_1} + \frac{1}{n_0}\right).$$

Efeito homogêneo é, portanto, o pior caso para a precisão — e não o melhor. Como $Y_i(1)$ e $Y_i(0)$ nunca são observados na mesma unidade, S_{01}^2 não é identificável a partir dos dados — por isso a prática usual

estima a variância de forma conservadora, substituindo o termo $-S_{01}^2/N$ por zero (Capítulo 3 retoma essa mesma ideia ao tratar da variância do estimador em desenhos completamente aleatorizados).

> **Uso do R** — verificando a fórmula de Neyman contra a variância empírica de Monte Carlo

```
S1_sq   <- var(Y1)          # variância amostral (denominador N-1) de Y_i(1) nas N=40
        parcelas
S0_sq   <- var(Y0)          # idem para Y_i(0)
S01_sq  <- var(Y1 - Y0)     # variância dos efeitos individuais tau_i = Y_i(1) -
        Y_i(0)

var_neyman <- S1_sq / n1 + S0_sq / (N - n1) - S01_sq / N
var_mc     <- var(ate_hat)  # variância empírica das 5.000 reamostragens já geradas
        acima

c(var_formula_Neyman = var_neyman, var_Monte_Carlo = var_mc,
  razao = var_mc / var_neyman)
```

```
## var_formula_Neyman    var_Monte_Carlo              razao
##          2.7895207          2.6881325          0.9636539
```

A variância empírica das 5000 reamostragens (a dispersão real do histograma) e a fórmula fechada de Neyman batem a menos do ruído de simulação esperado — confirmando que a fórmula não é só uma aproximação assintótica, mas a variância **exata** do desenho completamente aleatorizado para qualquer N finito.

1.4.4 Um terceiro domínio: resultados potenciais binários em um teste A/B

Os dois exemplos anteriores (técnicas de estudo, variedades de semente) têm resposta contínua. O mesmo arcabouço de resultados potenciais vale, sem alteração nenhuma, quando a resposta é **binária** — o caso mais comum em experimentação de produtos digitais.

> **Aplicação — Ciência de dados: teste A/B de layout de página**
> Uma loja *online* testa dois layouts da página de produto — **A** (lista) e **B** (grade) — quanto à conversão em checkout. A unidade experimental é a **sessão de usuário**: cada sessão é sorteada para ver o layout A ou o B, nunca os dois. Para cada sessão i, os resultados potenciais são indicadores binários $Y_i(0), Y_i(1) \in \{0,1\}$ — converteria (1) ou não (0) sob cada layout — e o estimando de interesse é $\text{ATE} = p_B - p_A$, a mesma definição já usada nos exemplos anteriores, agora com uma diferença de proporções em vez de uma diferença de médias contínuas.

```
set.seed(2026)
n_por_grupo <- 8000
taxa_A <- 0.052   # taxa de conversao real sob o layout A (Lista) -- desconhecida na
        pratica
taxa_B <- 0.061   # taxa de conversao real sob o layout B (Grade) -- desconhecida na
        pratica

dados_ab <- tibble(
  layout    = factor(rep(c("A (lista)", "B (grade)"), each = n_por_grupo)),
  converteu = c(rbinom(n_por_grupo, 1, taxa_A), rbinom(n_por_grupo, 1, taxa_B))
)

resumo_ab <- dados_ab %>%
```

```
  group_by(layout) %>%  summarise(sessoes = n(), conversoes = sum(converteu),
            taxa = mean(converteu), .groups = "drop")
teste_ab <- prop.test(x = resumo_ab$conversoes, n = resumo_ab$sessoes)
resumo_ab %>%
  kable(digits = 4, caption = "Sessões, conversões e taxa observada por layout") %>%
  kable_styling(full_width = FALSE)
```

Tabela 1.4: Sessões, conversões e taxa observada por layout

layout	sessoes	conversoes	taxa
A (lista)	8000	406	0.0508
B (grade)	8000	517	0.0646


Taxa de conversão observada por layout, com intervalo de confiança de 95% (teste de duas proporções). O intervalo de B não sobrepõe o de A, consistente com o p-valor da diferença.

Figura 1.4: Taxa de conversão observada por layout, com intervalo de confiança de 95% (teste de duas proporções). O intervalo de B não sobrepõe o de A, consistente com o p-valor da diferença.

O estimador do ATE é a diferença de proporções observadas, $\widehat{\text{ATE}} = \hat{p}_B - \hat{p}_A \approx 0.0139$, com IC de 95% que **não inclui zero** $(-0.0212, -0.0065)$ e $p < 0{,}001$. Em linguagem simples: o layout em grade aumentou a conversão em 1.4 pontos percentuais nesta amostra de sessões — efeito pequeno em magnitude absoluta, mas real e estatisticamente detectável com $n = 16.000$ sessões, exatamente porque a variância de uma proporção com n na casa dos milhares é pequena. Validade interna: alta, pela mesma aleatorização por sessão que garante $E[\widehat{\text{ATE}}] = \text{ATE}$ na demonstração geral acima. Validade externa: restrita aos usuários deste site, neste período — a Seção 1.4.5 (p. 14), a seguir, formaliza exatamente essa distinção. O Capítulo 8 retoma este mesmo tipo de experimento (conversão binária em produto digital) para tratar dos riscos de checar o resultado repetidamente antes do fim planejado do experimento (*peeking*).

1.4.5 Validade interna e validade externa

A demonstração acima garante **validade interna**: dentro da amostra de N unidades efetivamente estudadas, a diferença de médias observadas é não-viesada para o ATE *dessa amostra*. Isso é uma afirmação sobre o mecanismo de atribuição do tratamento (a aleatorização), não sobre quem são as N unidades. Uma pergunta logicamente separada — e igualmente importante — é a de **validade externa** (Owen, 2020): o efeito estimado nessas N unidades se generaliza para outras unidades, fora do estudo?

Validade interna alta não implica validade externa alta. Um experimento pode ter aleatorização impecável (validade interna máxima) e ainda assim dizer pouco sobre uma população mais ampla, se a amostra estudada não for representativa dela. Voluntários que se inscrevem para um "programa beta" de um site (Questão 3 da caixa de discussão da Seção 1.2 (p. 5)) podem diferir sistematicamente dos usuários em geral — mais tolerantes a instabilidade, mais engajados, mais jovens — e o efeito do novo layout *entre eles* pode não valer para o público inteiro. Estudantes de graduação em psicologia, o pool mais comum de sujeitos de pesquisa em experimentos de laboratório (Kirk, 2012), não são uma amostra aleatória da população humana. Parcelas de uma única estação experimental não representam todos os tipos de solo de uma região.

Não há solução puramente estatística para a validade externa — ela depende de julgamento sobre o domínio, não de mais uma fórmula. O que o delineamento experimental pode e deve fazer é **deixar explícito o alcance da conclusão**: a que população a amostra estudada pertence, e sob quais condições (local, época, instrumentos, tipo de unidade) o resultado foi obtido. Esse cuidado reaparecerá em cada

capítulo aplicado do livro, sempre que uma recomendação prática for extraída de uma análise — e é um dos pontos avaliados nos projetos-desafio do curso (ver a seção final deste capítulo).

1.4.6 O elo entre amostragem e planejamento de experimentos

A distinção entre validade interna e externa aponta para um fato que costuma passar despercebido: **existem duas aleatorizações logicamente distintas em jogo**, respondendo a duas perguntas diferentes, e a **teoria de amostragem** (*survey sampling*, (Kish, 1965)) formaliza a primeira delas com o mesmo rigor com que o Capítulo 2 em diante formaliza a segunda.

1. **Amostragem aleatória**: *quem entra no estudo?* Sorteia-se um subconjunto de n unidades a partir de uma população maior de N_{pop} unidades, para que a amostra observada seja representativa da população — o problema clássico da amostragem, com sua própria teoria de variância (estratificação, alocação ótima, correção para população finita). É essa aleatorização, ou a falta dela, que determina a **validade externa** discutida acima: testadores beta *auto-selecionados* não são uma amostragem aleatória da população de usuários.
2. **Atribuição aleatória (aleatorização)**: *quem recebe qual tratamento?* Sorteia-se, entre as unidades já presentes no estudo, qual recebe qual nível do fator — o problema deste capítulo, formalizado na Seção 1.4.3 (p. 9). É essa aleatorização que determina a **validade interna**: garante $E[\widehat{\text{ATE}}] = \text{ATE}$ *dentro* da amostra, qualquer que seja essa amostra.

As duas são independentes: um experimento pode ter atribuição aleatória impecável sobre uma amostra de conveniência (validade interna alta, externa baixa — o caso mais comum na prática de laboratório e o cenário da Questão 7 de `Listas2026/Lista01`), ou usar uma amostra probabilística cuidadosamente desenhada da população, mas deixar os próprios participantes escolherem seu tratamento (validade externa alta, interna baixa — o desenho observacional que o Capítulo 1 vem, desde o início, alertando contra). Um levantamento (*survey*) bem feito e sem nenhum tratamento manipulado tem só a primeira aleatorização; um experimento de laboratório com voluntários tem tipicamente só a segunda; poucos estudos têm as duas ao mesmo tempo — e são, por isso, os mais caros e mais raros de conduzir (Kish, 1965).

O elo entre os dois campos não é só conceitual. A fórmula de variância de Neyman para $\widehat{\text{ATE}}$ (acima) tem a mesma anatomia de uma variância de **amostragem sem reposição de duas amostras independentes** de uma população finita — divide-se cada S_t^2 pelo respectivo tamanho de grupo e desconta-se um termo de covariância por causa da restrição de que $n_1 + n_0 = N$ é fixo. Isso não é coincidência: **o mesmo Neyman** que formalizou, em 1923, a inferência sob aleatorização de tratamentos em experimentos agrícolas é também um dos fundadores da teoria moderna de amostragem em populações finitas (Kish, 1965; Splawa-Neyman, 1990), e tratou as duas aleatorizações — de amostra e de tratamento — com o mesmo formalismo combinatório de “qual subconjunto foi sorteado, entre todos os subconjuntos igualmente prováveis”. O **submuestreo**, que o Capítulo 3 formaliza em detalhe (3.3 (p. 57)), é o ponto em que as duas ideias se encontram dentro de um único experimento: a atribuição do tratamento acontece na unidade experimental, mas a *amostragem* de quantas e quais submuestras medir dentro de cada unidade é, literalmente, um problema de desenho amostral aninhado dentro do desenho experimental.

1.4.7 Controle local (blocagem)

Quando se sabe de antemão que as unidades experimentais não são homogêneas (turmas diferentes, talhões com fertilidade diferente, dias diferentes de coleta), é possível agrupá-las em **blocos** internamente homogêneos e aleatorizar os tratamentos *dentro* de cada bloco. A blocagem não elimina a necessidade de aleatorização — ela a torna mais eficiente, retirando uma fonte de variação conhecida do erro experimental antes mesmo da análise. O Capítulo 4 formaliza blocagem em delineamentos com uma ou mais fontes de bloqueio.

Para discutir

1. No exemplo das técnicas de estudo, suponha que o professor tivesse deixado os alunos escolherem livremente qual técnica usar, em vez de sortear. Quais variáveis de confusão plausíveis poderiam contaminar a comparação entre técnicas?
2. Em um experimento agrícola em que cada bloco é um dia de plantio diferente (com chuva, temperatura e luminosidade distintas), o que a blocagem por dia consegue — e o que ela *não* consegue — controlar?
3. Um time de produto testa um novo layout de site apenas com usuários que se voluntariam para o "programa beta". Isso é aleatorização? Que population é representada pela conclusão do teste?

1.5 Resumo do capítulo

- O delineamento experimental é a tradução operacional do método científico: desenhar a coleta de dados para que uma hipótese causal tenha, de fato, chance de ser refutada (Popper), em vez de ser “confirmada” por um estudo incapaz de contradizê-la.
- Confusão (*confounding*) é o problema central que separa estudo observacional de experimental — variáveis medidas ou não podem se misturar ao efeito do tratamento; a aleatorização, formalizada por Fisher e generalizada pelo modelo de Neyman-Rubin, é a única ferramenta que neutraliza confusão de fontes conhecidas *e* desconhecidas simultaneamente.
- Validade interna (a estimativa é não-viesada para o ATE da amostra estudada) e validade externa (o resultado generaliza para outras unidades/populações) são perguntas logicamente separadas — boa aleatorização garante a primeira, não a segunda.
- Unidade experimental é onde o tratamento é sorteado; unidade amostral é onde a resposta é medida — quando diferem, há submuestreo, e o tamanho amostral relevante para inferência é o número de unidades experimentais, não o de observações.
- Toda resposta varia por efeito do tratamento, por diferenças sistemáticas entre unidades e por erro experimental — o delineamento organiza essas três fontes.
- Fator, nível e tratamento formam o vocabulário do desenho de tratamentos; os princípios de repetição, aleatorização e controle local formam o desenho para controle do erro.

O Capítulo 2 introduz a maquinaria formal — o modelo linear — que usaremos para expressar precisamente essas ideias e estimar seus parâmetros a partir de dados.

2 Introdução aos modelos lineares

O Capítulo 1 tratou de *desenho*: como atribuir tratamentos a unidades experimentais para que uma comparação seja justa. Este capítulo trata da *maquinaria formal* que usaremos, do Capítulo 3 em diante, para transformar dados de um experimento bem desenhado em conclusões quantitativas: o **modelo linear**. A ideia central — escrever a resposta observada como uma combinação linear de parâmetros desconhecidos mais um erro aleatório — é simples de enunciar, mas sustenta toda a teoria de análise de variância (ANOVA) que vem a seguir. Dominar a álgebra deste capítulo é o que permite, no Capítulo 3, *deduzir* por que a ANOVA funciona, em vez de apenas aplicá-la mecanicamente (Rao, 1973; Searle, 1971).

2.1 Da população conceitual de respostas ao modelo linear

Antes de escrever qualquer símbolo, vale nomear explicitamente o objeto que a tabela científica do Capítulo 1 (Tabela 1.3) já descreveu informalmente. A literatura clássica de planejamento de experimentos (Hinkelmann & Kempthorne, 2008; Kempthorne, 1952) chama esse objeto de **população conceitual de respostas**: para cada unidade experimental u da população (ou amostra) sob estudo e cada um dos t tratamentos, existe um valor de resposta hipotético — o que se observaria *se* u recebesse aquele tratamento. Só um desses valores por unidade é de fato observado (o do tratamento que ela efetivamente recebeu); os demais existem apenas **conceitualmente**, nunca revelados pelos dados. É exatamente a mesma estrutura que o Capítulo 1 formalizou como resultados potenciais $Y_i(t)$ — duas literaturas, a da inferência causal (Neyman-Rubin) e a clássica de planejamento de experimentos (Kempthorne), descrevendo o mesmo objeto matemático com vocabulários diferentes. Vale reter os dois nomes: este livro seguirá usando “resultados potenciais” por sua ligação direta com a Seção 1.4.3 (p. 9), mas “população conceitual de respostas” é como o mesmo objeto aparece na tradição de Kempthorne e Federer, e o leitor deve reconhecê-lo em qualquer um dos dois vocabulários.

O modelo linear deste capítulo — e, com ele, toda a álgebra de somas de quadrados dos Capítulos 3–6 — é a maquinaria que permite resumir essa população conceitual (inteiramente hipotética, nunca observada por completo) através de um número finito de parâmetros estimáveis a partir da amostra efetivamente observada.

2.2 Diagramas de Hasse: a estrutura do delineamento antes da álgebra

Antes de escrever qualquer modelo em símbolos, vale formalizar uma pergunta que o Capítulo 1 já levantou de forma informal (Seção 1.3 (p. 7)) e que voltará em todo capítulo aplicado deste livro: *que fontes de variação o desenho do experimento gera, e quantos graus de liberdade cada uma consome?* Responder isso **antes** de rodar `aov()`/`lm()` — e não depois, como confirmação — é o padrão de rigor que este livro segue desde o início; o **diagrama de Hasse**, introduzido por Throckmorton (1961) e sistematizado depois por Bailey (2008) na forma usada hoje, é a ferramenta gráfica padrão para fazer essa pergunta de forma sistemática, útil sobretudo quando o delineamento tem múltiplos fatores cruzados e/ou aninhados (Capítulos 4–6).

2.2.1 O diagrama como um retrato da estrutura do dado

Um diagrama de Hasse representa cada **termo** do delineamento — a média geral, cada fator, cada interação, o erro — como um nó, e desenha uma aresta de um termo u para um termo v quando v é uma

partição mais fina de u (cada classe de v está contida em exatamente uma classe de u) e não existe nenhum termo intermediário entre os dois — a mesma ideia de "cobertura" que dá nome aos diagramas de Hasse em teoria de ordem. O termo do topo é sempre a **média geral** (uma única classe, contendo todas as N unidades) e o termo da base é sempre o **erro** (cada unidade em sua própria classe, dentro do que os termos acima já explicaram). Dois termos que não têm aresta entre si, nem um caminho de arestas ligando um ao outro, são **ortogonais** — nem um refina o outro — e é exatamente esse tipo de relação que caracteriza fatores **cruzados**; uma cadeia direta de arestas, por outro lado, caracteriza fatores **aninhados** (o padrão já visto no submuestreo do Capítulo 3, antes mesmo de termos o nome para ele).

A regra para contar graus de liberdade a partir do diagrama é simples e se aplica termo a termo:

$$\mathrm{gl}(v) = (\text{número de classes distintas de } v) - \sum_{u \prec v} \mathrm{gl}(u),$$

em que $u \prec v$ percorre todo termo mais grosso que v refina (todo nó "acima" de v no diagrama, ligado a ele por algum caminho). Em palavras: os graus de liberdade de um termo são a contagem de "coisas novas" que ele distingue, descontado tudo que os termos mais grossos já explicavam. Como consequência, os graus de liberdade de todos os termos do diagrama somam exatamente N — a decomposição do Capítulo 3 (1.3 (p. 7)) em "tratamento + erro" é o caso mais simples possível dessa regra, e a Seção 2.7 (p. 30) adiante mostrará que cada $\mathrm{gl}(v)$ é, algebricamente, o **posto de uma matriz de projeção** — o diagrama de Hasse é a contrapartida geométrica, expressa como uma figura em vez de uma matriz.

> **Uso do R** — diagrama de Hasse de um DCA de um fator

```r
# Informa-se o numero de CLASSES de cada termo; os graus de liberdade saem da
# estrutura do diagrama (ver hasse_helpers.R), nao de conta digitada a mao.
nos_dca <- tibble(
  termo   = c("Média", "Tratamento", "Erro"),
  classes = c(1, 4, 24)            # 1 media geral; t=4 tratamentos; N=24 unidades
)
arestas_dca <- tibble(de = c("Média", "Tratamento"), para = c("Tratamento", "Erro"))

knitr::include_graphics(
  hasse_svg(nos_dca, arestas_dca,
            arquivo = "figuras/hasse/dca.svg",
            titulo  = "DCA: t=4, n=6 (N=24)")
)
```

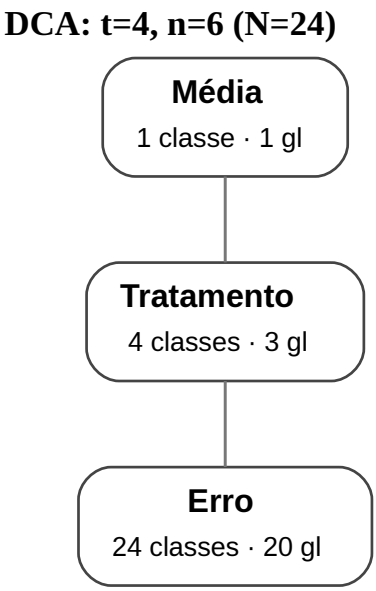


Figura 2.1: Diagrama de Hasse de um DCA com t=4 tratamentos e n=6 réplicas por tratamento (N=24). Uma cadeia simples: cada termo refina exatamente o termo anterior, sem ramificação — a assinatura de um delineamento de um único fator, sem estrutura de bloqueio.

O diagrama do DCA é uma simples cadeia — Média $\prec$ Tratamento $\prec$ Erro —, refletindo que não há nenhuma outra fonte de variação estrutural além do tratamento: $1 + 3 + 20 = 24$. Contraste isso com um delineamento de **dois fatores cruzados** $A \times B$, em que dois termos aparecem no mesmo nível — nenhum refina o outro — e só se reencontram na interação:

> **Uso do R** — diagrama de Hasse de um fatorial A×B cruzado

```
nos_axb <- tibble(
  termo   = c("Média", "A", "B", "A×B", "Erro"),
  classes = c(1, 3, 4, 3 * 4, 24)  # a=3; b=4; ab=12 caselas; N=24 unidades
)
arestas_axb <- tibble(
  de   = c("Média", "Média", "A", "B", "A×B"),
  para = c("A", "B", "A×B", "A×B", "Erro")
)

knitr::include_graphics(
  hasse_svg(nos_axb, arestas_axb,
            arquivo = "figuras/hasse/axb.svg",
            titulo  = "Fatorial A&#215;B: a=3, b=4, n=2 (N=24)")
)
```

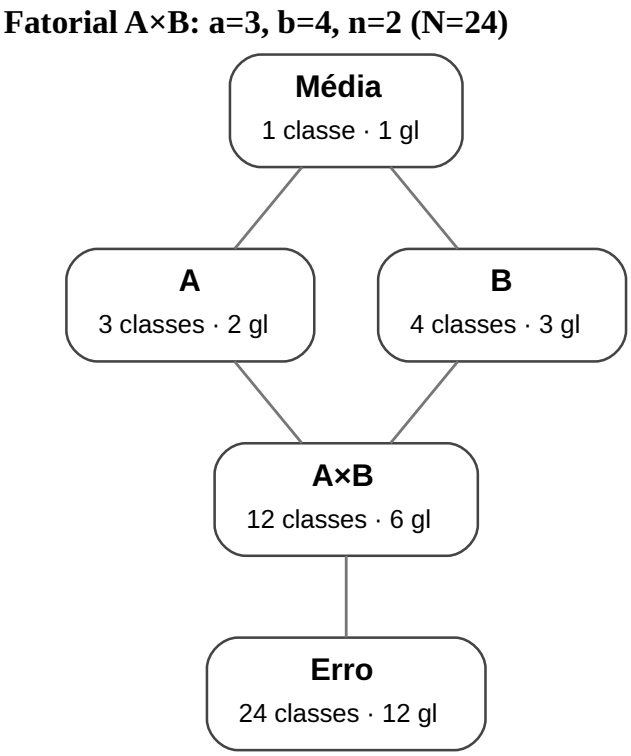


Figura 2.2: Diagrama de Hasse de um fatorial A×B cruzado, a=3 níveis de A, b=4 níveis de B, n=2 réplicas por casela (N=24). A e B aparecem no mesmo nível (cruzados, sem relação de refinamento entre si) e se reencontram na interação A×B, que os refina a ambos.

Note a leitura direta dos graus de liberdade de $A \times B$ pela regra de subtração: o termo $A \times B$ distingue $ab = 12$ caselas, das quais $\text{gl}(\text{Média}) = 1$, $\text{gl}(A) = 2$ e $\text{gl}(B) = 3$ já são "explicadas" pelos termos acima dele no diagrama — sobra $12 - 1 - 2 - 3 = 6 = (a-1)(b-1)$, exatamente a fórmula já familiar de graus de liberdade de interação, aqui obtida por contagem geométrica em vez de memorizada como fórmula solta. Os Capítulos 4 (bloqueio, onde bloco e tratamento tipicamente aparecem cruzados, como A e B acima) e 5–6 (fatoriais com três ou mais fatores, e confusão, em que o diagrama ajuda a visualizar com qual termo um bloco foi deliberadamente confundido) reaproveitam este mesmo diagrama e a mesma função `hasse_svg()` a cada novo delineamento.

2.3 O modelo linear geral

Um **modelo linear** escreve um vetor de respostas observadas $\mathbf{Y}$ ($n \times 1$) como

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon},$$

em que:

- $\mathbf{X}$ é a **matriz de delineamento** (ou matriz-modelo), $n \times p$, com valores conhecidos (fixados pelo desenho do experimento ou observados nas covariáveis);
- $\boldsymbol{\beta}$ é o vetor de parâmetros desconhecidos, $p \times 1$;
- $\boldsymbol{\varepsilon}$ é o vetor de erros aleatórios, $n \times 1$, com $\mathrm{E}[\boldsymbol{\varepsilon}] = \mathbf{0}$ e $\mathrm{Cov}(\boldsymbol{\varepsilon}) = \sigma^2 \mathbf{I}_n$ (erros não correlacionados, de variância comum σ^2 — as **suposições de Gauss-Markov**). Quando precisarmos de distribuições exatas (não só médias e variâncias), acrescentaremos $\boldsymbol{\varepsilon} \sim N(\mathbf{0}, \sigma^2 \mathbf{I}_n)$.

O termo “linear” refere-se à linearidade em $\boldsymbol{\beta}$, não em $\mathbf{X}$: um modelo com X contendo requisições^2 ou variáveis indicadoras continua sendo um modelo linear, desde que a resposta seja combinação linear das *colunas* de $\mathbf{X}$.

2.3.1 Por que esta é a forma natural, não arbitrária, do modelo

Vale parar um momento antes de seguir para a estimação e perguntar: por que escrever a resposta como $\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$, em vez de qualquer outra forma funcional? A resposta não é “porque é matematicamente conveniente” — é uma consequência direta da estrutura de um experimento aleatorizado, já antecipada no Capítulo 1 (Seção 1.3 (p. 7)) e formalizada ali com todo o rigor na Seção 1.3.1 (p. 7).

Relembrando o argumento: toda resposta varia por (1) efeito do tratamento, (2) diferenças sistemáticas pré-existentes entre unidades e (3) erro experimental residual. A Seção 1.3.1 (p. 7) mostrou que a decomposição $Y_i(t) = \mu + \tau_t + \delta_i(t)$ é sempre possível algebricamente, sem nenhuma suposição — mas que só se torna um **modelo estatístico útil**, com um termo de erro que não depende do tratamento e não carrega viés, quando a atribuição do tratamento é decidida por sorteio, independentemente das características das unidades. É exatamente essa mesma lógica que $\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ generaliza para qualquer estrutura de delineamento, não só para um único fator:

- $\mathbf{X}\boldsymbol{\beta}$ é a parte **sistemática** da resposta — tudo o que é determinado pelo desenho: quais colunas de tratamento, bloco ou covariável cada unidade carrega. $\mathbf{X}$ é tratada como **fixa**, não aleatória, porque suas entradas são decididas pelo pesquisador (o sorteio de tratamento, a alocação em blocos) ou observadas antes do experimento (covariáveis pré-tratamento) — a mesma leitura de “resultados potenciais fixos, só a atribuição é aleatória” do modelo de Neyman-Rubin (Capítulo 1, Seção 1.4.3 (p. 9)).
- $\boldsymbol{\varepsilon}$ absorve tudo o que $\mathbf{X}$ não explica: a fonte 3 (erro experimental) e qualquer parte da fonte 2 (variação sistemática de unidades) que não entrou explicitamente em nenhuma coluna de $\mathbf{X}$. A suposição de Gauss-Markov $\mathrm{E}[\boldsymbol{\varepsilon}] = \mathbf{0}$ — nenhum viés sistemático associado a nenhuma coluna de $\mathbf{X}$ — não é postulada “por conveniência algébrica”: é exatamente o que a aleatorização garante, porque ela impede que a fonte 2 não modelada fique correlacionada com as colunas de tratamento de $\mathbf{X}$ (o “vazamento” que a Seção 1.3.1 (p. 7) descreveu em detalhe). Um desenho sem aleatorização — em que a atribuição de tratamento correlaciona-se com características não incluídas em $\mathbf{X}$ — quebraria precisamente essa suposição, mesmo que a forma $\mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ continuasse fazendo sentido como reparametrização algébrica.

Em outras palavras: $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ é a tradução matricial exata de “efeito sistemático do desenho mais erro aleatório sob aleatorização” — e é por isso que o teorema de Gauss-Markov (Seção 2.6 (p. 29), adiante) consegue garantir otimalidade de mínimos quadrados sem exigir normalidade: a otimalidade depende só de $\mathrm{E}[\boldsymbol{\varepsilon}] = \mathbf{0}$ e variância constante, exatamente as duas propriedades que a aleatorização entrega, não de nenhuma suposição extra sobre a forma da distribuição de $\mathbf{Y}$.

Aplicação — Ciência de dados: tempo de resposta de uma API
Uma equipe de engenharia monitora o **tempo de resposta** (em milissegundos) de uma API sob diferentes números de **requisições simultâneas**, em três configurações de **servidor** (A, B, C). A pergunta: o tempo de resposta cresce com a carga? Difere entre servidores? Simulamos 60 medições.

Uso do R — simulando os dados da API

```
set.seed(2026)
n <- 60
dados_api <- tibble(
  id = 1:n,
  requisicoes = round(runif(n, 10, 500)),
  servidor = factor(sample(c("A", "B", "C"), n, replace = TRUE), levels = c("A", "B",
        "C"))
)
efeito_servidor <- c(A = 0, B = 15, C = -8)
dados_api <- dados_api %>%
  mutate(tempo_resposta = 42 + 0.35 * requisicoes +
           efeito_servidor[as.character(servidor)] + rnorm(n, 0, 12))

dados_api %>% slice_head(n = 6) %>%
  kable(digits = 1, caption = "Seis primeiras observações do conjunto de dados da
        API") %>%
  kable_styling(full_width = FALSE)
```

Tabela 2.1: Seis primeiras observações do conjunto de dados da API

id	requisicoes	servidor	tempo_resposta
1	352	A	165.3
2	283	A	157.2
3	79	C	51.5
4	150	A	99.8
5	282	C	121.0
6	22	A	75.2



Tempo de resposta em função da carga, por servidor, com retas de mínimos quadrados ajustadas separadamente em cada grupo.

Figura 2.3: Tempo de resposta em função da carga, por servidor, com retas de mínimos quadrados ajustadas separadamente em cada grupo.

O gráfico já antecipa, visualmente, tudo o que a álgebra desta seção vai formalizar: (i) as três nuvens de pontos têm inclinação semelhante, sugerindo que o efeito da carga (requisições) sobre o tempo de resposta é aproximadamente o mesmo nos três servidores; (ii) as retas estão deslocadas verticalmente umas em relação às outras — o servidor B responde sistematicamente mais devagar que A, e C mais rápido — o que é exatamente a diferença de intercepto que a Seção 2.5 (p. 25) vai tratar como uma função estimável ($\alpha_B - \alpha_A$); e (iii) a dispersão vertical em torno de cada reta parece razoavelmente constante ao longo do eixo horizontal, uma checagem visual informal da suposição de variância constante (σ^2 comum a todas as observações) que sustenta o teorema de Gauss-Markov da Seção 2.6 (p. 29).

Para o modelo mais simples deste conjunto — tempo de resposta em função apenas do número de requisições —, a linha i da equação $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ é

$$y_i = \beta_0 + \beta_1 \, x_i + \varepsilon_i, \qquad i = 1, \ldots, 60,$$

em que x_i é o número de requisições simultâneas na observação i. Em notação matricial,

$$\mathbf{X} = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_{60} \end{bmatrix}, \qquad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix}.$$

A primeira coluna de $\mathbf{X}$, constante e igual a 1, é o que permite ao modelo ter um intercepto β_0 — ela também é, ela mesma, um vetor de “delineamento”: corresponde a uma covariável fixa que vale 1 para todas as unidades. Concretamente, para as quatro primeiras observações simuladas, $\mathbf{X}$ e $\mathbf{Y}$ são

Tabela 2.2: As quatro primeiras linhas da matriz de delineamento X (modelo simples)

	(Intercept)	requisicoes
obs. 1	1	352
obs. 2	1	283
obs. 3	1	79
obs. 4	1	150

Note que `model.matrix()` é a função do R que constrói $\mathbf{X}$ a partir da fórmula do modelo e dos dados — ela é o objeto central de qualquer ajuste em R, mesmo quando `lm()` a esconde do usuário por trás dos panos. Voltaremos a inspecioná-la explicitamente sempre que a codificação de um fator não for óbvia.

2.4 Estimação por mínimos quadrados

Dado $\mathbf{X}$ conhecido e $\mathbf{Y}$ observado, queremos um valor $\hat{\boldsymbol{\beta}}$ que torne o modelo o mais compatível possível com os dados. O critério de **mínimos quadrados** escolhe $\hat{\boldsymbol{\beta}}$ que minimiza a soma de quadrados dos resíduos,

$$S(\boldsymbol{\beta}) = (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})'(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) = \sum_{i=1}^{n} (y_i - \mathbf{x}_i'\boldsymbol{\beta})^2,$$

em que $\mathbf{x}_i'$ é a i-ésima linha de $\mathbf{X}$. Expandindo, $S(\boldsymbol{\beta}) = \mathbf{Y}'\mathbf{Y} - 2\boldsymbol{\beta}'\mathbf{X}'\mathbf{Y} + \boldsymbol{\beta}'\mathbf{X}'\mathbf{X}\boldsymbol{\beta}$, e derivando em relação a $\boldsymbol{\beta}$ (usando $\partial(\mathbf{a}'\boldsymbol{\beta})/\partial\boldsymbol{\beta} = \mathbf{a}$ e $\partial(\boldsymbol{\beta}'\mathbf{A}\boldsymbol{\beta})/\partial\boldsymbol{\beta} = 2\mathbf{A}\boldsymbol{\beta}$ para $\mathbf{A}$ simétrica):

$$\frac{\partial S(\boldsymbol{\beta})}{\partial \boldsymbol{\beta}} = -2\mathbf{X}'\mathbf{Y} + 2\mathbf{X}'\mathbf{X}\boldsymbol{\beta}.$$

Igualando a $\mathbf{0}$ e escrevendo $\hat{\boldsymbol{\beta}}$ para a solução, obtemos as **equações normais**:

$$\mathbf{X}'\mathbf{X}\,\hat{\boldsymbol{\beta}} = \mathbf{X}'\mathbf{Y}.$$

(A matriz Hessiana da segunda derivada é $2\mathbf{X}'\mathbf{X}$, semidefinida positiva sempre — o que garante que qualquer ponto crítico é, de fato, um mínimo global de $S(\boldsymbol{\beta})$, não apenas um ponto estacionário.)

Se $\mathbf{X}$ tem posto coluna completo ($\operatorname{posto}(\mathbf{X}) = p$, isto é, as colunas de $\mathbf{X}$ são linearmente independentes), $\mathbf{X}'\mathbf{X}$ é invertível e a solução é única:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}.$$

Quando $\mathbf{X}$ **não** tem posto coluna completo — o que acontece, por exemplo, ao codificar um fator categórico com uma variável indicadora *para cada nível* mais um intercepto, como veremos na Seção 2.5 (p. 25) —, $\mathbf{X}'\mathbf{X}$ é singular (não invertível) e as equações normais têm **infinitas soluções** $\hat{\boldsymbol{\beta}}$. Uma forma de escolher uma delas é usar uma **inversa generalizada** $(\mathbf{X}'\mathbf{X})^{-}$ — qualquer matriz que satisfaça $\mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-}\mathbf{X}'\mathbf{X} = \mathbf{X}'\mathbf{X}$ — e tomar

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-}\mathbf{X}'\mathbf{Y}.$$

Duas inversas generalizadas diferentes produzem, em geral, **vetores $\hat{\boldsymbol{\beta}}$ diferentes** — por isso, quando $\mathbf{X}$ é deficiente em posto, $\boldsymbol{\beta}$ sozinho não tem interpretação única (ele é apenas um artifício de parametrização). O que *não* muda, qualquer que seja a inversa generalizada escolhida, são (i) os valores ajustados $\mathbf{X}\hat{\boldsymbol{\beta}}$ e (ii) o valor de qualquer função linear **estimável** $\boldsymbol{\lambda}'\hat{\boldsymbol{\beta}}$ — é exatamente esse fato que torna a noção de estimabilidade da Seção 2.5 (p. 25) necessária e útil, e não uma curiosidade técnica.

> **Uso do R** — mínimos quadrados via álgebra de matrizes

```
X <- model.matrix(~ requisicoes, data = dados_api)
Y <- dados_api$tempo_resposta

beta_hat <- solve(t(X) %*% X) %*% t(X) %*% Y
beta_hat
```

```
##                   [,1]
## (Intercept) 43.0996693
## requisicoes  0.3504591
```

```
# Comparação com lm(), que resolve as mesmas equações normais internamente
mod_simples <- lm(tempo_resposta ~ requisicoes, data = dados_api)
coef(mod_simples)
```

```
## (Intercept) requisicoes
##  43.0996693   0.3504591
```

Os dois métodos coincidem, como deveriam: `lm()` não faz nada conceitualmente diferente de resolver $\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}'\mathbf{Y}$ (na prática, usa decomposição QR por estabilidade numérica, não a inversão direta de $\mathbf{X}'\mathbf{X}$, mas o resultado é o mesmo). Cada requisição simultânea adicional está associada a um aumento estimado de 0.35 ms no tempo de resposta.

Uma propriedade geométrica das equações normais merece destaque: escrevendo os resíduos como $\mathbf{e} = \mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}$, as equações normais são equivalentes a $\mathbf{X}'\mathbf{e} = \mathbf{0}$ — os resíduos são **ortogonais** a cada coluna de $\mathbf{X}$. Em particular, se $\mathbf{X}$ tem uma coluna de 1's (intercepto), a soma dos resíduos é exatamente zero.

```
e <- residuals(mod_simples)
c(soma_residuos = sum(e), produto_com_x = sum(e * dados_api$requisicoes))
```

```
## soma_residuos produto_com_x
##  1.754152e-14 -2.650324e-12
```

Ambos os valores são numericamente zero (a menos de erro de arredondamento) — exatamente o que a teoria prevê.



Figura 2.4: Resíduos contra valores ajustados do modelo simples (tempo de resposta ~ requisições).

Este é o gráfico de diagnóstico mais usado em regressão. Aqui, a nuvem de resíduos se espalha em torno de zero sem nenhuma curvatura sistemática — a linha de suavização (em laranja) fica praticamente horizontal —, o que é consistente com termos incluído a covariável certa (não falta um termo quadrático, por exemplo) e com dispersão aproximadamente constante ao longo do eixo horizontal. Note que o modelo simples (sem o fator servidor) foi usado de propósito: ele omite uma variável relevante, mas isso não produz um padrão visível no gráfico de resíduos porque `servidor` é sorteado independentemente de `requisicoes` neste conjunto simulado — um lembrete de que a ausência de padrão nos resíduos não é, sozinha, prova de que o modelo está bem especificado.

2.5 Estimabilidade de funções lineares dos parâmetros

Quando $\mathbf{X}$ não tem posto coluna completo, nem todo parâmetro individual de $\boldsymbol{\beta}$ pode ser estimado de forma única — mas certas *combinações lineares* dos parâmetros podem. Essa distinção é o conceito de **estimabilidade**, essencial para interpretar corretamente os modelos de ANOVA do Capítulo 3, onde a codificação usual de um fator com k níveis por k variáveis indicadoras mais um intercepto é, propositalmente, deficiente em posto.

Definição (estimabilidade). Uma função linear $\boldsymbol{\lambda}'\boldsymbol{\beta}$ é **estimável** se existe um vetor $\mathbf{a}$ tal que $\mathrm{E}[\mathbf{a}'\mathbf{Y}] = \boldsymbol{\lambda}'\boldsymbol{\beta}$ para **todo** valor de $\boldsymbol{\beta}$. Como $\mathrm{E}[\mathbf{Y}] = \mathbf{X}\boldsymbol{\beta}$, isso equivale a $\mathbf{a}'\mathbf{X} = \boldsymbol{\lambda}'$ — ou seja, $\boldsymbol{\lambda}'\boldsymbol{\beta}$ é estimável se e somente se $\boldsymbol{\lambda}'$ pertence ao **espaço-linha de** $\mathbf{X}$.

Em outras palavras: $\boldsymbol{\lambda}'\boldsymbol{\beta}$ é estimável quando podemos escrevê-la como uma combinação linear das *médias* que o modelo de fato observa (as linhas de $\mathrm{E}[\mathbf{Y}]$), sem depender de uma parametrização específica e não identificável de $\boldsymbol{\beta}$. Quando $\mathbf{X}$ tem posto coluna completo, toda função linear é estimável, porque o espaço-linha de $\mathbf{X}$ é todo $\mathbb{R}^p$.

> **Aplicação — codificação sobreparametrizada do fator servidor**
> Em vez do contraste usual do R (que descarta uma coluna), codifique o fator `servidor` com uma coluna indicadora para **cada** nível (A, B, C) mais o intercepto. A matriz resultante tem 4 colunas, mas posto 3: a coluna do intercepto é a soma exata das três colunas indicadoras.

```
contrastes_completos <- contrasts(dados_api$servidor, contrasts = FALSE)
X_sobre <- model.matrix(~ servidor, data = dados_api,
                        contrasts.arg = list(servidor = contrastes_completos))
colnames(X_sobre) <- c("Intercepto", "servidorA", "servidorB", "servidorC")

c(colunas = ncol(X_sobre), posto = qr(X_sobre)$rank)
```

```
## colunas   posto
##       4       3
```

```
X_sobre[1:4, ] %>%
  kable(caption = "Primeiras linhas de X na codificação sobreparametrizada do fator
        servidor") %>%
  kable_styling(full_width = FALSE)
```

Tabela 2.3: Primeiras linhas de X na codificação sobreparametrizada do fator servidor

Intercepto	servidorA	servidorB	servidorC
1	1	0	0
1	1	0	0
1	0	0	1
1	1	0	0

A matriz tem 4 colunas e posto 3 — exatamente uma deficiência de posto, refletindo a redundância $\text{Intercepto} = \text{servidorA} + \text{servidorB} + \text{servidorC}$ (a primeira coluna é a soma exata das três últimas). Escrevendo o modelo como $y_i = \mu + \alpha_A 1\{\text{servidor}_i = A\} + \alpha_B 1\{\cdot = B\} + \alpha_C 1\{\cdot = C\} + \varepsilon_i$:

- μ sozinho **não é estimável**: não existe combinação de linhas de $\mathrm{E}[\mathbf{Y}]$ que isole μ sem também carregar algum α_j, porque toda observação tem exatamente um α_j "ligado".
- $\mu + \alpha_A$ **é estimável**: é exatamente a média populacional do tempo de resposta para o servidor A (a média dos y_i com $\text{servidor}_i = A$, ajustada por requisições se estas entrarem no modelo).
- $\alpha_A - \alpha_B$ **é estimável**: é a diferença entre as médias dos servidores A e B, independente de como μ foi parametrizado. Esta é a razão pela qual, na ANOVA de um fator (Capítulo 3), *contrastes* entre níveis são sempre estimáveis e interpretáveis, mesmo quando os efeitos individuais α_j, isoladamente, não são.

A regra prática para verificar estimabilidade sem procurar $\mathbf{a}$ à mão: $\boldsymbol{\lambda}'\boldsymbol{\beta}$ é estimável se e somente se $\boldsymbol{\lambda}'(\mathbf{X}'\mathbf{X})^{-}(\mathbf{X}'\mathbf{X}) = \boldsymbol{\lambda}'$, para **qualquer** inversa generalizada $(\mathbf{X}'\mathbf{X})^{-}$. Aplicando essa regra às quatro funções lineares discutidas acima:

```
XtX <- t(X_sobre) %*% X_sobre
XtX_g <- MASS::ginv(XtX)              # uma inversa generalizada de X'X (Moore-
        Penrose)

lambdas <- list(
  "mu"              = c(1, 0, 0, 0),
  "alpha_A"         = c(0, 1, 0, 0),
  "mu + alpha_A"    = c(1, 1, 0, 0),
  "alpha_A - alpha_B" = c(0, 1, -1, 0)
)
estimavel <- map_lgl(lambdas, function(lam) {
  isTRUE(all.equal(as.numeric(t(lam) %*% XtX_g %*% XtX), lam, tolerance = 1e-8))
})
tibble(funcao = names(lambdas), estimavel = estimavel) %>%
  kable(caption = "Verificação algébrica de estimabilidade via inversa generalizada")
        %>%
  kable_styling(full_width = FALSE)
```

Tabela 2.4: Verificação algébrica de estimabilidade via inversa generalizada

funcao	estimavel
mu	FALSE
alpha_A	FALSE
mu + alpha_A	TRUE
alpha_A - alpha_B	TRUE

O critério confirma exatamente a leitura intuitiva. Mais importante: embora $\hat{\boldsymbol{\beta}}$ não seja único quando $\mathbf{X}$ é deficiente em posto, **o valor de uma função estimável não depende de qual solução das equações normais usamos**. Comparando duas parametrizações completamente diferentes do mesmo fator (contrastes de tratamento vs. contrastes de soma no R):

```
mod_trat <- lm(tempo_resposta ~ servidor, data = dados_api)                    #
        contrastes de tratamento
mod_soma <- lm(tempo_resposta ~ servidor, data = dados_api,
               contrasts = list(servidor = "contr.sum"))                       #
        contrastes de soma

rbind(trat = coef(mod_trat), soma = coef(mod_soma))    # betas diferentes...
```

```
##      (Intercept) servidorB servidorC
## trat    117.0447 30.356612 -8.310288
## soma    124.3934 -7.348775 23.007837
```

```
c(max_diff_ajustados = max(abs(fitted(mod_trat) - fitted(mod_soma))),          #
        ...mas ajustados idênticos
  media_grupo_A_direta = mean(dados_api$tempo_resposta[dados_api$servidor == "A"]))
```

```
##   max_diff_ajustados media_grupo_A_direta
##         1.421085e-13         1.170447e+02
```

Os vetores $\hat{\boldsymbol{\beta}}$ são completamente diferentes entre as duas parametrizações — como deveria ser, já que $\boldsymbol{\beta}$ não é identificável sozinho —, mas os valores ajustados $\mathbf{X}\hat{\boldsymbol{\beta}}$ (e, portanto, qualquer função estimável, como a média do grupo A) coincidem exatamente. Essa invariância é a garantia formal de que a ANOVA do Capítulo 3 produz as mesmas conclusões independentemente de qual codificação de contrastes o software usa internamente.

2.5.1 A pseudoinversa de Moore-Penrose via decomposição em valores singulares

O chunk anterior usou `MASS::ginv()` para obter *uma* inversa generalizada de $\mathbf{X}'\mathbf{X}$ sem explicar como essa função a calcula por dentro. Vale a pena abrir essa caixa-preta, porque a construção é ao mesmo tempo concreta (poucas linhas de R) e a resposta canônica à pergunta "dentre as infinitas inversas generalizadas de uma matriz, existe uma mais natural?" — e a resposta é sim.

Toda matriz $\mathbf{A}$ ($m \times n$, posto r) admite uma **decomposição em valores singulares** (SVD, *singular value decomposition*):

$$\mathbf{A} = \mathbf{U}\mathbf{D}\mathbf{V}',$$

em que $\mathbf{U}$ $(m \times m)$ e $\mathbf{V}$ $(n \times n)$ são matrizes ortogonais ($\mathbf{U}'\mathbf{U} = \mathbf{I}_m$, $\mathbf{V}'\mathbf{V} = \mathbf{I}_n$) e $\mathbf{D}$ $(m \times n)$ é "diagonal" (zero fora da diagonal principal), com entradas $d_1 \geq d_2 \geq \cdots \geq d_{\min(m,n)} \geq 0$, os **valores singulares** de $\mathbf{A}$ — exatamente r deles são estritamente positivos (Golub & Van Loan, 2013). A SVD existe para *qualquer* matriz, quadrada ou não, de posto completo ou não, o que a torna mais geral do que a decomposição espectral (que exige simetria).

Definição (inversa de Moore-Penrose). Para qualquer matriz $\mathbf{A}$, existe uma única matriz $\mathbf{A}^+$, a **pseudoinversa de Moore-Penrose**, que satisfaz simultaneamente (Penrose, 1955):

1. $\mathbf{A}\mathbf{A}^+\mathbf{A} = \mathbf{A}$ (é uma inversa generalizada, no sentido já usado nesta seção);
2. $\mathbf{A}^+\mathbf{A}\mathbf{A}^+ = \mathbf{A}^+$;
3. $\mathbf{A}\mathbf{A}^+$ é simétrica;
4. $\mathbf{A}^+\mathbf{A}$ é simétrica.

A condição 1 é a única que $(\mathbf{X}'\mathbf{X})^-$ genérica precisa satisfazer; as condições 2–4 são o que torna $\mathbf{A}^+$ *única* entre as infinitas inversas generalizadas — é, em certo sentido, a "mais simétrica" de todas. Ela se constrói diretamente da SVD invertendo apenas os valores singulares não nulos e transpondo o formato:

$$\mathbf{A}^+ = \mathbf{V}\mathbf{D}^+\mathbf{U}', \qquad \mathbf{D}^+ = \begin{bmatrix} \mathbf{D}_r^{-1} & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{bmatrix},$$

em que $\mathbf{D}_r^{-1}$ inverte, um a um, os r valores singulares positivos. Quando $\mathbf{A}$ tem posto coluna completo, $\mathbf{A}^+ = (\mathbf{A}'\mathbf{A})^{-1}\mathbf{A}'$ (a inversa "de mínimos quadrados" usual); quando não tem, $\mathbf{A}^+$ generaliza essa fórmula de forma que as condições 1–4 continuem valendo.

> **Uso do R** — construindo A⁺ à mão via svd() e comparando com MASS::ginv()

```
# Reaproveitamos a mesma X'X deficiente em posto do exemplo do servidor (posto 3, 4
        colunas)
svd_XtX <- svd(XtX)          # svd() do R devolve $u, $d (vetor) e $v tais que XtX =
        u %*% diag(d) %*% t(v)
svd_XtX$d                    # valores singulares: o quarto é (numericamente) zero ->
        posto 3
```

```
## [1] 8.431114e+01 2.213304e+01 1.355582e+01 1.789853e-15
```

```
tol <- 1e-8
d_inv <- ifelse(svd_XtX$d > tol, 1 / svd_XtX$d, 0)   # inverte só os valores
        singulares "reais"
XtX_svd <- svd_XtX$v %*% diag(d_inv) %*% t(svd_XtX$u)  # A+ = V D+ U'

# Comparação com a "caixa-preta" MASS::ginv(), já usada acima
max(abs(XtX_svd - XtX_g))
```

```
## [1] 6.938894e-18
```

A diferença máxima entre as duas construções é numericamente zero: `MASS::ginv()` calcula exatamente essa fórmula $\mathbf{V}\mathbf{D}^+\mathbf{U}'$ internamente — não há mágica adicional. O quarto valor singular de $\mathbf{X}'\mathbf{X}$ está na casa de 10^{-15}, e não exatamente zero, por causa do arredondamento de ponto flutuante — daí a necessidade da tolerância `tol` para decidir quais valores singulares tratar como nulos, uma escolha prática que reaparece toda vez que se resolve um sistema linear deficiente em posto numericamente.

Note que a pseudoinversa de Moore-Penrose é apenas **uma** entre infinitas inversas generalizadas válidas de $\mathbf{X}'\mathbf{X}$ — a Seção anterior já mostrou que o critério de estimabilidade $\boldsymbol{\lambda}'(\mathbf{X}'\mathbf{X})^{-}(\mathbf{X}'\mathbf{X}) = \boldsymbol{\lambda}'$ vale para *qualquer* inversa generalizada, incluindo esta. A vantagem prática de $\mathbf{A}^{+}$ não é estatística (nenhuma inversa generalizada é "mais correta" para calcular funções estimáveis — todas dão o mesmo resultado, por definição), mas computacional e numérica: a SVD é o método mais estável para lidar com matrizes próximas de deficientes em posto (por exemplo, quando duas covariáveis são quase, mas não exatamente, colineares), e é o algoritmo que pacotes de álgebra linear (R, `numpy`, `MATLAB`) de fato usam por trás de rotinas como `MASS::ginv()`.

2.6 O teorema de Gauss-Markov e o BLUE

Sob as suposições de Gauss-Markov ($\mathrm{E}[\boldsymbol{\varepsilon}] = \mathbf{0}$, $\mathrm{Cov}(\boldsymbol{\varepsilon}) = \sigma^2\mathbf{I}_n$ — sem exigir normalidade), o estimador de mínimos quadrados de uma função estimável $\boldsymbol{\lambda}'\boldsymbol{\beta}$ tem uma propriedade de otimalidade notável.

Teorema (Gauss-Markov). Se $\boldsymbol{\lambda}'\boldsymbol{\beta}$ é estimável, então $\boldsymbol{\lambda}'\hat{\boldsymbol{\beta}}$ (com $\hat{\boldsymbol{\beta}}$ qualquer solução das equações normais) é o **BLUE** — *best linear unbiased estimator*, o melhor estimador linearmente não viesado: entre todos os estimadores da forma $\mathbf{c}'\mathbf{Y}$ que são não viesados para $\boldsymbol{\lambda}'\boldsymbol{\beta}$, $\boldsymbol{\lambda}'\hat{\boldsymbol{\beta}}$ tem a menor variância (Kutner et al., 2005; Plackett, 1950; Searle, 1971).

Duas observações práticas:

1. **"Melhor" é relativo à classe de estimadores lineares não viesados.** Estimadores viesados (como *ridge regression*) podem ter erro quadrático médio menor em certas situações — o teorema não afirma que mínimos quadrados é ótimo em qualquer sentido absoluto, só dentro dessa classe.
2. **O teorema não exige normalidade dos erros.** A otimalidade em variância vale sob as suposições de momentos apenas; a normalidade só entra quando precisamos de testes de hipótese exatos e intervalos de confiança (Seção 2.10 (p. 37) e Capítulo 3).

Quando $\mathbf{X}$ tem posto completo, a variância de $\hat{\boldsymbol{\beta}}$ é

$$\mathrm{Cov}(\hat{\boldsymbol{\beta}}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1},$$

e a variância de $\boldsymbol{\lambda}'\hat{\boldsymbol{\beta}}$ é $\sigma^2\boldsymbol{\lambda}'(\mathbf{X}'\mathbf{X})^{-1}\boldsymbol{\lambda}$ — nenhum outro estimador linear não viesado consegue variância menor, para nenhum $\boldsymbol{\lambda}$.

> **Uso do R** — variância de `beta_hat` vs. `vcov()`

```
sigma2_hat <- sum(residuals(mod_simples)^2) / mod_simples$df.residual
cov_manual <- sigma2_hat * solve(t(X) %*% X)
cov_manual
```

```
##             (Intercept)   requisicoes
## (Intercept) 12.68362254 -0.0404331773
## requisicoes -0.04043318  0.0001824602
```

```
vcov(mod_simples)
```

```
##             (Intercept)   requisicoes
## (Intercept) 12.68362254 -0.0404331773
```

```
## requisicoes -0.04043318  0.0001824602
```

As duas matrizes coincidem: `vcov()` do R não faz nada além de aplicar $\hat{\sigma}^2(\mathbf{X}'\mathbf{X})^{-1}$.

2.7 A matriz de projeção

Os valores ajustados $\hat{\mathbf{Y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$ podem ser escritos como uma transformação linear direta de $\mathbf{Y}$:

$$\hat{\mathbf{Y}} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y} = \mathbf{P}_X\mathbf{Y}, \qquad \mathbf{P}_X = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'.$$

$\mathbf{P}_X$ é a **matriz de projeção** (também chamada *hat matrix*, porque "coloca um chapéu" em $\mathbf{Y}$) sobre o **espaço-coluna de $\mathbf{X}$** — o subespaço de $\mathbb{R}^n$ gerado pelas colunas de $\mathbf{X}$. Geometricamente, $\hat{\mathbf{Y}}$ é o ponto desse subespaço mais próximo de $\mathbf{Y}$, na distância euclidiana — exatamente o que "mínimos quadrados" significa.

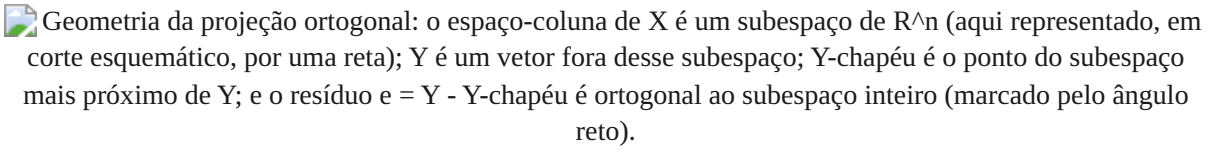

Geometria da projeção ortogonal: o espaço-coluna de X é um subespaço de R^n (aqui representado, em corte esquemático, por uma reta); Y é um vetor fora desse subespaço; Y-chapéu é o ponto do subespaço mais próximo de Y; e o resíduo e = Y - Y-chapéu é ortogonal ao subespaço inteiro (marcado pelo ângulo reto).

Figura 2.5: Geometria da projeção ortogonal: o espaço-coluna de X é um subespaço de R^n (aqui representado, em corte esquemático, por uma reta); Y é um vetor fora desse subespaço; Y-chapéu é o ponto do subespaço mais próximo de Y; e o resíduo e = Y - Y-chapéu é ortogonal ao subespaço inteiro (marcado pelo ângulo reto).

O diagrama acima é apenas um corte esquemático — na prática o espaço-coluna de $\mathbf{X}$ tem $\text{posto}(\mathbf{X})$ dimensões, não uma só —, mas captura exatamente a relação algébrica que a Seção 2.7 (p. 30) formaliza: $\hat{\mathbf{Y}}$ é a "sombra" ortogonal de $\mathbf{Y}$ sobre o subespaço, e o resíduo $\mathbf{e}$ é, por construção, perpendicular a esse subespaço inteiro — nunca correlacionado com nenhuma coluna de $\mathbf{X}$, o fato algébrico $\mathbf{X}'\mathbf{e} = \mathbf{0}$ já usado na Seção 2.4 (p. 23).

$\mathbf{P}_X$ tem três propriedades algébricas que a caracterizam como projeção ortogonal, e as duas primeiras se demonstram diretamente da definição:

1. **Simétrica:** $\mathbf{P}_X' = \big(\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\big)' = \mathbf{X}\big((\mathbf{X}'\mathbf{X})^{-1}\big)'\mathbf{X}' = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' = \mathbf{P}_X$, porque $(\mathbf{X}'\mathbf{X})^{-1}$ é simétrica (é a inversa de uma matriz simétrica, e a inversa de uma matriz simétrica é simétrica).
2. **Idempotente:**

$$\mathbf{P}_X\mathbf{P}_X = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\underbrace{\mathbf{X}'\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}}_{=\,\mathbf{I}_p}\mathbf{X}' = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}' = \mathbf{P}_X.$$

   Os dois fatores centrais $(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}$ se cancelam exatamente em $\mathbf{I}_p$, deixando $\mathbf{P}_X$ inalterada. Projetar duas vezes é o mesmo que projetar uma vez, como esperado geometricamente.
3. **Posto igual ao traço:** para qualquer matriz idempotente, $\text{posto} = \text{tr}$ (os autovalores de uma projeção só podem ser 0 ou 1, e o traço soma os autovalores enquanto o posto conta os não nulos); como $\mathbf{P}_X\mathbf{X} = \mathbf{X}$, o espaço-coluna de $\mathbf{P}_X$ coincide com o de $\mathbf{X}$, logo $\text{posto}(\mathbf{P}_X) = \text{posto}(\mathbf{X})$.

O complemento $\mathbf{I}_n - \mathbf{P}_X$ projeta sobre o espaço ortogonal ao espaço-coluna de $\mathbf{X}$, e produz os resíduos: $\mathbf{e} = (\mathbf{I}_n - \mathbf{P}_X)\mathbf{Y}$. Como $\mathbf{I}_n - \mathbf{P}_X$ também é simétrica e idempotente, ela é igualmente uma projeção — o

que explica geometricamente por que $\hat{\mathbf{Y}}$ e $\mathbf{e}$ são ortogonais entre si ($\hat{\mathbf{Y}}'\mathbf{e} = 0$): são as duas componentes de $\mathbf{Y}$ em subespaços ortogonais complementares.

Os elementos da diagonal de $\mathbf{P}_X$, chamados **alavancagens** (h_{ii}), medem o quanto a i-ésima observação influencia seu próprio valor ajustado — valores de h_{ii} próximos de 1 indicam pontos de alta alavancagem, potencialmente influentes.

> **Uso do R** — construindo e verificando a matriz de projeção

```
Xp <- model.matrix(~ requisicoes + servidor, data = dados_api)
Xp[1:4, ]   # a matriz de delineamento do modelo completo (requisições + servidor), 4
        primeiras linhas
```

```
##   (Intercept) requisicoes servidorB servidorC
## 1           1         352         0         0
## 2           1         283         0         0
## 3           1          79         0         1
## 4           1         150         0         0
```

```
P  <- Xp %*% solve(t(Xp) %*% Xp) %*% t(Xp)

mod_completo_api <- lm(tempo_resposta ~ requisicoes + servidor, data = dados_api)

# Propriedades algébricas
c(
  simetrica_max_diff   = max(abs(P - t(P))),
  idempotente_max_diff = max(abs(P %*% P - P)),
  traco                = sum(diag(P)),
  posto_X              = qr(Xp)$rank
)
```

```
##   simetrica_max_diff idempotente_max_diff               traco
##         3.469447e-17         4.163336e-17        4.000000e+00
##              posto_X
##         4.000000e+00
```

```
# Y-chapeu via P_X bate com fitted()
max(abs((P %*% Y) - fitted(mod_completo_api)))
```

```
## [1] 1.98952e-13
```

```
# Alavancagens: a diagonal de P bate com hatvalues()
max(abs(diag(P) - hatvalues(mod_completo_api)))
```

```
## [1] 5.551115e-17
```

Tudo confere: `hatvalues()` do R é, literalmente, a diagonal de $\mathbf{P}_X$.


Alavancagem (diagonal de P_X) de cada observação em função do número de requisições, no modelo completo (requisições + servidor).

Figura 2.6: Alavancagem (diagonal de P_X) de cada observação em função do número de requisições, no modelo completo (requisições + servidor).

As alavancagens mais altas se concentram nos extremos do eixo horizontal — observações com número de requisições muito baixo ou muito alto se afastam mais do centro $\bar{x}$ e, por isso, "puxam" mais a reta ajustada na própria direção (a linha tracejada marca a alavancagem média, p/n). Nenhum ponto aqui se destaca isoladamente muito acima dos demais, o que é esperado: como a covariável `requisicoes` foi simulada de uma distribuição uniforme, sem valores atípicos por construção, o padrão de alavancagem reflete só a geometria do desenho ($\mathbf{X}$), não uma anomalia dos dados — é exatamente esse ponto que a Seção 2.7 (p. 30) faz: $\mathbf{P}_X$ não depende de $\mathbf{Y}$.

2.7.1 A soma de quadrados total como forma quadrática

A matriz de projeção também permite escrever a decomposição clássica da soma de quadrados total inteiramente em notação matricial — sem nenhuma soma indexada por i —, o que é exatamente a forma que usaremos para construir a tabela de ANOVA no Capítulo 3. Seja $\mathbf{J} = \mathbf{1}\mathbf{1}'$ a matriz $n \times n$ de 1's, e $\mathbf{M} = \mathbf{I}_n - \frac{1}{n}\mathbf{J}$. $\mathbf{M}$ é, ela mesma, uma matriz de projeção — simétrica e idempotente — sobre o subespaço ortogonal ao vetor $\mathbf{1}$; projetar $\mathbf{Y}$ com $\mathbf{M}$ é **centrar** os dados:

$$\mathbf{Y}'\mathbf{M}\mathbf{Y} = \mathbf{Y}'\mathbf{Y} - \frac{1}{n}\mathbf{Y}'\mathbf{J}\mathbf{Y} = \sum_{i=1}^{n} y_i^2 - n\bar{y}^2 = \sum_{i=1}^{n}(y_i - \bar{y})^2 = \mathrm{SQ}_{\mathrm{Total}}.$$

Quando $\mathbf{X}$ inclui uma coluna de intercepto (o caso usual), o espaço-coluna de $\mathbf{X}$ contém $\mathbf{1}$, e portanto $\mathbf{P}_X\mathbf{1} = \mathbf{1}$, donde $\mathbf{P}_X\mathbf{J} = \mathbf{J}\mathbf{P}_X = \mathbf{J}$. Daí

$$\mathbf{P}_X\mathbf{M} = \mathbf{M}\mathbf{P}_X = \mathbf{P}_X - \tfrac{1}{n}\mathbf{J},$$

e como $\mathbf{J}\mathbf{J} = n\mathbf{J}$, segue $\left(\mathbf{P}_X - \frac{1}{n}\mathbf{J}\right)^2 = \mathbf{P}_X - \frac{1}{n}\mathbf{J}$: a matriz $\mathbf{P}_X - \frac{1}{n}\mathbf{J}$ é simétrica e idempotente, com posto $\mathrm{posto}(\mathbf{X}) - 1$. (Note que $\mathbf{P}_X\mathbf{M}$ **não** é igual a $\mathbf{M}$ — isso só valeria se $\mathbf{P}_X = \mathbf{I}$, ou seja, se o modelo ajustasse perfeitamente todos os pontos.) Isso permite decompor:

$$\underbrace{\mathbf{Y}'\mathbf{M}\mathbf{Y}}_{\mathrm{SQ}_{\mathrm{Total}}} = \underbrace{\mathbf{Y}'\left(\mathbf{P}_X - \tfrac{1}{n}\mathbf{J}\right)\mathbf{Y}}_{\mathrm{SQ}_{\mathrm{Regressão}}} + \underbrace{\mathbf{Y}'(\mathbf{I}_n - \mathbf{P}_X)\mathbf{Y}}_{\mathrm{SQ}_{\mathrm{Erro}}},$$

porque $\mathbf{M} = (\mathbf{P}_X - \frac{1}{n}\mathbf{J}) + (\mathbf{I}_n - \mathbf{P}_X)$ diretamente. Cada termo é uma forma quadrática em uma matriz idempotente diferente — é exatamente essa decomposição, com $\mathbf{X}$ especializada para o caso de um único fator categórico, que se torna a soma de quadrados entre e dentro de tratamentos da ANOVA de um fator no Capítulo 3.

> **Uso do R** — verificando a decomposição $\mathrm{SQ}_{\mathrm{Total}} = \mathrm{SQ}_{\mathrm{Regressão}} + \mathrm{SQ}_{\mathrm{Erro}}$

```
n <- nrow(dados_api)
J <- matrix(1, n, n)
M <- diag(n) - J / n

SQ_total <- as.numeric(t(Y) %*% M %*% Y)
SQ_reg   <- as.numeric(t(Y) %*% (P - J / n) %*% Y)
```

```
SQ_erro  <- as.numeric(t(Y) %*% (diag(n) - P) %*% Y)
c(SQ_total = SQ_total, soma_reg_erro = SQ_reg + SQ_erro,
  SQ_total_direto = sum((Y - mean(Y))^2))
```

```
##        SQ_total   soma_reg_erro SQ_total_direto
##        163350.1        163350.1        163350.1
```

A soma de $\mathrm{SQ}_{\text{Regressão}}$ e $\mathrm{SQ}_{\text{Erro}}$ reproduz $\mathrm{SQ}_{\text{Total}}$ exatamente, como a álgebra garante — e isso vale por construção, antes mesmo de olharmos para qualquer dado específico.

2.8 O modelo linear particionado

É comum querer comparar um modelo completo com um **submodelo** que remove algumas colunas de $\mathbf{X}$ — por exemplo, para testar se um conjunto de variáveis realmente contribui para explicar a resposta. Particionamos

$$\mathbf{X} = [\mathbf{X}_1 \;\; \mathbf{X}_2], \qquad \boldsymbol{\beta} = \begin{bmatrix} \boldsymbol{\beta}_1 \\ \boldsymbol{\beta}_2 \end{bmatrix}, \qquad \mathbf{Y} = \mathbf{X}_1\boldsymbol{\beta}_1 + \mathbf{X}_2\boldsymbol{\beta}_2 + \boldsymbol{\varepsilon},$$

em que $\mathbf{X}_1$ ($n \times p_1$) contém as colunas que ficam em qualquer versão do modelo, e $\mathbf{X}_2$ ($n \times p_2$) contém as colunas cuja utilidade queremos testar ($H_0 : \boldsymbol{\beta}_2 = \mathbf{0}$).



Partição da matriz de delineamento X em dois blocos de colunas: X1 (colunas mantidas em qualquer versão do modelo, p1 delas) e X2 (colunas cuja contribuição queremos testar, p2 delas). As linhas continuam representando as n observações em ambos os blocos.

Figura 2.7: Partição da matriz de delineamento X em dois blocos de colunas: X1 (colunas mantidas em qualquer versão do modelo, p1 delas) e X2 (colunas cuja contribuição queremos testar, p2 delas). As linhas continuam representando as n observações em ambos os blocos.

O **princípio da soma de quadrados extra** compara a soma de quadrados dos erros do modelo reduzido (só $\mathbf{X}_1$) com a do modelo completo:

$$\mathrm{SQE}(\text{reduzido}) - \mathrm{SQE}(\text{completo}) = \mathbf{Y}'(\mathbf{P}_X - \mathbf{P}_{X_1})\mathbf{Y},$$

em que $\mathbf{P}_{X_1} = \mathbf{X}_1(\mathbf{X}_1'\mathbf{X}_1)^{-1}\mathbf{X}_1'$ é a projeção sobre o espaço-coluna do modelo reduzido. Sob H_0 e normalidade dos erros, a estatística

$$F = \frac{\big[\mathrm{SQE}(\text{reduzido}) - \mathrm{SQE}(\text{completo})\big]/(p - p_1)}{\mathrm{SQE}(\text{completo})/(n - p)}$$

tem distribuição F com $(p - p_1,\, n - p)$ graus de liberdade — é exatamente o mecanismo por trás de `anova(modelo_reduzido, modelo_completo)` no R, e é **o mesmo mecanismo algébrico** que produz a tabela de ANOVA de um fator no Capítulo 3, em que $\mathbf{X}_1$ é só o intercepto e $\mathbf{X}_2$ são as colunas do fator de tratamento.

> **Aplicação — Psicologia: tempo de reação, sono e cafeína**
> Um laboratório de psicologia cognitiva mede o **tempo de reação** (ms) de 60 participantes em uma tarefa de atenção, registrando também suas **horas de sono** na noite anterior e o **consumo de cafeína** (mg) nas duas horas antes do teste. Pergunta: depois de controlar pelas horas de sono, a cafeína ainda ajuda a explicar o tempo de reação?

Uso do R — simulação e teste do submodelo

```
set.seed(2026)
n2 <- 60
dados_sono <- tibble(
  id = 1:n2,
  horas_sono = round(runif(n2, 4, 9), 1),
  cafeina_mg = round(runif(n2, 0, 200))
) %>%
  mutate(tempo_reacao = 480 - 18 * horas_sono + 0.22 * cafeina_mg + rnorm(n2, 0, 22))
```

 Tempo de reação em função de horas de sono; a cor de cada ponto mostra o consumo de cafeína.

Figura 2.8: Tempo de reação em função de horas de sono; a cor de cada ponto mostra o consumo de cafeína.

A tendência decrescente geral (mais sono, tempo de reação menor) é visível na reta tracejada ajustada só com `horas_sono`. Mas olhando a cor dos pontos, há um padrão adicional: para uma mesma quantidade de horas de sono, os pontos mais escuros (mais cafeína) tendem a ficar acima da reta, e os mais claros abaixo — um indício visual de que `cafeina_mg` carrega informação sobre `tempo_reacao` que `horas_sono` sozinha não captura. É exatamente esse tipo de padrão residual que o modelo particionado a seguir testa formalmente, em vez de apenas “olhar no gráfico”.

```
# X1 (modelo reduzido, so intercepto + sono) e X (modelo completo, + cafeina)
model.matrix(~ horas_sono, data = dados_sono)[1:4, ]
```

```
##   (Intercept) horas_sono
## 1           1        7.5
## 2           1        6.8
## 3           1        4.7
## 4           1        5.4
```

```
model.matrix(~ horas_sono + cafeina_mg, data = dados_sono)[1:4, ]
```

```
##   (Intercept) horas_sono cafeina_mg
## 1           1        7.5         60
## 2           1        6.8        179
## 3           1        4.7        113
## 4           1        5.4         91
```

```
mod_reduzido <- lm(tempo_reacao ~ horas_sono, data = dados_sono)
mod_completo <- lm(tempo_reacao ~ horas_sono + cafeina_mg, data = dados_sono)

anova(mod_reduzido, mod_completo)
```

```
## Analysis of Variance Table
##
## Model 1: tempo_reacao ~ horas_sono
## Model 2: tempo_reacao ~ horas_sono + cafeina_mg
##   Res.Df   RSS Df Sum of Sq      F   Pr(>F)
## 1     58 35885
## 2     57 31598  1    4286.7 7.7328 0.007337 **
```

```
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

A segunda matriz ($\mathbf{X}$, do modelo completo) contém exatamente as colunas da primeira ($\mathbf{X}_1$, do modelo reduzido) mais a coluna de `cafeina_mg` — a estrutura $\mathbf{X} = [\mathbf{X}_1 \;\; \mathbf{X}_2]$ da teoria, com $\mathbf{X}_2$ reduzida a uma única coluna neste caso.

O teste rejeita $H_0 : \beta_{\text{cafeína}} = 0$ ($p < 0.01$): mesmo controlando pelas horas de sono, a cafeína contribui para explicar o tempo de reação. Reproduzindo a mesma conta por álgebra de matrizes, para deixar explícito o que `anova()` calcula por trás:

```
X1 <- model.matrix(~ horas_sono, data = dados_sono)
X  <- model.matrix(~ horas_sono + cafeina_mg, data = dados_sono)
Yr <- dados_sono$tempo_reacao

P1 <- X1 %*% solve(t(X1) %*% X1) %*% t(X1)
P  <- X  %*% solve(t(X)  %*% X)  %*% t(X)

sqe_reduzido <- as.numeric(t(Yr) %*% (diag(n2) - P1) %*% Yr)
sqe_completo <- as.numeric(t(Yr) %*% (diag(n2) - P)  %*% Yr)
sq_extra     <- sqe_reduzido - sqe_completo

gl_extra  <- qr(X)$rank - qr(X1)$rank
gl_residuo <- n2 - qr(X)$rank
F_extra   <- (sq_extra / gl_extra) / (sqe_completo / gl_residuo)

c(sq_extra = sq_extra, gl_extra = gl_extra, F = F_extra,
  p_valor = pf(F_extra, gl_extra, gl_residuo, lower.tail = FALSE))
```

```
##     sq_extra     gl_extra            F      p_valor
## 4.286688e+03 1.000000e+00 7.732760e+00 7.336544e-03
```

Os valores batem exatamente com a saída de `anova()` — o modelo particionado é, literalmente, a conta que o R faz internamente.

2.9 O teorema de Frisch-Waugh-Lovell

A seção anterior respondeu "a covariável extra ($\mathbf{X}_2$) ajuda a explicar $\mathbf{Y}$?" comparando somas de quadrados. Uma pergunta relacionada, mas diferente, é: existe uma forma de *calcular* $\hat{\boldsymbol{\beta}}_2$ — não só testar se é zero — sem ajustar a regressão múltipla completa de uma vez? A resposta é sim, e é um resultado clássico da econometria (Frisch & Waugh, 1933; Lovell, 1963), hoje conhecido como **teorema de Frisch-Waugh-Lovell** (FWL). Ele formaliza precisamente a intuição de "manter $\mathbf{X}_1$ constante" e é o alicerce algébrico da **análise de covariância (ANCOVA)**, que usaremos com frequência nos capítulos seguintes para incorporar covariáveis pré-tratamento a desenhos experimentais.

Teorema (Frisch-Waugh-Lovell). Considere o modelo particionado $\mathbf{Y} = \mathbf{X}_1\boldsymbol{\beta}_1 + \mathbf{X}_2\boldsymbol{\beta}_2 + \boldsymbol{\varepsilon}$ da Seção 2.8 (p. 33), e seja $\mathbf{M}_1 = \mathbf{I}_n - \mathbf{P}_{X_1}$ a matriz que projeta sobre o complemento ortogonal do espaço-coluna de $\mathbf{X}_1$ (a "matriz residualizadora" de $\mathbf{X}_1$). Então o subvetor $\hat{\boldsymbol{\beta}}_2$ da regressão múltipla completa é numericamente idêntico ao coeficiente obtido em três passos:

1. Regrida $\mathbf{Y}$ em $\mathbf{X}_1$ e tome os resíduos, $\tilde{\mathbf{Y}} = \mathbf{M}_1\mathbf{Y}$ (a parte de $\mathbf{Y}$ *não explicada* por $\mathbf{X}_1$);
2. Regrida cada coluna de $\mathbf{X}_2$ em $\mathbf{X}_1$ e tome os resíduos, $\tilde{\mathbf{X}}_2 = \mathbf{M}_1\mathbf{X}_2$ (a parte de $\mathbf{X}_2$ *não explicada* por $\mathbf{X}_1$);

3. Regrida $\tilde{\mathbf{Y}}$ em $\tilde{\mathbf{X}}_2$ (sem intercepto). O vetor de coeficientes dessa regressão simples/múltipla é exatamente $\hat{\boldsymbol{\beta}}_2$.

Prova. Escrevendo as equações normais do modelo completo em forma de blocos 2×2,

$$\begin{bmatrix} \mathbf{X}_1'\mathbf{X}_1 & \mathbf{X}_1'\mathbf{X}_2 \\ \mathbf{X}_2'\mathbf{X}_1 & \mathbf{X}_2'\mathbf{X}_2 \end{bmatrix} \begin{bmatrix} \hat{\boldsymbol{\beta}}_1 \\ \hat{\boldsymbol{\beta}}_2 \end{bmatrix} = \begin{bmatrix} \mathbf{X}_1'\mathbf{Y} \\ \mathbf{X}_2'\mathbf{Y} \end{bmatrix}.$$

A primeira linha de blocos dá $\hat{\boldsymbol{\beta}}_1 = (\mathbf{X}_1'\mathbf{X}_1)^{-1}(\mathbf{X}_1'\mathbf{Y} - \mathbf{X}_1'\mathbf{X}_2\hat{\boldsymbol{\beta}}_2)$. Substituindo na segunda linha de blocos,

$$\mathbf{X}_2'\mathbf{X}_1(\mathbf{X}_1'\mathbf{X}_1)^{-1}\mathbf{X}_1'\mathbf{Y} - \mathbf{X}_2'\underbrace{\mathbf{X}_1(\mathbf{X}_1'\mathbf{X}_1)^{-1}\mathbf{X}_1'}_{=\mathbf{P}_{X_1}}\mathbf{X}_2\hat{\boldsymbol{\beta}}_2 + \mathbf{X}_2'\mathbf{X}_2\hat{\boldsymbol{\beta}}_2 = \mathbf{X}_2'\mathbf{Y},$$

que se rearranja em $\mathbf{X}_2'(\mathbf{X}_2 - \mathbf{P}_{X_1}\mathbf{X}_2)\hat{\boldsymbol{\beta}}_2 = \mathbf{X}_2'(\mathbf{Y} - \mathbf{P}_{X_1}\mathbf{Y})$, ou seja,

$$\mathbf{X}_2'\mathbf{M}_1\mathbf{X}_2\,\hat{\boldsymbol{\beta}}_2 = \mathbf{X}_2'\mathbf{M}_1\mathbf{Y} \qquad \Longrightarrow \qquad \hat{\boldsymbol{\beta}}_2 = (\mathbf{X}_2'\mathbf{M}_1\mathbf{X}_2)^{-1}\mathbf{X}_2'\mathbf{M}_1\mathbf{Y}.$$

Como $\mathbf{M}_1$ é simétrica e idempotente (Seção 2.7 (p. 30)), vale $\mathbf{M}_1 = \mathbf{M}_1'\mathbf{M}_1$, e basta notar que $\mathbf{X}_2'\mathbf{M}_1\mathbf{X}_2 = (\mathbf{M}_1\mathbf{X}_2)'(\mathbf{M}_1\mathbf{X}_2) = \tilde{\mathbf{X}}_2'\tilde{\mathbf{X}}_2$ e $\mathbf{X}_2'\mathbf{M}_1\mathbf{Y} = \tilde{\mathbf{X}}_2'\tilde{\mathbf{Y}}$ (usando $\mathbf{M}_1 = \mathbf{M}_1'\mathbf{M}_1$), logo

$$\hat{\boldsymbol{\beta}}_2 = (\tilde{\mathbf{X}}_2'\tilde{\mathbf{X}}_2)^{-1}\tilde{\mathbf{X}}_2'\tilde{\mathbf{Y}},$$

que é exatamente o estimador de mínimos quadrados da regressão de $\tilde{\mathbf{Y}}$ em $\tilde{\mathbf{X}}_2$. ■

O teorema não é apenas uma curiosidade algébrica — ele reaproveita, sem nenhum resultado novo, exatamente a mesma matriz $\mathbf{M}_1$ (projeção sobre o complemento ortogonal) e a mesma soma de quadrados extra $\mathbf{Y}'(\mathbf{P}_X - \mathbf{P}_{X_1})\mathbf{Y}$ da seção anterior: FWL mostra que essa soma de quadrados extra e o próprio coeficiente $\hat{\boldsymbol{\beta}}_2$ têm a mesma interpretação de “o que sobra depois de remover $\mathbf{X}_1$”.

2.9.1 Conexão com planejamento de experimentos: por que a ANCOVA funciona

O FWL explica precisamente por que incluir uma covariável pré-tratamento $\mathbf{X}_2$ (por exemplo, uma medida basal do resultado, coletada *antes* do experimento) em um modelo com o indicador de tratamento $\mathbf{X}_1$ não introduz viés e, ao mesmo tempo, pode aumentar a precisão — a lógica da ANCOVA (Fisher, 1935a).

1. **Sob aleatorização, o tratamento e as covariáveis pré-tratamento são ortogonais em expectativa.** No modelo causal do Capítulo 1 (Seção 1.4.3 (p. 9)), o indicador de tratamento Z_i é sorteado independentemente de qualquer característica pré-existente da unidade — incluindo qualquer covariável $\mathbf{X}_2$ medida antes da atribuição. Residualizar o tratamento em $\mathbf{X}_2$ (ou vice-versa) produz resíduos próximos do próprio tratamento original, porque há pouco a “explicar”. Isso implica que $\hat{\boldsymbol{\beta}}$ do tratamento muda pouco entre o modelo simples e o modelo com covariável — a covariável não é necessária para remover viés, porque a aleatorização já cuidou disso.
2. **A covariável reduz a variância do erro, ganhando precisão.** Se $\mathbf{X}_2$ explica parte da variação de $\mathbf{Y}$, o resíduo $\tilde{\mathbf{Y}} = \mathbf{M}_1\mathbf{Y}$ tem variância menor do que $\mathbf{Y}$ bruto. Pela fórmula de Gauss-Markov da Seção 2.6 (p. 29), $\mathrm{Var}(\hat{\beta}_2) \propto \sigma^2$ — reduzir σ^2 efetivo (a variância não explicada) reduz o erro-padrão do coeficiente de interesse, aumentando o poder do teste t/F associado, exatamente o mecanismo de soma de quadrados extra da Seção 2.8 (p. 33).

Em suma: aleatorização garante ausência de viés independentemente de covariáveis; covariáveis pré-tratamento, incluídas via ANCOVA, aumentam a precisão sem comprometer esse não-viés — e o FWL é o resultado algébrico que torna essa afirmação precisa, em vez de apenas intuitiva.

> **Uso do R** — verificando o FWL nos dados de sono e cafeína

```r
# Passo 1: residualizar Y (tempo de reacao) em X1 (so horas_sono)
Y_tilde <- resid(lm(tempo_reacao ~ horas_sono, data = dados_sono))

# Passo 2: residualizar X2 (cafeina_mg) em X1 (so horas_sono)
X2_tilde <- resid(lm(cafeina_mg ~ horas_sono, data = dados_sono))

# Passo 3: regressao simples dos residuos
mod_fwl <- lm(Y_tilde ~ X2_tilde)

# Comparacao com o coeficiente de cafeina_mg do modelo completo (secao anterior)
c(beta2_regressao_completa = unname(coef(mod_completo)["cafeina_mg"]),
  beta2_via_fwl            = unname(coef(mod_fwl)[2]))
```

```
## beta2_regressao_completa            beta2_via_fwl
##                0.1493076                0.1493076
```



Regressão dos resíduos: tempo de reação residualizado em horas de sono (eixo Y) contra cafeína residualizada em horas de sono (eixo X). A inclinação desta reta simples é idêntica ao coeficiente da cafeína na regressão múltipla completa.

Figura 2.9: Regressão dos resíduos: tempo de reação residualizado em horas de sono (eixo Y) contra cafeína residualizada em horas de sono (eixo X). A inclinação desta reta simples é idêntica ao coeficiente da cafeína na regressão múltipla completa.

Os dois coeficientes coincidem exatamente (a menos de erro de arredondamento de ponto flutuante), confirmando numericamente a prova algébrica acima. O gráfico mostra a relação “limpa” entre cafeína e tempo de reação depois de remover tudo o que horas de sono já explicava — é essa nuvem de pontos, e sua inclinação, que a regressão múltipla completa está de fato usando para estimar $\hat{\beta}_{\text{cafeína}}$, mesmo que `lm(tempo_reacao ~ horas_sono + cafeina_mg)` nunca calcule esses resíduos explicitamente.

2.10 Distribuição de formas lineares e quadráticas

Sob normalidade, $\boldsymbol{\varepsilon} \sim N(\mathbf{0}, \sigma^2 \mathbf{I}_n)$, é possível derivar a distribuição exata das quantidades que a inferência estatística usa: combinações lineares de $\mathbf{Y}$ (como $\hat{\boldsymbol{\beta}}$) e formas quadráticas (como somas de quadrados). Esses dois resultados são os alicerces algébricos da ANOVA — o Capítulo 3 não introduz nenhuma matemática nova, apenas aplica o que segue a decomposições específicas de $\mathbf{X}$.

Formas lineares. Se $\mathbf{L} = \mathbf{a}'\mathbf{Y}$ para um vetor fixo $\mathbf{a}$, então

$$\mathrm{E}[\mathbf{L}] = \mathbf{a}'\mathbf{X}\boldsymbol{\beta}, \qquad \mathrm{Var}(\mathbf{L}) = \sigma^2 \mathbf{a}'\mathbf{a},$$

e, sob normalidade, $\mathbf{L} \sim N(\mathbf{a}'\mathbf{X}\boldsymbol{\beta}, \sigma^2\mathbf{a}'\mathbf{a})$ exatamente (não apenas assintoticamente) — é isso que garante que $\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$, sendo uma combinação linear de $\mathbf{Y}$, tenha distribuição normal exata.

Formas quadráticas. Se $\mathbf{Q} = \mathbf{Y}'\mathbf{A}\mathbf{Y}$ para uma matriz simétrica fixa $\mathbf{A}$, e $\mathrm{E}[\mathbf{Y}] = \boldsymbol{\mu} = \mathbf{X}\boldsymbol{\beta}$, $\mathrm{Cov}(\mathbf{Y}) = \sigma^2\mathbf{I}_n$, então

$$\mathrm{E}[\mathbf{Q}] = \sigma^2 \operatorname{tr}(\mathbf{A}) + \boldsymbol{\mu}'\mathbf{A}\boldsymbol{\mu}.$$

O resultado que faz a ANOVA funcionar é o seguinte:

Teorema (distribuição qui-quadrado de formas quadráticas idempotentes). Se $\mathbf{A}$ é **idempotente** ($\mathbf{A}\mathbf{A} = \mathbf{A}$) com posto (= traço) r, e $\mathbf{Y} \sim N(\boldsymbol{\mu}, \sigma^2\mathbf{I}_n)$, então $\mathbf{Y}'\mathbf{A}\mathbf{Y}/\sigma^2$ tem distribuição **qui-quadrado** com r graus de liberdade, não central com parâmetro de não centralidade $\boldsymbol{\mu}'\mathbf{A}\boldsymbol{\mu}/\sigma^2$. Em particular, se $\mathbf{A}\boldsymbol{\mu} = \mathbf{0}$, a distribuição é qui-quadrado **central** com r graus de liberdade.

Como $\mathbf{I}_n - \mathbf{P}_X$ é idempotente com posto $n - \operatorname{posto}(\mathbf{X})$ e $(\mathbf{I}_n - \mathbf{P}_X)\mathbf{X}\boldsymbol{\beta} = \mathbf{0}$ (os resíduos não têm componente sistemática, por construção), segue diretamente que

$$\frac{\mathrm{SQE}}{\sigma^2} = \frac{\mathbf{Y}'(\mathbf{I}_n - \mathbf{P}_X)\mathbf{Y}}{\sigma^2} \;\sim\; \chi^2_{\,n - \operatorname{posto}(\mathbf{X})} \quad \text{(qui-quadrado central)},$$

e a soma de quadrados extra da Seção 2.8 (p. 33), $\mathbf{Y}'(\mathbf{P}_X - \mathbf{P}_{X_1})\mathbf{Y}$, é qui-quadrado não central sob a alternativa e central sob $H_0 : \boldsymbol{\beta}_2 = \mathbf{0}$ — a razão de duas quadráticas independentes, cada uma dividida por seus graus de liberdade, é exatamente a estatística F que usamos. (A independência entre $\mathbf{P}_X - \mathbf{P}_{X_1}$ e $\mathbf{I}_n - \mathbf{P}_X$ decorre de um resultado adicional — o teorema de Cochran — que não desenvolvemos aqui, mas que garante que a decomposição da soma de quadrados total em partes independentes, central ao Capítulo 3, é matematicamente válida.)

> **Uso do R** — verificando a distribuição qui-quadrado por simulação de Monte Carlo

```r
set.seed(2026)
sigma <- 22
n_rep <- 4000
gl_residuo2 <- n2 - qr(X)$rank

estatisticas <- replicate(n_rep, {
  Y_sim <- as.numeric(X %*% coef(mod_completo)) + rnorm(n2, 0, sigma)
  as.numeric(t(Y_sim) %*% (diag(n2) - P) %*% Y_sim) / sigma^2
})

ggplot(tibble(estatisticas), aes(x = estatisticas)) +
  geom_histogram(aes(y = after_stat(density)), bins = 40, fill = "#3b5bdb", alpha =
        0.6) +
  stat_function(fun = dchisq, args = list(df = gl_residuo2), color = "#d98324",
        linewidth = 1) +
  labs(x = expression(SQE / sigma^2), y = "Densidade",
       title = paste0("Distribuição simulada vs. qui-quadrado(", gl_residuo2, ")
        teórica")) +
  theme_minimal(base_size = 13)
```

O histograma simulado (4.000 réplicas de Monte Carlo, regerando $\mathbf{Y}$ sob o modelo verdadeiro a cada repetição) acompanha de perto a densidade qui-quadrado teórica com 57 graus de liberdade — a confirmação empírica de que SQE/σ^2 se comporta exatamente como a teoria prevê.

Para discutir

1. No exemplo da API, por que μ (o "intercepto puro" da codificação sobreparametrizada do servidor) não é estimável, mas a média de cada servidor, $\mu + \alpha_j$, é? O que isso diz sobre como devemos interpretar um coeficiente de intercepto em um modelo com fatores categóricos?
2. O teorema de Gauss-Markov garante que $\hat{\boldsymbol{\beta}}$ tem variância mínima entre estimadores lineares não viesados. Em que sentido isso é diferente de dizer que $\hat{\boldsymbol{\beta}}$ é o "melhor" estimador possível, sem qualificação?
3. Na análise de tempo de reação vs. sono e cafeína, o que aconteceria com a soma de quadrados extra se, em vez de cafeína, adicionássemos ao modelo completo uma variável irrelevante (por exemplo, o dia da semana em que o teste foi feito, sorteado aleatoriamente)? O teste F continuaria válido?
4. A matriz de projeção $\mathbf{P}_X$ depende apenas de $\mathbf{X}$, nunca de $\mathbf{Y}$. Que consequência prática isso tem para decidir, antes de coletar os dados, quão precisas serão as estimativas de um experimento planejado?

2.11 Resumo do capítulo

- O modelo linear $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ organiza qualquer resposta observada como combinação linear de parâmetros mais erro aleatório; a matriz $\mathbf{X}$ codifica o desenho do experimento.
- Mínimos quadrados resolve $\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}'\mathbf{Y}$; quando $\mathbf{X}$ não tem posto completo, só funções lineares **estimáveis** de $\boldsymbol{\beta}$ (contrastes, médias de grupo) têm estimativa única.
- O teorema de Gauss-Markov garante que mínimos quadrados é o BLUE entre estimadores lineares não viesados, sem exigir normalidade.
- A matriz de projeção $\mathbf{P}_X$ formaliza “ajuste” como projeção ortogonal sobre o espaço-coluna de $\mathbf{X}$; suas propriedades (simetria, idempotência, traço = posto) explicam a ortogonalidade entre ajustados e resíduos.
- O modelo particionado e o princípio da soma de quadrados extra formalizam a comparação entre um modelo completo e um submodelo — o mecanismo algébrico por trás de todo teste F que veremos.
- O teorema de Frisch-Waugh-Lovell mostra que o coeficiente de uma covariável na regressão múltipla completa é idêntico ao coeficiente de uma regressão simples entre os resíduos de $\mathbf{Y}$ e da covariável, ambos residualizados no resto do modelo — o fundamento algébrico da ANCOVA.
- A pseudoinversa de Moore-Penrose, construída via decomposição em valores singulares, é a inversa generalizada mais simétrica entre as infinitas possíveis para $\mathbf{X}'\mathbf{X}$ deficiente em posto — e é o que `MASS::ginv()` calcula internamente.
- Sob normalidade, formas lineares de $\mathbf{Y}$ são normais e formas quadráticas idempotentes de $\mathbf{Y}$ são qui-quadrado — a base exata da tabela de ANOVA do Capítulo 3.

Uma nota sobre notação: de β genérico a τ, e depois a $\alpha, \beta, \gamma, \ldots$

Este capítulo usou o vetor genérico $\boldsymbol{\beta}$ para os parâmetros do modelo linear, porque a teoria de mínimos quadrados, estimabilidade e projeção vale para *qualquer* matriz de delineamento $\mathbf{X}$, independentemente do que suas colunas representam. A partir do Capítulo 3, a notação se especializa, e vale registrar a convenção adotada no restante do livro para que a mudança não pareça arbitrária:

- Quando o modelo tem **um único fator de tratamento** (delineamento completamente aleatorizado, Capítulo 3; blocos, Capítulo 4), os efeitos de tratamento são denotados τ_i — não β_i — para deixar explícito, só pela notação, que a matriz $\mathbf{X}$ correspondente é a codificação sobreparametrizada de fator ($\mu + \tau_i$) discutida na Seção 2.5 (p. 25), e não um vetor de coeficientes de regressão sobre variáveis contínuas.
- Quando dois ou mais fatores são **cruzados** em um arranjo fatorial (Capítulos 5–6), cada fator recebe sua própria letra grega — α_i para o fator A, β_j para o fator B, γ_k para um terceiro fator C, e assim por diante — evitando que um único símbolo τ com múltiplos índices (τ_{ij}) deixe ambíguo se o índice pertence ao fator A, ao fator B ou à sua interação. Esta é a convenção padrão da literatura de planejamento de experimentos (Montgomery, 2017), e reaparecerá sem aviso adicional a partir do Capítulo 5.

Em todos os casos, o vetor $\boldsymbol{\beta}$ deste capítulo permanece o objeto matematicamente subjacente: τ_i, α_i, β_j etc. são apenas nomes diferentes para entradas específicas de $\boldsymbol{\beta}$ em uma parametrização de $\mathbf{X}$ particular — toda a maquinaria de estimabilidade, projeção e soma de quadrados extra construída aqui se aplica sem nenhuma modificação, trocando apenas os rótulos.

O Capítulo 3 aplica exatamente esta maquinaria ao caso do delineamento completamente aleatorizado (DCA): a matriz $\mathbf{X}$ passa a codificar um único fator categórico, e a decomposição $\mathbf{Y}'\mathbf{Y} = \mathbf{Y}'\mathbf{P}_X\mathbf{Y} + \mathbf{Y}'(\mathbf{I}_n - \mathbf{P}_X)\mathbf{Y}$ se torna, literalmente, a tabela de soma de quadrados entre e dentro de tratamentos.

3 Delineamento completamente aleatorizado

O Capítulo 1 estabeleceu repetição, aleatorização e controle local como os três pilares do controle do erro experimental; o Capítulo 2 deu a esses pilares uma linguagem formal — o modelo linear. Este capítulo une as duas coisas no delineamento mais simples possível: o **delineamento completamente aleatorizado (DCA)**, em que um único fator é sorteado livremente entre as unidades experimentais, sem qualquer restrição de blocagem. É o ponto de partida de todo o resto do curso — e, por ser o desenho mais simples, também é o lugar certo para introduzir com rigor a ideia de **teste de aleatorização**, o modelo estatístico, a ANOVA, o planejamento do tamanho amostral, o problema do submuestreo, o modelo de efeitos aleatórios e a verificação dos pressupostos que tornam a inferência clássica válida.

3.1 Princípios de aleatorização: a ideia de um teste de aleatorização

Antes de introduzir qualquer suposição distribucional, vale a pena perguntar: *de onde vem*, em termos lógicos, a validade de um teste estatístico em um experimento aleatorizado? A resposta de Fisher é elegante e não depende de normalidade alguma (Fisher, 1935b).

Considere um DCA com t tratamentos e N unidades experimentais ao todo. Sob a hipótese nula de que o tratamento não tem efeito algum, o valor que cada unidade experimental produziria é o *mesmo*, não importa qual tratamento ela receba — os rótulos de tratamento são, sob H_0, completamente permutáveis entre as unidades. O mecanismo físico de aleatorização escolheu **uma** entre as $\binom{N}{n_1, n_2, \ldots, n_t}$ formas possíveis de distribuir os tratamentos pelas unidades; sob H_0, todas essas formas são igualmente prováveis e teriam produzido exatamente os mesmos N valores de resposta, apenas reagrupados de outra maneira.

Um **teste de aleatorização** (ou teste de permutação) explora essa ideia diretamente:

1. Calcula-se uma estatística de teste T nos dados observados (por exemplo, a estatística F da ANOVA, definida na Seção 3.2.5 (p. 52)).
2. Reembaralham-se os rótulos de tratamento entre as N unidades, muitas vezes (idealmente, todas as permutações possíveis; na prática, um grande número delas sorteado aleatoriamente), e recalcula-se T a cada reembaralhamento.
3. O valor-p de aleatorização é a proporção de reembaralhamentos que produziu um T tão grande quanto (ou maior que) o observado.



O esquema geral por trás de todo teste de aleatorização, em quatro passos: dados observados produzem uma estatística observada T*; o mecanismo de aleatorização do próprio delineamento gera reembaralhamentos sob H0 e T é recalculado em cada um; a distribuição desses valores é a distribuição de referência; localizar T* nela define o valor-p.

Figura 3.1: O esquema geral por trás de todo teste de aleatorização, em quatro passos: dados observados produzem uma estatística observada T*; o mecanismo de aleatorização do próprio delineamento gera reembaralhamentos sob H0 e T é recalculado em cada um; a distribuição desses valores é a distribuição de referência; localizar T* nela define o valor-p.

O diagrama resume o princípio geral por trás não só do teste de aleatorização, mas de qualquer teste de hipótese baseado em simulação: (i) computar a estatística nos dados reais; (ii) simular repetidamente sob um modelo explícito de H_0; (iii) localizar a estatística observada na distribuição simulada. O

reembaralhamento de rótulos descrito acima **é** esse esquema, com o "modelo de H_0" sendo, literalmente, o mecanismo físico de aleatorização do próprio delineamento — não uma suposição extra importada de fora dos dados.

Esse procedimento não assume normalidade, nem variâncias iguais, nem qualquer outra forma distribucional — sua validade vem inteiramente do mecanismo de aleatorização em si (Edgington & Onghena, 2007). O que a teoria normal-linear faz, a partir da Seção 3.2.1 (p. 49), é oferecer uma **aproximação** ao teste de aleatorização exato — uma aproximação excelente quando os erros são razoavelmente próximos de normais, e que tem a enorme vantagem prática de fornecer fórmulas fechadas em vez de exigir reembaralhamento computacional.

> **Uso do R** — comparando o teste de aleatorização com o teste F

```
set.seed(48)
condicao <- c("Nenhuma", "Sonora", "Visual")
n_por_grupo <- 12

dados_tr <- tibble(
  sujeito      = 1:(3 * n_por_grupo),
  condicao     = factor(rep(condicao, each = n_por_grupo), levels = condicao),
  tempo_reacao = c(rnorm(n_por_grupo, 480, 45),
                   rnorm(n_por_grupo, 512, 45),
                   rnorm(n_por_grupo, 555, 45))
)

F_obs <- summary(aov(tempo_reacao ~ condicao, data = dados_tr))[[1]][["F value"]][1]

R_perm <- 4000
F_perm <- replicate(R_perm, {
  rotulo_embaralhado <- sample(dados_tr$condicao)
  summary(aov(dados_tr$tempo_reacao ~ rotulo_embaralhado))[[1]][["F value"]][1]
})

tibble(
  Método   = c("Teste F (teórico)", "Teste de aleatorização"),
  `Valor-p` = c(pf(F_obs, 2, 33, lower.tail = FALSE), mean(F_perm >= F_obs))
) %>%
  kable(digits = 4, caption = "Valor-p teórico vs. valor-p por aleatorização, mesmos
        dados") %>%
  kable_styling(full_width = FALSE)
```

Tabela 3.1: Valor-p teórico vs. valor-p por aleatorização, mesmos dados

Método	Valor-p
Teste F (teórico)	0.0066
Teste de aleatorização	0.0073



Distribuição de referência: os 4.000 valores de F recalculados sob reembaralhamentos aleatórios dos rótulos de condição (histograma), com o F observado nos dados reais (linha tracejada) e a densidade F(2,33) teórica sobreposta (curva). A área à direita da linha tracejada, sob o histograma, é o valor-p de aleatorização; sob a curva teórica, é o valor-p do teste F.

Figura 3.2: Distribuição de referência: os 4.000 valores de F recalculados sob reembaralhamentos aleatórios dos rótulos de condição (histograma), com o F observado nos dados reais (linha tracejada) e a densidade F(2,33) teórica sobreposta (curva). A área à direita da linha tracejada, sob o histograma, é o valor-p de aleatorização; sob a curva teórica, é o valor-p do teste F.

O histograma (distribuição empírica de aleatorização) e a curva $F(2, 33)$ teórica praticamente se sobrepõem, e a linha tracejada (F observado) cai na cauda direita de ambas — confirmação visual de que a aproximação normal-linear captura bem a distribuição de referência exata neste exemplo, sem que nenhuma das duas dependa de suposição alguma sobre a forma de Y: a curva F é válida sob normalidade dos erros; o histograma é válido apenas pelo mecanismo de aleatorização em si, qualquer que seja a distribuição verdadeira dos dados.

Os dois valores-p ficam muito próximos — é exatamente o comportamento esperado quando os pressupostos do modelo normal-linear (que introduzimos a seguir) são razoáveis. A Seção 3.5 (p. 68) trata de como verificar, na prática, se essa aproximação é confiável.

3.1.1 De onde vêm os graus de liberdade $(2, 33)$: a ponte entre aleatorização, variância decomposta e F

Vale amarrar, com todo o rigor já disponível neste ponto do livro, *por que* a curva $F(2, 33)$ é uma boa aproximação da distribuição de aleatorização — não apenas *que* ela é, como a Figura 3.2 já mostrou empiricamente. A resposta liga três coisas que, até aqui, apareceram em capítulos diferentes: a decomposição da variação em fontes (Capítulo 1, Seção 1.3 (p. 7)), a forma aditiva do modelo que essa decomposição força sob aleatorização (Seção 1.3.1 (p. 7) do Capítulo 1) e a contagem de graus de liberdade via posto de matrizes de projeção e diagramas de Hasse (Capítulo 2, Seções 2.7 (p. 30) e 2.2 (p. 17)).

O que permanece fixo em cada reembaralhamento, e o que muda. Reembaralhar os rótulos de tratamento entre as $N = 36$ unidades, como no chunk anterior, não move nenhum valor de resposta — os 36 tempos de reação observados são exatamente os mesmos a cada repetição, só a *partição* deles em três grupos de 12 muda. Consequentemente, $SQ_{\text{Total}} = \mathbf{Y}'\mathbf{M}\mathbf{Y}$ (Capítulo 2, Seção 2.7.1 (p. 32)) é **idêntica** em todas as 4.000 reamostragens — só $\mathbf{X}$ muda a cada reembaralhamento (a matriz de delineamento reflete a nova partição), e com ela a forma como SQ_{Total} se reparte entre $SQ_{\text{Trat}} = \mathbf{Y}'(\mathbf{P}_X - \frac{1}{N}\mathbf{J})\mathbf{Y}$ e $SQ_E = \mathbf{Y}'(\mathbf{I}_N - \mathbf{P}_X)\mathbf{Y}$. Essa é, literalmente, a mesma decomposição de fontes de variação do Capítulo 1 — fonte 1 (tratamento) *versus* fontes 2+3 combinadas (o que sobra) — só que agora vista sob 4.000 partições diferentes dos mesmos 36 valores, em vez de uma única partição observada.

Por que os graus de liberdade não mudam. Embora $\mathbf{X}$ mude a cada reembaralhamento, seu *posto* não muda: qualquer reembaralhamento continua produzindo $t = 3$ grupos não vazios (o sorteio apenas troca *quais* 12 unidades vão para cada grupo, nunca o número de grupos nem o tamanho de cada um, que ficam fixados pelo desenho). Logo $\text{posto}(\mathbf{X}) = 3$ em toda reamostragem, e a contagem por subtração do diagrama de Hasse (Capítulo 2, Seção 2.2 (p. 17)) — $\text{gl}(\text{Trat}) = t - 1 = 2$, $\text{gl}(\text{Erro}) = N - t = 33$ — vale identicamente para as 4.000 partições, não só para os dados observados. É exatamente por isso que a *forma* da curva de referência (uma F com $(2, 33)$ graus de liberdade) é estável sob reembaralhamento, mesmo sem nenhuma suposição de normalidade: os graus de liberdade são uma propriedade do **desenho** (*t*

e N fixos), não da distribuição dos erros — o que muda de uma reamostragem para outra é só *onde*, dentro dessa forma fixa, cada estatística F recalculada cai.

> **Uso do R** — confirmando que os graus de liberdade vêm do posto de X, não da distribuição dos dados

```
X_dca_tr <- model.matrix(~ condicao, data = dados_tr)

gl_trat_matriz <- qr(X_dca_tr)$rank - 1          # posto(X) - 1 (Cap. 2, Secao
        matriz-projecao)
gl_erro_matriz <- nrow(dados_tr) - qr(X_dca_tr)$rank  # N - posto(X)

c(gl_trat = gl_trat_matriz, gl_erro = gl_erro_matriz)
```

```
## gl_trat gl_erro
##       2      33
```

Os valores batem exatamente com o $(2, 33)$ já usado em `df(..., df1 = 2, df2 = 33)` na Figura 3.2 — não por coincidência ou por termos "sabido de antemão" quais graus de liberdade usar, mas porque $2 = 3 - 1$ e $33 = 36 - 3$ vêm diretamente do posto de $\mathbf{X}$, exatamente como a regra de subtração do diagrama de Hasse prediz, e esse posto é uma função só de t e N (quantos grupos o desenho tem e quantas unidades ao todo), não de $\mathbf{Y}$.

Por que a aproximação F funciona tão bem aqui. A teoria normal-linear (Capítulo 2, Seção 2.10 (p. 37)) prevê que, *se* os erros fossem exatamente normais e i.i.d. — a leitura de ε_{ij} que a Seção 1.3.1 (p. 7) do Capítulo 1 justificou como consequência da aleatorização, não como suposição gratuita —, então $SQ_{\text{Trat}}/\sigma^2$ e SQ_E/σ^2 seriam qui-quadrado independentes com 2 e 33 graus de liberdade sob H_0, e sua razão (normalizada pelos respectivos graus de liberdade) seguiria $F_{2,33}$ **exatamente**, não apenas aproximadamente. A distribuição de aleatorização, por outro lado, não usa normalidade alguma: ela é exata *por construção*, qualquer que seja a distribuição de Y, porque enumera (ou amostra) diretamente as $\binom{36}{12,12,12}$ formas de particionar os mesmos 36 valores. As duas curvas da Figura 3.2 quase se sobrepõem porque, quando $n_i = 12$ por grupo já não é pequeno e a distribuição de Y não é patologicamente assimétrica, o Teorema Central do Limite aplicado a cada média de grupo $\bar{Y}_{i\cdot}$ torna a distribuição de SQ_{Trat} sob reembaralhamento cada vez mais próxima da qui-quadrado teórica que a normalidade exigiria (Box et al., 2005; Edgington & Onghena, 2007) — a aproximação melhora com n, e pioraria em desenhos com n_i muito pequeno ou Y muito assimétrico (o cenário de heterocedasticidade da Seção 3.5 (p. 68), adiante). Em suma: **aleatorização** garante que o modelo aditivo $Y_{ij} = \mu + \tau_i + \varepsilon_{ij}$ é uma leitura válida dos dados (Seção 1.3.1 (p. 7)); a **decomposição de variância** em fontes fixa os graus de liberdade $(t - 1,\ N - t)$ como propriedade do desenho, geometricamente visível no diagrama de Hasse (Capítulo 2); e é só quando essas duas peças já estão no lugar que a normalidade entra — não para criar a validade da inferência, que já vem da aleatorização, mas para trocar reembaralhamento computacional por uma fórmula fechada, a $F_{t-1,N-t}$.

3.1.2 O modelo linear deduzido da aleatorização

Até aqui usamos o modelo $Y_{ij} = \mu + \tau_i + \varepsilon_{ij}$ como ponto de partida, justificando-o informalmente. Vale agora fazer melhor: **deduzi-lo** do ato físico de sortear, sem postulá-lo. É esta derivação — devida a Cornfield (1944) e sistematizada por Kempthorne (1952) — que separa um curso de planejamento de experimentos de um curso de regressão. No fim dela teremos algo inesperado: o erro que emerge do sorteio é **correlacionado**, e ainda assim mínimos quadrados ordinários continuam ótimos.

3.1.2.1 A população conceitual de respostas

Considere N unidades experimentais e t tratamentos, e defina

$$Y_{ij} \;=\; \text{resposta que a unidade } j \text{ apresentaria sob o tratamento } i, \qquad i = 1, \dots, t, \quad j = 1, \dots, N.$$

O quadro $t \times N$ dos Y_{ij} é a **população conceitual de respostas**. Ela não é observável: de cada unidade j veremos **uma** linha apenas, a do tratamento que o sorteio lhe deu. São exatamente os **resultados potenciais** de Neyman-Rubin da Seção 3.2.3 (p. 51), agora organizados como uma tabela — e é essa tabela que torna a derivação possível.

Escreva as médias marginais $\bar{Y}_{i\cdot}$ (sobre unidades, para o tratamento i), $\bar{Y}_{\cdot j}$ (sobre tratamentos, para a unidade j) e $\bar{Y}_{\cdot\cdot}$ (geral). A identidade algébrica exata de qualquer tabela de dupla entrada é

$$Y_{ij} = \bar{Y}_{\cdot\cdot} + \underbrace{(\bar{Y}_{i\cdot} - \bar{Y}_{\cdot\cdot})}_{\text{efeito do tratamento}} + \underbrace{(\bar{Y}_{\cdot j} - \bar{Y}_{\cdot\cdot})}_{\text{efeito da unidade}} + \underbrace{(Y_{ij} - \bar{Y}_{i\cdot} - \bar{Y}_{\cdot j} + \bar{Y}_{\cdot\cdot})}_{\text{interação tratamento}\times\text{unidade}}.$$

O último termo é uma **interação entre tratamento e unidade**: o tratamento i favorecendo especialmente a unidade j. A **aditividade no sentido estrito** consiste em supor esse termo nulo — e convém ser franco sobre o que se está supondo: que o efeito de trocar o tratamento i pelo k é o mesmo em toda unidade. É uma suposição, não uma conveniência de notação, e é precisamente a que o Capítulo 4 voltará a interrogar ao discutir aditividade em blocos.

3.1.2.2 A variável de seleção de Cornfield

Falta a peça que liga a população conceitual ao dado observado: uma representação matemática do **sorteio**. Seja y_{ir} a resposta da r-ésima réplica do tratamento i e defina

$$\delta_{ir}^{\,j} = \begin{cases} 1, & \text{se a } r\text{-ésima réplica do tratamento } i \text{ foi aplicada à unidade } j, \\ 0, & \text{caso contrário.} \end{cases}$$

Os índices têm papéis distintos, e confundi-los é o erro comum aqui: ir designa uma **posição no plano experimental** (a 2ª réplica do tratamento A), enquanto j designa uma **unidade física** (o voluntário nº 5). A aleatoriedade de δ não vem de natureza alguma: vem do papelzinho sorteado pelo pesquisador. Sob aleatorização completa,

$$P(\delta_{ir}^{\,j} = 1) = \frac{1}{N}, \qquad P\big(\delta_{ir}^{\,j} = 1 \,\big|\, \delta_{i'r'}^{\,j'} = 1\big) = \frac{1}{N-1} \;\; (ir \neq i'r',\; j \neq j'), \qquad \sum_{j=1}^{N} \delta_{ir}^{\,j} = 1.$$

A última identidade diz apenas que toda posição do plano é preenchida por exatamente uma unidade. Com ela, a **relação de seleção** que conecta o observável ao conceitual é uma soma que "filtra" a população:

$$y_{ir} = \sum_{j=1}^{N} \delta_{ir}^{\,j}\, Y_{ij}.$$

3.1.2.3 A dedução

Substituindo a identidade algébrica já simplificada pela aditividade estrita, $Y_{ij} \approx \bar{Y}_{\cdot\cdot} + (\bar{Y}_{i\cdot} - \bar{Y}_{\cdot\cdot}) + (\bar{Y}_{\cdot j} - \bar{Y}_{\cdot\cdot})$, na relação de seleção, e usando $\sum_j \delta_{ir}^{\,j} = 1$ para eliminar os termos que não dependem de j:

$$y_{ir} = \underbrace{\bar{Y}_{\cdot\cdot}}_{\mu} + \underbrace{(\bar{Y}_{i\cdot} - \bar{Y}_{\cdot\cdot})}_{\tau_i} + \underbrace{\sum_{j=1}^{N} \delta_{ir}^{\,j}\,(\bar{Y}_{\cdot j} - \bar{Y}_{\cdot\cdot})}_{\omega_{ir}} \qquad \Longrightarrow \qquad \boxed{y_{ir} = \mu + \tau_i + \omega_{ir}}$$

O modelo linear **não foi suposto: foi obtido**. E note o que ω_{ir} é — não um "ruído" abstrato, mas o efeito da unidade específica que o sorteio colocou naquela posição. Daí o nome **erro de aleatorização**, e daí a diferença decisiva em relação ao ε_{ij} de Gauss-Markov: as propriedades de ε são *assumidas*; as de ω são *deduzidas* da distribuição do sorteio, que o próprio pesquisador escolheu.

3.1.2.4 As propriedades de ω — e uma surpresa

Escreva $u_j = \bar{Y}_{\cdot j} - \bar{Y}_{\cdot\cdot}$ para o efeito da unidade j, de modo que $\sum_j u_j = 0$, e defina $\sigma_u^2 = \frac{1}{N-1}\sum_j u_j^2$. Tomando esperanças sobre a distribuição de aleatorização (indicada por $\mathbb{E}_R$):

$$\mathbb{E}_R(\omega_{ir}) = \sum_j \frac{1}{N}\,u_j = 0, \qquad \operatorname{Var}_R(\omega_{ir}) = \sum_j \frac{1}{N} u_j^2 = \Big(1 - \frac{1}{N}\Big)\sigma_u^2,$$

e, para duas posições distintas $ir \neq i'r'$,

$$\operatorname{Cov}_R(\omega_{ir}, \omega_{i'r'}) = \frac{1}{N(N-1)}\Big[\Big(\sum_j u_j\Big)^2 - \sum_j u_j^2\Big] = -\frac{\sigma_u^2}{N} \;<\; 0.$$

A covariância é **negativa**, e a razão é puramente combinatória: as unidades são sorteadas **sem reposição**, então a unidade que foi parar numa posição não pode estar em outra. Em forma matricial, empilhando as N observações,

$$\operatorname{Var}_R(\boldsymbol{\omega}) = \mathbf{V} = \sigma_u^2\Big(\mathbf{I}_N - \tfrac{1}{N}\mathbf{J}_N\Big),$$

que **não é diagonal**. Ou seja: a aleatorização, que é o que garante a validade da inferência, produz por construção erros correlacionados — exatamente a hipótese que o teorema de Gauss-Markov (Seção 2.6 (p. 29) do Capítulo 2) exige que *não* seja violada.

> **Uso do R** — verificando as três identidades por enumeração exaustiva

As identidades acima não são aproximações assintóticas: valem exatamente. Com N pequeno dá para conferir isso enumerando **todas** as aleatorizações possíveis, em vez de simular.

```
N <- 7
set.seed(7)
u <- rnorm(N, 0, 3); u <- u - mean(u)          # efeitos de unidade (somam zero)
sigma2_u <- sum(u^2) / (N - 1)

# todas as N! atribuicoes possiveis de unidades a posicoes
permutacoes <- function(v) {
  if (length(v) == 1) return(matrix(v))
  do.call(rbind, lapply(seq_along(v),
                        function(i) cbind(v[i], permutacoes(v[-i]))))
}
omega <- matrix(u[permutacoes(seq_len(N))], ncol = N)   # uma linha por aleatorizacao

tibble(
```

```
  Quantidade = c("E(ω)", "Var(ω)", "Cov(ω, ω′)"),  Enumerado  = c(mean(omega[, 1]),
                 mean(omega[, 1]^2),                 mean(omega[, 1] * omega[, 2])),
  Fórmula    = c(0,                  (1 - 1 / N) * sigma2_u,
                 -sigma2_u / N)) %>%
  kable(digits = 10, caption = "Propriedades do erro de aleatorização, sobre todas as
        N! atribuições") %>%
  kable_styling(full_width = FALSE)
```

Tabela 3.2: Propriedades do erro de aleatorização, sobre todas as N! atribuições

Quantidade	Enumerado	Fórmula
E(ω)	0.000000	0.000000
Var(ω)	12.232455	12.232455
Cov(ω, ω′)	-2.038742	-2.038742

3.1.2.5 Zyskind: por que ainda assim usamos mínimos quadrados ordinários

Se $\mathrm{Var}(\boldsymbol{\omega}) = \mathbf{V} \neq \sigma^2\mathbf{I}$, o teorema de Gauss-Markov não se aplica, e o estimador de variância mínima passa a ser o de **mínimos quadrados generalizados** de Aitken (1936), $\hat{\boldsymbol{\beta}}_{GLS} = (\mathbf{X}'\mathbf{V}^{-1}\mathbf{X})^{-}\mathbf{X}'\mathbf{V}^{-1}\mathbf{Y}$. Seria desconfortável: todo o curso usa MQO.

O resultado que resolve a questão é de Zyskind (1967). Sob o modelo de Aitken, o estimador de **mínimos quadrados ordinários** permanece BLUE se e somente se existe uma matriz $\mathbf{Q}$ tal que

$$\mathbf{V}\mathbf{X} = \mathbf{X}\mathbf{Q},$$

isto é, se e somente se o espaço-coluna de $\mathbf{V}\mathbf{X}$ está contido no de $\mathbf{X}$ — $\mathcal{C}(\mathbf{V}\mathbf{X}) \subseteq \mathcal{C}(\mathbf{X})$.

Verifiquemos a condição no nosso caso. Como o DCA tem intercepto, $\mathbf{1} \in \mathcal{C}(\mathbf{X})$, e portanto $\mathbf{J}\mathbf{X} = \mathbf{1}(\mathbf{1}'\mathbf{X})$ tem todas as colunas proporcionais a $\mathbf{1}$, logo em $\mathcal{C}(\mathbf{X})$. Daí

$$\mathbf{V}\mathbf{X} = \sigma_u^2\left(\mathbf{X} - \tfrac{1}{N}\mathbf{J}\mathbf{X}\right) \in \mathcal{C}(\mathbf{X}),$$

e a condição de Zyskind **é satisfeita**.

```
trat <- factor(rep(1:3, each = 3))       # t=3 tratamentos, 3 replicas, N=9
X <- model.matrix(~ trat)
V <- diag(9) - matrix(1 / 9, 9, 9)       # sigma_u^2 fatorado (nao altera a condicao)

Q <- qr.solve(X, V %*% X)                # resolve V X = X Q em Q
max(abs(V %*% X - X %*% Q))              # zero numerico => condicao satisfeita
```

```
## [1] 3.885781e-16
```

A conclusão é a que faltava para fechar o argumento, e merece ser dita sem rodeios: **embora os erros de aleatorização sejam correlacionados, podemos proceder como se não fossem**. Não porque a correlação seja pequena ou desprezível, mas porque a estrutura particular que o sorteio induz — simetria composta com covariância negativa constante — é exatamente uma para a qual MQO continua sendo o melhor estimador linear não viesado. A licença é formal, não uma concessão prática.

Vale reter o desenho completo do argumento, porque ele reaparece no Capítulo 4 para blocos (Hinkelmann & Kempthorne, 2008): a aleatorização **gera** o modelo linear (não o supõe), **gera** um erro correlacionado

(não i.i.d.), e **gera**, pela condição de Zyskind, a permissão de analisá-lo com a ferramenta mais simples. As três coisas vêm do mesmo sorteio.

3.2 O delineamento completamente aleatorizado a uma via de classificação

> **Aplicação — Psicologia: tempo de reação sob distração**
> Um pesquisador em psicologia cognitiva quer saber se o tipo de distração afeta o tempo de reação em uma tarefa de decisão simples (pressionar um botão assim que um estímulo aparece na tela). Ele recruta 36 voluntários e sorteia 12 para cada uma de três condições: **nenhuma distração**, **distração sonora** (um ruído constante de fundo) e **distração visual** (elementos piscando na periferia da tela). Cada voluntário realiza a tarefa uma única vez sob sua condição sorteada, e o tempo de reação (em milissegundos) é registrado.

Este é um DCA a uma via de classificação: um único fator (tipo de distração), três níveis, sem blocagem — a atribuição de voluntários às condições é inteiramente aleatória. A **unidade experimental e a unidade amostral coincidem** aqui (um voluntário, uma medição): não há submuestreo — assunto ao qual voltaremos na Seção 3.3 (p. 57).



Layout de um DCA: 36 unidades experimentais dispostas em uma grade puramente ilustrativa (a posição na grade não tem nenhum significado -- não há linha, coluna nem vizinhança relevante), coloridas pelo tratamento sorteado. Note a ausência de qualquer padrão espacial ou de agrupamento: essa é justamente a marca do DCA -- nenhuma restrição além do sorteio -- que o contrasta com os delineamentos em blocos do Capítulo 4.

Figura 3.3: Layout de um DCA: 36 unidades experimentais dispostas em uma grade puramente ilustrativa (a posição na grade não tem nenhum significado – não há linha, coluna nem vizinhança relevante), coloridas pelo tratamento sorteado. Note a ausência de qualquer padrão espacial ou de agrupamento: essa é justamente a marca do DCA – nenhuma restrição além do sorteio – que o contrasta com os delineamentos em blocos do Capítulo 4.

Antes de qualquer ajuste de modelo, vale sempre inspecionar a estrutura completa do dado e deixar explícito, coluna a coluna, o papel de cada variável — o hábito que evita, mais adiante, o erro de pseudorreplicação descrito no Capítulo 1 (Seção 1.2 (p. 5)):

```
glimpse(dados_tr)   # dados_tr foi simulado na Seção 3.1, ao comparar teste F e
        aleatorização
```

```
## Rows: 36
## Columns: 3
## $ sujeito      <int> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17…
## $ condicao     <fct> Nenhuma, Nenhuma, Nenhuma, Nenhuma, Nenhuma, Nenhuma, Nen…
## $ tempo_reacao <dbl> 488.9892, 354.8937, 448.6911, 573.3930, 515.5600, 502.043…
```

Tabela 3.3: Estrutura do dado: papel de cada variável

Variável	Papel
`sujeito`	Identificador da unidade experimental (e, aqui, também da unidade amostral)
`condicao`	Fator de tratamento (3 níveis) — sorteado por `sujeito`
`tempo_reacao`	Resposta — uma única medição por `sujeito`

3.2.1 O modelo estatístico

O modelo de efeitos fixos para um DCA com t tratamentos, cada um com n_i repetições ($i = 1, \dots, t$; $j = 1, \dots, n_i$; $N = \sum_i n_i$), é

$$Y_{ij} = \mu + \tau_i + \varepsilon_{ij}, \qquad \varepsilon_{ij} \overset{iid}{\sim} N(0, \sigma^2),$$

em que μ é a média geral, τ_i é o efeito (fixo, desconhecido) do i-ésimo tratamento, sujeito à restrição $\sum_i n_i \tau_i = 0$ (ou $\sum_i \tau_i = 0$ no caso balanceado) para tornar o modelo identificável, e ε_{ij} é o erro experimental — a soma de tudo aquilo que não é explicado pelo tratamento nem pela média geral (Capítulo 1, Seção 1.3 (p. 7)). A média do i-ésimo tratamento é $\mu_i = \mu + \tau_i$, de modo que o modelo pode ser lido, de forma equivalente, como $Y_{ij} = \mu_i + \varepsilon_{ij}$: cada observação é a média populacional do seu grupo mais um desvio aleatório.

As variáveis aleatórias envolvidas são: Y_{ij} (a resposta observada, aleatória antes da coleta de dados), ε_{ij} (o erro experimental, aleatório e não observável diretamente) — já μ e τ_i são parâmetros fixos e desconhecidos, e t, n_i são constantes de delineamento, fixadas pelo pesquisador antes do experimento.

Os estimadores de mínimos quadrados — que, sob o modelo acima, coincidem com os estimadores de máxima verossimilhança — são as médias amostrais:

$$\hat{\mu}_i = \bar{Y}_{i\cdot} = \frac{1}{n_i} \sum_{j=1}^{n_i} Y_{ij}, \qquad \hat{\sigma}^2 = \mathrm{MS}_E = \frac{1}{N - t} \sum_{i=1}^{t} \sum_{j=1}^{n_i} (Y_{ij} - \bar{Y}_{i\cdot})^2,$$

em que MS_E (quadrado médio do erro) é definido formalmente na próxima seção.

3.2.2 Notação matricial: o DCA como caso particular do modelo linear geral

O Capítulo 2 (Seções 2.7 (p. 30) e 2.7.1 (p. 32)) já anunciava que a decomposição $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$, especializada para um único fator categórico, se tornaria a soma de quadrados entre e dentro de tratamentos da ANOVA. Cumprimos essa promessa aqui, usando a **parametrização de médias de célula**: t colunas indicadoras (sem intercepto), uma por tratamento, de modo que $\boldsymbol{\beta} = (\mu_1, \dots, \mu_t)'$ diretamente — sem a restrição de soma zero que a parametrização $\mu + \tau_i$ da Seção 3.2.1 (p. 49) exige para identificabilidade.

$$\mathbf{X}_{[ij],\, i'} = 1\{i' = i\}, \qquad \mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \qquad \boldsymbol{\varepsilon} \sim N(\mathbf{0}, \sigma^2 \mathbf{I}_N).$$

Para os seis primeiros voluntários do experimento de distração (dois por condição), $\mathbf{X}$ é

```
toy <- dados_tr %>% group_by(condicao) %>% slice_head(n = 2) %>% ungroup()
X_toy <- model.matrix(~ condicao - 1, data = toy)
X_toy
```

```
##   condicaoNenhuma condicaoSonora condicaoVisual
## 1               1              0              0
## 2               1              0              0
## 3               0              1              0
## 4               0              1              0
## 5               0              0              1
## 6               0              0              1
## attr(,"assign")
## [1] 1 1 1
```

```
## attr(,"contrasts")
## attr(,"contrasts")$condicao
## [1] "contr.treatment"
```

Como as colunas de $\mathbf{X}$ são indicadoras de grupos disjuntos, $\mathbf{X}'\mathbf{X} = \text{diag}(n_1, \ldots, n_t)$ — diagonal, sem termos cruzados — e $\mathbf{X}$ tem **posto completo** (t, um por coluna): diferente do caso geral do Capítulo 2, aqui **todo** μ_i (e toda diferença $\mu_i - \mu_k$) é trivialmente estimável, sem exigir contrastes especiais.

```
Xfull <- model.matrix(~ condicao - 1, data = dados_tr)
t(Xfull) %*% Xfull
```

```
##                 condicaoNenhuma condicaoSonora condicaoVisual
## condicaoNenhuma              12             0              0
## condicaoSonora                0            12              0
## condicaoVisual                0             0             12
```

Consequentemente, $\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y} = (\bar{Y}_{1\cdot}, \ldots, \bar{Y}_{t\cdot})'$: o vetor de médias amostrais reaparece, agora como instância direta da fórmula geral de mínimos quadrados, não como um resultado ad hoc.

Como $\mathbf{X}$ tem posto completo, o Teorema de Gauss-Markov (Seção 2.6 (p. 29)) se aplica sem qualificações: $\hat{\boldsymbol{\beta}}$ é o **BLUE** de $\boldsymbol{\beta}$ — em particular, $\hat{\mu}_i = \bar{Y}_{i\cdot}$ é o BLUE de μ_i — e

$$\text{Cov}(\hat{\boldsymbol{\beta}}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1} = \sigma^2\,\text{diag}(1/n_1, \ldots, 1/n_t),$$

exatamente o erro-padrão $\sqrt{\sigma^2/n_i}$ usado nos ICs da próxima seção — agora com justificativa matricial completa em vez de apenas invocada. A dedução detalhada, para este $\mathbf{X}$ específico, é o Exercício 4 da Lista 04.

A matriz de projeção $\mathbf{P}_X = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$ herda a estrutura de blocos de $\mathbf{X}'\mathbf{X}$: é **bloco-diagonal**, com o bloco do grupo i igual a $\frac{1}{n_i}\mathbf{J}_{n_i}$ (a matriz $n_i \times n_i$ de 1's dividida por n_i) — projetar $\mathbf{Y}$ com $\mathbf{P}_X$ substitui cada observação pela média do seu próprio grupo, e nada mais:

```
P_toy <- X_toy %*% solve(t(X_toy) %*% X_toy) %*% t(X_toy)
round(P_toy, 3)
```

```
##     1   2   3   4   5   6
## 1 0.5 0.5 0.0 0.0 0.0 0.0
## 2 0.5 0.5 0.0 0.0 0.0 0.0
## 3 0.0 0.0 0.5 0.5 0.0 0.0
## 4 0.0 0.0 0.5 0.5 0.0 0.0
## 5 0.0 0.0 0.0 0.0 0.5 0.5
## 6 0.0 0.0 0.0 0.0 0.5 0.5
```

Com $\mathbf{P}_X$ em mãos, a decomposição $\mathbf{M} = (\mathbf{P}_X - \frac{1}{N}\mathbf{J}) + (\mathbf{I}_N - \mathbf{P}_X)$ do Capítulo 2 (Seção 2.7.1 (p. 32)) — válida porque o espaço-coluna de $\mathbf{X}$ contém $\mathbf{1}$ (a soma das t colunas indicadoras é o vetor de uns) — dá, sem nenhuma soma indexada por i, j,

$$\underbrace{\mathbf{Y}'\mathbf{M}\mathbf{Y}}_{SQ_{\text{Total}}} = \underbrace{\mathbf{Y}'\left(\mathbf{P}_X - \tfrac{1}{N}\mathbf{J}\right)\mathbf{Y}}_{SQ_{\text{Trat}}} + \underbrace{\mathbf{Y}'(\mathbf{I}_N - \mathbf{P}_X)\mathbf{Y}}_{SQ_E}.$$

Substituindo a forma em blocos de $\mathbf{P}_X$, essas duas formas quadráticas se reduzem exatamente às somas indexadas $\sum_i n_i(\bar{Y}_{i\cdot} - \bar{Y}_{\cdot\cdot})^2$ e $\sum_{i,j}(Y_{ij} - \bar{Y}_{i\cdot})^2$ da Seção 3.2.5 (p. 52) — a tabela de ANOVA não é

maquinaria nova, é o Teorema de formas quadráticas idempotentes do Capítulo 2 (Seção 2.10 (p. 37)) aplicado às matrizes $\mathbf{P}_X - \frac{1}{N}\mathbf{J}$ (idempotente, posto $t-1$) e $\mathbf{I}_N - \mathbf{P}_X$ (idempotente, posto $N-t$). As duas **formas quadráticas** correspondentes são independentes — as matrizes, sendo determinísticas, não têm do que ser independentes; o que o resultado de Craig garante é que $\mathbf{A}_1\mathbf{A}_2 = \mathbf{0}$ implica independência das formas $\mathbf{Y}'\mathbf{A}_1\mathbf{Y}$ e $\mathbf{Y}'\mathbf{A}_2\mathbf{Y}$ sob normalidade, e aqui $(\mathbf{P}_X - \frac{1}{N}\mathbf{J})(\mathbf{I}_N - \mathbf{P}_X) = \mathbf{0}$. Daí decorre diretamente a distribuição $F_{t-1,N-t}$ sob H_0 e a não centralidade λ sob H_1 da Seção 3.2.5 (p. 52): nenhuma suposição adicional além das já feitas no Capítulo 2.

3.2.3 Resultados potenciais e o estimando causal

O que significa, formalmente, “o tipo de distração afeta o tempo de reação”? Até aqui, $\mu_i - \mu_k$ é apenas um contraste entre parâmetros do modelo — para interpretá-lo como um **efeito causal**, precisamos do arcabouço de resultados potenciais de Neyman e Rubin (Imbens & Rubin, 2015; Rubin, 1974; Splawa-Neyman, 1990).

Para cada uma das N unidades experimentais $u = 1, \dots, N$ da população em estudo, postulamos t **resultados potenciais** $Y_u(1), \dots, Y_u(t)$ — um por tratamento —, valores fixos (não aleatórios) que existiriam se u recebesse cada um dos tratamentos. Dois pressupostos, reunidos sob o nome **SUTVA** (*stable unit treatment value assumption*) (Imbens & Rubin, 2015), tornam $Y_u(i)$ bem definido:

1. **Sem interferência:** o resultado potencial de u depende apenas do tratamento atribuído a u, não do que é atribuído às demais unidades (um voluntário sob “nenhuma distração” não é afetado pela condição sorteada para outro voluntário).
2. **Sem versões ocultas de tratamento:** “distração sonora” significa a mesma intervenção, consistente, para toda unidade que a recebe.

Sob SUTVA, o resultado **observado** é $Y_u = Y_u(T_u)$, em que $T_u \in \{1, \dots, t\}$ é o tratamento efetivamente sorteado para u — apenas um dos t resultados potenciais de cada unidade é jamais observável; os demais permanecem contrafactuais. O **estimando causal** de interesse, para dois tratamentos i, k, é o efeito médio de tratamento na população finita do experimento,

$$\tau_{i,k} = \frac{1}{N}\sum_{u=1}^{N}\big[Y_u(i) - Y_u(k)\big].$$

Proposição (Neyman, 1923/1990). Em um DCA — N unidades, n_i sorteadas para o tratamento i por amostragem aleatória simples sem reposição, para cada i —, a diferença de médias observadas $\bar{Y}_i^{\text{obs}} - \bar{Y}_k^{\text{obs}}$ é **não viesada** para $\tau_{i,k}$, em que a esperança é tomada sobre o mecanismo de aleatorização, mantendo os $Y_u(i)$ fixos.

Demonstração. Seja $R_{u,i} = \mathbb{1}\{T_u = i\}$. O mecanismo de aleatorização completa garante, por simetria, que toda unidade u tem a mesma chance marginal de cair no grupo i: $P(R_{u,i} = 1) = n_i/N$, para todo u — essa é a única propriedade probabilística de que precisamos, e ela não depende de $Y_u(i)$ de forma alguma. Como $Y_u^{\text{obs}} = Y_u(i)$ quando $R_{u,i} = 1$,

$$\bar{Y}_i^{\text{obs}} = \frac{1}{n_i}\sum_{u=1}^{N} R_{u,i}\,Y_u(i) \;\Longrightarrow\; E\big[\bar{Y}_i^{\text{obs}}\big] = \frac{1}{n_i}\sum_{u=1}^{N} E[R_{u,i}]\,Y_u(i) = \frac{1}{n_i}\sum_{u=1}^{N}\frac{n_i}{N}\,Y_u(i) = \frac{1}{N}\sum_{u=1}^{N} Y_u(i),$$

pela linearidade da esperança — os $Y_u(i)$ são constantes, só $R_{u,i}$ é aleatório. O mesmo argumento vale para o tratamento k, e subtraindo,

$$E\big[\bar{Y}_i^{\text{obs}} - \bar{Y}_k^{\text{obs}}\big] = \frac{1}{N}\sum_u Y_u(i) - \frac{1}{N}\sum_u Y_u(k) = \tau_{i,k}. \qquad \blacksquare$$

Note o que a demonstração **não** usa: nenhuma suposição sobre a distribuição dos $Y_u(i)$, nenhuma normalidade, nenhum modelo $Y_{ij} = \mu + \tau_i + \varepsilon_{ij}$. A validade do estimador $\bar{Y}_{i\cdot} - \bar{Y}_{k\cdot}$ para o efeito causal médio vem inteiramente do **mecanismo físico de aleatorização** — o mesmo mecanismo que justificou o teste de aleatorização da Seção 3.1 (p. 41). Os dois resultados são complementares: o argumento de Fisher testa a hipótese nula "aguda" $Y_u(i) = Y_u(k)$ para *toda* unidade u (nenhum efeito, em nenhum caso), enquanto o argumento de Neyman estima e testa a hipótese "fraca" $\tau_{i,k} = 0$ (nenhum efeito, *em média*). O que o modelo normal-linear $Y_{ij} = \mu + \tau_i + \varepsilon_{ij}$ acrescenta a essa base puramente aleatorizada não é a validade do ponto estimado — já garantida por Neyman — mas sim distribuições exatas em amostra finita (t, F) para intervalos de confiança e testes, como visto na Seção 3.2.4 (p. 52) a seguir.

3.2.4 Estimação e intervalos de confiança

Sob o modelo normal, $\bar{Y}_{i\cdot} \sim N\big(\mu_i, \sigma^2/n_i\big)$ e $(N-t)\,\mathrm{MS}_E/\sigma^2 \sim \chi^2_{N-t}$, independente de todas as $\bar{Y}_{i\cdot}$. Isso dá origem a dois intervalos de confiança fundamentais, ambos baseados na distribuição t de Student com $N - t$ graus de liberdade (os graus de liberdade do erro).

IC para a média de um tratamento. Um intervalo de $100(1-\alpha)\%$ de confiança para μ_i é

$$\bar{Y}_{i\cdot} \;\pm\; t_{\alpha/2,\,N-t}\sqrt{\frac{\mathrm{MS}_E}{n_i}}.$$

IC para a diferença entre duas médias de tratamento. Um intervalo de $100(1-\alpha)\%$ de confiança para $\mu_i - \mu_k$ ($i \neq k$) é

$$(\bar{Y}_{i\cdot} - \bar{Y}_{k\cdot}) \;\pm\; t_{\alpha/2,\,N-t}\sqrt{\mathrm{MS}_E\left(\frac{1}{n_i} + \frac{1}{n_k}\right)}.$$

Note que os dois intervalos usam o mesmo MS_E — a *combinação* (pooling) da variabilidade de todos os t grupos para estimar um único σ^2 comum é o que torna a ANOVA mais eficiente do que fazer t estimativas de variância separadas, uma por grupo, desde que a suposição de variância comum (Seção 3.5 (p. 68)) seja razoável.

3.2.5 A tabela de análise de variância

A ANOVA decompõe a soma de quadrados total em uma parte atribuível ao tratamento e uma parte residual (erro):

$$\underbrace{\sum_{i,j}(Y_{ij} - \bar{Y}_{\cdot\cdot})^2}_{SQ_{\text{Total}}} = \underbrace{\sum_{i} n_i(\bar{Y}_{i\cdot} - \bar{Y}_{\cdot\cdot})^2}_{SQ_{\text{Trat}}} + \underbrace{\sum_{i,j}(Y_{ij} - \bar{Y}_{i\cdot})^2}_{SQ_E}.$$

Tabela 3.4: Tabela de análise de variância do DCA a uma via

Fonte de variação	G.l.	Soma de quadrados	Quadrado médio	F
Tratamento	$t-1$	SQ_{Trat}	$MS_{\text{Trat}} = SQ_{\text{Trat}}/(t-1)$	MS_{Trat}/MS_E
Erro	$N-t$	SQ_E	$MS_E = SQ_E/(N-t)$	
Total	$N-1$	SQ_{Total}		

A coluna de graus de liberdade da tabela acima é, em miniatura, o diagrama de Hasse de um único fator já apresentado no Capítulo 2 (Seção 2.2 (p. 17)): uma cadeia de três nós Média $\prec$ Tratamento $\prec$ Erro. Vale a pena vê-lo com os números concretos deste próprio experimento ($t = 3$ condições, $n = 12$ voluntários por condição, $N = 36$), em vez de reler apenas o exemplo genérico do capítulo anterior:

> **Uso do R** — diagrama de Hasse do DCA de distração

```
nos_tr <- tibble(
  termo   = c("Média", "Condição", "Erro"),
  classes = c(1, 3, 36)            # t=3 condicoes; N=36 voluntarios
)
arestas_tr <- tibble(de = c("Média", "Condição"), para = c("Condição", "Erro"))

knitr::include_graphics(
  hasse_svg(nos_tr, arestas_tr,
            arquivo = "figuras/hasse/dca-distracao.svg",
            titulo  = "DCA de distração: t=3, n=12 (N=36)")
)
```

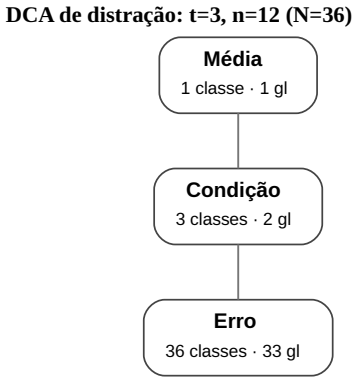


Figura 3.4: Diagrama de Hasse do DCA de distração e tempo de reação: t=3 condições, n=12 voluntários por condição (N=36). A mesma cadeia de três nós do exemplo genérico do Capítulo 2 (Seção sobre diagramas de Hasse), agora com os graus de liberdade deste experimento.

Os três nós somam $1 + 2 + 33 = 36 = N$, confirmando a leitura da tabela: nenhuma outra fonte de variação estrutural além da condição experimental, exatamente como no exemplo genérico do Capítulo 2 — a diferença entre os dois diagramas é só de escala ($t = 3$ contra $t = 4$), não de forma, porque os dois são o mesmo delineamento (um único fator, sem blocagem nem aninhamento).

Sob $H_0 : \tau_1 = \cdots = \tau_t = 0$ (nenhum efeito de tratamento), $F = MS_{\text{Trat}}/MS_E \sim F_{t-1,\,N-t}$; rejeita-se H_0 para valores grandes de F. Quando H_0 é falsa, F segue uma distribuição F **não central**, cujo parâmetro de não centralidade é

$$\lambda = \frac{\sum_i n_i \tau_i^2}{\sigma^2} \overset{\text{balanceado}}{=} N f^2,$$

em que f é o tamanho de efeito de Cohen. Quanto maiores os efeitos de tratamento em relação ao erro, maior λ e maior o poder do teste.

Convém distinguir λ de uma segunda quantidade que aparece na literatura clássica e é fácil de confundir com ele:

$$\Phi^2 = \frac{\lambda}{t} = \frac{\sum_i n_i \tau_i^2}{t\,\sigma^2} \overset{\text{balanceado}}{=} n f^2.$$

Φ^2 é a grandeza auxiliar usada nas **curvas características de operação** (curvas OC) de Montgomery (2017), tabuladas para leitura gráfica do poder; **não** é o parâmetro de não centralidade de distribuição alguma. A distinção é prática, não pedante: funções como `pwr::pwr.anova.test()` e `stats::pf(..., ncp = )` esperam $\lambda = N f^2$, de modo que usar Φ^2 no lugar de λ subestima o poder por um fator t. É λ que será a chave da Seção 3.2.6 (p. 55).

Uso do R — ajustando o DCA e obtendo IC's

```
modelo_tr <- aov(tempo_reacao ~ condicao, data = dados_tr)
summary(modelo_tr)
```

```
##             Df Sum Sq Mean Sq F value  Pr(>F)
## condicao     2  31366   15683   5.872 0.00658 **
## Residuals   33  88133    2671
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
MS_E  <- summary(modelo_tr)[[1]][["Mean Sq"]][2]
df_E  <- summary(modelo_tr)[[1]][["Df"]][2]
t_crit <- qt(0.975, df_E)

dados_tr %>%
  group_by(condicao) %>%
  summarise(media = mean(tempo_reacao), n = n(), .groups = "drop") %>%
  mutate(
    ep  = sqrt(MS_E / n),
    lwr = media - t_crit * ep,
    upr = media + t_crit * ep
  ) %>%
  kable(digits = 1, caption = "Médias por condição com IC de 95% (pooled MS_E)") %>%
  kable_styling(full_width = FALSE)
```

Tabela 3.5: Médias por condição com IC de 95% (pooled MS_E)

condicao	media	n	ep	lwr	upr
Nenhuma	494.0	12	14.9	463.7	524.4
Sonora	514.4	12	14.9	484.1	544.8
Visual	564.3	12	14.9	534.0	594.7

O teste F rejeita H_0 ($p = 0.0066$): o tipo de distração afeta o tempo de reação médio. Os intervalos de confiança individuais mostram que a condição visual se destaca das demais, um ponto que será formalizado com comparações múltiplas (próxima seção do capítulo, além do escopo deste texto).



Médias de tempo de reação por condição, com intervalos de confiança de 95% construídos a partir do quadrado médio do erro (QME) comum às três condições.

Figura 3.5: Médias de tempo de reação por condição, com intervalos de confiança de 95% construídos a partir do quadrado médio do erro (QME) comum às três condições.

O gráfico traduz visualmente a tabela anterior: os três intervalos usam a mesma largura, porque todos compartilham o mesmo QME (o erro-padrão pooled da ANOVA, não um erro-padrão calculado grupo a grupo), o que é, por si só, a suposição de variância homogênea em ação. A condição visual se destaca claramente das demais — seu intervalo não se sobrepõe ao das outras duas —, enquanto os intervalos de "Nenhuma" e "Sonora" se tocam, sugerindo que a diferença entre elas é mais tênue. Essa leitura visual antecipa exatamente o que os procedimentos de comparação múltipla da Seção 3.6 (p. 71) vão formalizar com rigor estatístico.

3.2.6 Número de réplicas necessário

Quantas unidades experimentais por tratamento são necessárias? A resposta depende de três escolhas do pesquisador — o nível de significância α, o poder desejado $1 - \beta$, e o **tamanho de efeito** mínimo que se quer ter boa chance de detectar — e de uma quantidade que raramente é conhecida com exatidão antes do experimento: σ^2, normalmente estimada a partir de um estudo piloto ou da literatura.

Uma forma conveniente de expressar o tamanho de efeito para t grupos é o f **de Cohen**,

$$f = \frac{\sigma_\mu}{\sigma}, \qquad \sigma_\mu^2 = \frac{1}{t}\sum_{i}(\mu_i - \bar{\mu})^2,$$

isto é, o desvio-padrão das médias populacionais dividido pelo desvio-padrão comum dentro dos grupos — quanto mais as médias se afastam entre si em relação ao ruído, maior f. A relação com o parâmetro de não centralidade da Seção 3.2.5 (p. 52) é direta: $\lambda = N f^2 = n\,t\,f^2$ no caso balanceado (e a grandeza das curvas OC é $\Phi^2 = \lambda / t = n f^2$). Dado f, α e o poder desejado, o número de réplicas n por grupo é obtido numericamente (não há fórmula fechada, pois a distribuição F não central não se inverte analiticamente).

> **Uso do R** — número de réplicas via $pwr::pwr.anova.test()$

```
medias_grupo <- c(494, 514, 564)     # estimativa piloto das médias por condição
sigma_piloto <- sqrt(MS_E)           # estimativa piloto do desvio-padrão comum

f_cohen <- sqrt(mean((medias_grupo - mean(medias_grupo))^2)) / sigma_piloto
f_cohen
```

```
## [1] 0.5696575
```

```
pwr::pwr.anova.test(k = 3, f = f_cohen, sig.level = 0.05, power = 0.80)
```

```
##
##      Balanced one-way analysis of variance power calculation
```

```
##
##               k = 3
##               n = 10.95974
##               f = 0.5696575
##       sig.level = 0.05
##           power = 0.8
##
## NOTE: n is number in each group
```

Com o tamanho de efeito observado neste estudo ($f \approx 0.57$), seriam necessárias cerca de 11 unidades por grupo para poder de 80% — as 12 efetivamente usadas já garantem poder ligeiramente superior a 80%. Na prática, essa conta deve ser feita **antes** da coleta de dados, com f estimado a partir de um piloto, da literatura, ou de uma diferença mínima de interesse prático especificada pelo próprio pesquisador (por exemplo, “uma diferença de 40 ms ou mais entre condições é relevante clinicamente”).

3.2.7 Um segundo exemplo, com dado real: fertilizante em feijão

O exemplo de distração e tempo de reação, acima, foi simulado deliberadamente — controlar o “efeito verdadeiro” permite verificar cada passo da álgebra contra um valor conhecido. Fecha-se a seção com a mesma maquinaria aplicada a um dado genuinamente real, sem efeito verdadeiro conhecido de antemão.

> **Aplicação — Agricultura: dose de fertilizante na produção de feijão**
> Um agrônomo compara quatro fertilizantes (F1–F4) quanto à produção de feijão. Vinte parcelas de terra, previamente homogeneizadas quanto a exposição solar e tipo de solo, são sorteadas em quatro grupos de cinco (**UE = parcela**), cada grupo recebendo um dos quatro fertilizantes. Produção (kg) é medida ao final da colheita.

```
feijao <- read_csv("data/feijao.csv", show_col_types = FALSE) %>%
  mutate(Fertilizante = factor(Fertilizante, labels = paste0("F", 1:4)))
glimpse(feijao)
```

```
## Rows: 20
## Columns: 3
## $ Parcela      <dbl> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17…
## $ Fertilizante <fct> F1, F1, F4, F1, F2, F3, F4, F4, F3, F1, F2, F3, F3, F3, F…
## $ Producao     <dbl> 5.91, 3.76, 8.31, 4.04, 6.81, 1.69, 8.46, 8.51, 5.69, 5.3…
```

```
mod_feijao <- aov(Producao ~ Fertilizante, data = feijao)
summary(mod_feijao)
```

```
##              Df Sum Sq Mean Sq F value   Pr(>F)
## Fertilizante  3  54.74  18.248   9.209 0.000897 ***
## Residuals    16  31.70   1.982
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```



Produção de feijão por fertilizante: pontos individuais (parcelas) e média por grupo com intervalo de confiança de 95%, construído a partir do QME comum.

Figura 3.6: Produção de feijão por fertilizante: pontos individuais (parcelas) e média por grupo com intervalo de confiança de 95%, construído a partir do QME comum.

O teste F rejeita H_0 ($p < 0{,}001$): há diferença real entre fertilizantes. F4 (média 9.2 kg) supera claramente F1 (média 5 kg), com F2 e F3 numa faixa intermediária — leitura visual confirmada pelos intervalos de confiança do gráfico, que já antecipa o que uma comparação múltipla (Seção 3.7 (p. 76)) formalizaria.

Honestidade estatística: ao contrário do exemplo simulado, aqui não há garantia de que os pressupostos do modelo se sustentam — e de fato não se sustentam perfeitamente. O teste de Shapiro-Wilk nos resíduos dá $p \approx 0.046$ — no limiar de $0{,}05$, uma normalidade duvidosa com só 20 observações. É exatamente o tipo de situação real que a Seção 3.5 (p. 68), a seguir, ensina a diagnosticar e tratar (em vez de ignorar).

3.3 Submuestreo em um DCA

Retomamos aqui, com rigor, a distinção entre unidade experimental (UE) e unidade amostral introduzida no Capítulo 1 (Seção 1.2 (p. 5)): quando uma UE é medida mais de uma vez — várias tentativas de um mesmo sujeito, vários peixes do mesmo aquário, várias leituras do mesmo lote — dizemos que há **submuestreo**. As submuestras não são réplicas do tratamento: são réplicas da *medição* dentro de uma única aplicação do tratamento, e carregam uma fonte de variação a mais, que precisa ser modelada separadamente.



Três formas de organizar o mesmo experimento com três tratamentos (rótulos Trat. 1-3), adaptado de Hinkelmann e Kempthorne (1994). Situação Experimental 1 (esquerda): uma única caixa de 4 vasos por tratamento -- a caixa é a UE, cada vaso é uma submuestra, e só 3 UEs existem em todo o experimento (uma por tratamento). Situação Experimental 2 (centro): cada vaso é sorteado individualmente -- UE e unidade amostral coincidem, 12 UEs verdadeiras, sem submuestreo. Situação Experimental 3 (direita): duas caixas de 2 vasos por tratamento -- submuestreo como na Situação 1, mas agora com 2 UEs por tratamento em vez de 1.

Figura 3.7: Três formas de organizar o mesmo experimento com três tratamentos (rótulos Trat. 1-3), adaptado de Hinkelmann e Kempthorne (1994). Situação Experimental 1 (esquerda): uma única caixa de 4 vasos por tratamento – a caixa é a UE, cada vaso é uma submuestra, e só 3 UEs existem em todo o experimento (uma por tratamento). Situação Experimental 2 (centro): cada vaso é sorteado individualmente – UE e unidade amostral coincidem, 12 UEs verdadeiras, sem submuestreo. Situação Experimental 3 (direita): duas caixas de 2 vasos por tratamento – submuestreo como na Situação 1, mas agora com 2 UEs por tratamento em vez de 1.



Três formas de organizar o mesmo experimento com três tratamentos (rótulos Trat. 1-3), adaptado de Hinkelmann e Kempthorne (1994). Situação Experimental 1 (esquerda): uma única caixa de 4 vasos por tratamento -- a caixa é a UE, cada vaso é uma submuestra, e só 3 UEs existem em todo o experimento (uma por tratamento). Situação Experimental 2 (centro): cada vaso é sorteado individualmente -- UE e unidade amostral coincidem, 12 UEs verdadeiras, sem submuestreo. Situação Experimental 3 (direita): duas caixas de 2 vasos por tratamento -- submuestreo como na Situação 1, mas agora com 2 UEs por tratamento em vez de 1.

Figura 3.8: Três formas de organizar o mesmo experimento com três tratamentos (rótulos Trat. 1-3), adaptado de Hinkelmann e Kempthorne (1994). Situação Experimental 1 (esquerda): uma única caixa de 4 vasos por tratamento – a caixa é a UE, cada vaso é uma submuestra, e só 3 UEs existem em todo o experimento (uma por tratamento). Situação Experimental 2 (centro): cada vaso é sorteado individualmente – UE e unidade amostral coincidem, 12 UEs verdadeiras, sem submuestreo. Situação Experimental 3 (direita): duas caixas de 2 vasos por tratamento – submuestreo como na Situação 1, mas agora com 2 UEs por tratamento em vez de 1.



Três formas de organizar o mesmo experimento com três tratamentos (rótulos Trat. 1-3), adaptado de Hinkelmann e Kempthorne (1994). Situação Experimental 1 (esquerda): uma única caixa de 4 vasos por tratamento -- a caixa é a UE, cada vaso é uma submuestra, e só 3 UEs existem em todo o experimento (uma por tratamento). Situação Experimental 2 (centro): cada vaso é sorteado individualmente -- UE e unidade amostral coincidem, 12 UEs verdadeiras, sem submuestreo. Situação Experimental 3 (direita): duas caixas de 2 vasos por tratamento -- submuestreo como na Situação 1, mas agora com 2 UEs por tratamento em vez de 1.

Figura 3.9: Três formas de organizar o mesmo experimento com três tratamentos (rótulos Trat. 1-3), adaptado de Hinkelmann e Kempthorne (1994). Situação Experimental 1 (esquerda): uma única caixa de 4 vasos por tratamento – a caixa é a UE, cada vaso é uma submuestra, e só 3 UEs existem em todo o experimento (uma por tratamento). Situação Experimental 2 (centro): cada vaso é sorteado individualmente – UE e unidade amostral coincidem, 12 UEs verdadeiras, sem submuestreo. Situação Experimental 3 (direita): duas caixas de 2 vasos por tratamento – submuestreo como na Situação 1, mas agora com 2 UEs por tratamento em vez de 1.

Os três diagramas mostram o mesmo número de plantas (12 no total, três tratamentos) organizadas de formas distintas. Na Situação 1, o sorteio de tratamento ocorre **caixa a caixa**: uma vez que uma caixa recebe, digamos, o Tratamento 1, todos os quatro vasos dentro dela recebem necessariamente o mesmo tratamento — a caixa é a UE, e as quatro plantas dentro dela são submuestras da mesma UE. Como só existe **uma** caixa por tratamento, há apenas **3 UEs em todo o experimento** — uma por tratamento, não três por tratamento —, e isso é fatal: com uma única UE por tratamento, não sobra nenhum grau de liberdade para estimar o erro experimental *entre* UEs, e o efeito do tratamento fica completamente confundido com qualquer peculiaridade daquela caixa específica (Capítulo 1, Seção 1.3 (p. 7)). Na Situação 2, cada vaso é sorteado **individualmente**: a moeda do desenho aleatorizado é lançada 12 vezes, uma por vaso, e UE e unidade amostral coincidem — não há submuestreo, e as 12 observações são, de fato, 12 réplicas independentes do sorteio de tratamento, com $12 - 3 = 9$ graus de liberdade de erro. A Situação 3 corrige o problema fatal da Situação 1 sem abrir mão do submuestreo: **duas** caixas por tratamento (não uma) dão 2 UEs por tratamento — poucas, mas suficientes para estimar o erro experimental entre caixas, com $2 \times 3 - 3 = 3$ graus de liberdade — a mesma estrutura, em miniatura, do exemplo real da tilápia a seguir (4 probióticos, 5 aquários cada). A diferença entre as três situações não aparece em nenhuma estatística descritiva calculada ingenuamente sobre os 12 valores brutos — só se torna visível quando se pergunta, explicitamente, “quantas vezes o mecanismo de aleatorização foi acionado?” — e é exatamente essa pergunta que a distinção UE/unidade amostral formaliza.

> **Aplicação — Agricultura: probiótico e ganho de peso em tilápia**
> Um estudo de aquicultura testa quatro formulações de probiótico (dados `mojarra.csv`) quanto ao ganho de peso de tilápias entre o início do experimento e o dia 45. O delineamento usa 20 aquários, sorteados 5 para cada probiótico — o **aquário é a unidade experimental**, pois é nele que o probiótico é aplicado (misturado à ração de todo o aquário) e não é possível sortear o probiótico peixe a peixe dentro de um mesmo aquário. Cada aquário contém, em geral, 5 peixes medidos individualmente — o **peixe é a unidade amostral** (submuestra).

3.3.1 O modelo com dois níveis de erro

Com t tratamentos, r unidades experimentais (UEs) por tratamento e q unidades amostrais (submuestras) por UE, o modelo passa a ter **dois** termos de erro:

$$Y_{ijk} = \mu + \tau_i + \delta_{ij} + \varepsilon_{ijk},$$

$$i = 1, \ldots, t; \quad j = 1, \ldots, r; \quad k = 1, \ldots, q,$$

em que $\delta_{ij} \overset{iid}{\sim} N(0, \sigma^2_\delta)$ é o **erro experimental** (o desvio específico da UE j dentro do tratamento i — por exemplo, algo peculiar daquele aquário, além do efeito do probiótico) e $\varepsilon_{ijk} \overset{iid}{\sim} N(0, \sigma^2_\varepsilon)$ é o **erro de amostragem** (o desvio específico da submuestra k dentro da UE — a variação entre peixes de um mesmo aquário), independente de δ_{ij}. A variância total de uma observação individual é $\text{Var}(Y_{ijk}) = \sigma^2_\delta + \sigma^2_\varepsilon$, mas o que importa para comparar tratamentos é apenas σ^2_δ: aumentar q (mais peixes por aquário) nunca reduz a incerteza sobre o efeito do tratamento além de um certo ponto, porque não gera novas UEs.

Em notação matricial, o submuestreo quebra a suposição $\text{Cov}(\boldsymbol{\varepsilon}) = \sigma^2 \mathbf{I}_N$ do Capítulo 2 (Seção 2.6 (p. 29)): empilhando as $N = trq$ observações, $\text{Cov}(\mathbf{Y}) = \mathbf{V} = \sigma^2_\delta \, \mathbf{Z}\mathbf{Z}' + \sigma^2_\varepsilon \mathbf{I}_N$, em que $\mathbf{Z}$ é a matriz $N \times tr$ de indicadores de UE ($Z_{[ijk],\, i'j'} = 1\{i = i', j = j'\}$). $\mathbf{V}$ tem estrutura de blocos de **simetria composta**: dentro de uma mesma UE, $\text{Cov}(Y_{ijk}, Y_{ijk'}) = \sigma^2_\delta$ ($k \neq k'$); entre UEs diferentes, covariância nula. Um $\mathbf{X}$ com $\text{Cov}(\mathbf{Y}) = \sigma^2 \mathbf{I}$ deixa de bastar — é exatamente essa estrutura de $\mathbf{V}$ que faz do DCA com submuestreo um caso particular de **modelo linear misto**, ajustável de forma exata (inclusive sob desbalanceamento) por `nlme::lme()` ou `lme4::lmer()`, embora a ANOVA clássica com `Error()` usada adiante já recupere o teste correto no caso balanceado.

O que acontece se o número de submuestras por UE **não** for o mesmo em toda UE — um aquário perdeu um peixe, por exemplo? A condição de Zyskind (Seção 3.1.2.5 (p. 47)) deixa de se verificar, e a ANOVA clássica com `Error()` deixa de ter uma base algébrica sólida — o R, nesse caso, geralmente avisa:

> **Uso do R** — o sintoma de perder o balanceamento: `aov()` quebra, `lmer()` não

```
set.seed(77)
q_desigual <- c(4, 4, 4, 4, 4, 2)   # uma UE com 2 submuestras em vez de 4
delta_ue   <- rnorm(6, 0, 1.7)
dados_desbal <- map_dfr(1:6, function(j) {
  tibble(ue = factor(j), trat = factor(rep(1:3, each = 2)[j]),
         y  = 10 + 2 * rep(1:3, each = 2)[j] + delta_ue[j] + rnorm(q_desigual[j], 0,
        0.9))
})
aov(y ~ trat + Error(trat:ue), data = dados_desbal)   # emite o aviso abaixo
```

```
## Warning in aov(y ~ trat + Error(trat:ue), data = dados_desbal): Error() model
## is singular
```

```
##
## Call:
## aov(formula = y ~ trat + Error(trat:ue), data = dados_desbal)
##
## Grand Mean: 14.76871
##
## Stratum 1: trat:ue
##
## Terms:
##                       trat Residuals
## Sum of Squares  87.37902   8.45898
## Deg. of Freedom        2         3
##
## Residual standard error: 1.679184
## Estimated effects may be unbalanced
##
```

```
## Stratum 2: Within
##
## Terms:
##                 Residuals
## Sum of Squares   15.53889
## Deg. of Freedom        16
##
## Residual standard error: 0.9854851
```

O aviso **“Error() model is singular”** não é cosmético: é o `aov()` avisando que a separação em estratos experimental/amostral, que a condição de Zyskind garante no caso balanceado, não fecha aqui. `lme4::lmer(y ~ trat + (1 | ue), data = dados_desbal)` estima os dois componentes de variância por máxima verossimilhança restrita sem exigir essa condição — o preço é que os graus de liberdade do teste F deixam de ter fórmula fechada, exigindo uma aproximação (Satterthwaite ou Kenward-Roger) fora do escopo deste livro.

3.3.2 O diagrama de Hasse do submuestreo: aninhamento em duas camadas

A estrutura de dois erros descrita acima tem um retrato imediato no diagrama de Hasse introduzido no Capítulo 2 (Seção 2.2 (p. 17)). O DCA simples é uma cadeia de três nós — Média $\prec$ Tratamento $\prec$ Erro (Figura 2.1 do Capítulo 2). O submuestreo insere um quarto elo *abaixo* do erro experimental: a unidade experimental (aquário) é, ela própria, refinada pela unidade amostral (peixe) dentro dela — exatamente o padrão de **aninhamento** que a Seção 2.2 (p. 17) definiu como “uma cadeia direta de arestas, sem ramificação”.

> **Uso do R** — diagrama de Hasse do DCA com submuestreo

```
nos_sub <- tibble(
  termo   = c("Média", "Tratamento", "UE (aquário)", "Unidade amostral (peixe)"),
  classes = c(1, 4, 4 * 5, 4 * 5 * 5)  # t=4; 20 aquarios; N=100 peixes
)
arestas_sub <- tibble(
  de   = c("Média", "Tratamento", "UE (aquário)"),
  para = c("Tratamento", "UE (aquário)", "Unidade amostral (peixe)")
)

knitr::include_graphics(
  hasse_svg(nos_sub, arestas_sub,
            arquivo = "figuras/hasse/dca-submuestreo.svg",
            titulo  = "DCA com submuestreo: t=4, r=5, q=5 (N=100)")
)
```

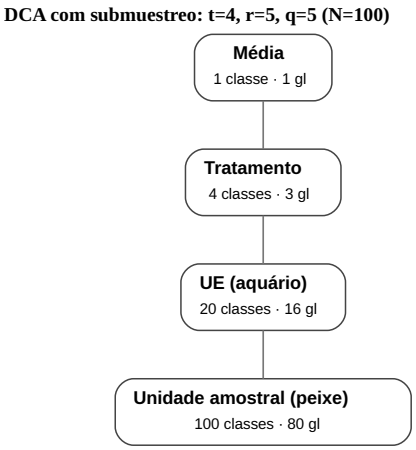


Figura 3.10: Diagrama de Hasse do DCA com submuestreo, exemplo mojarra: t=4 probióticos, r=5 aquários (UEs) por probiótico, q=5 peixes (unidades amostrais) por aquário, N=100. Uma cadeia de quatro nós – Média, Tratamento, UE e unidade amostral – em vez dos três nós do DCA simples do Capítulo 2 (seção sobre diagramas de Hasse): o submuestreo insere um quarto elo, aninhando a amostragem de peixes dentro de cada aquário dentro de cada probiótico.

Os graus de liberdade dos quatro nós somam exatamente $N = trq = 4 \times 5 \times 5 = 100$: 1 (Média) $+ 3$ (Tratamento, $t-1$) $+ 16$ (UE dentro de tratamento, $t(r-1)$) $+ 80$ (unidade amostral dentro de UE, $tr(q-1)$) $= 100$ — os mesmos dois últimos números que aparecem, com outros nomes (“erro experimental” e “erro de amostragem”), na tabela de ANOVA da seção seguinte. O diagrama não acrescenta informação nova à tabela; torna **visível** algo que a tabela só codifica em símbolos: os dois erros do modelo não são dois termos soltos e paralelos, são dois elos sucessivos de uma mesma cadeia de refinamento, e o segundo só existe *dentro* do primeiro.

Essa dupla estrutura de aninhamento é precisamente o que a Seção 1.4.6 (p. 15) do Capítulo 1 antecipava ao introduzir o elo entre teoria de amostragem e planejamento de experimentos: a atribuição do probiótico acontece uma única vez, no aquário (a unidade experimental, sorteada por aleatorização de tratamento); mas decidir **quantos e quais** peixes medir dentro de cada aquário é um problema de amostragem — literalmente, qual subconjunto de peixes daquele aquário entra na base de dados — aninhado *dentro* do desenho experimental já definido. O diagrama de Hasse deixa essa dupla camada impossível de confundir: os dois nós superiores (Média, Tratamento) pertencem à lógica de atribuição aleatória de Neyman-Rubin formalizada no Capítulo 1; o nó de UE e o nó de unidade amostral, abaixo dele, pertencem à lógica de amostragem de Kish — e é exatamente por isso que aumentar q (mais amostragem dentro da UE) nunca substitui aumentar r (mais aleatorização de tratamento), como a Seção 3.3.4 (p. 63), adiante, quantifica.

3.3.3 ANOVA com submuestreo

A soma de quadrados total se decompõe agora em três partes, não duas:

Tabela 3.6: ANOVA do DCA com submuestreo balanceado (q submuestras por UE)

Fonte de variação	G.l.	E[QM]
Tratamento	$t-1$	$\sigma^2_\varepsilon + q\sigma^2_\delta + \frac{qr\sum \tau_i^2}{t-1}$
Erro experimental (entre UEs, dentro de trat.)	$t(r-1)$	$\sigma^2_\varepsilon + q\sigma^2_\delta$
Erro de amostragem (dentro de UEs)	$tr(q-1)$	σ^2_ε
Total	$trq-1$	

O ponto crucial está na coluna de esperanças de quadrados médios (E[QM]): o teste correto para o efeito do tratamento é

$$F = \frac{MS_{\text{Trat}}}{MS_{\text{Erro experimental}}} \sim F_{t-1,\, t(r-1)} \text{ sob } H_0,$$

não $MS_{\text{Trat}}/MS_{\text{Erro de amostragem}}$. Usar o erro de amostragem no denominador — como aconteceria ao rodar a ANOVA diretamente nas trq observações individuais, ignorando a estrutura de aquários — é exatamente o erro de pseudorreplicação descrito no Capítulo 1: o denominador fica artificialmente pequeno (baseado em $tr(q-1)$ graus de liberdade "emprestados" de dentro das UEs, não entre elas), o que infla o valor de F e a taxa de falsos positivos.

> **Uso do R** — ANOVA aninhada com Err or $()$

```
mojarra <- read_csv("data/mojarra.csv", show_col_types = FALSE) %>%
  rename(probiotico = probiotico, aquario = Acuario,
         peso_inicial = `Peso Inicial`, peso_45 = `Peso 45`) %>%
  drop_na(peso_45) %>%                                    # 3 peixes sem medição no dia
        45
  mutate(
    probiotico = factor(probiotico),
    aquario    = factor(aquario),
    ganho      = peso_45 - peso_inicial
  )

glimpse(mojarra)
```

```
## Rows: 97
## Columns: 5
## $ probiotico   <fct> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, …
## $ aquario      <fct> 1, 1, 1, 1, 1, 2, 2, 2, 2, 2, 3, 3, 3, 3, 4, 4, 4, 4, 5, …
## $ peso_inicial <dbl> 8.9, 8.5, 8.1, 9.1, 9.3, 9.0, 8.4, 8.7, 8.6, 9.4, 9.0, 8.…
## $ peso_45      <dbl> 21.1, 17.0, 17.5, 22.8, 18.2, 16.5, 26.0, 18.1, 23.5, 25.…
## $ ganho        <dbl> 12.2, 8.5, 9.4, 13.7, 8.9, 7.5, 17.6, 9.4, 14.9, 15.8, 13…
```

Tabela 3.7: Mojarra: papel de cada variável e mapeamento UE/unidade amostral

Variável	Papel
`probiotico`	Fator de tratamento (4 níveis) — sorteado por aquário
`aquario`	Identificador da unidade experimental (20 níveis, aninhado em `probiotico`)
`peso_inicial`, `peso_45`, `ganho`	Peso por peixe (unidade amostral) e resposta derivada (`ganho`)

Tabela 3.7: Aquários por probiótico (20 UEs no total)

probiotico	n_aquarios
1	5
2	5
3	5
4	5

Cada bloco de cor agrupa os aquários de um mesmo probiótico, e dentro de cada aquário os peixes (pontos) se espalham em torno da média daquele aquário (losango) — a variação *entre* losangos dentro de

uma mesma cor é o erro experimental σ^2_δ; a variação dos pontos *ao redor* do losango do seu próprio aquário é o erro de amostragem σ^2_ε. O gráfico deixa visível o que a seção seguinte formaliza: as 20 médias de aquário (os losangos) já parecem crescer de probiótico 1 para 4, um padrão que a ANOVA a seguir testa formalmente usando apenas essas 20 médias como unidade de comparação — não os quase 100 pontos coloridos.

```
modelo_sub <- aov(ganho ~ probiotico + Error(probiotico:aquario), data = mojarra)
summary(modelo_sub)
```

```
##
## Error: probiotico:aquario
##            Df Sum Sq Mean Sq F value   Pr(>F)
## probiotico  3   1845   615.0   12.98 0.000149 ***
## Residuals  16    758    47.4
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Error: Within
##           Df Sum Sq Mean Sq F value Pr(>F)
## Residuals 77   1360   17.66
```

Note que o erro-padrão de mortalidade (3 peixes sem peso registrado no dia 45) deixa o desenho levemente desbalanceado — 4 ou 5 peixes por aquário em vez de exatamente 5 — o que é comum em dados reais e não invalida a lógica da decomposição, ainda que a fórmula fechada de E[QM] acima valha exatamente apenas no caso perfeitamente balanceado. O teste do efeito do probiótico usa o quadrado médio **entre aquários dentro de probiótico** como erro (16 g.l.), não o quadrado médio entre peixes dentro de aquário (77 g.l.) — se o pesquisador tivesse usado este último por engano, o denominador do teste F seria bem menor, inflando artificialmente a significância.

3.3.4 Tamanho de amostra com submuestreo

Combinando δ_{ij} e ε_{ijk}, a variância efetiva da média de uma UE baseada em q submuestras é

$$\mathrm{Var}(\bar{Y}_{ij\cdot}) = \sigma^2_\delta + \frac{\sigma^2_\varepsilon}{q}.$$

Essa expressão tem uma implicação prática importante: como função de q, ela decresce, mas com retornos decrescentes, aproximando-se assintoticamente de um **piso** igual a σ^2_δ — nenhuma quantidade de submuestragem elimina a variação entre unidades experimentais. Se o objetivo é reduzir a incerteza sobre o efeito do tratamento, aumentar r (mais UEs) tem retorno direto e ilimitado; aumentar q (mais submuestras por UE) tem retorno limitado por esse piso.

> **Uso do R** — retorno decrescente da submuestragem

```
tab_sub <- summary(modelo_sub)
MS_exp <- tab_sub[["Error: probiotico:aquario"]][[1]][["Mean Sq"]][2]  # erro
       experimental
MS_am  <- tab_sub[["Error: Within"]][[1]][["Mean Sq"]][1]              # erro de
       amostragem
q_medio <- nrow(mojarra) / n_distinct(mojarra$aquario)

sigma2_delta <- (MS_exp - MS_am) / q_medio
sigma2_eps   <- MS_am
```

```
        tibble(q = c(1, 2, 5, 10, 20, 50)) %>%
  mutate(var_media_UE = sigma2_delta + sigma2_eps / q) %>%  kable(digits = 2,
        caption = "Variância da média de uma UE conforme o número de submuestras q")
        %>%
  kable_styling(full_width = FALSE)
```

Tabela 3.8: Variância da média de uma UE conforme o número de submuestras q

q	var_media_UE
1	23.79
2	14.96
5	9.66
10	7.89
20	7.01
50	6.48

Com $\hat{\sigma}^2_\delta \approx 6.1$ e $\hat{\sigma}^2_\varepsilon \approx 17.7$, passar de $q = 5$ (o desenho usado) para $q = 20$ reduziria a variância da média de UE em cerca de 27% (de 9.66 para 7.01) — uma melhora real, mas limitada pelo piso σ^2_δ. Já passar de $r = 5$ para $r = 20$ aquários por tratamento (o mesmo fator de aumento, $4\times$) reduziria a variância da **média de tratamento**, que decresce como σ^2_δ / r sem nenhum piso, em exatos 75% $(1 - 1/4)$ — quase o triplo da redução obtida investindo o mesmo fator de aumento em submuestras. Sempre que o custo por UE adicional for comparável ao custo por submuestra adicional, investir em mais UEs é a escolha mais eficiente — uma recomendação de delineamento amostral que decorre diretamente da estrutura do modelo, não de intuição.

3.4 O modelo de efeitos aleatórios

Até aqui, os níveis do fator eram os níveis de interesse *per se*: o pesquisador queria comparar justamente aquelas três condições de distração, ou justamente aqueles quatro probióticos. Há situações, porém, em que os níveis usados no experimento são apenas **uma amostra aleatória** de uma população maior e muito mais numerosa de níveis possíveis — e o interesse não está nos níveis específicos sorteados, mas em **quanto** a fonte de variação que eles representam contribui para a variabilidade total da resposta, de modo a generalizar para toda a população de níveis.

> **Aplicação — Psicologia: variabilidade entre estímulos sonoros de distração**
> Voltando ao experimento de distração sonora: existe, na prática, uma população enorme de possíveis sons de distração (sirenes, conversas, tráfego, música...). Em vez de fixar um único som, o pesquisador sorteia aleatoriamente **5 clipes sonoros** de um banco com centenas de gravações e testa cada clipe em 8 novos voluntários (sorteados independentemente entre clipes). A pergunta não é "o clipe 3 difere do clipe 1?" — não há interesse nesses clipes específicos — mas sim "o tipo de som usado, de modo geral, contribui de forma relevante para a variabilidade do tempo de reação?".

3.4.1 Quando os tratamentos são uma amostra aleatória

O modelo tem a mesma forma algébrica de antes,

$$Y_{ij} = \mu + \tau_i + \varepsilon_{ij}, \qquad i = 1, \ldots, t;\ j = 1, \ldots, n,$$

mas agora $\tau_i \overset{iid}{\sim} N(0, \sigma^2_\tau)$ é **aleatório** (não mais sujeito à restrição de soma zero), independente de $\varepsilon_{ij} \overset{iid}{\sim} N(0, \sigma^2)$. Consequentemente, $\mathrm{Var}(Y_{ij}) = \sigma^2_\tau + \sigma^2$, e observações da mesma UE de nível i (aqui, do mesmo clipe sonoro) são correlacionadas: $\mathrm{Corr}(Y_{ij}, Y_{ij'}) = \sigma^2_\tau / (\sigma^2_\tau + \sigma^2)$ para $j \neq j'$ — o **coeficiente de correlação intraclasse (ICC)**. Em notação matricial, isso é a mesma estrutura de blocos de simetria composta $\mathbf{V} = \sigma^2_\tau \mathbf{Z}\mathbf{Z}' + \sigma^2 \mathbf{I}_N$ da Seção 3.3.1 (p. 58), agora com $\mathbf{Z}$ indicando o **nível sorteado** (o clipe), não a UE — sinal de que submuestreo e efeitos aleatórios são duas instâncias do mesmo fenômeno estatístico: observações que compartilham um rótulo aleatório deixam de ser independentes. A hipótese de interesse muda de “as médias são iguais?” para “a variância entre níveis é nula?”:

$$H_0 : \sigma^2_\tau = 0 \quad \text{vs.} \quad H_1 : \sigma^2_\tau > 0.$$

3.4.2 ANOVA e componentes de variância

A tabela de ANOVA é calculada exatamente como no modelo de efeitos fixos (as somas de quadrados não mudam — a diferença está só na interpretação e nas esperanças de quadrados médios):

Tabela 3.9: ANOVA do DCA de efeitos aleatórios balanceado

Fonte de variação	G.l.	E[QM]
Entre níveis	$t - 1$	$\sigma^2 + n\sigma^2_\tau$
Erro	$t(n-1)$	σ^2
Total	$tn - 1$	

O teste $F = MS_{\text{Entre}} / MS_E$ é numericamente idêntico ao do modelo fixo, mas a estimativa de interesse passa a ser o **componente de variância** σ^2_τ, obtido pelo método dos momentos a partir da tabela de ANOVA (método de Henderson tipo I):

$$\hat{\sigma}^2 = MS_E, \qquad \hat{\sigma}^2_\tau = \frac{MS_{\text{Entre}} - MS_E}{n}.$$

Uso do R — variância entre clipes sonoros

```
set.seed(77)
t_niveis <- 5; n_por_nivel <- 8
efeito_clipe <- rnorm(t_niveis, 0, sqrt(300))

dados_clipe <- tibble(
  clipe        = factor(rep(paste("Clipe", 1:t_niveis), each = n_por_nivel)),
  efeito       = rep(efeito_clipe, each = n_por_nivel),   # efeito ALEATÓRIO do clipe sorteado
  tempo_reacao = 520 + efeito + rnorm(t_niveis * n_por_nivel, 0, sqrt(1200))
)
glimpse(dados_clipe)
```

```
## Rows: 40
## Columns: 3
## $ clipe        <fct> Clipe 1, Clipe 1, Clipe 1, Clipe 1, Clipe 1, Clipe 1, Cli…
## $ efeito       <dbl> -9.520009, -9.520009, -9.520009, -9.520009, -9.520009, -9…
## $ tempo_reacao <dbl> 549.8946, 476.8590, 505.9134, 515.5454, 560.4078, 408.587…
```

```r
# UE = voluntário (8 por clipe, sem submuestreo); "clipe" é o nível sorteado da
        população de sons

modelo_clipe <- aov(tempo_reacao ~ clipe, data = dados_clipe)
summary(modelo_clipe)
```

```
##             Df Sum Sq Mean Sq F value Pr(>F)
## clipe        4  13379    3345   2.377 0.0706 .
## Residuals   35  49247    1407
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
tab_cl <- summary(modelo_clipe)[[1]]
MS_entre <- tab_cl["Mean Sq"][1]; MS_erro <- tab_cl["Mean Sq"][2]
sigma2_tau_hat <- (MS_entre - MS_erro) / n_por_nivel

tibble(
  Componente = c("Entre clipes (sigma_tau^2)", "Erro (sigma^2)", "ICC"),
  Estimativa = c(sigma2_tau_hat, MS_erro, sigma2_tau_hat / (sigma2_tau_hat +
        MS_erro))
) %>%
  kable(digits = 3, caption = "Componentes de variância estimados") %>%
  kable_styling(full_width = FALSE)
```

Tabela 3.10: Componentes de variância estimados

Componente	Estimativa
Entre clipes (sigma_tau^2)	242.222
Erro (sigma^2)	1407.053
ICC	0.147

O ICC estimado de cerca de 0,15 sugere que a *identidade do clipe sonoro* explica uma fração modesta, mas não desprezível, da variabilidade do tempo de reação — informação que o modelo de efeitos fixos, ao tratar os cinco clipes como se fossem os únicos de interesse, simplesmente não poderia fornecer.



Tempo de reação por clipe sonoro (pontos), com a média de cada clipe (losango preto). A dispersão dos losangos em torno da média geral estima sigma_tau^2 (entre clipes); a dispersão dos pontos em torno do próprio losango estima sigma^2 (dentro de clipe).

Figura 3.11: Tempo de reação por clipe sonoro (pontos), com a média de cada clipe (losango preto). A dispersão dos losangos em torno da média geral estima sigma_tau^2 (entre clipes); a dispersão dos pontos em torno do próprio losango estima sigma^2 (dentro de clipe).

A linha tracejada marca a média geral. Os losangos (médias de cada clipe) se espalham em torno dela — essa dispersão *entre* losangos é o que $\hat{\sigma}^2_\tau$ mede — enquanto os pontos individuais (voluntários) se espalham em torno do losango do seu próprio clipe — a dispersão *dentro* de cada coluna, que $\hat{\sigma}^2$ mede. Note que nenhum clipe específico se destaca de forma sistemática: é exatamente esse padrão, em que os cinco níveis observados parecem uma amostra de uma população maior de clipes possíveis, que justifica tratá-los como efeitos aleatórios em vez de fixos.

3.4.3 Tamanho de amostra no modelo de efeitos aleatórios

O planejamento de n (réplicas por nível) no modelo aleatório não usa a distribuição F não central da Seção 3.2.6 (p. 55) — em vez disso, sob H_1,

$$\frac{F}{1+n\gamma} \sim F_{t-1,\,t(n-1)} \quad \text{(central)}, \qquad \gamma = \frac{\sigma_\tau^2}{\sigma^2},$$

de modo que o poder do teste, para um dado γ (a razão de variâncias que se deseja detectar) e um número de níveis t fixado de antemão, é

$$\text{Poder}(n) = P\left(F_{t-1,\,t(n-1)} > \frac{F_{\alpha,\,t-1,\,t(n-1)}}{1+n\gamma} \right).$$

Uso do R — poder em função de n, dado gamma

```
gamma_alvo <- 300 / 1200   # sigma_tau^2 / sigma^2 assumido no planejamento
t_niveis   <- 5
alpha      <- 0.05

poder_n <- function(n) {
  Fc <- qf(1 - alpha, t_niveis - 1, t_niveis * (n - 1))
  pf(Fc / (1 + n * gamma_alvo), t_niveis - 1, t_niveis * (n - 1), lower.tail = FALSE)
}

tibble(n = c(8, 10, 15, 20, 25, 30)) %>%
  mutate(poder = map_dbl(n, poder_n)) %>%
  kable(digits = 3, caption = "Poder para detectar gamma = 0,25 com t = 5 níveis")
        %>%
  kable_styling(full_width = FALSE)
```

Tabela 3.11: Poder para detectar gamma = 0,25 com t = 5 níveis

n	poder
8	0.486
10	0.572
15	0.716
20	0.800
25	0.852
30	0.886

Com apenas 8 réplicas por clipe (o desenho do exemplo), o poder para detectar $\gamma = 0{,}25$ é de apenas cerca de 0,49 — seriam necessárias por volta de 20 réplicas por nível para atingir poder de 0,80. O modelo aleatório costuma exigir mais réplicas por nível do que o modelo fixo para o mesmo poder nominal, porque a variabilidade entre níveis (σ_τ^2) se soma à incerteza da estimativa, em vez de ser um efeito fixo perfeitamente estimável.

3.5 Verificação de pressupostos

Toda a inferência das seções anteriores — testes F, intervalos de confiança, cálculos de tamanho amostral — depende de três suposições sobre os erros do modelo: **normalidade**, **variância constante** entre tratamentos (homocedasticidade) e **independência**. A independência é garantida (ou não) pelo desenho — pela aleatorização e pela ausência de dependências não modeladas, como o submuestreo tratado incorretamente — e não se verifica diretamente nos dados; normalidade e homocedasticidade, por sua vez, são checáveis a partir dos **resíduos** do modelo ajustado, $e_{ij} = Y_{ij} - \bar{Y}_{i\cdot}$ — em notação matricial da Seção 3.2.2 (p. 49), o vetor $\mathbf{e} = (\mathbf{I}_N - \mathbf{P}_X)\mathbf{Y}$, a projeção de $\mathbf{Y}$ sobre o complemento ortogonal do espaço-coluna de $\mathbf{X}$. É precisamente por $\mathbf{e}$ viver nesse subespaço, ortogonal aos valores ajustados, que ele funciona como um proxy observável dos erros $\boldsymbol{\varepsilon}$ não observáveis.

> **Aplicação — Psicologia: heterocedasticidade em tempos de reação**
> Tempos de reação são um exemplo clássico de variável que raramente é normal em escala bruta: a distribuição costuma ser assimétrica à direita (a maioria das respostas é rápida, mas há uma cauda de respostas bem mais lentas) e a variância tende a crescer com a média — sujeitos/condições mais lentos não são apenas deslocados, são também mais variáveis. Simulamos abaixo um cenário assim, com efeito multiplicativo (e não aditivo) do tipo de distração.

3.5.1 Normalidade: gráfico Q-Q e testes formais

```
set.seed(1234)
condicao <- c("Nenhuma", "Sonora", "Visual")
n <- 15
media_base <- c(420, 470, 560)
cv <- 0.28  # erro multiplicativo: log(tempo) tem desvio-padrão constante nessa
        escala

dados_het <- tibble(
  sujeito  = 1:(3 * n),
  condicao = factor(rep(condicao, each = n), levels = condicao),
  tempo    = rep(media_base, each = n) * exp(rnorm(3 * n, 0, cv))
)

modelo_het <- aov(tempo ~ condicao, data = dados_het)
```

O gráfico à esquerda é o Q-Q plot de todos os resíduos combinados; o da direita — um diagnóstico complementar, tão útil quanto o Q-Q e frequentemente esquecido — mostra a **distribuição dos resíduos separada por tratamento**: além de revelar o mesmo afastamento de simetria (caixas alongadas para cima em vez de centradas), ele já antecipa o próximo pressuposto a checar, porque a altura das três caixas cresce visivelmente de “Nenhuma” para “Visual” — sinal de que a variância não é a mesma nos três grupos, o assunto da próxima seção.

O afastamento sistemático da reta nas caudas do Q-Q — pontos acima da reta à direita, indicando uma cauda mais pesada que a normal — é o padrão típico de assimetria à direita. O gráfico Q-Q é sempre o primeiro diagnóstico: mais informativo que um único número, porque mostra *onde* (em qual parte da distribuição) o desvio da normalidade ocorre. Ele é complementado, não substituído, por um teste formal — mais útil como confirmação do que o olho já sugeriu do que como árbitro único, sobretudo em amostras pequenas (baixo poder) ou muito grandes (rejeita quase sempre, por desvios sem relevância prática):

```
shapiro.test(residuals(modelo_het))
```

```
##
##  Shapiro-Wilk normality test
##
## data:  residuals(modelo_het)
## W = 0.84551, p-value = 2.812e-05
```

O teste de **Shapiro-Wilk** (Shapiro & Wilk, 1965) rejeita a normalidade dos resíduos ($p < 0{,}001$), consistente com o Q-Q plot.

3.5.2 Homogeneidade de variância

Antes do teste formal, o gráfico de **resíduos contra valores ajustados** é o diagnóstico visual mais direto de heterocedasticidade: se a dispersão vertical dos pontos aumenta sistematicamente da esquerda para a direita (grupos com médias maiores), a variância não é constante.

```
tibble(
  ajustado = fitted(modelo_het),
  residuo  = residuals(modelo_het),
  condicao = dados_het$condicao
) %>%
  ggplot(aes(ajustado, residuo, color = condicao)) +
  geom_hline(yintercept = 0, linetype = "dashed", color = "grey40") +
  geom_point(size = 2, alpha = 0.75) +
  labs(title = "Resíduos vs. valores ajustados", x = "Valor ajustado (média do
        grupo)",
       y = "Resíduo", color = "Condição") +
  theme_minimal(base_size = 13)
```

O leque se abre visivelmente da esquerda (condição “Nenhuma”, ajustado mais baixo) para a direita (condição “Visual”, ajustado mais alto): os resíduos ficam mais dispersos exatamente onde a média é maior — a marca registrada de um erro multiplicativo, e o mesmo padrão que o teste de Levene, a seguir, tentará (sem muito sucesso, dado o n pequeno) capturar formalmente.

```
car::leveneTest(tempo ~ condicao, data = dados_het)
```

```
## Levene's Test for Homogeneity of Variance (center = median)
##       Df F value Pr(>F)
## group  2  0.1136 0.8929
##       42
```

O teste de **Levene** (Levene, 1960) (que compara os desvios absolutos em torno da mediana de cada grupo, sendo por isso mais robusto a não normalidade do que o teste de Bartlett (1937)) não rejeita a homogeneidade de variância aqui — mas isso não deve surpreender: com apenas 15 observações por grupo, o teste tem pouco poder para detectar diferenças de variância moderadas, mesmo quando, por construção (erro multiplicativo) e como o gráfico acima já deixou claro, a variância populacional realmente cresce com a média. É outro lembrete de que ausência de significância não é evidência de que o pressuposto vale — sobretudo em amostras pequenas, a inspeção gráfica continua indispensável.

3.5.3 Transformações usuais

Quando a normalidade e/ou a homocedasticidade falham, a estratégia clássica é **transformar** a variável resposta para uma escala em que o modelo se comporte melhor, em vez de abandonar a ANOVA por um método menos eficiente. As transformações mais comuns:

- **Logaritmo** ($\log Y$): indicada quando a variância cresce proporcionalmente ao *quadrado* da média (erro multiplicativo, como simulado acima) — muito comum em tempos, concentrações, contagens grandes e dados sempre positivos com assimetria à direita.
- **Raiz quadrada** ($\sqrt{Y}$, ou $\sqrt{Y + 1/2}$ com contagens pequenas ou zeros): indicada quando a variância cresce proporcionalmente à média, o padrão típico de dados de **contagem** (número de erros, número de respostas corretas).
- **Box-Cox** (Box & Cox, 1964): uma família de transformações de potência que generaliza as duas anteriores,

$$Y^{(\lambda)} = \begin{cases} \dfrac{Y^{\lambda} - 1}{\lambda}, & \lambda \neq 0 \\ \log Y, & \lambda = 0 \end{cases}$$

em que λ é escolhido pelos dados, maximizando a log-verossimilhança perfilada do modelo ANOVA ajustado a $Y^{(\lambda)}$ para uma grade de valores de λ (frequentemente entre -2 e 2). $\lambda = 1$ (sem transformar), $\lambda = 0$ (log) e $\lambda = 1/2$ (raiz quadrada) são casos particulares interpretáveis dessa família.

> **Uso do R** — Box-Cox e verificação pós-transformação

```
bc <- MASS::boxcox(modelo_het, plotit = TRUE, lambda = seq(-2, 2, by = 0.01))
```

```
lambda_otimo <- bc$x[which.max(bc$y)]
lambda_otimo
```

```
## [1] -0.6
```

O valor que maximiza a verossimilhança perfilada é $\hat{\lambda} \approx -0.6$, mas o intervalo de verossimilhança de 95% ao redor desse máximo é largo o bastante para incluir $\lambda = 0$ — ou seja, a transformação **logarítmica**, mais simples de interpretar (diferenças na escala log correspondem a razões, não diferenças, na escala original), é estatisticamente compatível com os dados e é a escolha usual nesse tipo de situação:

```
dados_het <- dados_het %>% mutate(log_tempo = log(tempo))
modelo_log <- aov(log_tempo ~ condicao, data = dados_het)

shapiro.test(residuals(modelo_log))
```

```
##
##  Shapiro-Wilk normality test
##
## data:  residuals(modelo_log)
## W = 0.95569, p-value = 0.08363
```

```r
car::leveneTest(log_tempo ~ condicao, data = dados_het)
```

```
## Levene's Test for Homogeneity of Variance (center = median)
##       Df F value Pr(>F)
## group  2  0.0259 0.9744
##       42
```

Depois de transformar, o teste de Shapiro-Wilk deixa de rejeitar a normalidade ($p \approx 0.084$) e a homogeneidade de variância permanece não rejeitada — evidência de que a escala logarítmica é adequada para a ANOVA neste conjunto de dados. As conclusões substantivas devem então ser reportadas na escala transformada (por exemplo, "a condição visual aumenta o tempo de reação em um fator estimado de…"), com cuidado ao traduzir de volta diferenças na escala log para razões multiplicativas na escala original.

> **Uso do R** — antes e depois da transformação, lado a lado

O leque de dispersão que crescia da esquerda para a direita no painel "Antes" desaparece no painel "Depois": na escala log, a variabilidade dos resíduos é visualmente comparável entre as três condições, sinal direto (mais informativo do que qualquer teste isolado) de que a transformação cumpriu o que se propunha — estabilizar a variância sem distorcer a estrutura de tratamento que estamos tentando comparar.

Reunindo as três camadas desenvolvidas até aqui para o DCA a uma via: a camada **algébrica** (Seção 3.2.2 (p. 49)) mostra que SQ_{Trat} e SQ_E são formas quadráticas em projeções ortogonais, herdadas diretamente do Capítulo 2; a camada **causal** (Seção 3.2.3 (p. 51)) mostra que $\bar{Y}_{i\cdot} - \bar{Y}_{k\cdot}$ estima um efeito de tratamento bem definido *independentemente* do modelo normal, só em função da aleatorização; e a camada **distribucional** (Seções 3.2.5 (p. 52) a 3.5.3 (p. 69)) usa a normalidade para transformar essa base algébrica e causal em testes e ICs exatos em amostra finita — e para diagnosticar quando essa última camada, especificamente, está em risco.

O restante deste capítulo trata de perguntas mais refinadas dentro do mesmo DCA — comparações planejadas (contrastes), tendências ao longo de níveis quantitativos (polinômios ortogonais), comparações múltiplas *a posteriori*, ajuste por covariáveis (ANCOVA) e a alternativa não paramétrica de Kruskal-Wallis quando nem mesmo as transformações da seção anterior bastam para justificar o modelo normal.

3.6 Contrastes e comparações múltiplas

A ANOVA de um fator responde a uma pergunta agregada: *existe pelo menos uma diferença entre as t médias de tratamento?* Rejeitar $H_0 : \mu_1 = \mu_2 = \cdots = \mu_t$ não diz **quais** médias diferem, nem **em que direção**. Contrastes e procedimentos de comparação múltipla respondem exatamente a essas perguntas mais específicas — mas, como veremos, fazê-lo com rigor exige cuidado extra, porque testar muitas hipóteses sobre o mesmo conjunto de dados infla a chance de pelo menos um falso positivo.

Vale explicitar a leitura causal por trás desta seção, retomando o arcabouço de resultados potenciais introduzido no Capítulo 1: cada unidade experimental tem t resultados potenciais $Y_i(1), \ldots, Y_i(t)$ — um por braço de tratamento —, dos quais só o do braço sorteado é observado. Cada média $\mu_i = E[Y(i)]$ é a média populacional do resultado potencial sob o tratamento i, e um contraste par a par $\mu_i - \mu_j$ é, literalmente, um **efeito médio de tratamento** (ATE) entre os braços i e j. Quando $t > 2$, existem $\binom{t}{2}$ ATEs par a par possíveis — mais uma infinidade de contrastes que agregam grupos de braços —, e é essa multiplicidade de efeitos causais estimados simultaneamente sobre o mesmo experimento que faz emergir,

de forma natural e não como artefato técnico do procedimento estatístico, o problema de comparações múltiplas da próxima seção: cada ATE testado isoladamente carrega seu próprio risco de falso positivo, e responder “algum desses efeitos é diferente de zero?” exige um controle de erro que leve todos eles em conta simultaneamente.

```
suppressPackageStartupMessages({
  library(tidyverse)
  library(kableExtra)
  library(broom)
  library(emmeans)
  library(multcomp)
  library(car)
  library(agricolae)
})

set.seed(2026)
config <- c("Nenhum", "Analytics", "Anúncios", "Combo")
n_por_grupo <- 10

# efeito verdadeiro (ms) de cada configuração de scripts de terceiros sobre o
# tempo de carregamento da página, em relação à configuração "Nenhum" (controle)
efeito_config <- c(Nenhum = 0, Analytics = 60, Anúncios = 140, Combo = 210)

dados_scripts <- tibble(
  pagina   = 1:(4 * n_por_grupo),
  config   = factor(rep(config, each = n_por_grupo), levels = config),
  tempo_ms = 900 + efeito_config[as.character(config)] +
    rnorm(4 * n_por_grupo, mean = 0, sd = 70)
)

mod_scripts <- aov(tempo_ms ~ config, data = dados_scripts)
```

Aplicação — Ciência de dados: scripts de terceiros e tempo de carregamento
Uma equipe de engenharia web quer comparar quatro configurações de uma página de produto quanto ao tempo de carregamento: **Nenhum** script de terceiros (controle), **Analytics** apenas, **Anúncios** apenas, e **Combo** (chat de suporte + anúncios). Dez carregamentos independentes são medidos em cada configuração (`n = 10` por grupo, 40 no total), sob condições de rede controladas.

Tabela 3.12: Tempo de carregamento (ms) por configuração de scripts

config	n	media_ms	dp_ms
Nenhum	10	859.4	60.3
Analytics	10	945.5	74.6
Anúncios	10	1079.9	77.4
Combo	10	1113.6	46.7

3.6.1 Definição, esperança e variância de um contraste

Sejam $\mu_1, \ldots, \mu_t$ as médias populacionais dos t tratamentos. Um **contraste** é qualquer combinação linear

$$L = \sum_{i=1}^{t} c_i \mu_i, \qquad \text{sujeita a} \qquad \sum_{i=1}^{t} c_i = 0.$$

A restrição $\sum c_i = 0$ é o que distingue um contraste de uma combinação linear qualquer: ela garante que L mede uma **diferença** entre grupos (ou grupos de grupos), não um nível geral. Com os dados, L é estimado por $\hat{L} = \sum_{i=1}^{t} c_i \bar{y}_{i\cdot}$, trocando cada μ_i pela média amostral do respectivo grupo. Como as médias amostrais dos t grupos são independentes (unidades experimentais diferentes) e $E(\bar{y}_{i\cdot}) = \mu_i$,

$$E(\hat{L}) = \sum_{i=1}^{t} c_i \, E(\bar{y}_{i\cdot}) = \sum_{i=1}^{t} c_i \mu_i = L,$$

ou seja, $\hat{L}$ é um estimador não viesado de L. Assumindo variância homogênea σ^2 entre tratamentos (o mesmo pressuposto de homocedasticidade da ANOVA) e n_i réplicas no tratamento i,

$$\operatorname{Var}(\hat{L}) = \sum_{i=1}^{t} c_i^2 \operatorname{Var}(\bar{y}_{i\cdot}) = \sigma^2 \sum_{i=1}^{t} \frac{c_i^2}{n_i},$$

que se reduz a $\operatorname{Var}(\hat{L}) = \dfrac{\sigma^2}{n} \sum_{i=1}^{t} c_i^2$ no caso balanceado ($n_i = n$ para todo i), o caso mais comum na prática e o único em que os coeficientes c_i tabulados na literatura clássica se aplicam diretamente.

3.6.2 Soma de quadrados de um contraste e sua distribuição

A soma de quadrados atribuível a um contraste é

$$SQ_L = \frac{\hat{L}^{\,2}}{\sum_{i=1}^{t} c_i^2 / n_i},$$

com **1 grau de liberdade**, qualquer que seja o número de tratamentos t — um contraste é, por construção, uma comparação de uma única dimensão. Sob $H_0 : L = 0$ e o modelo usual de ANOVA com erros $\varepsilon_{ij} \sim N(0, \sigma^2)$ independentes,

$$F = \frac{SQ_L}{QME} \sim F_{1,\, gl_{\text{erro}}},$$

onde QME é o quadrado médio do erro da ANOVA completa. Essa estatística é equivalente a um teste t com gl_{erro} graus de liberdade ($t^2 = F$), que é a forma mais comum de reportar um contraste isolado:

$$t = \frac{\hat{L}}{\sqrt{QME \sum_i c_i^2 / n_i}}.$$

Um contraste é, portanto, um teste com 1 grau de liberdade **encaixado dentro** da ANOVA — mais específico e, em geral, mais poderoso do que o teste F global de $t - 1$ graus de liberdade, desde que a pergunta específica seja definida **antes** de olhar os dados.

3.6.3 Notação matricial: contraste como forma linear e quadrática

Recorde o modelo linear do Capítulo 2 (Seção 2.3 (p. 20)) e sua parametrização de médias de casela (*cell-means*) para o DCA: $\mathbf{Y} = \mathbf{X}\boldsymbol{\mu} + \boldsymbol{\varepsilon}$, em que $\mathbf{X}$ é a matriz $N \times t$ de indicadoras de tratamento (posto coluna completo nessa parametrização) e $\mathbf{X}'\mathbf{X} = \operatorname{diag}(n_1, \ldots, n_t)$. Nessa notação, um contraste é a forma linear

$$L = \boldsymbol{\lambda}'\boldsymbol{\mu}, \qquad \boldsymbol{\lambda} = (c_1, \ldots, c_t)', \qquad \mathbf{1}'\boldsymbol{\lambda} = 0,$$

estimado por $\hat{L} = \boldsymbol{\lambda}'\hat{\boldsymbol{\mu}} = \boldsymbol{\lambda}'\bar{\mathbf{y}}$. Como $\boldsymbol{\lambda}'\boldsymbol{\mu}$ é uma combinação linear estimável (Capítulo 2, Seção 2.5 (p. 25): toda combinação linear é estimável quando $\mathbf{X}$ tem posto completo), o teorema de Gauss-Markov (Capítulo 2, Seção 2.6 (p. 29)) garante que $\hat{L}$ é BLUE, com variância

$$\operatorname{Var}(\hat{L}) = \sigma^2\, \boldsymbol{\lambda}'(\mathbf{X}'\mathbf{X})^{-1}\boldsymbol{\lambda} = \sigma^2 \sum_{i=1}^{t} \frac{c_i^2}{n_i},$$

que reproduz exatamente o resultado escalar da subseção anterior — agora como caso particular de $\operatorname{Cov}(\hat{\boldsymbol{\beta}}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}$.

A soma de quadrados do contraste é a forma quadrática de posto 1

$$SQ_L = (\boldsymbol{\lambda}'\hat{\boldsymbol{\mu}})\left[\boldsymbol{\lambda}'(\mathbf{X}'\mathbf{X})^{-1}\boldsymbol{\lambda}\right]^{-1}(\boldsymbol{\lambda}'\hat{\boldsymbol{\mu}}) \;=\; \mathbf{Y}'\mathbf{A}_{\boldsymbol{\lambda}}\mathbf{Y},$$

em que $\mathbf{A}_{\boldsymbol{\lambda}}$ é simétrica e idempotente, de posto 1 — uma projeção sobre a direção definida por $\boldsymbol{\lambda}$ dentro do subespaço de tratamento. Pelo teorema sobre formas quadráticas idempotentes do Capítulo 2 (Seção 2.10 (p. 37)), $SQ_L/\sigma^2 \sim \chi^2_1$ sob $H_0 : L = 0$ — a mesma conclusão obtida escalarmente acima, agora como caso particular de um resultado geral, não uma coincidência.

Essa leitura geométrica também explica *por que* contrastes ortogonais se comportam tão bem: um conjunto de $t-1$ contrastes ortogonais $\boldsymbol{\lambda}_1, \ldots, \boldsymbol{\lambda}_{t-1}$ corresponde a $t-1$ projeções de posto 1 mutuamente ortogonais, cuja soma reconstrói exatamente a projeção sobre todo o subespaço de tratamento:

$$\sum_{k=1}^{t-1} \mathbf{A}_{\boldsymbol{\lambda}_k} \;=\; \mathbf{P}_X - \mathbf{P}_{\mathbf{1}},$$

a mesma diferença de projeções do princípio da soma de quadrados extra (Capítulo 2, Seção 2.8 (p. 33)), com $\mathbf{X}_1 = \mathbf{1}$ (só o intercepto). É essa identidade — uma soma de $t-1$ projeções ortogonais de posto 1 reconstruindo a projeção de posto $t-1$ — que, pelo teorema de Cochran citado no Capítulo 2, garante que as $t-1$ **somas de quadrados** $SQ_{L_1}, \ldots, SQ_{L_{t-1}}$ são mutuamente independentes, e independentes de SQ_E. Note com cuidado o que isso **não** diz: as estatísticas $F_k = SQ_{L_k}/QM_E$ compartilham o mesmo denominador aleatório QM_E e, por isso, **não** são independentes entre si, ainda que seus numeradores sejam. A distinção é formalizada a seguir.

3.6.4 Contrastes ortogonais

Dois contrastes com coeficientes $\{c_i\}$ e $\{d_i\}$ são **ortogonais** se

$$\sum_{i=1}^{t} \frac{c_i d_i}{n_i} = 0 \qquad \Big(\text{balanceado: } \sum_{i=1}^{t} c_i d_i = 0\Big).$$

Para t tratamentos existem no máximo $t-1$ contrastes mutuamente ortogonais. A propriedade notável de um **conjunto completo** de $t-1$ contrastes ortogonais é que suas somas de quadrados particionam exatamente a soma de quadrados de tratamento, sem sobra e sem sobreposição:

$$SQ_{\text{Trat}} = \sum_{k=1}^{t-1} SQ_{L_k}, \qquad gl_{\text{Trat}} = \sum_{k=1}^{t-1} 1 = t-1.$$

Além disso, sob normalidade, os $t - 1$ testes F resultantes são **estatisticamente independentes** entre si — uma propriedade que nenhuma coleção arbitrária de contrastes possui. Isso torna contrastes ortogonais a ferramenta natural para decompor a variação entre tratamentos em perguntas específicas, planejadas antes da coleta de dados.

Para os quatro grupos do exemplo de carregamento de página, um conjunto de 3 contrastes ortogonais planejados a priori poderia ser:

Tabela 3.13: Um conjunto de 3 contrastes ortogonais (3 graus de liberdade = gl_{Trat})

Contraste	Nenhum	Analytics	Anúncios	Combo
L_1: Nenhum vs. demais	3	-1	-1	-1
L_2: Analytics vs. (Anúncios, Combo)	0	2	-1	-1
L_3: Anúncios vs. Combo	0	0	1	-1

Uso do R — calculando contrastes e verificando a partição de SQ_{Trat}

```
medias  <- with(dados_scripts, tapply(tempo_ms, config, mean))
ns      <- with(dados_scripts, tapply(tempo_ms, config, length))
qme     <- summary(mod_scripts)[[1]]["Residuals", "Mean Sq"]
gl_erro <- summary(mod_scripts)[[1]]["Residuals", "Df"]

coefs <- list(
  L1 = c(Nenhum = 3, Analytics = -1, `Anúncios` = -1, Combo = -1),
  L2 = c(Nenhum = 0, Analytics =  2, `Anúncios` = -1, Combo = -1),
  L3 = c(Nenhum = 0, Analytics =  0, `Anúncios` =  1, Combo = -1)
)

resultado_contrastes <- map_dfr(names(coefs), function(nm) {
  cc   <- coefs[[nm]][names(medias)]
  Lhat <- sum(cc * medias)
  SQ   <- Lhat^2 / sum(cc^2 / ns)
  Fval <- SQ / qme
  tibble(contraste = nm, L_hat = Lhat, SQ = SQ, F = Fval,
         p_valor = pf(Fval, 1, gl_erro, lower.tail = FALSE))
})
resultado_contrastes
```

```
## # A tibble: 3 × 5
##   contraste  L_hat      SQ     F       p_valor
##   <chr>      <dbl>   <dbl> <dbl>         <dbl>
## 1 L1        -561.  262161. 60.3  0.00000000333
## 2 L2        -302.  152438. 35.1  0.000000883
## 3 L3         -33.7   5691.  1.31 0.260
```

```
# verificação: a soma das SQ dos 3 contrastes ortogonais reproduz SQ_Trat da ANOVA
sum(resultado_contrastes$SQ)
```

```
## [1] 420290.4
```

```
summary(mod_scripts)[[1]]["config", "Sum Sq"]
```

```
## [1] 420290.4
```

A soma das três somas de quadrados dos contrastes reproduz exatamente a soma de quadrados de tratamento da ANOVA — confirmando a partição. Os contrastes L_1 e L_2 são significativos (scripts, de fato, atrasam o carregamento, e Analytics sozinho atrasa menos que Anúncios/Combo); L_3 não é (Anúncios e Combo não diferem significativamente entre si neste conjunto de dados).

3.7 Procedimentos de comparação múltipla

Contrastes ortogonais planejados a priori resolvem o problema de forma elegante quando o número de perguntas é pequeno e conhecido antes da coleta de dados. Mas frequentemente queremos comparar **todos os pares de médias**, ou comparar cada tratamento contra um grupo controle, sem ter decidido de antemão exatamente quais comparações importam. Fazer isso com testes t repetidos, um por par, é perigoso: com $t = 4$ grupos há $\binom{4}{2} = 6$ comparações possíveis, e mesmo que H_0 seja verdadeira em todas elas, a probabilidade de pelo menos um falso positivo ao nível nominal $\alpha = 0{,}05$ por teste é

$$P(\text{pelo menos 1 falso positivo}) = 1 - (1-\alpha)^6 \approx 1 - 0{,}95^6 \approx 0{,}26,$$

mais de cinco vezes o nível nominal. Essa inflação da **taxa de erro por família** (*family-wise error rate*, FWER) é o problema que os procedimentos a seguir resolvem, cada um com um compromisso diferente entre conservadorismo e poder.

3.7.1 O perigo do “data snooping”

Antes de listar os procedimentos, vale nomear explicitamente o problema mais sutil que eles resolvem — não apenas “muitos testes t”, mas a prática de decidir **qual** comparação fazer depois de já ter visto os dados. O método científico usual segue a ordem hipótese $\rightarrow$ delineamento $\rightarrow$ coleta $\rightarrow$ análise; o **“data snooping”** (“espionagem de dados”, ou garimpagem de hipóteses) inverte essa ordem: primeiro se exploram os dados em busca de qualquer padrão que pareça interessante, e só então se formula — e se “testa” — uma hipótese construída sob medida para aquele padrão, usando os **mesmos** dados que a sugeriram.

O problema não é hipotético. Suponha t grupos cujas médias populacionais são, na verdade, idênticas. Por puro ruído amostral, as t médias observadas nunca serão exatamente iguais; haverá sempre um par de médias mais distante entre si do que os demais. Se o pesquisador percorre os dados à procura do par mais discrepante e só então formula a hipótese “esses dois grupos diferem”, o teste t usual sobre esse par específico quase certamente rejeitará H_0 com frequência bem maior que α — não porque exista um efeito real, mas porque **escolher o maior de vários desvios aleatórios e testá-lo como se fosse a única comparação planejada** ignora toda a variabilidade dos $\binom{t}{2} - 1$ pares que não foram escolhidos. A analogia usual é a do atirador que dispara uma flecha na parede e só depois desenha o alvo ao redor do ponto de impacto: ele acerta o “alvo” sempre, mas isso nada prova sobre sua pontaria.

Os procedimentos planejados a priori (contrastes ortogonais da Seção 3.6 (p. 71), Tukey, Dunnett, Bonferroni) protegem apenas o conjunto de comparações **especificado antes** de examinar os dados — nenhum deles oferece garantia alguma sobre um contraste “descoberto” depois. O método de Scheffé, a seguir, é a resposta formal a essa lacuna: ele protege simultaneamente **todo** o espaço infinito de contrastes lineares possíveis, de modo que, mesmo que o pesquisador escolha o contraste mais favorável depois de olhar os dados, o FWER continua controlado em α.

3.7.2 Método de Scheffé

Controla o FWER para **qualquer** contraste que se queira testar, incluindo contrastes definidos *depois* de examinar os dados (comparações não planejadas, ou "garimpadas", na linha da Seção 3.7.1 (p. 76)) — é o procedimento mais geral e, por isso, o mais conservador. Rejeita-se $H_0 : L = 0$ se

$$\frac{SQ_L}{QME} > (t-1)\, F_{\alpha;\, t-1,\, gl_{\text{erro}}}.$$

O fator $(t-1)$ multiplicando o valor crítico de F é o preço pago por proteger simultaneamente uma família infinita de contrastes possíveis (Scheffé, 1959) — e é exatamente esse fator extra que torna Scheffé a "licença para bisbilhotar os dados" de forma estatisticamente honesta: qualquer contraste, planejado ou não, só é declarado significativo se for grande o bastante para não ser apenas o maior entre muitos desvios aleatórios possíveis.

3.7.3 Método de Bonferroni

O método de Bonferroni (1936) divide o nível de significância global α igualmente entre as m comparações planejadas: cada teste individual é avaliado contra α/m (equivalentemente, cada p-valor é multiplicado por m). É simples, aplica-se a qualquer conjunto pré-especificado de comparações (não só pares), mas é conservador quando m é grande, perdendo poder.

3.7.4 Tukey HSD (*honestly significant difference*)

Desenhado especificamente para **todas as comparações par a par** entre t médias, usa a distribuição da **amplitude estudentizada** (*studentized range*) em vez da distribuição t, o que o torna mais poderoso que Bonferroni para essa família específica de comparações (Tukey, 1949a). É o procedimento padrão quando o objetivo é "comparar tudo com tudo" sem um grupo controle privilegiado.

3.7.5 Comparação com um grupo controle: Dunnett

Quando o interesse não é comparar todos os pares, mas sim **cada tratamento contra um único grupo controle** (como "Nenhum" no exemplo de scripts), o número de comparações cai de $\binom{t}{2}$ para $t-1$, e essas comparações são correlacionadas entre si (todas compartilham o mesmo grupo controle). O teste de Dunnett explora essa estrutura, sendo mais poderoso que Tukey ou Bonferroni para esse propósito específico (Dunnett, 1955).

3.7.6 Teste de amplitude múltipla de Duncan

Todos os procedimentos anteriores usam um **único** valor crítico para julgar qualquer par de médias. O teste de **Duncan** (Duncan, 1955) rompe com essa ideia: ordena as t médias amostrais, $\bar{y}_{(1)} \le \cdots \le \bar{y}_{(t)}$, e define a **amplitude** p de uma comparação como o número de médias ordenadas que ela abrange ($p = 2$ para médias adjacentes, $p = t$ para a maior contra a menor). Para cada amplitude $p = 2, \ldots, t$, calcula-se um valor crítico próprio — a **amplitude mínima significativa**

$$R_p = r_{\alpha,\, p,\, gl_{\text{erro}}} \sqrt{\frac{QME}{n}},$$

em que $r_{\alpha,p,\nu}$ vem de uma tabela específica de Duncan (implementada, por exemplo, em `agricolae::duncan.test()`) e cresce com p: $R_2 < R_3 < \cdots < R_t$. A diferença $\bar{y}_{(j)} - \bar{y}_{(i)}$ é

declarada significativa se exceder R_{j-i+1} — médias adjacentes ($p = 2$) só precisam superar o menor valor crítico da lista, enquanto a diferença entre a maior e a menor média precisa superar o maior.

Essa escala móvel equivale a proteger cada amplitude p com um nível $\alpha_p = 1 - (1 - \alpha)^{p-1}$, que **cresce** com p em vez de permanecer fixo em α — ao contrário de Tukey, que usa o mesmo nível α para toda comparação par a par, qualquer que seja sua amplitude. Na prática, isso torna Duncan sistematicamente mais liberal (mais poder, mais comparações declaradas significativas) do que Tukey, mas ao custo de **não controlar o FWER** no nível nominal α para o conjunto de comparações como um todo — a taxa real de pelo menos um falso positivo na família de testes fica acima de α. Por essa razão, seu uso vem sendo desaconselhado na literatura em favor de procedimentos que controlam o FWER de forma rigorosa (Tukey para pares, Dunnett contra um controle); ainda assim, permanece comum em periódicos de ciências agrárias, o que torna sua interpretação correta — inclusive de suas limitações — relevante para quem for ler ou revisar esse tipo de trabalho.

3.7.7 Agrupamento de tratamentos (*compact letter display*)

Uma forma compacta de reportar o resultado de comparações múltiplas par a par é atribuir letras às médias: tratamentos que compartilham pelo menos uma letra **não** diferem significativamente entre si; tratamentos sem letra em comum diferem. Essa representação (*compact letter display*, CLD) é extremamente comum em tabelas de resultados agronômicos e biológicos.

> **Uso do R** — Tukey, Bonferroni, Scheffé, Dunnett, Duncan e agrupamento

```
emm_scripts <- emmeans(mod_scripts, ~ config)

# todos os pares, três correções diferentes
pairs(emm_scripts, adjust = "tukey")
```

```
##  contrast             estimate   SE df t.ratio p.value
##  Nenhum - Analytics      -86.2 29.5 36  -2.922  0.0291
##  Nenhum - Anúncios      -220.5 29.5 36  -7.478 <0.0001
##  Nenhum - Combo         -254.2 29.5 36  -8.623 <0.0001
##  Analytics - Anúncios   -134.3 29.5 36  -4.556  0.0003
##  Analytics - Combo      -168.1 29.5 36  -5.701 <0.0001
##  Anúncios - Combo        -33.7 29.5 36  -1.144  0.6650
##
## P value adjustment: tukey method for comparing a family of 4 estimates
```

```
pairs(emm_scripts, adjust = "bonferroni")
```

```
##  contrast             estimate   SE df t.ratio p.value
##  Nenhum - Analytics      -86.2 29.5 36  -2.922  0.0359
##  Nenhum - Anúncios      -220.5 29.5 36  -7.478 <0.0001
##  Nenhum - Combo         -254.2 29.5 36  -8.623 <0.0001
##  Analytics - Anúncios   -134.3 29.5 36  -4.556  0.0003
##  Analytics - Combo      -168.1 29.5 36  -5.701 <0.0001
##  Anúncios - Combo        -33.7 29.5 36  -1.144  1.0000
##
## P value adjustment: bonferroni method for 6 tests
```

```
pairs(emm_scripts, adjust = "scheffe")
```

```
##  contrast             estimate   SE df t.ratio p.value
##  Nenhum - Analytics      -86.2 29.5 36  -2.922  0.0511
##  Nenhum - Anúncios      -220.5 29.5 36  -7.478 <0.0001
##  Nenhum - Combo         -254.2 29.5 36  -8.623 <0.0001
##  Analytics - Anúncios   -134.3 29.5 36  -4.556  0.0009
##  Analytics - Combo      -168.1 29.5 36  -5.701 <0.0001
##  Anúncios - Combo        -33.7 29.5 36  -1.144  0.7282
##
## P value adjustment: scheffe method with rank 3
```

```
# cada tratamento vs. o controle "Nenhum" (Dunnett)
contrast(emm_scripts, method = "trt.vs.ctrl", ref = "Nenhum", adjust = "dunnettx")
```

```
##  contrast           estimate   SE df t.ratio p.value
##  Analytics - Nenhum     86.2 29.5 36   2.922  0.0167
##  Anúncios - Nenhum     220.5 29.5 36   7.478 <0.0001
##  Combo - Nenhum        254.2 29.5 36   8.623 <0.0001
##
## P value adjustment: dunnettx method for 3 tests
```

```
# agrupamento compacto por letras (compact letter display)
multcomp::cld(emm_scripts, Letters = letters, adjust = "tukey")
```

```
##  config    emmean   SE df lower.CL upper.CL .group
##  Nenhum       859 20.8 36      805      914  a
##  Analytics    946 20.8 36      891     1000   b
##  Anúncios    1080 20.8 36     1025     1135    c
##  Combo       1114 20.8 36     1059     1168    c
##
## Confidence level used: 0.95
## Conf-level adjustment: sidak method for 4 estimates
## P value adjustment: tukey method for comparing a family of 4 estimates
## significance level used: alpha = 0.05
## NOTE: If two or more means share the same grouping symbol,
##       then we cannot show them to be different.
##       But we also did not show them to be the same.
```

```
# Teste de Duncan (amplitude múltipla): fora do R base, via agricolae
duncan_scripts <- agricolae::duncan.test(mod_scripts, "config", console = FALSE)
duncan_scripts$groups   # médias ordenadas + agrupamento por letras (Duncan)
```

```
##            tempo_ms groups
## Combo     1113.6160      a
## Anúncios  1079.8775      a
## Analytics  945.5325      b
## Nenhum     859.3801      c
```

O agrupamento de Duncan reaparece na coluna `groups` acima: neste conjunto de dados, ele coincide com o `cld()` de Tukey exibido antes (mesma partição em três grupos, “a”/“b”/“c”), porque os quatro efeitos de configuração são grandes o bastante para que até o critério mais rigoroso de Tukey já os separe. A diferença entre os dois métodos fica visível justamente nos casos de fronteira — pares cuja diferença observada fica **entre** o valor crítico mais liberal de Duncan para aquela amplitude e o valor crítico único, mais conservador, de Tukey; nesses casos, e só neles, Duncan declara significativo um par que Tukey não declara, exatamente o preço, discutido acima, de usar valores críticos R_p menores para amplitudes pequenas sem controlar rigorosamente o FWER no nível nominal.

Note que os quatro procedimentos concordam nas conclusões mais nítidas (Nenhum difere de todos os demais) mas divergem nos casos de fronteira: Bonferroni e Scheffé — os mais conservadores — não rejeitam a diferença entre “Nenhum” e “Analytics” ao nível de 5%, enquanto Tukey a considera significativa. Não existe um procedimento universalmente “correto”; a escolha depende de qual família de comparações reflete a pergunta de pesquisa.

Um par difere significativamente quando seu IC não cruza zero: só “Anúncios − Combo” cruza, confirmando SQ_{L_3} não significativo da partição por contrastes ortogonais.

Para discutir

1. Por que faz sentido usar Dunnett (não Tukey) quando a única pergunta de interesse é "cada configuração aumenta o tempo de carregamento em relação a não usar nenhum script?"
2. Um pesquisador roda a ANOVA, olha os dados, percebe uma diferença "interessante" entre dois grupos que não tinha planejado comparar, e testa essa diferença com um teste t comum. Por que isso viola as premissas por trás de todos os procedimentos desta seção, mesmo que o p-valor reportado pareça pequeno?
3. Em que situação prática o conservadorismo extra do método de Scheffé compensa a perda de poder, em vez de ser simplesmente um custo a evitar?
4. O teste de Duncan é mais liberal que Tukey porque usa um nível de proteção α_p que cresce com a amplitude p da comparação, em vez de manter α fixo. Isso é uma vantagem ou uma desvantagem? Em que tipo de publicação você esperaria ver Duncan preferido a Tukey, apesar de sua FWER não controlada?

3.8 Polinômios ortogonais

Quando os níveis do fator são **quantitativos e igualmente espaçados** — como doses de um fármaco, ou concentrações de um insumo — comparar médias par a par desperdiça a informação de que os níveis têm uma ordem e uma métrica. Nesses casos, é mais informativo perguntar: *a resposta cresce linearmente com o nível? Há curvatura (efeito quadrático)? A curva se inverte de novo (cúbico)?* Polinômios ortogonais decompõem SQ_{Trat} exatamente nesses componentes.

```
set.seed(7)
dose_mg <- c(0, 50, 100, 150, 200)
n_dose  <- 8

# covariável: nível basal de atenção (medido ANTES da dose), usado adiante na ANCOVA
basal <- rnorm(5 * n_dose, mean = 60, sd = 8)
dose_f <- factor(rep(dose_mg, each = n_dose))

# efeito verdadeiro tem forma de "U invertido": atenção sobe com a dose até um
# ponto e depois cai (excesso de estimulação) -- um caso clássico de curvatura
efeito_dose <- function(d) 20 + 0.35 * d - 0.0013 * d^2

cafeina <- tibble(
  participante = 1:(5 * n_dose),
  dose         = dose_f,
  basal        = basal,
  atencao_pos  = 40 + 0.5 * basal + efeito_dose(as.numeric(as.character(dose_f))) +
```

```
    rnorm(5 * n_dose, mean = 0, sd = 5))
```

Aplicação — Psicologia: dose de cafeína e atenção sustentada
Um laboratório testa o efeito da cafeína (0, 50, 100, 150 e 200 mg) sobre o desempenho em um teste de atenção sustentada, aplicado 40 minutos após a ingestão. Quarenta participantes são sorteados em 5 grupos de 8 (**UE = participante**). Os níveis do fator — a dose — são quantitativos e igualmente espaçados em 50 mg, o cenário ideal para polinômios ortogonais.

3.8.1 Esperança, variância e soma de quadrados

Para níveis quantitativos igualmente espaçados e n constante por grupo, existe uma tabela padrão de coeficientes ortogonais λ_i (Fisher & Yates) para cada grau do polinômio — linear, quadrático, cúbico etc. — com até $t-1$ graus disponíveis para t níveis:

Tabela 3.14: Coeficientes ortogonais tabulados para $t = 5$ níveis igualmente espaçados

Grau	0 mg	50 mg	100 mg	150 mg	200 mg
Linear	-2	-1	0	1	2
Quadrático	2	-1	-2	-1	2
Cúbico	-1	2	0	-2	1
Quártico	1	-4	6	-4	1

Cada linha da tabela é um contraste com $\sum_i \lambda_i = 0$, e quaisquer duas linhas são ortogonais entre si ($\sum_i \lambda_i \lambda_i' = 0$) — são exatamente o caso particular de contrastes ortogonais da Seção 3.6 (p. 71), com coeficientes escolhidos para isolar tendência polinomial em vez de comparações ad hoc entre grupos. Para o componente de grau k, com coeficientes λ_i:

$$\hat{L}_k = \sum_{i=1}^{t} \lambda_i \bar{y}_{i\cdot}, \qquad \operatorname{Var}(\hat{L}_k) = \frac{\sigma^2}{n} \sum_{i=1}^{t} \lambda_i^2, \qquad SQ_k = \frac{n\,\hat{L}_k^{\,2}}{\sum_{i=1}^{t} \lambda_i^2},$$

cada um com 1 grau de liberdade, e $SQ_{\text{Trat}} = \sum_{k=1}^{t-1} SQ_k$ exatamente como na partição por contrastes ortogonais gerais. Na prática, o R constrói esses coeficientes automaticamente (função `contr.poly()`), reescalados para ter norma 1.

3.8.2 A matriz de polinômios ortogonais como parte de $\mathbf{X}$

Os coeficientes tabulados acima não são um truque à parte: são, literalmente, colunas adicionais da matriz de delineamento $\mathbf{X}$. Na parametrização por polinômios ortogonais, o modelo do DCA para a cafeína se escreve

$$\mathbf{Y} = \mathbf{X}_{\text{poly}}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \qquad \mathbf{X}_{\text{poly}} = \left[\, \mathbf{1} \mid \boldsymbol{\lambda}_L \mid \boldsymbol{\lambda}_Q \mid \boldsymbol{\lambda}_C \mid \boldsymbol{\lambda}_4 \,\right], \qquad \boldsymbol{\beta} = (\mu,\ \beta_L,\ \beta_Q,\ \beta_C,\ \beta_4)',$$

em que cada $\boldsymbol{\lambda}_k$ ($N \times 1$) repete o coeficiente tabulado do grau k tantas vezes quanto o número de réplicas na respectiva dose — exatamente as colunas que `contr.poly(5)` gera. Como as cinco colunas de $\mathbf{X}_{\text{poly}}$ são mutuamente ortogonais por construção (o intercepto $\mathbf{1}$ incluído: $\mathbf{1}'\boldsymbol{\lambda}_k = 0$ para todo k), $\mathbf{X}_{\text{poly}}'\mathbf{X}_{\text{poly}}$ é **diagonal** — a situação mais simples possível para mínimos quadrados: cada $\hat{\beta}_k$ se estima independentemente dos demais, sem covariância entre as estimativas, e SQ_k é exatamente a forma quadrática de posto 1 da Seção 3.6 (p. 71), com $\boldsymbol{\lambda} = \boldsymbol{\lambda}_k$. Essa é a razão algébrica — não apenas um

resultado feliz — de SQ_{Trat} se decompor sem sobra em $t-1$ somas de quadrados de 1 grau de liberdade cada.

```
contrasts(cafeina$dose) <- contr.poly(5)
X_poly <- model.matrix(atencao_pos ~ dose, data = cafeina)  # 5 colunas: 1, L, Q, C,
        quártico

round(crossprod(X_poly), 3)  # X'X_poly -- diagonal, exatamente como o argumento
        algébrico prevê
```

```
##             (Intercept) dose.L dose.Q dose.C dose^4
## (Intercept)          40      0      0      0      0
## dose.L                0      8      0      0      0
## dose.Q                0      0      8      0      0
## dose.C                0      0      0      8      0
## dose^4                0      0      0      0      8
```

Uso do R — ANOVA com componentes polinomiais

```
contrasts(cafeina$dose) <- contr.poly(5)  # coeficientes ortogonais, dose como fator
mod_poly <- aov(atencao_pos ~ dose, data = cafeina)

summary(mod_poly, split = list(dose = list(Linear = 1, Quadratic = 2,
                                           Cubic = 3, Quartic = 4)))
```

```
##                   Df Sum Sq Mean Sq F value   Pr(>F)
## dose               4   3717   929.2  22.534 2.82e-09 ***
##   dose: Linear     1   1089  1089.4  26.419 1.05e-05 ***
##   dose: Quadratic  1   2345  2345.3  56.874 7.75e-09 ***
##   dose: Cubic      1     29    28.5   0.692   0.4110
##   dose: Quartic    1    254   253.6   6.149   0.0181 *
## Residuals         35   1443    41.2
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Como no experimento do algodão de Montgomery — um DCA clássico em que a resistência de um fio têxtil é medida sob cinco concentrações de algodão igualmente espaçadas —, o jeito mais direto de “ver” qual grau de polinômio é necessário é ajustar os quatro graus possíveis lado a lado e comparar visualmente o quanto cada um se aproxima das cinco médias observadas:

```
c(R2_linear = summary(mod_lin_num)$r.squared, R2_quadratico =
        summary(mod_quad_num)$r.squared,
  R2_cubico = summary(mod_cub_num)$r.squared, R2_quartico =
        summary(mod_quart_num)$r.squared)
```

```
##     R2_linear R2_quadratico     R2_cubico   R2_quartico
##     0.2111213     0.6656282     0.6711609     0.7203006
```

O painel deixa a progressão visível: a reta (canto superior esquerdo) claramente erra por baixo no meio da faixa de doses e por cima nas pontas, com $R^2 \approx 0.21$ apenas; a parábola (canto superior direito) já captura a maior parte do padrão — sobe até um pico e desce —, saltando para $R^2 \approx 0.67$; os ajustes cúbico e quártico (linha de baixo) acrescentam flexibilidade extra, mas a melhora de R^2 de um para o outro é pequena, sinal de que os termos de ordem mais alta agregam pouco além do que a parábola já explica. Essa

é a mesma conclusão que a tabela ANOVA particionada abaixo confirma numericamente, mas o painel a torna imediatamente visível: o **grau necessário** para descrever a curva de resposta é o menor grau que já "parece certo" a olho, antes mesmo de olhar qualquer p-valor — os testes formais servem para confirmar, com rigor, o que o gráfico já sugeriu.

O termo **linear** e o **quadrático** são ambos significativos, consistente com a curva de resposta desenhada por construção: a atenção sobe com a dose até um ponto e depois se estabiliza ou cai — um clássico efeito de "U invertido" na relação entre estimulação e desempenho. Isso é informação que uma ANOVA comum, ou comparações par a par entre as 5 doses, não expõe diretamente: a decomposição polinomial responde à pergunta de forma que o pesquisador realmente tem em mente quando o fator é uma dose.

3.9 Análise de covariância (ANCOVA)

Mesmo com aleatorização perfeita, grupos podem diferir por acaso em alguma variável relevante medida **antes** do tratamento — aqui, o nível basal de atenção de cada participante. A **análise de covariância** incorpora essa covariável ao modelo para (i) ajustar as médias de tratamento pela diferença de linha de base entre grupos e (ii) remover parte da variação residual explicada pela covariável, aumentando a precisão da comparação entre tratamentos.

3.9.1 O modelo

$$y_{ij} = \mu + \tau_i + \beta\,(x_{ij} - \bar{x}_{\cdot\cdot}) + \varepsilon_{ij}, \qquad \varepsilon_{ij} \sim N(0, \sigma^2)\ \text{i.i.d.},$$

onde x_{ij} é a covariável (o basal, medido antes de qualquer tratamento) e β é a inclinação **comum** a todos os grupos — pressuposto central da ANCOVA, chamado de *homogeneidade das inclinações*, que deve ser verificado antes de interpretar o modelo: se a relação entre covariável e resposta difere por grupo (interação $\tau_i \times x_{ij}$ significativa), o ajuste simples por uma única inclinação comum deixa de fazer sentido, e a covariável deve ser tratada de outra forma (por exemplo, analisando os grupos separadamente).

As médias de tratamento são reportadas **ajustadas** para o valor médio geral da covariável:

$$\bar{y}_{i\cdot(\text{ajustada})} = \bar{y}_{i\cdot} - \hat{\beta}\,(\bar{x}_{i\cdot} - \bar{x}_{\cdot\cdot}).$$

3.9.2 ANCOVA em notação matricial: mais uma coluna em $\mathbf{X}$

Nenhuma teoria nova precisa ser aprendida para tratar a ANCOVA algebricamente: basta acrescentar a covariável como mais uma coluna de $\mathbf{X}$. Com qualquer parametrização de posto completo para o efeito de tratamento,

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \qquad \mathbf{X} = \left[\ \mathbf{X}_{\text{trat}} \mid \mathbf{z}\ \right], \qquad \boldsymbol{\beta} = \begin{bmatrix} \boldsymbol{\tau} \\ \beta \end{bmatrix},$$

em que $\mathbf{X}_{\text{trat}}$ codifica o fator dose como em qualquer DCA (Capítulo 2, Seção 2.3 (p. 20)) e $\mathbf{z}$ ($N \times 1$) é a coluna da covariável (o basal). A ANCOVA é, literalmente, **um caso particular do modelo linear geral** — a única novidade é uma coluna extra em $\mathbf{X}$.

Geometricamente, essa coluna extra amplia o espaço-coluna de $\mathbf{X}_{\text{trat}}$ em uma dimensão. A projeção $\mathbf{P}_X$ passa a projetar sobre esse espaço maior, e o teste de tratamento **ajustado** pela covariável é, de novo, uma soma de quadrados extra (Capítulo 2, Seção 2.8 (p. 33)) — mas comparando dois modelos que **já incluem** a covariável:

$$SQ_{\text{Trat(ajustado)}} = \mathbf{Y}'\big(\mathbf{P}_X - \mathbf{P}_{[\mathbf{1}\mid\mathbf{z}]}\big)\mathbf{Y},$$

a diferença entre projetar sobre $[\mathbf{X}_{\text{trat}} \mid \mathbf{z}]$ e projetar apenas sobre $[\mathbf{1} \mid \mathbf{z}]$ (o modelo só com a covariável, sem tratamento). O ajuste pela covariável é, nesse sentido, **uma projeção adicional**: primeiro removemos a direção de **z** do espaço de resposta, e só então perguntamos se o tratamento explica alguma variação **além** dela — exatamente por que a soma de quadrados sequencial da tabela a seguir entra a covariável primeiro.

```
X_ancova <- model.matrix(atencao_pos ~ dose + basal, data = cafeina)  # X_trat | z
dim(X_ancova)                                      # N x (t + 1): 5 colunas de dose +
        basal
```

```
## [1] 40  6
```

```
beta_hat_ancova <- solve(t(X_ancova) %*% X_ancova) %*% t(X_ancova) %*%
        cafeina$atencao_pos
round(t(beta_hat_ancova), 3)                       # bate com coef(mod_ancova) abaixo
```

```
##      (Intercept) dose.L  dose.Q dose.C dose^4 basal
## [1,]       68.36 13.281 -14.009 -1.748 -2.507 0.625
```

3.9.3 A tabela de ANOVA ajustada pela covariável

A soma de quadrados total se particiona em covariável (regressão), tratamento (ajustado pela covariável) e erro — nessa ordem, porque a covariável deve ser removida do erro **antes** de avaliar o efeito de tratamento:

> **Uso do R** — ANCOVA: ajustando pela atenção basal

```
# 1. Verificar homogeneidade das inclinações: a interação basal:dose deve ser não
        significativa
mod_inclinacoes <- lm(atencao_pos ~ basal * dose, data = cafeina)
anova(mod_inclinacoes)
```

```
## Analysis of Variance Table
##
## Response: atencao_pos
##            Df  Sum Sq Mean Sq F value    Pr(>F)
## basal       1 1478.46 1478.46 79.2477 6.384e-10 ***
## dose        4 3022.36  755.59 40.5009 1.103e-11 ***
## basal:dose  4   99.50   24.87  1.3333    0.2804
## Residuals  30  559.68   18.66
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
# 2. Interação não significativa (p > 0.05) -> prossegue com o modelo aditivo
        (ANCOVA)
mod_ancova <- lm(atencao_pos ~ basal + dose, data = cafeina)
anova(mod_ancova)          # soma de quadrados sequencial: covariável entra primeiro
```

```
## Analysis of Variance Table
##
## Response: atencao_pos
##           Df  Sum Sq Mean Sq F value    Pr(>F)
## basal      1 1478.46 1478.46  76.257 3.327e-10 ***
## dose       4 3022.36  755.59  38.973 2.988e-12 ***
## Residuals 34  659.18   19.39
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
# médias de dose ajustadas para o valor médio de basal (emmeans faz o ajuste
        automaticamente)
emmeans(mod_ancova, ~ dose)
```

```
##  dose emmean   SE df lower.CL upper.CL
##  0      91.6 1.59 34     88.3     94.8
##  50    106.8 1.75 34    103.3    110.4
##  100   112.9 1.56 34    109.7    116.1
##  150   117.4 1.56 34    114.3    120.6
##  200   107.3 1.59 34    104.0    110.5
##
## Confidence level used: 0.95
```

O termo `basal` é altamente significativo — confirma que a covariável de fato explica parte da variação em atenção pós-dose e "vale a pena" incorporar ao modelo — e o termo `dose`, ajustado para basal, permanece significativo, com quadrado médio do erro (`Residuals`) menor do que na ANOVA sem covariável da seção anterior: a ANCOVA tornou a comparação entre doses mais precisa ao remover uma fonte de variação conhecida (a atenção basal) do erro experimental, no mesmo espírito da blocagem — mas usando uma covariável contínua, medida, em vez de um agrupamento categórico.

A visualização canônica da ANCOVA é o gráfico de dispersão da resposta contra a covariável, colorido por tratamento, com uma reta de regressão ajustada para cada grupo. Sob o modelo aditivo (inclinações homogêneas), essas retas são **paralelas por construção** — a mesma inclinação $\hat{\beta}$, só com interceptos diferentes por dose:

As cinco retas sobem juntas (inclinação comum $\hat{\beta} \approx 0.62$: cada ponto a mais de atenção basal está associado, em média, a esse mesmo ganho de atenção pós-dose, **qualquer que seja a dose**), mas partem de alturas diferentes — é essa separação vertical entre as retas, e não a inclinação, que representa o efeito ajustado da dose. Visualmente, a reta da dose de 150 mg fica acima das demais mesmo comparando participantes com o **mesmo** nível basal, confirmando que a diferença não é inteiramente explicada pela covariável — é exatamente essa comparação "a covariável igual" que a ANCOVA formaliza e que a inspeção das médias brutas (sem ajuste) não deixaria clara.

Para discutir

1. Por que é essencial que a covariável seja medida *antes* do tratamento (ou, ao menos, não ser afetada por ele)? O que dá errado se, em vez do basal, o "basal" fosse medido depois de alguns participantes já terem recebido cafeína?
2. Compare ANCOVA com blocagem por uma variável categórica (Capítulo 4): em que situação prática uma covariável contínua está disponível, mas uma blocagem categórica não seria possível ou seria menos eficiente?

3.10 Teste de Kruskal-Wallis

Todos os procedimentos anteriores neste capítulo assumem normalidade dos erros e variância homogênea entre grupos — pressupostos que a seção sobre verificação de pressupostos ensinou a checar. Quando esses pressupostos falham de forma severa (assimetria acentuada, valores atípicos influentes, amostras muito pequenas) e nenhuma transformação os resolve satisfatoriamente, o **teste de Kruskal-Wallis** oferece uma alternativa não paramétrica à ANOVA de um fator (Kruskal & Wallis, 1952), testando se as t populações têm a mesma distribuição (em particular, a mesma mediana) sem assumir normalidade.

```
# tempos de carregamento reais são tipicamente assimétricos à direita: a maioria das
# cargas é rápida, mas uma cauda de conexões lentas/congestionadas produz outliers.
# Simulamos esse cenário contaminando o dataset de scripts com alguns tempos
        extremos.
dados_scripts_out <- dados_scripts
set.seed(3)
idx_lentos <- sample(seq_len(nrow(dados_scripts_out)), 4)
dados_scripts_out$tempo_ms[idx_lentos] <- dados_scripts_out$tempo_ms[idx_lentos] +
  rexp(4, rate = 1 / 2000)
```

Aplicação — Ciência de dados: carregamento de página com conexões lentas
Retomamos o experimento de configurações de scripts, mas agora quatro carregamentos (de 40) foram medidos em conexões congestionadas, produzindo tempos muito acima do restante da amostra. Um teste de Shapiro-Wilk sobre os resíduos da ANOVA rejeitaria normalidade — o cenário em que o Kruskal-Wallis é a escolha mais defensável.

3.10.1 O que muda em relação à ANOVA

O procedimento substitui os valores observados pelos seus **postos** (*ranks*) na amostra combinada de $N = \sum n_i$ observações (posto 1 para o menor valor, N para o maior, com médias de posto em caso de empates). Sendo R_i a soma dos postos no grupo i, a estatística é

$$H = \frac{12}{N(N+1)} \sum_{i=1}^{t} \frac{R_i^2}{n_i} \; - \; 3(N+1),$$

que, sob H_0 (as t populações têm a mesma distribuição) e amostras não muito pequenas, segue aproximadamente $H \sim \chi^2_{t-1}$. Intuitivamente, H mede o quanto os postos médios de cada grupo se afastam do posto médio esperado sob a hipótese nula — um “ANOVA sobre os postos”, em vez de sobre os valores

originais, o que o torna robusto a outliers e a distribuições assimétricas, ao custo de menor poder quando a normalidade de fato se sustenta.

> **Uso do R** — Kruskal-Wallis e comparações par a par não paramétricas

```
kruskal.test(tempo_ms ~ config, data = dados_scripts_out)
```

```
##
##  Kruskal-Wallis rank sum test
##
## data:  tempo_ms by config
## Kruskal-Wallis chi-squared = 22.026, df = 3, p-value = 6.443e-05
```

```
# comparações par a par não paramétricas, com correção de Bonferroni
pairwise.wilcox.test(dados_scripts_out$tempo_ms, dados_scripts_out$config,
                     p.adjust.method = "bonferroni")
```

```
##
##  Pairwise comparisons using Wilcoxon rank sum exact test
##
## data:  dados_scripts_out$tempo_ms and dados_scripts_out$config
##
##           Nenhum  Analytics Anúncios
## Analytics 0.21278 -         -
## Anúncios  0.00903 0.01254   -
## Combo     0.00903 0.00026   1.00000
##
## P value adjustment method: bonferroni
```



Tempo de carregamento por configuração, com os quatro tempos contaminados por conexões lentas (destacados). A cauda assimétrica à direita, presente em pelo menos uma configuração, é o sintoma visual que motiva a troca da ANOVA pelo teste de Kruskal-Wallis.

Figura 3.12: Tempo de carregamento por configuração, com os quatro tempos contaminados por conexões lentas (destacados). A cauda assimétrica à direita, presente em pelo menos uma configuração, é o sintoma visual que motiva a troca da ANOVA pelo teste de Kruskal-Wallis.

Os quatro pontos em laranja — sorteados aleatoriamente entre as 40 observações, portanto espalhados de forma desigual entre as quatro configurações — puxam a caixa correspondente para cima e alongam sua cauda superior, exatamente o tipo de assimetria que infla a variância dentro de grupo e compromete a suposição de normalidade dos resíduos por trás do teste F clássico. É essa distorção visual, e não apenas o resultado do teste de Shapiro-Wilk mencionado na aplicação acima, que justifica substituir os valores brutos pelos seus postos.

O teste de Kruskal-Wallis rejeita H_0 com folga, confirmando que as configurações diferem mesmo na presença dos valores atípicos que violariam os pressupostos da ANOVA clássica — e as comparações par a par por postos (Wilcoxon com correção de Bonferroni) mantêm o padrão geral de conclusões da Seção 3.7 (p. 76), com um pouco menos de nitidez nas diferenças mais sutis, o preço esperado por abrir mão do pressuposto de normalidade.

3.11 Resumo do capítulo

Este capítulo cobriu o delineamento completamente aleatorizado (DCA) do início ao fim:

- Um **teste de aleatorização** obtém validade diretamente do mecanismo físico de sorteio dos tratamentos, sem pressupor normalidade; o teste F da ANOVA normal-linear é, sob condições razoáveis, uma excelente aproximação a ele.
- O modelo do DCA, $Y_{ij} = \mu + \tau_i + \varepsilon_{ij}$, gera a tabela de ANOVA, ICs para médias e diferenças de médias, e um cálculo de número de réplicas baseado em tamanho de efeito.
- **Submuestreo** exige um segundo termo de erro no modelo; o teste correto do tratamento usa o erro *experimental* (entre unidades experimentais), não o de amostragem — usar o segundo por engano é pseudorreplicação.
- O **modelo de efeitos aleatórios** troca “os níveis diferem?” por “quanto os níveis variam?”, com a mesma tabela de ANOVA mas esperanças de quadrados médios e planejamento amostral diferentes.
- Normalidade e homocedasticidade dos resíduos devem ser verificadas antes de confiar na ANOVA; quando falham, transformações da família Box-Cox costumam restaurar a validade da análise.
- **Contrastes**: sua esperança, variância, soma de quadrados com 1 grau de liberdade e distribuição F; e **contrastes ortogonais**, que particionam SQ_{Trat} em perguntas independentes planejadas a priori.
- O perigo do **“data snooping”** — testar como planejada uma hipótese formulada só depois de ver os dados — e por que o método de **Scheffé** é a resposta formal a ele, protegendo o espaço infinito de todos os contrastes possíveis.
- **Procedimentos de comparação múltipla** (Scheffé, Bonferroni, Tukey, Dunnett, Duncan, agrupamento por letras) para controlar (ou, no caso de Duncan, deliberadamente não controlar) a taxa de erro por família quando muitas comparações são feitas sobre o mesmo conjunto de dados.
- **Polinômios ortogonais**, o caso particular de contrastes ortogonais mais útil quando os níveis do fator são quantitativos e igualmente espaçados, decompondo a tendência em componentes linear, quadrático, cúbico etc.
- **ANCOVA**, que ajusta as médias de tratamento e reduz o erro experimental incorporando uma covariável contínua medida antes do tratamento — o análogo, para covariáveis contínuas, do que a blocagem faz para fatores categóricos.
- O teste de **Kruskal-Wallis**, alternativa não paramétrica baseada em postos para quando os pressupostos da ANOVA não se sustentam.

Todo esse ferramental resolve comparações dentro de **um único** fator de classificação. O Capítulo 4 introduz uma segunda fonte de estrutura no delineamento — os **blocos** — mostrando como controlar formalmente uma fonte de variação sistemática conhecida (turma, dia, sujeito, talhão) sem sacrificar a validade da comparação entre tratamentos.

4 Delineamentos com fontes de bloqueio

O princípio do **controle local** foi apresentado na Seção 1.4 (p. 8): quando se sabe de antemão que as unidades experimentais não são homogêneas, agrupá-las em blocos internamente homogêneos e aleatorizar os tratamentos *dentro* de cada bloco retira uma fonte conhecida de variação do erro experimental antes mesmo da análise. Este capítulo formaliza essa ideia. Partimos do caso de **uma única fonte de bloqueio** (o delineamento em blocos completos aleatorizados, DBCA), tratamos do que fazer quando falta uma observação e de como quantificar o ganho obtido com a blocagem. Em seguida apresentamos uma alternativa não paramétrica (teste de Friedman) e uma extensão para quando os blocos são pequenos demais para conter todos os tratamentos (blocos incompletos balanceados). Terminamos com **duas fontes de bloqueio cruzadas** (quadrado latino) e **três** (quadrado greco-latino).

4.1 O delineamento em blocos completos aleatorizados (DBCA)

4.1.1 Motivação: o que dá errado sem controle local — fatores confundidos

Antes de descrever o DBCA formalmente, vale entender **o que exatamente ele evita**. Dois fatores A e B são ditos **completamente confundidos** quando, no delineamento usado, seus efeitos são matematicamente indistinguíveis — toda vez que A está em um certo nível, B também está, sem exceção, de modo que nenhuma comparação isola um do outro.

> **Aplicação — Ciência de dados: um programa de incentivo mal desenhado**
> Uma prefeitura lança um programa de incentivo ao comércio local e, por conveniência logística, implementa-o apenas em bairros de renda alta, usando bairros de renda baixa como "controle" (sem o programa). Depois de um trimestre, compara o faturamento médio do comércio nos bairros com programa contra os sem programa.

```
set.seed(777)
dados_confundido <- tibble(
  bairro    = c("Boa Viagem", "Casa Forte", "Graças", "Ibura", "Coelhos", "Brasília
        Teimosa"),
  renda     = factor(rep(c("Alta", "Baixa"), each = 3), levels = c("Alta", "Baixa")),
  programa  = factor(rep(c("Incentivo", "Controle"), each = 3), levels =
        c("Incentivo", "Controle")),
  # bairros de renda alta já faturam mais, com ou sem programa
  faturamento = c(rnorm(3, 520, 40), rnorm(3, 210, 25))
)
dados_confundido
```

```
## # A tibble: 6 × 4
##   bairro           renda programa  faturamento
##   <chr>            <fct> <fct>           <dbl>
## 1 Boa Viagem       Alta  Incentivo        540.
## 2 Casa Forte       Alta  Incentivo        504.
## 3 Graças           Alta  Incentivo        540.
## 4 Ibura            Baixa Controle         200.
## 5 Coelhos          Baixa Controle         251.
## 6 Brasília Teimosa Baixa Controle         226.
```

```
ggplot(dados_confundido, aes(x = programa, y = faturamento, fill = renda)) +
  geom_boxplot(alpha = 0.6, width = 0.5) +
  geom_jitter(width = 0.08, size = 2.6) +
  scale_fill_manual(values = c("#2a78d6", "#eb6834"), name = "Renda do bairro") +
  labs(x = NULL, y = "Faturamento médio (R$ mil)",
       title = "Efeito aparente do programa — ou efeito de renda?") +
  theme_minimal(base_size = 12)
```

O grupo “Incentivo” fatura visivelmente mais — mas **não há como saber se isso é efeito do programa, da renda pré-existente do bairro, ou de ambos**, porque `renda` e `programa` variam em perfeita sincronia nesse delineamento: todo bairro de renda alta recebeu o programa, e nenhum de renda baixa recebeu. Ajustar `lm(faturamento ~ renda + programa)` sequer é possível de forma identificável aqui (as duas colunas de X seriam idênticas a menos de uma constante) — o R reportaria um coeficiente `NA` para uma delas. Isso não é uma falha de estimação, é uma falha de **delineamento**: nenhuma quantidade de dados adicionais no mesmo esquema resolveria o problema.

O DBCA é, em certo sentido, o oposto desse erro. Ele **não** trava um tratamento a um nível fixo de uma variável de ruído (o que criaria confusão); ao contrário, ele **agrupa** unidades por essa variável de ruído em blocos e depois **sorteia** os tratamentos dentro de cada bloco, de modo que todo tratamento seja observado em todo nível da variável de ruído. Um bairro poderia, por exemplo, funcionar como bloco geográfico legítimo — desde que a alocação do tratamento dentro dele seja aleatória, não determinada pela própria característica do bloco. O mapa abaixo, com os bairros do Recife (RPA — Região Político-Administrativa) coloridos por sua área de planejamento, ilustra a escala em que uma blocagem geográfica desse tipo é definida: cada RPA agruparia unidades vizinhas, presumivelmente mais parecidas entre si, dentro das quais os tratamentos seriam então sorteados.

```
recife <- st_read("../Aulas2026/assets/Bairros_Recife/bairros-polygon.shp", quiet =
        TRUE)

ggplot(recife) +
  geom_sf(aes(fill = factor(rpa)), color = "white", linewidth = 0.15) +
  scale_fill_brewer(palette = "Set2", name = "RPA\n(bloco geográfico)") +
  labs(title = "Bairros do Recife agrupados por Região Político-Administrativa",
       subtitle = "Cada RPA poderia servir de bloco geográfico em um DBCA") +
  theme_minimal(base_size = 11) +
  theme(axis.text = element_blank(), panel.grid = element_blank())
```

Com 94 bairros distribuídos em seis RPAs, um pesquisador que quisesse comparar, por exemplo, três estratégias de precificação no comércio local poderia blocar por RPA (controlando diferenças regionais de renda e densidade comercial) e, **dentro de cada RPA**, sortear os bairros participantes entre as três estratégias — o mesmo princípio do exemplo agrícola que segue, só que com blocos definidos por geografia urbana em vez de área de viveiro.

4.1.2 O modelo

Sejam t tratamentos e b blocos. No DBCA, cada bloco contém exatamente uma unidade experimental por tratamento — os blocos são “completos” porque nenhum tratamento fica de fora de nenhum bloco — e a ordem de aplicação dos tratamentos dentro de cada bloco é sorteada independentemente em cada bloco. O modelo estatístico é

$$Y_{ij} = \mu + \tau_i + \beta_j + \varepsilon_{ij}, \qquad i = 1, \dots, t;\ j = 1, \dots, b,$$

em que μ é a média geral, τ_i é o efeito (fixo) do i-ésimo tratamento, β_j é o efeito do j-ésimo bloco (em geral tratado como aleatório, $\beta_j \sim N(0, \sigma^2_\beta)$, independente dos erros, embora a análise de efeitos fixos produza os mesmos testes-F sobre os tratamentos) e $\varepsilon_{ij} \sim N(0, \sigma^2)$, independentes. Usamos as restrições $\sum_i \tau_i = 0$ e $\sum_j \beta_j = 0$ para identificabilidade. Note a ausência de um termo de interação tratamento$\times$bloco: o modelo assume que o efeito de um tratamento é o mesmo, a menos de erro aleatório, em todos os blocos (**aditividade** tratamento-bloco) — retomaremos essa suposição ao final da seção.



Situação Experimental 4: a mesma lógica de unidade experimental (UE) e unidade amostral da Seção 3.5, agora cruzada com blocos. Dentro de cada Bloco, os três tratamentos são sorteados independentemente entre as UEs daquele bloco; cada UE contém, por sua vez, duas unidades amostrais (vasos) medidas individualmente.

Figura 4.1: Situação Experimental 4: a mesma lógica de unidade experimental (UE) e unidade amostral da Seção 3.5, agora cruzada com blocos. Dentro de cada Bloco, os três tratamentos são sorteados independentemente entre as UEs daquele bloco; cada UE contém, por sua vez, duas unidades amostrais (vasos) medidas individualmente.

O diagrama retoma as Situações Experimentais 1 e 2 da Seção 3.3 (p. 57), acrescentando agora a estrutura de blocagem: cada retângulo maior (“Bloco 1”, “Bloco 2”) é um bloco completo, e o sorteio dos três tratamentos ocorre **dentro** de cada bloco, de forma independente — Bloco 1 sorteia a ordem Trat. 3, Trat. 1, Trat. 2, enquanto Bloco 2 sorteia Trat. 1, Trat. 3, Trat. 2, uma permutação diferente, exatamente como a Seção 4.1 (p. 89) descreve a aleatorização restrita: cada UE dentro de um bloco tem a mesma chance de receber cada tratamento, mas o sorteio não se estende entre blocos. Note também que cada UE aqui contém duas unidades amostrais (dois vasos), o que significa que este desenho combina blocagem **e** submuestreo simultaneamente — um lembrete de que as duas ideias (Seção 3.3 (p. 57) e esta seção) não são mutuamente exclusivas: é perfeitamente possível ter um DBCA com submuestreo dentro de cada UE, embora o modelo $Y_{ij} = \mu + \tau_i + \beta_j + \varepsilon_{ij}$ apresentado acima descreva o caso mais simples, sem submuestreo (uma única observação por combinação tratamento-bloco).

4.1.3 Notação matricial: $Y = X\beta + \varepsilon$

O modelo do DBCA é um caso particular do modelo linear geral que formalizaremos no Capítulo 2, $Y = X\beta + \varepsilon$, e vale a pena escrevê-lo assim desde já, porque a estrutura de X deixa visualmente óbvio um fato que, em palavras, é fácil de esquecer: **não há colunas de produto entre tratamento e bloco**. Empilhando as tb observações em um vetor Y, a matriz de delineamento tem a forma em blocos de colunas

$$X = \left[\, \mathbf{1} \mid X_{trat} \mid X_{bloco} \,\right],$$

em que $\mathbf{1}$ é a coluna de uns (intercepto), X_{trat} tem $t-1$ colunas indicadoras dos tratamentos e X_{bloco} tem $b-1$ colunas indicadoras dos blocos (uma coluna é omitida em cada grupo para evitar colinearidade com o intercepto, na parametrização usual de “tratamento de referência”). O vetor de parâmetros é $\beta = (\mu, \tau_2, \ldots, \tau_t, \beta_2, \ldots, \beta_b)'$. Repare que **não existe** nenhuma coluna do tipo (indicador de tratamento) $\times$ (indicador de bloco): é exatamente essa ausência — não uma suposição adicional escondida em algum lugar — que constitui, em termos de X, a suposição de aditividade tratamento-bloco. Um quadrado latino (Seção 4.4 (p. 105)) terá a mesma estrutura, só que com **três** blocos de colunas lado a lado (tratamento, linha, coluna) em vez de dois — e nenhuma delas cruzada com as outras.

> **Uso do R** — a estrutura de X para um DBCA pequeno (t=3, b=2)

```r
dados_toy <- expand_grid(bloco = factor(1:2), tratamento = factor(1:3))
model.matrix(~ tratamento + bloco, data = dados_toy)
```

```
##   (Intercept) tratamento2 tratamento3 bloco2
## 1           1           0           0      0
## 2           1           1           0      0
## 3           1           0           1      0
## 4           1           0           0      1
## 5           1           1           0      1
## 6           1           0           1      1
## attr(,"assign")
## [1] 0 1 1 2
## attr(,"contrasts")
## attr(,"contrasts")$tratamento
## [1] "contr.treatment"
##
## attr(,"contrasts")$bloco
## [1] "contr.treatment"
```

O estimador de mínimos quadrados $\hat{\beta} = (X'X)^{-1}X'Y$ e a matriz de projeção $H = X(X'X)^{-1}X'$ (Capítulo 2) aplicam-se sem modificação — a ANOVA que segue nada mais é do que uma forma de organizar $\|Y - \hat{Y}\|^2 = \|(I - H)Y\|^2$ e suas partes atribuíveis a cada bloco de colunas de X.

4.1.4 Blocagem como aleatorização restrita: a camada causal

Vale a pena revisitar a blocagem sob a ótica causal potencial-outcomes de Neyman e Rubin (Imbens & Rubin, 2015; Rubin, 1974; Splawa-Neyman, 1990), já que ela explica *por que* o DBCA continua produzindo um estimador não viesado do efeito do tratamento, e não apenas *como* calculá-lo. Para cada unidade u e tratamento i, existe um resultado potencial $Y_u(i)$ — a resposta que u *teria* sob o tratamento i, quer esse tratamento tenha sido de fato aplicado a u ou não. O efeito causal médio do tratamento i contra o tratamento i' é $\mathbb{E}[Y_u(i) - Y_u(i')]$, tomado sobre a população de unidades.

Em um DCA (sem blocos), o sorteio é *completo*: cada unidade tem a mesma probabilidade de receber cada tratamento, e essa aleatorização garante $\mathbb{E}[Y_u(i) \mid \text{recebeu } i] = \mathbb{E}[Y_u(i)]$ — o grupo que de fato recebeu i é, em expectativa, uma amostra representativa de como *toda* a população responderia a i. No DBCA, o sorteio é **restrito** (ou *estratificado*): dentro de cada bloco j, sorteiam-se os t tratamentos entre as unidades daquele bloco. Isso ainda é aleatorização — cada unidade dentro do bloco tem a mesma chance de receber cada tratamento —, só que aplicada separadamente em cada estrato. A analogia com amostragem estratificada é direta: assim como estimar uma média populacional estratificando por uma variável correlacionada com a resposta produz um estimador **igualmente não viesado**, mas com **variância menor** que a amostragem aleatória simples, blocar por uma variável correlacionada com a resposta produz um estimador do efeito de tratamento igualmente não viesado, mas com erro-padrão menor — precisamente o ganho que a eficiência relativa, adiante, quantifica. A condição para que a blocagem *não piore nada* é fraca (basta que o sorteio dentro de cada bloco seja de fato aleatório); a condição para que ela *ajude* é que os blocos correlacionem com a resposta — se não correlacionarem, o único custo é gastar $b - 1$ graus de liberdade do erro à toa, como veremos no exemplo do viveiro de pepineiros.

4.1.5 Tabela de ANOVA

A soma de quadrados total se decompõe em três partes:

$$\underbrace{\sum_{i,j}(Y_{ij}-\bar{Y}_{..})^2}_{SQ_{Total}} = \underbrace{b\sum_{i}(\bar{Y}_{i.}-\bar{Y}_{..})^2}_{SQ_{Trat}} + \underbrace{t\sum_{j}(\bar{Y}_{.j}-\bar{Y}_{..})^2}_{SQ_{Bloco}} + \underbrace{SQ_{Total}-SQ_{Trat}-SQ_{Bloco}}_{SQ_{Erro}}.$$

Tabela 4.1: Tabela de ANOVA do DBCA

Fonte de variação	Graus de liberdade	Soma de quadrados	Quadrado médio
Tratamento	$t-1$	SQ_{Trat}	$QM_{Trat}=SQ_{Trat}/(t-1)$
Bloco	$b-1$	SQ_{Bloco}	$QM_{Bloco}=SQ_{Bloco}/(b-1)$
Erro	$(t-1)(b-1)$	SQ_{Erro}	$QM_{Erro}=SQ_{Erro}/[(t-1)(b-1)]$
Total	$tb-1$	SQ_{Total}	

O teste de interesse compara $F_0 = QM_{Trat}/QM_{Erro}$ com $F_{\alpha,\,t-1,\,(t-1)(b-1)}$. Um teste sobre os blocos (QM_{Bloco}/QM_{Erro}) também é produzido pelo software, mas **não deve guiar decisões de retirar a blocagem do modelo**: os blocos foram fixados pelo delineamento (não sorteados), então o objetivo de incluí-los é reduzir o erro experimental, não testar sua significância — mesmo um bloco "não significativo" já removeu variação do erro que, de outra forma, inflaria QM_{Erro} e reduziria o poder do teste sobre os tratamentos.

4.1.6 Esperança dos quadrados médios

A afirmação anterior — que o teste F sobre blocos não deve orientar decisão alguma — não é só uma convenção prática; ela é uma consequência direta de quem entra na **esperança** de cada quadrado médio. Sob o modelo de efeitos fixos $\sum_i \tau_i = 0$, $\sum_j \beta_j = 0$,

$$\mathbb{E}[QM_{Trat}] = \sigma^2 + \frac{b}{t-1}\sum_{i=1}^{t}\tau_i^2, \qquad \mathbb{E}[QM_{Bloco}] = \sigma^2 + \frac{t}{b-1}\sum_{j=1}^{b}\beta_j^2, \qquad \mathbb{E}[QM_{Erro}] = \sigma^2.$$

O denominador correto de um teste F é sempre um quadrado médio cuja esperança é σ^2 **sob a hipótese nula de interesse** — e QM_{Erro} cumpre esse papel tanto para o teste de tratamentos quanto, formalmente, para um teste de blocos. O problema não é a matemática do teste QM_{Bloco}/QM_{Erro} (ele é perfeitamente calculável e o software o reporta sem erro); é que $H_0 : \beta_1 = \cdots = \beta_b = 0$ não corresponde a pergunta científica alguma neste delineamento — os blocos não foram sorteados de uma população de blocos possíveis, foram *escolhidos* porque já se sabia, a priori, que representavam uma fonte real de heterogeneidade (áreas do viveiro com solos e insolação diferentes). Testar se algo que já sabíamos ser heterogêneo é "estatisticamente heterogêneo" é uma pergunta mal colocada; a pergunta que importa — "quanto essa heterogeneidade conhecida contaminaria o erro se eu a ignorasse?" — é justamente o que a eficiência relativa, adiante, responde.

> **Aplicação — Agricultura: irrigação, silício e altura de pepineiros**
> Um experimento de horticultura investiga o efeito conjunto de dois **níveis de irrigação** (0,5 e 1,0, uma fração da lâmina de referência) e **quatro doses de silício** (0, 500, 1000 e 1500 ml) sobre a altura de plantas de pepino. As oito combinações de irrigação e silício foram aplicadas em **três blocos** (áreas contíguas do viveiro, cada uma com sua própria heterogeneidade de solo e insolação), com uma planta de cada combinação por bloco.

Para introduzir o DBCA de um único fator, tratamos cada uma das $2 \times 4 = 8$ combinações de irrigação e silício como um "tratamento" só, deixando a decomposição desse efeito em irrigação, silício e sua interação para o Capítulo 5 (fatoriais em blocos), quando retomaremos exatamente este conjunto de dados.

Uso do R — ajustando o DBCA

```
pepino <- read_csv("data/pepino.csv", show_col_types = FALSE) %>%
  mutate(
    tratamento = factor(paste0("riego", riego, "_", silicio)),
    bloco      = factor(bloque)
  )
glimpse(pepino)
```

```
## Rows: 24
## Columns: 6
## $ riego      <dbl> 0.5, 0.5, 0.5, 0.5, 1.0, 1.0, 1.0, 1.0, 0.5, 0.5, 0.5, 0.5,…
## $ silicio    <chr> "0 ml", "500 ml", "1000 ml", "1500 ml", "0 ml", "500 ml", "…
## $ bloque     <dbl> 1, 1, 1, 1, 1, 1, 1, 1, 2, 2, 2, 2, 2, 2, 2, 2, 3, 3, 3, 3,…
## $ altura     <dbl> 4.26, 4.91, 4.35, 4.44, 4.72, 5.22, 4.62, 5.25, 4.07, 5.21,…
## $ tratamento <fct> riego0.5_0 ml, riego0.5_500 ml, riego0.5_1000 ml, riego0.5_…
## $ bloco      <fct> 1, 1, 1, 1, 1, 1, 1, 1, 2, 2, 2, 2, 2, 2, 2, 2, 3, 3, 3, 3,…
```

A coluna `bloco` não é uma variável de interesse científico — ninguém pergunta “o bloco 2 produz plantas mais altas que o bloco 1?” — ela apenas identifica **qual área contígua do viveiro** originou cada planta, uma fonte conhecida de heterogeneidade de solo e insolação que queremos neutralizar antes de comparar irrigação e silício. É por isso, e não por acaso de notação, que a Seção anterior insistiu em não usar o teste F de blocos para decidir se vale a pena mantê-los no modelo: a pergunta “o bloco é estatisticamente significativo?” não é a pergunta que nos interessa sobre essa coluna.

```
mod_dbca <- aov(altura ~ tratamento + bloco, data = pepino)
anova(mod_dbca) %>%
  broom::tidy() %>%
  kable(digits = 4, caption = "ANOVA do DBCA — altura de pepineiros") %>%
  kable_styling(full_width = FALSE)
```

Tabela 4.2: ANOVA do DBCA — altura de pepineiros

term	df	sumsq	meansq	statistic	p.value
tratamento	7	2.0359	0.2908	5.2478	0.0041
bloco	2	0.0128	0.0064	0.1157	0.8916
Residuals	14	0.7759	0.0554	NA	NA

Há evidência forte de efeito de tratamento ($F_{7,14} = 5{,}25$, $p = 0{,}0041$): pelo menos uma combinação de irrigação/silício produz altura média diferente das demais. O efeito de bloco é pequeno neste conjunto de dados ($p = 0{,}89$) — voltaremos a esse ponto na discussão sobre eficiência relativa, adiante.

4.1.7 Visualizando aditividade: o gráfico de perfis

A suposição de aditividade tratamento-bloco (Seção anterior) tem um diagnóstico visual direto: plotar a resposta por tratamento, com uma linha ligando as observações de cada bloco. Se o efeito de bloco fosse puramente aditivo — um simples deslocamento vertical, igual para todos os tratamentos —, as três linhas seriam **aproximadamente paralelas**.

Uso do R — gráfico de perfis por bloco

```
pal_blocos <- c("#2a78d6", "#eb6834", "#1baf7a")  # paleta categórica validada (3
        blocos)

ggplot(pepino, aes(x = tratamento, y = altura, group = bloco, color = bloco)) +
  geom_line(linewidth = 0.9, alpha = 0.85) +
  geom_point(size = 2.6) +
  scale_color_manual(values = pal_blocos, name = "Bloco") +
  labs(x = NULL, y = "Altura (cm)",
       title = "Altura por combinação irrigação-silício, uma linha por bloco") +
  theme_minimal(base_size = 12) +
  theme(axis.text.x = element_text(angle = 40, hjust = 1))
```

As três linhas não são exatamente paralelas: cruzam-se em vários pontos (por exemplo, em torno de `riego1_0 ml`, o bloco 3 cai abaixo dos blocos 1 e 2, invertendo a ordem que tinham no tratamento anterior). A pergunta é se esse cruzamento é sinal de não aditividade ou apenas ruído — e o gráfico sozinho não responde.

Com uma única observação por casela tratamento×bloco, a interação **completa**, de $(t-1)(b-1)$ graus de liberdade, de fato não é separável do erro: ela ocupa exatamente o mesmo espaço. Mas daí **não** se segue que a aditividade seja intestável. O que não se pode testar é a interação irrestrita; uma **forma restrita** dela, sim.

4.1.8 O teste de não aditividade de Tukey

A ideia de Tukey (1949b) é abrir mão de estimar $(t-1)(b-1)$ parâmetros de interação e postular que a não aditividade, se existir, tem a forma **multiplicativa** de um único parâmetro:

$$(\tau\beta)_{ij} \;=\; \eta\,\tau_i\,\beta_j,$$

isto é, o desvio da aditividade na casela (i,j) é proporcional ao produto dos dois efeitos principais. Sob essa restrição sobra **um** grau de liberdade a estimar — η —, e um grau de liberdade cabe folgadamente nos $(t-1)(b-1)$ do erro. A soma de quadrados de não aditividade é

$$SQ_N = \frac{\Big[\sum_i \sum_j y_{ij}\,(\bar y_{i\cdot}-\bar y_{\cdot\cdot})\,(\bar y_{\cdot j}-\bar y_{\cdot\cdot})\Big]^2}{\sum_i (\bar y_{i\cdot}-\bar y_{\cdot\cdot})^2\;\sum_j (\bar y_{\cdot j}-\bar y_{\cdot\cdot})^2}, \qquad 1\text{ gl},$$

e, sob a hipótese de aditividade estrita,

$$F_0 = \frac{SQ_N}{\big(SQ_{Erro}-SQ_N\big)\,/\,\big[(t-1)(b-1)-1\big]} \;\sim\; F_{1,\;(t-1)(b-1)-1}.$$

Em palavras: parte-se o termo de erro do DBCA em duas linhas — *não aditividade* (1 gl) e *resto* — e pergunta-se se a primeira é grande demais para ser ruído.

> **Uso do R** — teste de Tukey de não aditividade, à mão e por pacote

```
mu_g  <- mean(pepino$altura)
ef_t  <- tapply(pepino$altura, pepino$tratamento, mean) - mu_g  # efeitos de
       tratamento
ef_b  <- tapply(pepino$altura, pepino$bloco,      mean) - mu_g  # efeitos de bloco
```

```
num <- sum(pepino$altura *           ef_t[as.character(pepino$tratamento)] *
           ef_b[as.character(pepino$bloco)])
SQ_N <- num^2 / (sum(ef_t^2) * sum(ef_b^2))        tab   <- summary(mod_dbca)[[1]]
SQ_E  <- tab["Residuals", "Sum Sq"]gl_E  <- tab["Residuals", "Df"]
F_0   <- SQ_N / ((SQ_E - SQ_N) / (gl_E - 1))
tibble(Fonte = c("Não aditividade", "Resto", "Erro do DBCA (total)"),
       gl    = c(1, gl_E - 1, gl_E),       SQ    = c(SQ_N, SQ_E - SQ_N, SQ_E)) %>%
  mutate(QM = SQ / gl,          F  = c(F_0, NA, NA),
         `valor-p` = c(pf(F_0, 1, gl_E - 1, lower.tail = FALSE), NA, NA)) %>%
  kable(digits = 4, caption = "Partição do erro do DBCA pelo teste de Tukey") %>%
  kable_styling(full_width = FALSE)
```

Tabela 4.3: Partição do erro do DBCA pelo teste de Tukey

Fonte	gl	SQ	QM	F	valor-p
Não aditividade	1	0.0018	0.0018	0.0306	0.8639
Resto	13	0.7741	0.0595	NA	NA
Erro do DBCA (total)	14	0.7759	0.0554	NA	NA

O resultado é inequívoco: $F_{1,13}$ próximo de zero, com valor-p muito alto. **Não há evidência alguma de não aditividade** — o cruzamento das linhas no gráfico de perfis é ruído, exatamente o que se esperaria de um experimento em que o bloco explica pouquíssima variação (o próprio teste F de blocos, na tabela de ANOVA acima, não chega perto da significância). O gráfico levantou a suspeita; o teste a descartou. É essa a divisão de trabalho entre diagnóstico visual e teste formal, e é por isso que o primeiro nunca dispensa o segundo.

Duas ressalvas sobre o alcance do teste. A primeira: ele só tem poder contra a forma **multiplicativa** de não aditividade; uma interação de outro feitio pode passar despercebida. A segunda, que é a face positiva da mesma moeda: quando η é significativo, a forma multiplicativa costuma indicar que uma **transformação** da resposta (tipicamente na família potência — Seção 3.5 (p. 68) do Capítulo 3) restauraria a aditividade, o que torna o teste também um diagnóstico construtivo, e não apenas um veredito.

```
X <- model.matrix(mod_dbca)
dim(X)              # 24 linhas (unidades), 10 colunas: 1 + (8-1) trat + (3-1) bloco
```

```
## [1] 24 10
```

```
X[1:4, c(1:3, 8:9)]  # note: nenhuma coluna cruza tratamento com bloco
```

```
##   (Intercept) tratamentoriego0.5_1000 ml tratamentoriego0.5_1500 ml
## 1           1                          0                          0
## 2           1                          0                          0
## 3           1                          1                          0
## 4           1                          0                          1
##   tratamentoriego1_500 ml bloco2
## 1                       0      0
## 2                       0      0
## 3                       0      0
## 4                       0      0
```

4.1.9 Diagrama de Hasse do DBCA: por que não há nó de interação

A ausência de colunas de produto em X, confirmada acima, e a ausência de graus de liberdade sobráveis para testar tratamento×bloco (parágrafo anterior) são a mesma afirmação vista de dois ângulos diferentes

— e o diagrama de Hasse do Capítulo 2 (Seção 2.2 (p. 17)) é o terceiro ângulo, geométrico, que amarra os outros dois. No fatorial $A \times B$ cruzado do Capítulo 2 (Figura 2.2), A e B aparecem no mesmo nível e se reencontram em um nó de interação $A{\times}B$, que absorve $(a-1)(b-1)$ graus de liberdade *antes* de chegar ao erro. O DBCA tem a mesma estrutura de topo — Tratamento e Bloco cruzados, no mesmo nível — mas **sem** esse nó intermediário:

> **Uso do R** — diagrama de Hasse do DBCA (exemplo pepino)

```
nos_dbca <- tibble(
  termo   = c("Média", "Tratamento", "Bloco", "Erro"),
  classes = c(1, 8, 3, 24)         # t=8 tratamentos; b=3 blocos; N=24 parcelas
)
arestas_dbca <- tibble(
  de   = c("Média", "Média", "Tratamento", "Bloco"),
  para = c("Tratamento", "Bloco", "Erro", "Erro")
)

knitr::include_graphics(
  hasse_svg(nos_dbca, arestas_dbca,
            arquivo = "figuras/hasse/dbca.svg",
            titulo  = "DBCA (pepino): t=8, b=3 (N=24)")
)
```

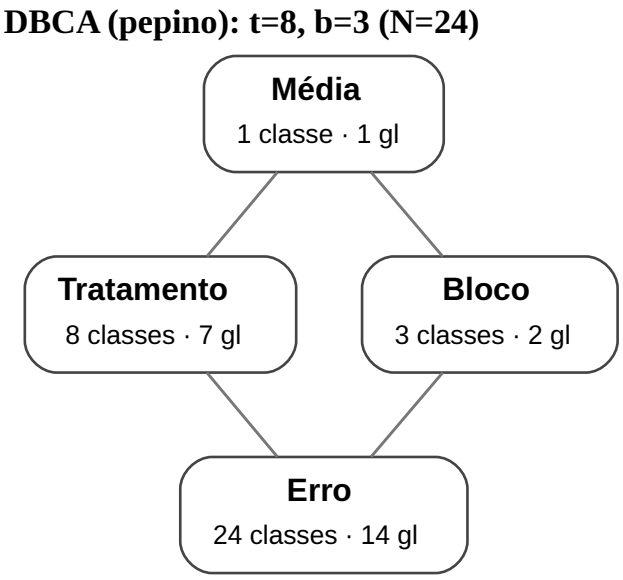


Figura 4.2: Diagrama de Hasse do DBCA, exemplo pepino: t=8 combinações irrigação-silício (tratamento), b=3 blocos, N=24. Tratamento e Bloco aparecem no mesmo nível (cruzados), mas – ao contrário do fatorial A x B do Capítulo 2 (seção sobre diagramas de Hasse) – não há nó de interação entre eles: com uma única observação por casela tratamento x bloco, os dois convergem direto no Erro.

Os quatro nós somam $1 + 7 + 2 + 14 = 24 = tb = N$: nada sobra para um quinto nó de interação. A razão algébrica é a mesma que gera esse fato geométrico — cada casela tratamento$\times$bloco do DBCA contém **exatamente uma** unidade experimental, então o próprio Erro *é* a variação residual dentro de cada casela, o mesmo lugar onde um eventual efeito de interação teria de morar. Não é que a interação tratamento$\times$bloco seja assumida igual a zero por conveniência; é que o delineamento, ao não replicar dentro de casela, não deixa **nenhum** grau de liberdade disponível para separar os dois — a formalização de $\mathbb{E}[QM_{Erro}] = \sigma^2$ da Seção anterior já assume essa ausência, e o diagrama simplesmente torna visível,

como contagem de nós e arestas, o motivo pelo qual $\mathbb{E}[QM_{Erro}]$ não tem outro termo a mais somado a σ^2: não há onde ele seria estimado. O que a seção sobre o teste de Tukey mostrou é que essa impossibilidade vale para a interação **irrestrita**: ao postular a forma multiplicativa $\eta\,\tau_i\beta_j$, reduz-se a interação a um único parâmetro, e esse grau de liberdade pode ser tomado emprestado do erro. O diagrama continua explicando por que $\mathbb{E}[QM_{Erro}] = \sigma^2$ não tem termo adicional; o teste de Tukey apenas mostra que uma fatia de 1 gl desse erro pode ser interrogada.

4.1.10 Dados faltantes: estimação do valor perdido

Perder uma observação é comum em campo (planta morre, parcela é destruída por um evento externo). O DBCA deixa de ser balanceado, e o cálculo manual das somas de quadrados deixa de ser trivial. A solução clássica de Yates (Yates, 1936) é **estimar o valor perdido** de modo a minimizar a soma de quadrados do erro, e então prosseguir com a ANOVA usual, com duas ressalvas: (i) reduz-se em 1 o grau de liberdade do erro (a observação estimada não traz informação nova), e (ii) a soma de quadrados de tratamentos calculada com o valor estimado fica levemente viesada para cima e pode ser corrigida.

Para uma única observação perdida na célula (tratamento i^{*}, bloco j^{*}), o valor que minimiza SQ_{Erro} é

$$\hat{y}_{i^{*}j^{*}} = \frac{t\,T'_{i^{*}} + b\,B'_{j^{*}} - G'}{(t-1)(b-1)},$$

em que $T'_{i^{*}}$ é o total do tratamento i^{*} (excluindo a observação perdida), $B'_{j^{*}}$ é o total do bloco j^{*} (idem) e G' é o total geral (idem). A correção aproximada para a soma de quadrados de tratamentos é

$$SQ_{Trat}^{\,ajustada} = SQ_{Trat}^{\,ingênua} - \frac{\left[B'_{j^{*}} - (t-1)\hat{y}_{i^{*}j^{*}}\right]^2}{t(t-1)}.$$

> **Uso do R** — estimando um valor perdido (fórmula de Yates)

```
# Removemos, propositalmente, a altura observada para riego = 1, silicio = "1000 ml",
        bloco 2
alvo <- which(pepino$riego == 1 & pepino$silicio == "1000 ml" & pepino$bloque == 2)
valor_real <- pepino$altura[alvo]

pepino_miss <- pepino
pepino_miss$altura[alvo] <- NA

t <- nlevels(pepino$tratamento); b <- nlevels(pepino$bloco)
trat_alvo  <- pepino$tratamento[alvo]
bloco_alvo <- pepino$bloco[alvo]

Tlinha <- sum(pepino_miss$altura[pepino_miss$tratamento == trat_alvo], na.rm = TRUE)
Blinha <- sum(pepino_miss$altura[pepino_miss$bloco == bloco_alvo], na.rm = TRUE)
Glinha <- sum(pepino_miss$altura, na.rm = TRUE)

y_hat <- (t * Tlinha + b * Blinha - Glinha) / ((t - 1) * (b - 1))
c(valor_real = valor_real, estimado = y_hat, erro = y_hat - valor_real)
```

```
## valor_real   estimado       erro
##  5.1200000  4.6914286 -0.4285714
```

```
pepino_imputado <- pepino_miss
pepino_imputado$altura[alvo] <- y_hat
mod_imputado <- aov(altura ~ tratamento + bloco, data = pepino_imputado)
tab_imp <- anova(mod_imputado)

correcao <- (Blinha - (t - 1) * y_hat)^2 / (t * (t - 1))
SS_trat_ajustado <- tab_imp["tratamento", "Sum Sq"] - correcao
c(SQ_trat_ingenua = tab_imp["tratamento", "Sum Sq"],
  correcao = correcao, SQ_trat_ajustada = SS_trat_ajustado)
```

```
##  SQ_trat_ingenua         correcao SQ_trat_ajustada
##      2.010202381      0.001207143      2.008995238
```

Neste exemplo, o valor real era $5{,}12$ cm e a fórmula de Yates estimou $4{,}69$ cm — um erro de $0{,}43$ cm, razoável frente ao desvio-padrão residual do modelo completo. A correção da soma de quadrados de tratamentos foi minúscula ($0{,}0012$), porque a discrepância entre bloco e tratamento neste conjunto de dados já era pequena. Em conjuntos de dados com blocos muito diferentes entre si, a correção pode ser relevante, e ignorá-la infla ligeiramente a estatística F de tratamentos. Com **mais de um valor perdido**, o mesmo princípio se generaliza por iteração: estima-se cada valor faltante pela fórmula acima usando os demais valores (observados e já estimados), repetindo o processo até os valores estimados convergirem — na prática, hoje, resolve-se de forma exata por mínimos quadrados com dados desbalanceados (Capítulo 2), e a fórmula de Yates permanece valiosa por seu valor didático e por dispensar software especializado.

4.1.11 Eficiência relativa do DBCA frente ao DCA

Ter reduzido o erro experimental valeu a pena? A **eficiência relativa (ER)** do DBCA em relação a um DCA hipotético (que teria usado as mesmas tb unidades, mas ignorado os blocos) responde essa pergunta comparando as variâncias por unidade experimental que os dois desenhos produziriam. A quantidade tem duas partes. A primeira é a razão entre a variância por unidade que um DCA teria e a que o DBCA obteve. Como não se rodou o DCA, sua variância é **estimada** a partir da própria ANOVA do DBCA, agrupando de volta o que a blocagem separou:

$$\hat{\sigma}^2_{DCA} = \frac{(b-1)\,QM_{Bloco} + \big[(t-1) + (t-1)(b-1)\big]\,QM_{Erro}}{tb-1}.$$

A segunda parte é um **fator de correção de graus de liberdade**: $\hat{\sigma}^2_{DCA}$ e QM_{Erro} são estimativas com números diferentes de graus de liberdade, e comparar variâncias estimadas com poucos graus de liberdade favorece artificialmente a que tem mais. Com $\nu_b = (t-1)(b-1)$ (erro do DBCA) e $\nu_c = t(b-1)$ (erro que o DCA teria),

$$\widehat{ER}(DBCA, DCA) = \underbrace{\frac{(\nu_b+1)(\nu_c+3)}{(\nu_b+3)(\nu_c+1)}}_{\text{correção de gl}} \cdot \frac{\hat{\sigma}^2_{DCA}}{QM_{Erro}}.$$

$ER > 1$ indica que o DBCA foi mais eficiente: seria preciso aumentar as repetições do DCA por um fator ER para igualar a precisão do DBCA. Note que o fator de correção é **sempre menor que 1** quando $\nu_b < \nu_c$ — ele penaliza o DBCA, que é o desenho com menos graus de liberdade de erro, e nunca o promove. Há ainda um critério exato, devido a Lentner, Arnold e Hinkelmann, que dispensa a fórmula: $ER > 1$ se e somente se $H = QM_{Bloco}/QM_{Erro} > 1$.

```
tab <- anova(mod_dbca)
MSB <- tab["bloco", "Mean Sq"];      MSE      <- tab["Residuals", "Mean Sq"]
gl_b <- tab["bloco", "Df"];          gl_e_dbca <- tab["Residuals", "Df"]
gl_e_dca <- gl_e_dbca + gl_b

t_niv <- nlevels(pepino$tratamento); b_niv <- nlevels(pepino$bloco)

sigma2_dca <- ((b_niv - 1) * MSB +
               ((t_niv - 1) + (t_niv - 1) * (b_niv - 1)) * MSE) / (t_niv * b_niv - 1)

correcao <- ((gl_e_dbca + 1) * (gl_e_dca + 3)) / ((gl_e_dbca + 3) * (gl_e_dca + 1))
ER <- correcao * sigma2_dca / MSE

c(sigma2_DCA = sigma2_dca, correcao_gl = correcao, ER = ER,
  H = MSB / MSE)   # criterio exato: ER > 1 se e so se H > 1
```

```
##  sigma2_DCA correcao_gl          ER           H
##  0.05116033  0.98615917  0.91032808  0.11570310
```

$ER , isto é, **menor que 1**: neste experimento a blocagem por área do viveiro não só deixou de ajudar como **piorou** a precisão. O critério exato confirma, sem depender da fórmula:
$H = QM_{Bloco}/QM_{Erro} \approx 0{,}12 \ll 1$.

O diagnóstico é coerente com tudo o mais que já vimos sobre estes dados: o quadrado médio de blocos é bem **menor** que o do erro, e o teste F de blocos não chega perto da significância. Os blocos não capturaram heterogeneidade nenhuma — as unidades do viveiro já eram homogêneas quanto ao que importa para a altura das plantas — e o DBCA gastou $b - 1 = 2$ graus de liberdade do erro sem retorno.

Isso **não** significa que blocar tenha sido um erro de julgamento. A decisão de blocar é tomada *antes* de coletar os dados, sob incerteza sobre a heterogeneidade do material experimental, e o custo de blocar à toa (perder alguns graus de liberdade) é tipicamente muito menor que o custo de não blocar quando havia heterogeneidade real (inflar o erro e perder poder para sempre). O que o cálculo de eficiência oferece é uma **avaliação a posteriori**, útil para planejar o *próximo* experimento no mesmo viveiro: se a homogeneidade se confirmar em novas rodadas, um DCA com as mesmas tb unidades entregaria mais graus de liberdade de erro e, portanto, mais poder.

> **Uso do R** — comparando o quadrado médio do erro dos dois desenhos

```
QME_dbca <- MSE
QME_dca  <- (tab["Residuals","Sum Sq"] + tab["bloco","Sum Sq"]) / gl_e_dca  # erro +
        bloco, agrupados

df_re <- tibble(
  Delineamento = factor(c("DBCA", "DCA (hipotético)"), levels = c("DBCA", "DCA
        (hipotético)")),
  QM_Erro = c(QME_dbca, QME_dca)
)

ggplot(df_re, aes(x = Delineamento, y = QM_Erro, fill = Delineamento)) +
  geom_col(width = 0.55) +
  geom_text(aes(label = sprintf("%.4f", QM_Erro)), vjust = -0.5, size = 4.2) +
  scale_fill_manual(values = c("#2a78d6", "#eb6834"), guide = "none") +
  labs(x = NULL, y = expression(QM[Erro]),
       title = "Quadrado médio do erro: DBCA vs. DCA hipotético") +
```

```
  ylim(0, max(df_re$QM_Erro) * 1.2) +  theme_minimal(base_size = 12)
```

O gráfico conta a mesma história que o cálculo de eficiência: o QM_{Erro} do DCA hipotético (0,0493) é **menor** que o do DBCA (0,0554). Isso acontece porque agrupar SQ_{Bloco} (muito pequena) de volta ao erro, dividida por mais graus de liberdade (16 em vez de 14), baixa a média. Os dois diagnósticos — a razão de quadrados médios e o ER corrigido — apontam na mesma direção aqui, e é bom que apontem: quando $QM_{Bloco} < QM_{Erro}$, blocar não ajudou.

Vale, ainda assim, entender o que a correção de graus de liberdade faz, porque ela é a parte não óbvia da fórmula. Uma estimativa de variância com **mais** graus de liberdade é, por si só, mais confiável — produz intervalos e testes mais precisos — do que uma com menos. Como é o DCA hipotético que teria mais graus de liberdade de erro (16 contra 14), a correção $\frac{(\nu_b+1)(\nu_c+3)}{(\nu_b+3)(\nu_c+1)} = 0.9862$ **penaliza o DBCA**, e não o contrário. Ela nunca converte um desenho pior num melhor: com $\nu_b < \nu_c$ o fator é sempre menor que 1. É por isso que o critério exato de Lentner, Arnold e Hinkelmann pode ser enunciado de forma tão simples — $ER > 1 \iff QM_{Bloco} > QM_{Erro}$ —, e é uma boa verificação de sanidade para qualquer conta de eficiência relativa: **se o quadrado médio de blocos é menor que o do erro, nenhuma fórmula de ER pode concluir que a blocagem ajudou**.

Para discutir

1. Se, neste experimento, o quadrado médio de blocos tivesse sido bem maior que o quadrado médio do erro, o que isso indicaria sobre a decisão original de blocar por área do viveiro?
2. O modelo do DBCA não inclui interação tratamento×bloco. O que essa suposição de aditividade significa em termos práticos — por exemplo, é razoável supor que a diferença entre duas doses de silício seja a mesma nos três blocos deste experimento?
3. Por que não se deve decidir remover o termo de bloco do modelo com base no teste F de blocos não ser significativo?

4.2 Teste de Friedman

Quando a suposição de normalidade dos erros é implausível — respostas em escala ordinal, poucos blocos, distribuições muito assimétricas — o **teste de Friedman** (Friedman, 1937) oferece uma alternativa não paramétrica ao DBCA. É particularmente natural quando **o bloco é o próprio sujeito** em um desenho de medidas repetidas: cada indivíduo é observado sob todos os tratamentos, e a comparação entre tratamentos é feita *dentro* de cada indivíduo, exatamente como no DBCA.

Aplicação — Psicologia: bloco = paciente em um desenho terapêutico
Uma clínica compara três técnicas terapêuticas breves — **TCC** (terapia cognitivo-comportamental), **terapia interpessoal** e **ativação comportamental** — quanto à redução percentual de sintomas depressivos autorreportados. Doze pacientes (o **bloco**) recebem, cada um, as três técnicas em sessões diferentes, em ordem aleatorizada, com período de washout entre elas. A resposta é assimétrica à direita (a maioria melhora pouco, alguns melhoram muito), o que torna a suposição de normalidade do DBCA questionável com apenas 12 blocos.

Dentro de cada bloco j, atribuem-se postos $1, \ldots, t$ às t respostas (do menor para o maior). Sejam $R_i = \sum_j \text{posto}(Y_{ij})$ as somas de posto por tratamento. Sob H_0 (nenhuma diferença sistemática entre

tratamentos), a estatística de Friedman

$$F_r = \frac{12}{bt(t+1)} \sum_{i=1}^{t} R_i^2 - 3b(t+1)$$

segue, aproximadamente, uma distribuição χ^2_{t-1} para b ou t não muito pequenos.

> **Uso do R** — `friedman.test()`

```
set.seed(2026)
n_pac <- 12
tecnicas <- c("TCC", "Terapia_Interpessoal", "Ativacao_Comportamental")
efeito_pac <- rexp(n_pac, rate = 1 / 8)                # heterogeneidade entre
        pacientes, assimétrica
efeito_tec <- c(TCC = 2, Terapia_Interpessoal = 0, Ativacao_Comportamental = 4)

dados_terapia <- expand_grid(paciente = 1:n_pac, tecnica = tecnicas) %>%
  mutate(
    tecnica = factor(tecnica, levels = tecnicas),
    reducao = round(5 + efeito_pac[paciente] + efeito_tec[as.character(tecnica)] +
                      rexp(n(), rate = 1 / 2), 1)
  )

mat <- dados_terapia %>%
  pivot_wider(names_from = tecnica, values_from = reducao) %>%
  select(-paciente) %>%
  as.matrix()

friedman.test(mat) %>% broom::tidy() %>%
  kable(digits = 3, caption = "Teste de Friedman — redução de sintomas por técnica")
        %>%
  kable_styling(full_width = FALSE)
```

Tabela 4.4: Teste de Friedman — redução de sintomas por técnica

statistic	p.value	parameter	method
2.085	0.353	2	Friedman rank sum test

Tabela 4.5: Soma de postos por técnica (12 blocos, postos de 1 a 3)

Técnica	Soma de postos
TCC	21.5
Terapia_Interpessoal	22.5
Ativacao_Comportamental	28.0

O gráfico de perfis usado para o DBCA (Seção anterior) tem uma versão natural aqui: uma linha por paciente, ligando sua resposta nas três técnicas, sobreposta a um boxplot por técnica que resume a distribuição marginal.

```
ggplot(dados_terapia, aes(x = tecnica, y = reducao)) +
  geom_line(aes(group = paciente), color = "grey70", alpha = 0.6) +
  geom_boxplot(aes(fill = tecnica), width = 0.35, alpha = 0.7, outlier.shape = NA) +
  geom_point(aes(color = tecnica), size = 1.8) +
  scale_fill_manual(values = pal_blocos, guide = "none") +
  scale_color_manual(values = pal_blocos, guide = "none") +
  labs(x = NULL, y = "Redução de sintomas (%)",
```

```
       title = "Redução de sintomas por técnica, uma linha por paciente") +
  theme_minimal(base_size = 12) +
  theme(axis.text.x = element_text(angle = 15, hjust = 1))
```

Duas coisas ficam visíveis que a estatística de Friedman, por si só, não mostra: (i) a assimetria à direita mencionada na motivação — a maioria dos pacientes melhora pouco e uma cauda melhora muito, em todas as três técnicas, o que já é um sinal contra a normalidade assumida pelo DBCA; e (ii) as linhas cinzas cruzam-se com frequência — poucos pacientes mantêm a mesma ordenação relativa entre as três técnicas —, o que é visualmente coerente com a soma de postos pouco discrepante e o p-valor não significativo do teste.

Com $\chi^2_2 = 2{,}09$ e $p = 0{,}35$, não há evidência, nesta amostra simulada, de diferença sistemática entre as três técnicas — apesar de a soma de postos da ativação comportamental ser a maior (indicando a técnica mais frequentemente “melhor” em cada paciente), a diferença não é grande o bastante frente à variabilidade entre pacientes para ser distinguida de acaso com apenas 12 blocos. O teste de Friedman troca sensibilidade (ele usa menos informação que a ANOVA quando a normalidade de fato vale) por robustez: não assume forma alguma para a distribuição dos erros, apenas que, sob H_0, qualquer ordenação dos t tratamentos dentro de um bloco é igualmente provável.

4.3 Blocos incompletos balanceados

Às vezes o bloco não comporta todos os t tratamentos — um degustador só consegue avaliar um número limitado de amostras antes que o paladar sature; uma parcela experimental só tem espaço físico para poucas variedades; um paciente só tolera um número limitado de sessões de teste. Um **delineamento em blocos incompletos** usa blocos de tamanho $k < t$. Se, além disso, o desenho é construído de modo que **cada par de tratamentos apareça junto no mesmo bloco o mesmo número de vezes**, o delineamento é dito **balanceado (BIB)** (Yates, 1936) — a propriedade que preserva a comparabilidade entre quaisquer dois tratamentos, análoga ao que a completude dos blocos garante no DBCA.

Um BIB é caracterizado por cinco parâmetros: t tratamentos, b blocos, cada tratamento aparecendo em r blocos, cada bloco de tamanho k, e cada par de tratamentos coocorrendo em λ blocos. Esses parâmetros satisfazem duas identidades de contagem:

$$bk = tr \qquad \text{e} \qquad \lambda(t-1) = r(k-1).$$

> **Aplicação — Agricultura: painel sensorial com degustadores**
> Um painel sensorial compara **quatro** variedades de café ($t = 4$), mas cada degustador (o bloco) consegue avaliar de forma confiável apenas **três** xícaras por sessão ($k = 3$) antes de o paladar saturar.

Tabela 4.6: Um BIB com t=4, b=4, k=3, r=3, λ=2

Bloco	Tratamentos no bloco
1	1, 2, 3
2	1, 2, 4
3	1, 3, 4
4	2, 3, 4

Cada tratamento aparece em $r = 3$ dos $b = 4$ blocos, e cada par (por exemplo, tratamentos 1 e 2) coocorre em exatamente $\lambda = 2$ blocos — confira: $bk = 4 \times 3 = 12 = tr = 4 \times 3$ e $\lambda(t-1) = 2 \times 3 = 6 = r(k-1) = 3 \times 2$.

A propriedade de balanceamento fica mais fácil de enxergar em uma **matriz de incidência** bloco$\times$ tratamento: cada célula marca se aquele tratamento aparece naquele bloco.

Cada linha (bloco) tem exatamente $k = 3$ células azuis, cada coluna (tratamento) tem exatamente $r = 3$ células azuis, e qualquer par de colunas compartilha azul em exatamente $\lambda = 2$ linhas — a checagem visual imediata de que o arranjo é de fato balanceado, sem precisar reconferir a tabela de blocos linha por linha. A análise de um BIB é mais elaborada que a do DBCA porque as médias de tratamento observadas precisam ser **ajustadas** pelos blocos em que cada tratamento efetivamente apareceu — nem todo tratamento convive com os mesmos "vizinhos", ao contrário do DBCA, em que todo tratamento aparece em todo bloco.

Análise intrablocos. Sejam $T_{i\cdot}$ a soma de todas as observações do tratamento i e $B_{\cdot j}$ a soma de todas as observações do bloco j. Como o tratamento i não aparece em todo bloco, comparar $T_{i\cdot}$ diretamente entre tratamentos confundiria o efeito do tratamento com o efeito dos blocos particulares em que ele calhou de aparecer. A correção clássica (Montgomery, 2017) define o **total ajustado**

$$Q_i = T_{i\cdot} - \frac{1}{k} \sum_{j:\, i \in \text{bloco } j} B_{\cdot j}, \qquad i = 1, \ldots, t,$$

que subtrai de $T_{i\cdot}$ a média dos totais dos blocos em que i apareceu (ponderada por k) — por construção, $\sum_i Q_i = 0$. A soma de quadrados de tratamentos **ajustada por blocos** é

$$SQ_{\text{Trat(ajustada)}} = \frac{k \sum_{i=1}^{t} Q_i^2}{\lambda t},$$

com $t - 1$ graus de liberdade, entrando na tabela de ANOVA no lugar da SQ_{Trat} não ajustada usada no DBCA — é essa soma de quadrados, e não a diferença ingênua entre médias de tratamento brutas, que deve orientar o teste F de tratamentos em um BIB.

> **Uso do R** — verificando a fórmula de Q_i contra a soma de quadrados sequencial de aov()

```
set.seed(2026)
blocos_lista <- list(c(1,2,3), c(1,2,4), c(1,3,4), c(2,3,4))   # os 4 blocos da
        Tabela acima
efeito_trat_bib  <- c(0, 3, -2, 5)     # tau_i (apenas para simular uma resposta
        plausivel)
efeito_bloco_bib <- c(-4, 2, 1, 6)     # beta_j

dados_bib <- map_dfr(seq_along(blocos_lista), function(j) {
  tibble(bloco = j, trat = blocos_lista[[j]],
         nota = 50 + efeito_trat_bib[blocos_lista[[j]]] + efeito_bloco_bib[j] +
        rnorm(3, 0, 1.5))
}) %>% mutate(bloco = factor(bloco), trat = factor(trat))

k_bib <- 3; t_bib <- 4; lambda_bib <- 2
T_trat  <- tapply(dados_bib$nota, dados_bib$trat, sum)
B_bloco <- tapply(dados_bib$nota, dados_bib$bloco, sum)
```

```
soma_blocos_do_trat <- sapply(1:t_bib, function(i) {
  bl <- which(map_lgl(blocos_lista, ~ i %in% .x))  sum(B_bloco[bl])})
Q <- T_trat - soma_blocos_do_trat / k_bib
SQ_trat_ajustada <- k_bib * sum(Q^2) / (lambda_bib * t_bib)
c(SQ_trat_formula = SQ_trat_ajustada,
  SQ_trat_aov = anova(aov(nota ~ bloco + trat, data = dados_bib))["trat", "Sum Sq"])
```

```
## SQ_trat_formula     SQ_trat_aov
##        62.04573        62.04573
```

Os dois valores coincidem: ajustar `bloco` **antes** de `trat` no modelo linear e pedir a soma de quadrados sequencial (Tipo I) de `trat` é, algebricamente, a mesma conta que a fórmula de Q_i calcula à mão — o software não faz nada além disso por trás de `aov()`. Fica o essencial: **use um BIB quando o tamanho físico ou logístico do bloco força $k < t$, e quando for possível construir um arranjo em que todo par de tratamentos seja comparado com a mesma frequência**; a análise, embora mais trabalhosa que a do DBCA, permanece inteiramente dentro do mesmo princípio de isolar a variação de bloco antes de comparar tratamentos.

4.4 Delineamento em quadrado latino

O DBCA controla **uma** fonte de variação sistemática. Quando há **duas** fontes de bloqueio cruzadas e conhecidas — por exemplo, uma tendência de fertilidade ao longo das linhas de um talhão *e*, simultaneamente, ao longo das colunas —, um **quadrado latino** de ordem n permite controlar as duas simultaneamente usando apenas n^2 unidades experimentais para comparar n tratamentos, em vez das n^3 que um cruzamento completo de linha $\times$ coluna $\times$ tratamento exigiria. A ideia, que remonta aos ensaios de campo de Fisher em Rothamsted (Fisher, 1935b), é arranjar os n tratamentos em uma matriz $n \times n$ de modo que **cada tratamento apareça exatamente uma vez em cada linha e exatamente uma vez em cada coluna**.

4.4.1 Motivação: dois gradientes ortogonais, e por que um bloqueio simples não basta

Suponha um talhão em que a fertilidade varia em **duas direções ao mesmo tempo e independentemente**: ao longo das linhas (por exemplo, declividade do terreno) e ao longo das colunas (por exemplo, um gradiente de umidade, perpendicular à declividade).

```
set.seed(48)
campo <- expand_grid(linha = 1:8, coluna = 1:8) %>%
  mutate(fertilidade = 70 - 3 * linha - 4 * coluna + rnorm(n(), 0, 3))

ggplot(campo, aes(x = coluna, y = linha, fill = fertilidade)) +
  geom_tile(color = "white") +
  scale_fill_gradient(low = "khaki1", high = "olivedrab", name = "Fertilidade") +
  scale_y_reverse() +
  labs(x = "Coluna (gradiente de umidade)", y = "Linha (gradiente de declividade)",
       title = "Fertilidade sob dois gradientes ortogonais") +
  theme_minimal(base_size = 12)
```

Se bloqueássemos **só** por linha (faixas horizontais), cada bloco ainda conteria o gradiente inteiro de coluna, não neutralizado; se bloqueássemos **só** por coluna, sobraria o gradiente de linha. Nenhum bloqueio de um único fator resolve os dois simultaneamente — e um DBCA com blocos definidos pelo cruzamento linha$\times$coluna (cada combinação um bloco) exigiria n observações por bloco, ou seja, voltaríamos a precisar de

replicação completa dentro de cada célula da grade. O quadrado latino resolve isso de forma mais econômica: em vez de tratar linha×coluna como um único fator de blocagem com n^2 níveis, ele trata linha e coluna como **dois** fatores de bloqueio cruzados, cada um com n níveis, e usa a restrição de que cada tratamento apareça uma vez por linha e uma vez por coluna para caber em exatamente n^2 unidades — sem replicação dentro de cada célula.

4.4.2 O modelo

$$Y_{ijk} = \mu + \rho_i + \gamma_j + \tau_k + \varepsilon_{ijk},$$

em que ρ_i ($i = 1, \ldots, n$) é o efeito da linha, γ_j ($j = 1, \ldots, n$) é o efeito da coluna e τ_k ($k = 1, \ldots, n$) é o efeito do tratamento — mas, diferentemente de um fatorial completo, apenas **uma** das n combinações (i, j) recebe cada tratamento k: o índice k é determinado pelo arranjo do quadrado latino, não varia livremente. Há apenas n^2 observações, não n^3.

Tabela 4.7: Tabela de ANOVA do quadrado latino

Fonte de variação	Graus de liberdade
Linha	$n - 1$
Coluna	$n - 1$
Tratamento	$n - 1$
Erro	$(n - 1)(n - 2)$
Total	$n^2 - 1$

Como no DBCA, vale explicitar a esperança de cada quadrado médio, sob $\sum_i \rho_i = \sum_j \gamma_j = \sum_k \tau_k = 0$:

$$\mathbb{E}[QM_{Linha}] = \sigma^2 + \frac{n}{n-1}\sum_i \rho_i^2, \quad \mathbb{E}[QM_{Coluna}] = \sigma^2 + \frac{n}{n-1}\sum_j \gamma_j^2, \quad \mathbb{E}[QM_{Trat}] = \sigma^2 + \frac{n}{n-1}\sum_k \tau_k^2,$$

com $\mathbb{E}[QM_{Erro}] = \sigma^2$ em qualquer caso. Como no DBCA, só o teste sobre tratamentos usa essa estrutura para inferência; linha e coluna foram escolhidas pelo delineamento, não sorteadas de uma população de linhas/colunas possíveis, então seus quadrados médios servem para *purificar* o erro, não para serem testados.

Aplicação — Agricultura: quatro adubações, controlando declividade e umidade
Um talhão experimental tem uma tendência de fertilidade ao longo de suas **linhas** (declividade do terreno) e, independentemente, ao longo de suas **colunas** (gradiente de umidade). Quatro formulações de adubo (A, B, C, D) são comparadas usando um quadrado latino 4×4, de modo que cada formulação apareça uma vez em cada linha e uma vez em cada coluna.

Uso do R — construindo e analisando um quadrado latino 4x4

```
quad <- matrix(c(
  "A","B","C","D",
  "B","C","D","A",
  "C","D","A","B",
  "D","A","B","C"
), nrow = 4, byrow = TRUE)
quad   # cada linha e cada coluna contém A, B, C, D exatamente uma vez
```

```
##      [,1] [,2] [,3] [,4]
## [1,] "A"  "B"  "C"  "D"
## [2,] "B"  "C"  "D"  "A"
## [3,] "C"  "D"  "A"  "B"
## [4,] "D"  "A"  "B"  "C"
```

O arranjo abstrato de letras fica mais concreto como um diagrama: cada célula da grade linha×coluna recebe a cor do tratamento que lhe cabe, com a letra sobreposta para que a identidade do tratamento nunca dependa só da cor.

Cada linha da grade (lida da esquerda para a direita) contém as quatro letras exatamente uma vez, e o mesmo vale para cada coluna (lida de cima para baixo) — é essa dupla restrição, visível de imediato na figura, que define um quadrado latino. Ler o diagrama por linha diz que fixação em qualquer talhão (linha) já garante que os quatro adubos serão testados; ler por coluna diz o mesmo para qualquer data de aplicação.

4.4.3 Diagrama de Hasse do quadrado latino: três fatores cruzados dois a dois

O quadrado latino é o primeiro delineamento deste livro com **três** fatores no mesmo nível do diagrama de Hasse, em vez de dois — Linha, Coluna e Tratamento são cruzados dois a dois (nenhum refina o outro), e os três convergem diretamente no Erro, pela mesma razão geométrica já vista no DBCA: sem repetição dentro de cada célula linha×coluna, não sobra grau de liberdade para nenhuma interação entre eles.

> **Uso do R** — diagrama de Hasse do quadrado latino 4x4

```
nos_ql <- tibble(
  termo   = c("Média", "Linha", "Coluna", "Tratamento", "Erro"),
  classes = c(1, 4, 4, 4, 16)      # n=4 linhas, colunas e tratamentos; N=16 parcelas
)
arestas_ql <- tibble(
  de   = c("Média", "Média", "Média", "Linha", "Coluna", "Tratamento"),
  para = c("Linha", "Coluna", "Tratamento", "Erro", "Erro", "Erro")
)

knitr::include_graphics(
  hasse_svg(nos_ql, arestas_ql,
            arquivo = "figuras/hasse/quadrado-latino.svg",
            titulo  = "Quadrado latino: n=4 (N=16)")
)
```

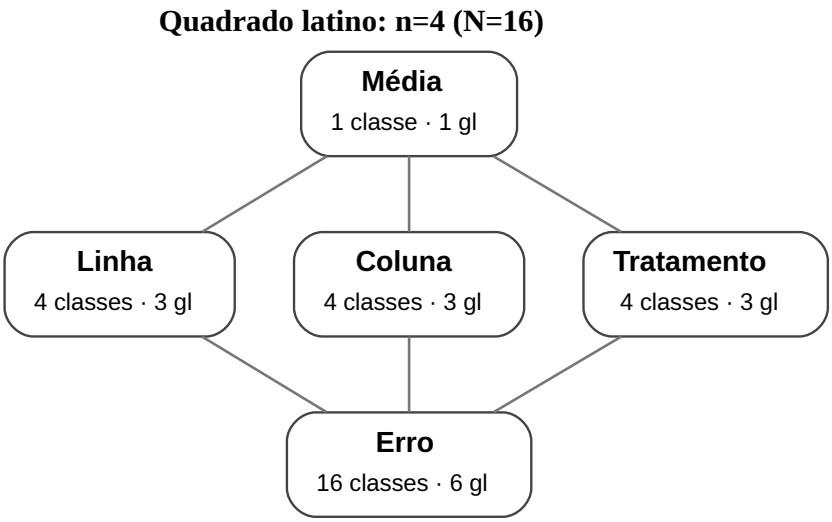


Figura 4.3: Diagrama de Hasse do quadrado latino 4x4 (exemplo dos quatro adubos): n=4 linhas, n=4 colunas, n=4 tratamentos, N=n^2=16. Linha, Coluna e Tratamento aparecem no mesmo nível – cruzados dois a dois – e convergem direto no Erro, sem nó de interação, pela mesma razão do DBCA (seção anterior).

Os cinco nós somam $1 + 3 + 3 + 3 + 6 = 16 = n^2$: Linha, Coluna e Tratamento consomem $n - 1 = 3$ graus de liberdade cada um (idêntico entre si, porque os três têm exatamente n níveis), e sobram $(n-1)(n-2) = 3 \times 2 = 6$ para o Erro — a mesma fórmula da tabela de ANOVA acima, aqui obtida por contagem direta no diagrama: n^2 caselas menos os $1 + 3 + 3 + 3 = 10$ graus de liberdade já “explicados” pelos quatro nós superiores. Note o padrão que se repete a cada capítulo: quanto mais fatores cruzados sem repetição dentro de casela, menos graus de liberdade sobram para o erro — um quadrado latino de ordem n “gasta” $3(n-1)$ graus de liberdade em estrutura antes de chegar ao erro, contra apenas $(t-1) + (b-1)$ do DBCA de dois fatores.

4.4.4 Aleatorização de um quadrado latino (Yates, 1933)

O quadro `quad` acima foi escrito de próprio punho, na ordem “óbvia” — mas usar sempre o mesmo arranjo fixo reintroduz exatamente o problema que a aleatorização deveria evitar: se, por exemplo, o adubo A está sempre na diagonal principal, e a diagonal principal coincidir por acaso com alguma característica não modelada do talhão (digamos, um carreador de máquinas), o efeito de A ficaria confundido com essa característica em **todo** experimento que reusasse esse quadrado. Yates (1933) (ver Fisher (1935b) para o contexto experimental) propôs um procedimento de aleatorização em quatro etapas que garante que a atribuição de tratamentos a células não dependa de nenhuma escolha arbitrária do pesquisador:

1. Partir de um **quadrado latino reduzido** (primeira linha e primeira coluna em ordem “alfabética” $1, 2, \ldots, n$) — existe pelo menos um para toda ordem n, e é fácil de escrever (por exemplo, a construção cíclica $\text{quad}[i, j] = ((i + j - 2) \bmod n) + 1$).
2. Permutar aleatoriamente as **linhas** do quadrado reduzido.
3. Permutar aleatoriamente as **colunas** do resultado.
4. Sortear aleatoriamente **quais tratamentos reais** correspondem a cada símbolo $1, \ldots, n$.

Uso do R — implementação do algoritmo de Yates (1933)

```r
aleatorizar_quadrado_latino <- function(n, tratamentos, seed = NULL) {
  if (!is.null(seed)) set.seed(seed)
  # Passo 0: quadrado latino reduzido, construção cíclica
  reduzido <- outer(0:(n - 1), 0:(n - 1), function(i, j) ((i + j) %% n) + 1)

  # Passos 2-3: permutar linhas e colunas independentemente
  perm_linhas  <- sample(n)
  perm_colunas <- sample(n)
  design_idx   <- reduzido[perm_linhas, perm_colunas]

  # Passo 4: atribuir tratamentos reais aos símbolos 1..n
  atrib <- sample(tratamentos)
  design <- matrix(atrib[design_idx], nrow = n)

  list(design = design, perm_linhas = perm_linhas, perm_colunas = perm_colunas, atrib
        = atrib)
}

set.seed(2026)
resultado_yates <- aleatorizar_quadrado_latino(4, c("A", "B", "C", "D"))
resultado_yates$design
```

```
##      [,1] [,2] [,3] [,4]
## [1,] "D"  "C"  "B"  "A"
## [2,] "B"  "A"  "C"  "D"
## [3,] "C"  "D"  "A"  "B"
## [4,] "A"  "B"  "D"  "C"
```

```r
# a aleatorização não pode violar a definição de quadrado latino
d <- resultado_yates$design
c(linhas_ok  = all(apply(d, 1, function(r) length(unique(r)) == 4)),
  colunas_ok = all(apply(d, 2, function(cl) length(unique(cl)) == 4)))
```

```
##  linhas_ok colunas_ok
##       TRUE       TRUE
```

O quadrado gerado por essa execução (D C B A na primeira linha) é apenas **um entre muitos** igualmente válidos e igualmente prováveis sob o procedimento de Yates — rodar novamente com outra semente produziria outro arranjo, também válido. É esse espaço de arranjos possíveis, e não um único quadrado fixo, que sustenta a distribuição de referência da aleatorização por trás do teste F: o argumento de Neyman-Rubin da Seção 4.1 (p. 89) se aplica aqui do mesmo modo, só que a aleatorização agora é restrita simultaneamente por linha e por coluna, não apenas por bloco.

```r
efeito_linha  <- c(0, 2, -1, 1)
efeito_coluna <- c(0, -2, 1, 1)
efeito_trat   <- c(A = 0, B = 3, C = 5, D = 1)

set.seed(11)
dados_ql <- expand_grid(linha = 1:4, coluna = 1:4) %>%
  mutate(
    tratamento = factor(mapply(function(i, j) quad[i, j], linha, coluna),
                        levels = c("A","B","C","D")),
    linha  = factor(linha), coluna = factor(coluna),
    resposta = round(20 + efeito_linha[as.integer(linha)] +
        efeito_coluna[as.integer(coluna)] +
                efeito_trat[as.character(tratamento)] + rnorm(n(), 0, 1.2), 2)
  )
```

```
        mod_ql <- aov(resposta ~ linha + coluna + tratamento, data = dados_ql)
anova(mod_ql) %>% broom::tidy() %>%
  kable(digits = 4, caption = "ANOVA do quadrado latino 4x4 (dados simulados)") %>%
  kable_styling(full_width = FALSE)
```

Tabela 4.8: ANOVA do quadrado latino 4x4 (dados simulados)

term	df	sumsq	meansq	statistic	p.value
linha	3	43.6726	14.5575	10.7030	0.0080
coluna	3	27.0569	9.0190	6.6309	0.0247
tratamento	3	56.8363	18.9454	13.9291	0.0041
Residuals	6	8.1608	1.3601	NA	NA

Vale explicitar a matriz de delineamento aqui: agora $X = [\mathbf{1} \mid X_{linha} \mid X_{coluna} \mid X_{trat}]$ tem **três** blocos de colunas, e continua sem nenhum produto cruzado entre eles — essa ortogonalidade de blocos de colunas é exatamente o que torna o quadrado latino "econômico": ele estima três efeitos principais com n^2 observações porque abre mão de qualquer termo de interação entre linha, coluna e tratamento.

```
X_ql <- model.matrix(mod_ql)
dim(X_ql)   # 16 linhas, 1 + 3 (linha) + 3 (coluna) + 3 (tratamento) = 10 colunas
```

```
## [1] 16 10
```

```
X_ql[1:4, ]
```

```
##   (Intercept) linha2 linha3 linha4 coluna2 coluna3 coluna4 tratamentoB
## 1           1      0      0      0       0       0       0           0
## 2           1      0      0      0       1       0       0           1
## 3           1      0      0      0       0       1       0           0
## 4           1      0      0      0       0       0       1           0
##   tratamentoC tratamentoD
## 1           0           0
## 2           0           0
## 3           1           0
## 4           0           1
```

Com apenas 16 unidades experimentais, controlamos duas fontes de variação e ainda testamos o efeito de adubação ($F_{3,6} = 13{,}9$, $p = 0{,}004$) — um fatorial completo de linha $\times$ coluna $\times$ tratamento precisaria de $4^3 = 64$ unidades para o mesmo número de níveis. O preço é a suposição extra de que **não há interação** entre linha, coluna e tratamento: se o efeito de uma adubação de fato depender da combinação específica de declividade e umidade, o quadrado latino confunde essa interação com o erro experimental, sem meios de separá-las.

4.4.5 Quadrados latinos replicados

Com n pequeno (tipicamente $n \leq 5$), o quadrado latino sozinho deixa poucos graus de liberdade para o erro — apenas $(n-1)(n-2)$, que é 6 para $n = 4$ e apenas 2 para $n = 3$. **Replicar** o quadrado latino em p conjuntos independentes de unidades experimentais (por exemplo, p fazendas ou p safras, cada uma com suas próprias linhas e colunas) aumenta os graus de liberdade do erro sem aumentar n. Quando cada réplica tem suas próprias linhas e colunas (o caso mais comum, em que os blocos de linha/coluna não são os mesmos de uma réplica para outra):

Tabela 4.9: Tabela de ANOVA do quadrado latino replicado (p réplicas independentes)

Fonte de variação	Graus de liberdade
Réplicas	$p-1$
Linhas (dentro de réplica)	$p(n-1)$
Colunas (dentro de réplica)	$p(n-1)$
Tratamento	$n-1$
Erro	$(n-1)[p(n-1)-1]$
Total	pn^2-1

Uso do R — duas réplicas independentes do mesmo quadrado latino

```
n <- 4; p <- 2
dados_rep <- map_dfr(1:p, function(rep_id) {
  expand_grid(linha = 1:4, coluna = 1:4) %>%
    mutate(
      replica    = rep_id,
      tratamento = factor(mapply(function(i, j) quad[i, j], linha, coluna),
                          levels = c("A","B","C","D")),
      linha_id   = factor(paste0(rep_id, "-", linha)),
      coluna_id  = factor(paste0(rep_id, "-", coluna))
    )
})

set.seed(22)
dados_rep <- dados_rep %>%
  mutate(
    replica  = factor(replica),
    resposta = round(20 + rnorm(n(), 0, 1) + efeito_trat[as.character(tratamento)] +
                 as.numeric(replica) * 1.5 + rnorm(n(), 0, 1.2), 2)
  )

mod_rep <- aov(resposta ~ replica + linha_id + coluna_id + tratamento, data =
        dados_rep)
anova(mod_rep) %>% broom::tidy() %>%
  kable(digits = 4, caption = "ANOVA de duas réplicas do quadrado latino 4x4") %>%
  kable_styling(full_width = FALSE)
```

Tabela 4.10: ANOVA de duas réplicas do quadrado latino 4x4

term	df	sumsq	meansq	statistic	p.value
replica	1	6.2747	6.2747	3.2820	0.0901
linha_id	6	3.8766	0.6461	0.3379	0.9061
coluna_id	6	31.1797	5.1966	2.7182	0.0544
tratamento	3	116.8563	38.9521	20.3744	0.0000
Residuals	15	28.6772	1.9118	NA	NA

Confira: $gl_{Erro} = (n-1)[p(n-1)-1] = 3 \times (2 \times 3 - 1) = 15$, exatamente o valor produzido pelo ajuste acima — replicar duas vezes elevou os graus de liberdade do erro de 6 para 15, tornando o teste sobre tratamentos bem mais sensível do que seria com um único quadrado.

4.4.6 Quantas réplicas? Uma análise de poder

A pergunta prática — “vale a pena replicar, e quantas vezes?” — pode ser respondida antes de coletar qualquer dado, por **análise de poder**. A estatística de teste do quadrado latino replicado segue, sob H_1, uma distribuição F não central com parâmetro de não-centralidade $\lambda = N f^2$, em que $N = pn^2$ é o número total de unidades e f é o tamanho de efeito de Cohen para o fator de tratamento — a mesma convenção usada em análises de poder de ANOVA de um fator ($f = 0{,}10$: efeito pequeno; $f = 0{,}25$: médio; $f = 0{,}40$: grande).

> **Uso do R** — poder do teste de tratamento em função do número de réplicas

```
poder_ql_replicado <- function(n, p, alpha = 0.05, f = 0.4) {
  gl1 <- n - 1
  gl2 <- (n - 1) * (p * (n - 1) - 1)
  N   <- p * n^2
  ncp <- N * f^2
  f_crit <- qf(1 - alpha, gl1, gl2)
  1 - pf(f_crit, gl1, gl2, ncp)
}

tab_poder <- tibble(p = 1:6) %>%
  mutate(
    gl_erro = (4 - 1) * (p * (4 - 1) - 1),
    poder   = poder_ql_replicado(n = 4, p = p, f = 0.4)
  )
tab_poder %>%
  kable(digits = 3, caption = "Poder do teste de tratamento vs. número de réplicas
        (n=4, f=0,4)") %>%
  kable_styling(full_width = FALSE)
```

Tabela 4.11: Poder do teste de tratamento vs. número de réplicas (n=4, f=0,4)

p	gl_erro	poder
1	6	0.148
2	15	0.356
3	24	0.557
4	33	0.716
5	42	0.828
6	51	0.901

```
ggplot(tab_poder, aes(x = p, y = poder)) +
  geom_line(color = "#2a78d6", linewidth = 1) +
  geom_point(size = 2.6, color = "#2a78d6") +
  geom_hline(yintercept = 0.8, linetype = "dashed", color = "grey40") +
  scale_x_continuous(breaks = 1:6) +
  labs(x = "Número de réplicas do quadrado (p)", y = "Poder estatístico",
       title = "Poder para detectar um efeito grande (f=0,4) de tratamento") +
  ylim(0, 1) +
  theme_minimal(base_size = 12)
```

Com um único quadrado ($p = 1$, $gl_{Erro} = 6$), o poder para detectar um efeito grande é de apenas 15% — mesmo um efeito real e substantivo tem boa chance de passar despercebido. Duas réplicas (o exemplo acima) elevam o poder para 36%; são necessárias 5 réplicas para cruzar a convenção usual de poder $\geq 0{,}80$. Essa é exatamente a natureza da decisão prática de delineamento: replicar tem custo (mais unidades experimentais, mais tempo, mais recursos), e a análise de poder converte "quantas réplicas?" de uma escolha arbitrária em uma conta explícita, condicionada ao menor efeito que se considera cientificamente relevante detectar. Efeitos menores ($f = 0{,}25$ ou $f = 0{,}10$) exigiriam ainda mais réplicas para o mesmo poder — vale repetir o cálculo acima variando `f` antes de decidir o tamanho do experimento.

4.4.7 Eficiência relativa do quadrado latino frente ao DBCA e ao DCA

A Seção 4.1 (p. 89) definiu a eficiência relativa do DBCA frente ao DCA comparando a variância por unidade experimental que cada delineamento produziria. A mesma lógica formal se estende ao quadrado latino — só que agora há **duas** fontes de bloqueio (linha e coluna), e cabe perguntar não só "valeu a pena blocar?", mas "qual das duas fontes carregou mais peso?". A comparação mais direta aqui é, na verdade, **exata**, sem nenhuma aproximação: como SQ_{Total} não depende de qual modelo foi ajustado, a soma de quadrados que um DCA hipotético (que ignorasse linha e coluna) atribuiria ao erro é exatamente o que sobra depois de remover só o tratamento,

$$SQ_{Erro}^{(DCA)} = SQ_{Total} - SQ_{Trat} = SQ_{Linha} + SQ_{Coluna} + SQ_{Erro}^{(QL)},$$

com $gl_{Erro}^{(DCA)} = n^2 - 1 - (n-1) = n(n-1)$ graus de liberdade. Substituindo $SQ_{Linha} = (n-1)QM_{Linha}$, $SQ_{Coluna} = (n-1)QM_{Coluna}$ e $SQ_{Erro}^{(QL)} = (n-1)(n-2)QM_{Erro}$ e dividindo pelos graus de liberdade,

$$QM_{Erro}^{(DCA)} = \frac{QM_{Linha} + QM_{Coluna} + (n-2)\,QM_{Erro}}{n}, \qquad ER(QL, DCA) = \frac{QM_{Erro}^{(DCA)}}{QM_{Erro}^{(QL)}}.$$

O mesmo raciocínio, aplicado a um DBCA hipotético que usasse **só uma** das duas fontes de bloqueio (digamos, só linha, absorvendo coluna de volta ao erro), dá

$$QM_{Erro}^{(DBCA\text{-linha})} = \frac{QM_{Coluna} + (n-2)\,QM_{Erro}}{n-1}, \qquad ER(QL, DBCA\text{-linha}) = \frac{QM_{Erro}^{(DBCA\text{-linha})}}{QM_{Erro}^{(QL)}},$$

e simetricamente para $ER(QL, DBCA\text{-coluna})$, trocando QM_{Coluna} por QM_{Linha}. Diferente da fórmula de Fisher usada na Seção 4.1 (p. 89) (que corrige o pequeno viés de usar uma variância *estimada*, com poucos graus de liberdade, para julgar precisão futura), estas três razões são identidades algébricas exatas — seguem diretamente de como SQ_{Total} se particiona entre fontes ortogonais, não de uma aproximação assintótica.

> **Uso do R** — eficiência relativa do quadrado latino das quatro adubações

```
tab_ql <- anova(mod_ql)
QM_linha_ql  <- tab_ql["linha", "Mean Sq"]
QM_coluna_ql <- tab_ql["coluna", "Mean Sq"]
QM_erro_ql   <- tab_ql["Residuals", "Mean Sq"]
n_ql <- 4
```

```
QM_erro_dca <- (QM_linha_ql + QM_coluna_ql + (n_ql - 2) * QM_erro_ql) / n_ql
ER_dca      <- QM_erro_dca / QM_erro_ql
QM_erro_dbca_linha <- (QM_coluna_ql + (n_ql - 2) * QM_erro_ql) / (n_ql - 1)
ER_dbca_linha       <- QM_erro_dbca_linha / QM_erro_ql
QM_erro_dbca_coluna <- (QM_linha_ql + (n_ql - 2) * QM_erro_ql) / (n_ql - 1)
ER_dbca_coluna       <- QM_erro_dbca_coluna / QM_erro_ql        tibble(
  Comparação = c("QL vs. DCA (ignora linha e coluna)",
                 "QL vs. DBCA (só bloqueia linha)",
                 "QL vs. DBCA (só bloqueia coluna)"),
  `Eficiência relativa` = c(ER_dca, ER_dbca_linha, ER_dbca_coluna)) %>%
  kable(digits = 2, caption = "Eficiência relativa do quadrado latino 4x4 das quatro
        adubações") %>%
  kable_styling(full_width = FALSE)
```

Tabela 4.12: Eficiência relativa do quadrado latino 4x4 das quatro adubações

Comparação	Eficiência relativa
QL vs. DCA (ignora linha e coluna)	4.83
QL vs. DBCA (só bloqueia linha)	2.88
QL vs. DBCA (só bloqueia coluna)	4.23

O quadrado latino é claramente a escolha certa neste experimento: comparado a um DCA que ignorasse os dois gradientes, seria preciso 4.8 vezes mais unidades experimentais para igualar sua precisão; mesmo comparado a um DBCA que já controlasse a declividade (linha), ainda seria preciso 2.9 vezes mais. O padrão $ER(QL, DBCA\text{-linha}) < ER(QL, DBCA\text{-coluna})$ é informativo por si só: como $QM_{Linha} = 14.56$ é maior que $QM_{Coluna} = 9.02$ na Tabela de ANOVA acima, é a **linha** (declividade) que carrega mais heterogeneidade real — um DBCA que já a controlasse deixaria pouca "sobra" para o quadrado latino explicar ao acrescentar a coluna, exatamente o que a eficiência relativa menor (2.9 contra 4.2) mostra. É esse tipo de decomposição — não apenas "o quadrado latino ajudou?", mas "qual das duas fontes de bloqueio carregou mais peso?" — que a extensão da eficiência relativa a duas dimensões permite responder.

4.4.8 Um segundo exemplo completo: cinco variantes de checkout em e-commerce

Para fixar a notação matricial do quadrado latino em um domínio bem diferente da agricultura — ciência de dados, o mesmo cenário que o Capítulo 8 retomará sob a ótica de testes A/B —, considere um segundo exemplo completo, agora com $n = 5$.

Aplicação — Ciência de dados: cinco variantes de checkout, controlando hora do dia e dia da semana
Uma equipe de produto quer comparar **cinco variantes** (A–E) do botão de finalizar compra em um site de e-commerce, medindo a taxa de conversão (%). A conversão varia sistematicamente tanto pela **hora do dia** (cinco faixas horárias) quanto pelo **dia da semana** (cinco dias úteis) — duas fontes de bloqueio conhecidas e cruzadas, o cenário exato de um quadrado latino 5×5: cada variante é exibida exatamente uma vez em cada faixa horária e uma vez em cada dia da semana, ao longo de 25 janelas de exibição.

Uso do R — construção, ajuste e notação matricial do quadrado latino 5x5

```r
n5 <- 5
quad5 <- matrix(LETTERS[outer(0:(n5-1), 0:(n5-1), function(i, j) ((i + j) %% n5) +
        1)], nrow = n5)
quad5   # construção cíclica: quad5[i,j] = letra ((i+j) mod 5)
```

```
##      [,1] [,2] [,3] [,4] [,5]
## [1,] "A"  "B"  "C"  "D"  "E"
## [2,] "B"  "C"  "D"  "E"  "A"
## [3,] "C"  "D"  "E"  "A"  "B"
## [4,] "D"  "E"  "A"  "B"  "C"
## [5,] "E"  "A"  "B"  "C"  "D"
```

```r
ef_hora <- c(0, 0.5, 1.2, 0.8, -0.3)             # efeito de faixa horária (pontos
        percentuais)
ef_dia  <- c(0, -0.4, 0.2, 0.6, -0.2)            # efeito de dia da semana
ef_var  <- c(A = 0, B = 0.9, C = 1.6, D = 0.4, E = -0.5)  # efeito de variante

set.seed(2025)
dados_ec <- expand_grid(hora = 1:n5, dia = 1:n5) %>%
  mutate(
    variante = factor(mapply(function(i, j) quad5[i, j], hora, dia), levels =
        LETTERS[1:5]),
    hora = factor(hora), dia = factor(dia),
    conversao = round(8 + ef_hora[as.integer(hora)] + ef_dia[as.integer(dia)] +
                  ef_var[as.character(variante)] + rnorm(n(), 0, 0.35), 3)
  )

mod_ec <- aov(conversao ~ hora + dia + variante, data = dados_ec)
anova(mod_ec) %>% broom::tidy() %>%
  kable(digits = 4, caption = "ANOVA do quadrado latino 5x5 (variantes de checkout)")
        %>%
  kable_styling(full_width = FALSE)
```

Tabela 4.13: ANOVA do quadrado latino 5x5 (variantes de checkout)

term	df	sumsq	meansq	statistic	p.value
hora	4	4.5980	1.1495	9.3376	0.0011
dia	4	3.7466	0.9366	7.6084	0.0027
variante	4	16.8330	4.2083	34.1842	0.0000
Residuals	12	1.4773	0.1231	NA	NA

Como no exemplo anterior, a matriz de delineamento tem a forma em blocos de colunas $X = [\mathbf{1} \mid X_{hora} \mid X_{dia} \mid X_{variante}]$, agora com $n - 1 = 4$ colunas indicadoras para cada um dos três fatores (parametrização de referência): $1 + 4 + 4 + 4 = 13$ colunas para $N = n^2 = 25$ observações.

```r
X_ec <- model.matrix(mod_ec)
dim(X_ec)   # 25 linhas, 13 colunas
```

```
## [1] 25 13
```

O posto de X tem que ser exatamente 13 — nenhuma coluna é combinação linear das demais, porque não há produto cruzado entre os três blocos de colunas. A matriz de projeção $H = X(X'X)^{-1}X'$ (Capítulo 2) confirma isso diretamente: seu traço, que mede a dimensão do subespaço de $\mathbb{R}^{25}$ em que Y é projetado, coincide com o posto de X.

```
H_ec <- X_ec %*% solve(t(X_ec) %*% X_ec) %*% t(X_ec)
c(traco_H = sum(diag(H_ec)), posto_X = qr(X_ec)$rank)
```

```
## traco_H posto_X
##      13      13
```

Os três testes-F são significativos — hora do dia ($F = 9.34$, $p = 0.0011$), dia da semana ($F = 7.61$, $p = 0.0027$) e, principalmente, variante ($F = 34.18$, $p < 0{,}001$) —, confirmando que as duas fontes de bloqueio de fato carregavam variação real (o quadrado latino não gastou seus graus de liberdade à toa) e que as variantes diferem entre si.

> **Uso do R** — médias ajustadas por variante, controlando hora e dia

```
library(emmeans)
emm_var <- emmeans(mod_ec, ~ variante)
emm_df  <- as_tibble(emm_var)

ggplot(emm_df, aes(x = variante, y = emmean)) +
  geom_pointrange(aes(ymin = lower.CL, ymax = upper.CL), color = "#2a78d6", linewidth
        = 0.9) +
  labs(x = "Variante de checkout", y = "Conversão média ajustada (%)",
       title = "Médias ajustadas por variante (IC 95%, controlando hora e dia)") +
  theme_minimal(base_size = 12)
```

As médias ajustadas separam claramente a variante C (10.35%, a melhor) da variante E (7.93%, a pior) — os intervalos de 95% não se sobrepõem entre as duas, evidência forte de que a diferença é real e não ruído de amostragem. Note o paralelo direto com um teste A/B: se a equipe tivesse testado só C contra A sem controlar hora e dia (um DCA disfarçado de “teste A/B simples”), o mesmo efeito real de variante teria ficado misturado com a variação sistemática de tráfego ao longo do dia e da semana — o Capítulo 8 retoma exatamente esse ponto ao discutir por que testes A/B ingênuos, sem nenhum controle local, podem levar a conclusões erradas mesmo com milhares de observações.

4.4.9 Quadrados de Youden: quando o quadrado latino não pode ser completo

Um quadrado latino exige n linhas *e* n colunas — mas, às vezes, o número de “posições” disponíveis em uma das duas direções é menor que o número de tratamentos: um viveiro tem $v = 7$ variedades a comparar, mas a bancada de casa de vegetação só tem $r = 3$ posições físicas por data de plantio; um painel sensorial quer balancear v produtos contra v sessões, mas cada degustador (linha) só avalia $r < v$ produtos por sessão. Um **quadrado de Youden** resolve exatamente esse caso: é um quadrado latino **incompleto**, em que uma das duas dimensões de bloqueio (aqui, coluna) tem menos níveis do que tratamentos.

Formalmente, um quadrado de Youden com parâmetros (v, r), $r < v$, é um arranjo retangular de r linhas por v colunas, com v tratamentos, tal que:

1. cada **linha** contém cada um dos v tratamentos exatamente uma vez — como em um quadrado latino completo, a linha não é incompleta;
2. cada **coluna** contém apenas r dos v tratamentos, e o conjunto de tratamentos que aparece em cada coluna forma um bloco de um delineamento em blocos incompletos balanceados (Seção 4.3 (p. 103))

simétrico, com parâmetros $t = b = v$, $k = r$ e $\lambda = \dfrac{r(r-1)}{v-1}$.

Em outras palavras: um quadrado de Youden é, ao mesmo tempo, um quadrado latino em relação a linha$\times$tratamento (ortogonalidade completa) e um BIB em relação a coluna$\times$tratamento (balanceamento incompleto) — as duas estruturas dos capítulos anterior e desta seção, combinadas em um único delineamento. Com $N = rv$ unidades em vez das v^2 que um quadrado latino completo exigiria, o modelo é

$$Y_{ijk} = \mu + \rho_i + \gamma_j + \tau_k + \varepsilon_{ijk}, \qquad i = 1, \ldots, r, \;\; j = 1, \ldots, v,$$

com k novamente determinado pelo arranjo, não livre. Como linha é ortogonal a tratamento (item 1 acima), a soma de quadrados de tratamento **não** precisa de ajuste em relação à linha — só em relação à coluna, exatamente com a fórmula de Q_i e $SQ_{Trat(ajustada)}$ da Seção 4.3 (p. 103), usando $T_{i\cdot}$ (soma do tratamento i) e $B_{\cdot j}$ (soma da coluna j) no lugar de bloco:

$$Q_i = T_{i\cdot} - \frac{1}{r} \sum_{j:\, i \in \text{coluna } j} B_{\cdot j}, \qquad SQ_{\text{Trat(ajustada)}} = \frac{r \sum_{i=1}^{v} Q_i^2}{\lambda v}.$$

Tabela 4.14: Tabela de ANOVA do quadrado de Youden

Fonte de variação	Graus de liberdade
Linha	$r - 1$
Coluna	$v - 1$
Tratamento (ajustado)	$v - 1$
Erro	$(v-1)(r-2)$
Total	$rv - 1$

Aplicação — Agricultura: sete genótipos de soja, três posições por data de plantio
Um experimento de casa de vegetação compara **sete genótipos** de soja ($v = 7$) ao longo de **sete datas de plantio** (colunas), mas a bancada só comporta **três** vasos por data ($r = 3$). Cada genótipo ainda deve aparecer exatamente uma vez em cada "posição" (linha) da bancada, e cada par de genótipos deve coocorrer no mesmo número de datas — a estrutura de um quadrado de Youden $(v, r) = (7, 3)$.

A construção clássica parte de um **conjunto de diferenças perfeito** — aqui, $D = \{1, 2, 4\} \pmod 7$ (os resíduos quadráticos módulo 7): a célula (i, j) recebe o tratamento $(d_i + j) \bmod 7$, para $d_i \in D$ (na ordem fixa $1, 2, 4$) e $j = 0, \ldots, 6$. Ler ao longo de uma linha i fixa faz j percorrer $0, \ldots, 6$ e, portanto, $(d_i + j) \bmod 7$ percorre todos os 7 tratamentos — a propriedade (1) acima. Ler ao longo de uma coluna j fixa dá o bloco $D + j \pmod 7$, uma translação cíclica de D: como D é um conjunto de diferenças perfeito, todo par de tratamentos coocorre em exatamente $\lambda = 1$ coluna — a propriedade (2).

Uso do R — construção e verificação do quadrado de Youden (7,3)

```
v_y <- 7; r_y <- 3
D <- c(1, 2, 4)                                  # resíduos quadráticos mod 7
        (conjunto de diferenças)
genotipos <- paste0("G", 1:7)

Y <- matrix(NA_integer_, nrow = r_y, ncol = v_y)
for (i in 1:r_y) for (j in 0:(v_y - 1)) Y[i, j + 1] <- (D[i] + j) %% v_y + 1
```

```
rownames(Y) <- paste0("linha", 1:r_y); colnames(Y) <- paste0("data", 1:v_y)
matrix(genotipos[Y], nrow = r_y, dimnames = dimnames(Y))
```

```
##        data1 data2 data3 data4 data5 data6 data7
## linha1 "G2"  "G3"  "G4"  "G5"  "G6"  "G7"  "G1"
## linha2 "G3"  "G4"  "G5"  "G6"  "G7"  "G1"  "G2"
## linha3 "G5"  "G6"  "G7"  "G1"  "G2"  "G3"  "G4"
```

```
# verificação: cada linha e uma permutação dos 7 genotipos; cada par coocorre 1 vez
linhas_ok <- all(apply(Y, 1, function(lin) length(unique(lin)) == v_y))
pares <- combn(1:v_y, 2)
lambda_obs <- range(apply(pares, 2, function(p) sum(sapply(1:v_y, function(j) all(p
        %in% Y[, j])))))
c(linhas_sao_permutacoes = linhas_ok, lambda_min = lambda_obs[1], lambda_max =
        lambda_obs[2])
```

```
## linhas_sao_permutacoes             lambda_min             lambda_max
##                      1                      1                      1
```

O contraste com o quadrado latino completo salta aos olhos: cada **linha** ainda contém todos os 7 genótipos (lida na horizontal, a figura mostra os 7 rótulos diferentes), mas cada **coluna** só mostra 3 dos 7 (a "incompletude" que dá nome ao delineamento) — e ainda assim, por construção via o conjunto de diferenças, todo par de genótipos aparece junto em exatamente uma coluna.

```
ef_trat_y  <- c(G1 = 0, G2 = 1.5, G3 = 3, G4 = -1, G5 = 2, G6 = 0.5, G7 = -2)
ef_linha_y <- c(0, 1, -1)
ef_col_y   <- c(0, 0.5, -0.5, 1, -1, 0.3, -0.3)

set.seed(48)
dados_youden <- expand_grid(linha = 1:r_y, coluna = 1:v_y) %>%
  mutate(
    trat  = factor(genotipos[mapply(function(i, j) Y[i, j], linha, coluna)], levels =
        genotipos),
    linha = factor(linha), coluna = factor(coluna),
    altura = round(30 + ef_linha_y[as.integer(linha)] + ef_col_y[as.integer(coluna)]
        +
              ef_trat_y[as.character(trat)] + rnorm(n(), 0, 1), 2)
  )

mod_youden <- aov(altura ~ linha + coluna + trat, data = dados_youden)
anova(mod_youden) %>% broom::tidy() %>%
  kable(digits = 4, caption = "ANOVA do quadrado de Youden (7,3): altura de plântulas
        de soja") %>%
  kable_styling(full_width = FALSE)
```

Tabela 4.15: ANOVA do quadrado de Youden (7,3): altura de plântulas de soja

term	df	sumsq	meansq	statistic	p.value
linha	2	22.9422	11.4711	24.0077	0.0014
coluna	6	41.7391	6.9565	14.5592	0.0024
trat	6	37.2358	6.2060	12.9884	0.0033
Residuals	6	2.8669	0.4778	NA	NA

```
lambda_y <- r_y * (r_y - 1) / (v_y - 1)   # = 1 para (v,r) = (7,3)
```

```
T_trat  <- tapply(dados_youden$altura, dados_youden$trat, sum)
B_col   <- tapply(dados_youden$altura, dados_youden$coluna, sum)
soma_col_do_trat <- sapply(genotipos, function(g) {
  cols <- unique(dados_youden$coluna[dados_youden$trat == g])
  sum(B_col[as.character(cols)])})
Q_y <- T_trat - soma_col_do_trat / r_y
SQ_trat_ajustada_y <- r_y * sum(Q_y^2) / (lambda_y * v_y)
c(SQ_trat_formula_Qi = SQ_trat_ajustada_y,
  SQ_trat_aov         = anova(mod_youden)["trat", "Sum Sq"])
```

```
## SQ_trat_formula_Qi        SQ_trat_aov
##            37.2358            37.2358
```

Os dois valores coincidem, exatamente como no BIB da Seção 4.3 (p. 103) — a diferença é que aqui a linha, por ser ortogonal a tratamento, pode entrar no modelo em qualquer ordem sem alterar a soma de quadrados de tratamento; só a coluna exige o ajuste de Q_i. Com apenas $N = rv = 21$ unidades (bem menos que as $v^2 = 49$ de um quadrado latino 7×7 completo), o quadrado de Youden ainda separa com clareza os efeitos de linha, coluna e genótipo, ao custo de $(v-1)(r-2) = 6$ graus de liberdade de erro — a mesma troca entre economia de unidades experimentais e graus de liberdade de erro já vista para o BIB e para o quadrado latino replicado.

W. J. Youden introduziu esse delineamento em 1937, em ensaios agrícolas de campo; a referência ainda não consta em `Livro/refs.bib`, então nenhuma citação foi inserida aqui para evitar uma chave bibliográfica quebrada no PDF/HTML final.

4.5 Delineamento em quadrado greco-latino

Quando há **três** fontes de bloqueio cruzadas — ou, equivalentemente, duas fontes de bloqueio e um segundo fator de tratamento que se deseja controlar simultaneamente à primeira — o **quadrado greco-latino** sobrepõe dois quadrados latinos **ortogonais** de ordem n: um com letras romanas (A, B, C, …) e outro com letras gregas ($\alpha, \beta, \gamma, \ldots$), construídos de modo que **cada par (letra romana, letra grega) ocorra exatamente uma vez** no quadrado $n \times n$. Isso só é possível quando existe um **par de quadrados latinos ortogonais** de ordem n — a próxima subseção formaliza para quais n isso vale, e conta a história de sua exceção mais famosa.

4.5.1 Quadrados latinos mutuamente ortogonais (MOLS): existência e o problema de Euler

Dois quadrados latinos L_1 e L_2 de ordem n são **ortogonais** se, ao sobrepô-los, cada um dos n^2 pares ordenados de símbolos $(L_1(i,j), L_2(i,j))$ ocorre exatamente uma vez — a propriedade exigida na construção do quadrado greco-latino acima. Um conjunto de k quadrados latinos de ordem n, ortogonais dois a dois, é chamado de **MOLS** de ordem n (*mutually orthogonal Latin squares*), denotado $\mathrm{MOLS}(n, k)$.

Cota superior. O número máximo $N(n)$ de quadrados latinos de ordem n mutuamente ortogonais satisfaz

$$N(n) \leq n - 1$$

(Dean et al., 2017; Montgomery, 2017). Esse máximo é **atingido** — existe um conjunto completo de $n-1$ MOLS — sempre que n é uma potência de primo: identificando os n símbolos com os elementos do corpo de Galois $GF(n)$, os $n-1$ quadrados $L_a(x,y) = ax + y$ (aritmética em $GF(n)$), para $a \in GF(n) \setminus \{0\}$, são ortogonais dois a dois — duas linhas x, x' de L_a coincidem em coluna y apenas se $ax + y = ax' + y$

, ou seja $x = x'$, e o mesmo argumento aplicado a $L_a(x,y) - L_{a'}(x,y) = (a-a')x$ garante que L_a e $L_{a'}$ ($a \neq a'$) nunca repetem um par (s,t). Essa é exatamente a construção por trás dos exemplos de quadrado greco-latino desta seção (que usam $n = 4 = 2^2$, potência de primo).

> **Uso do R** — construindo e verificando um conjunto completo de MOLS de ordem 5

```
n_mols <- 5   # primo: GF(5) = Z_5 com aritmetica usual
mols5 <- lapply(1:(n_mols - 1), function(a) {
  outer(0:(n_mols - 1), 0:(n_mols - 1), function(x, y) (a * x + y) %% n_mols)
})

ortogonais <- function(A, B) length(unique(paste(A, B))) == n_mols^2
pares_idx  <- combn(1:(n_mols - 1), 2)
todos_ortogonais <- all(apply(pares_idx, 2, function(p) ortogonais(mols5[[p[1]]],
        mols5[[p[2]]])))

c(quadrados_construidos = length(mols5), maximo_teorico = n_mols - 1,
  todos_pares_ortogonais = todos_ortogonais)
```

```
##  quadrados_construidos         maximo_teorico todos_pares_ortogonais
##                      4                      4                      1
```

Os 4 quadrados $L_1, \ldots, L_4$ atingem exatamente a cota $N(5) \leq 4$ — um conjunto completo de MOLS de ordem 5.

A exceção de Euler: o problema dos 36 oficiais ($n = 6$). Em 1782, Euler propôs o problema dos *36 oficiais*: arranjar 36 oficiais, provenientes de 6 regimentos e com 6 postos distintos — um oficial de cada posto por regimento —, em uma formação 6×6 de modo que cada fileira e cada coluna contenha exatamente um oficial de cada posto **e** um de cada regimento. Isso é, exatamente, um quadrado greco-latino de ordem 6 (postos = letras romanas, regimentos = letras gregas), e portanto exige um **par** de quadrados latinos ortogonais de ordem 6, ou seja, $N(6) \geq 2$. Euler não encontrou solução e conjecturou que não existe nenhuma; Tarry (1900) confirmou a conjectura por enumeração exaustiva de todos os quadrados latinos de ordem 6: $N(6) = 1$ — não há sequer **um** par de quadrados latinos ortogonais de ordem 6, o único caso, entre todas as ordens $n \geq 3$, em que o quadrado greco-latino é impossível de construir.

O caso geral. Euler foi além do caso $n = 6$ e conjecturou que $N(n) = 1$ (nenhum par ortogonal) para **todo** $n \equiv 2 \pmod 4$, isto é, $n = 2, 6, 10, 14, 18, \ldots$ — o caso $n = 2$ é trivial (só existe um quadrado latino de ordem 2, a menos de renomear símbolos, então nada pode ser ortogonal a ele). Essa conjectura mais geral permaneceu em aberto por quase 180 anos, até que Bose, Shrikhande e Parker (1960) a **refutaram**: construíram explicitamente pares de quadrados latinos ortogonais para **todo** $n \equiv 2 \pmod 4$ com $n \geq 10$ — ficando conhecidos, por isso, como os “Euler spoilers”. Combinando esse resultado com a verificação direta de Tarry para $n = 6$ e a trivialidade de $n = 2$, o quadro completo é

$$N(n) \geq 2 \quad \text{para todo } n \geq 3 \text{ exceto } n = 6.$$

Ou seja: $n = 6$ não é apenas um exemplo de dificuldade — é a **única** ordem, entre todas as possíveis, em que o quadrado greco-latino simplesmente não existe (Bose et al., 1960; Tarry, 1900).

4.5.2 O modelo

$$Y_{ijkl} = \mu + \rho_i + \gamma_j + \tau_k + \omega_l + \varepsilon_{ijkl},$$

com ρ_i (linha), γ_j (coluna), τ_k (tratamento romano) e ω_l (tratamento grego), $i, j, k, l = 1, \ldots, n$, novamente com apenas n^2 observações — cada uma das quatro fontes consome $n - 1$ graus de liberdade, restando $(n-1)(n-3)$ para o erro.

Tabela 4.16: Tabela de ANOVA do quadrado greco-latino

Fonte de variação	Graus de liberdade
Linha	$n - 1$
Coluna	$n - 1$
Tratamento (romano)	$n - 1$
Tratamento (grego)	$n - 1$
Erro	$(n-1)(n-3)$
Total	$n^2 - 1$

Com $(n-1)(n-3)$ graus de liberdade para o erro, o quadrado greco-latino só é útil quando n é razoavelmente grande — em $n = 4$, restam apenas 3 graus de liberdade, insuficientes para uma estimativa confiável do erro na prática, mas ainda ilustrativos para o exemplo abaixo.

Aplicação — Agricultura: variedade e adubo, controlando linha e coluna
Ao experimento de quadrado latino anterior (linha = declividade, coluna = umidade, tratamento romano = variedade de semente), acrescenta-se um segundo fator de tratamento — **tipo de adubo** ($\alpha, \beta, \gamma, \delta$) — que também se deseja balancear perfeitamente contra variedade, linha e coluna, sem aumentar o número de parcelas.

Uso do R — sobrepondo dois quadrados latinos ortogonais

```
L1 <- matrix(c(1,2,3,4, 2,1,4,3, 3,4,1,2, 4,3,2,1), nrow = 4, byrow = TRUE)  # letras
        romanas
L2 <- matrix(c(1,2,3,4, 3,4,1,2, 4,3,2,1, 2,1,4,3), nrow = 4, byrow = TRUE)  # letras
        gregas
romanos <- c("A","B","C","D")
gregos  <- c("alpha","beta","gamma","delta")

dados_glq <- expand_grid(linha = 1:4, coluna = 1:4) %>%
  mutate(
    roman  = factor(mapply(function(i, j) romanos[L1[i, j]], linha, coluna), levels =
        romanos),
    grego  = factor(mapply(function(i, j) gregos[L2[i, j]],  linha, coluna), levels =
        gregos),
    linha  = factor(linha), coluna = factor(coluna)
  )

n_distinct(paste(dados_glq$roman, dados_glq$grego))  # 16: todo par (romano, grego)
        aparece 1 vez
```

```
## [1] 16
```

A sobreposição dos dois quadrados fica mais concreta como diagrama: a cor de cada célula marca a variedade (letra romana), e o rótulo mostra o par completo (variedade, adubo).

O padrão de cores reproduz exatamente o quadrado latino de variedades da seção anterior — cada cor (romano) ainda aparece uma vez por linha e uma vez por coluna —, mas agora cada célula também traz um rótulo grego, e **nenhum par (romano, grego) se repete** no quadro inteiro: é essa dupla ortogonalidade, visível de imediato, que permite estimar os efeitos de variedade e de adubo simultaneamente, além de linha e coluna, com as mesmas 16 unidades experimentais do quadrado latino original.

```
set.seed(33)
ef_roman <- c(A = 0, B = 2, C = 4, D = 1)
ef_grego <- c(alpha = 0, beta = 1, gamma = -1, delta = 2)

dados_glq <- dados_glq %>%
  mutate(resposta = round(30 + ef_roman[as.character(roman)] +
         ef_grego[as.character(grego)] +
                rnorm(n(), 0, 1.5), 2))

mod_glq <- aov(resposta ~ linha + coluna + roman + grego, data = dados_glq)
anova(mod_glq) %>% broom::tidy() %>%
  kable(digits = 4, caption = "ANOVA do quadrado greco-latino 4x4 (dados simulados)")
        %>%
  kable_styling(full_width = FALSE)
```

Tabela 4.17: ANOVA do quadrado greco-latino 4x4 (dados simulados)

term	df	sumsq	meansq	statistic	p.value
linha	3	5.8191	1.9397	0.7245	0.6013
coluna	3	0.6709	0.2236	0.0835	0.9645
roman	3	55.7674	18.5891	6.9428	0.0729
grego	3	52.2580	17.4193	6.5059	0.0792
Residuals	3	8.0325	2.6775	NA	NA

Com apenas 3 graus de liberdade para o erro, os testes-F de variedade e adubo ficam pouco sensíveis ($p \approx 0{,}07$ e $p \approx 0{,}08$, respectivamente, apesar de os efeitos simulados serem reais) — o preço de controlar quatro fontes de variação com só 16 unidades experimentais. Na prática, quadrados greco-latinos só compensam quando n é grande o bastante para deixar um erro estimável com confiança, ou quando são replicados como na Seção anterior.

Para discutir

1. Por que o modelo de um quadrado latino não permite estimar uma interação entre linha e tratamento, ao contrário de um fatorial completo linha$\times$tratamento?
2. No exemplo do painel sensorial (BIB), por que faz sentido balancear a *frequência* com que cada par de variedades é degustado junto, e não apenas garantir que cada variedade apareça o mesmo número de vezes no total?
3. Um pesquisador tem $n = 4$ tratamentos e poderia usar um quadrado latino 4×4 (16 unidades) ou um DBCA com 4 blocos de 4 unidades cada (também 16 unidades, mas controlando só uma fonte de bloqueio). Em que condições vale a pena "gastar" o grau de liberdade extra do quadrado latino controlando uma segunda fonte de variação, em vez de usá-lo para estimar o erro com mais precisão?

4.6 Parcelas subdivididas (*split-plot*)

> **Além do programa do semestre** — esta seção não corresponde a nenhuma das Aulas 09–11: é material extra, na mesma linha do Capítulo 8, que estende o Capítulo 4 além do que cabe em três aulas.

Todas as seções anteriores deste capítulo assumem que **um único** mecanismo de aleatorização atribui tratamentos a unidades experimentais. Em muitos experimentos de campo — a origem histórica deste delineamento, em Rothamsted, nos anos 1920 e 1930 (Yates, 1937) —, isso é logisticamente inviável: certos fatores só podem ser aplicados a **parcelas grandes** (um sistema de irrigação cobre uma faixa inteira de terreno; não há como irrigar diferentemente cada metro quadrado), enquanto outros fatores variam livremente em **parcelas pequenas** dentro de cada parcela grande (a variedade plantada pode mudar a cada poucos metros). O delineamento em **parcelas subdivididas** (*split-plot*) formaliza exatamente essa restrição prática — não é uma escolha de conveniência estatística, é a estrutura que o próprio processo físico de aleatorização impõe (Montgomery, 2017).

> **Aplicação — Agricultura: irrigação e variedade na produção de sorgo**
> Um experimento compara 3 métodos de irrigação e 4 variedades de sorgo. O terreno é dividido em 4 blocos (homogêneos internamente); dentro de cada bloco, o método de irrigação é sorteado a **3 parcelas principais** — faixas grandes de terra, porque cada sistema de irrigação exige uma faixa contígua. Cada parcela principal é então subdividida em **4 subparcelas**, e a variedade é sorteada às subparcelas dentro de cada parcela principal. Produção (kg/parcela) é medida em cada subparcela.

4.6.1 Dois erros experimentais, não um

A restrição prática acima tem uma consequência estatística direta: **há dois processos de aleatorização independentes**, um em cada nível (aleatorizar irrigação às parcelas principais dentro de cada bloco; aleatorizar variedade às subparcelas dentro de cada parcela principal) — e cada aleatorização gera seu próprio erro experimental. O modelo precisa de **dois** termos de erro distintos, não um:

$$Y_{ijk} = \mu + \rho_i + \alpha_j + \underbrace{\delta_{ij}}_{\text{erro da parcela principal}} + \beta_k + (\alpha\beta)_{jk} + \underbrace{\varepsilon_{ijk}}_{\text{erro da subparcela}},$$

com $i = 1, \ldots, r$ blocos, $j = 1, \ldots, a$ níveis do fator de parcela principal (irrigação), $k = 1, \ldots, b$ níveis do fator de subparcela (variedade), $\delta_{ij} \overset{iid}{\sim} N(0, \sigma^2_\delta)$ o erro da parcela principal (a variação entre parcelas principais dentro do mesmo bloco, não explicada por irrigação) e $\varepsilon_{ijk} \overset{iid}{\sim} N(0, \sigma^2_\varepsilon)$ o erro da subparcela (a variação entre subparcelas dentro da mesma parcela principal), independente de δ_{ij}. ρ_i (bloco) e α_j (irrigação) são efeitos fixos sujeitos às restrições usuais de soma zero, assim como β_k (variedade) e $(\alpha\beta)_{jk}$ (interação).

```
nos_sp <- tibble(
  termo   = c("Média", "Bloco", "Irrigação", "Variedade", "Erro(a)\n(parcela
        principal)",
              "Irrigação\n×Variedade", "Erro(b)\n(subparcela)"),
  classes = c(1, 4, 3, 4, 4*3, 3*4, 4*3*4)
)
arestas_sp <- tibble(
```

```
  de   = c("Média", "Média", "Média", "Bloco", "Irrigação", "Irrigação", "Variedade",
           "Erro(a)\n(parcela principal)", "Irrigação\n×Variedade"),
  para = c("Bloco", "Irrigação", "Variedade", "Erro(a)\n(parcela principal)",
           "Erro(a)\n(parcela principal)", "Irrigação\n×Variedade",
           "Irrigação\n×Variedade", "Erro(b)\n(subparcela)", "Erro(b)\n(subparcela)")
)             knitr::include_graphics(  hasse_svg(nos_sp, arestas_sp,
            arquivo = "figuras/hasse/split-plot.svg",
            titulo  = "Split-plot: r=4, a=3, b=4 (N=48)",
            tamanho = c(5.5, 4)))
```

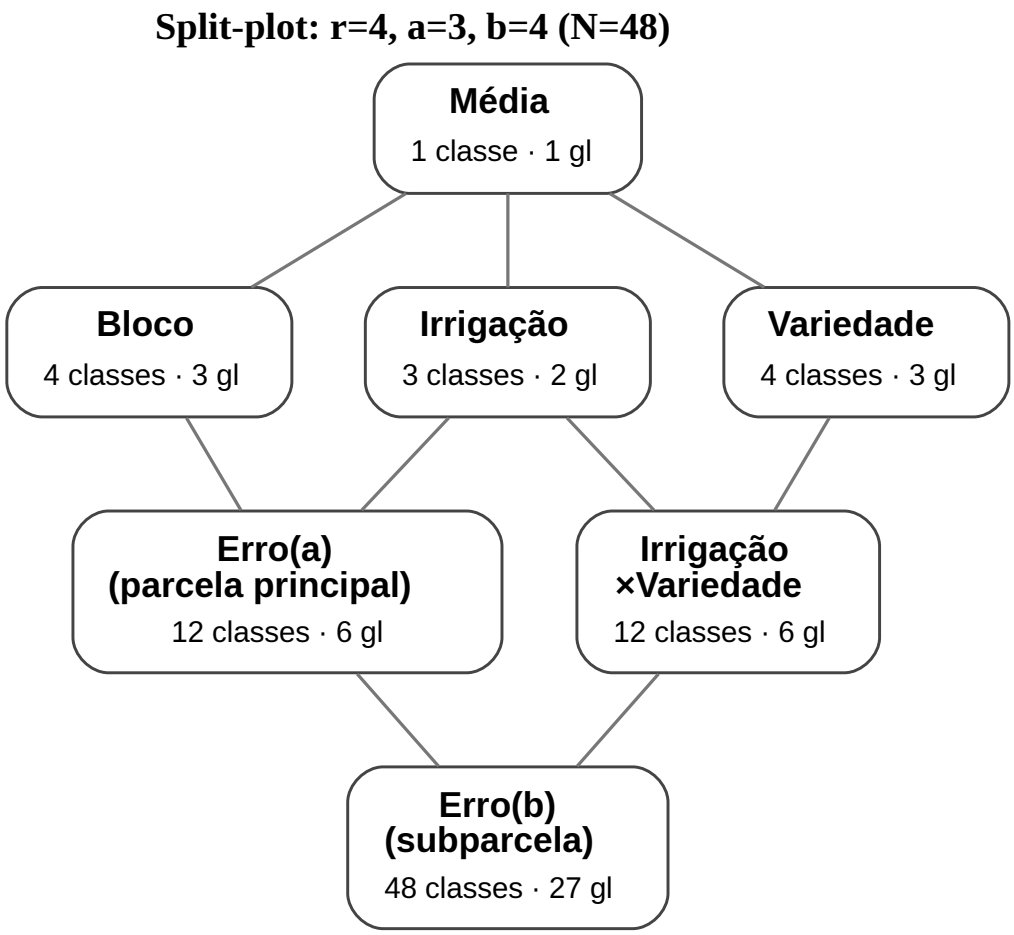


Figura 4.4: Diagrama de Hasse do split-plot: r=4 blocos, a=3 métodos de irrigação (parcela principal), b=4 variedades (subparcela), N=48. Note os DOIS nós de erro – Erro(a), que fecha o estrato da parcela principal, e Erro(b), que fecha o estrato da subparcela – em vez do único nó de Erro do DBCA (Figura anterior).

A soma de todos os gl é $1 + 3 + 2 + 3 + 6 + 6 + 27 = 48 = N$ — dois nós de erro em vez de um, exatamente porque há dois estratos de aleatorização, cada um com sua própria variação residual. $gl(\text{Erro(a)}) = ra - 1 - gl(\text{Bloco}) - gl(\text{Irrigação}) = 12 - 1 - 3 - 2 = 6 = (r-1)(a-1)$; $gl(\text{Erro(b)}) = rab - [\text{soma dos } gl \text{ de todos os outros seis nós}] = 48 - 21 = 27 = a(r-1)(b-1)$.

4.6.2 Por que o teste de irrigação usa um erro diferente do teste de variedade

A esperança dos quadrados médios torna explícito por que dois erros são necessários, e não apenas uma curiosidade algébrica do diagrama:

$$\mathbb{E}[QM_{\text{Erro(a)}}] = \sigma^2_\varepsilon + b\,\sigma^2_\delta, \qquad \mathbb{E}[QM_{\text{Irrigação}}] = \sigma^2_\varepsilon + b\,\sigma^2_\delta + \frac{rb}{a-1}\sum_j \alpha_j^2,$$

$$\mathbb{E}[QM_{\text{Erro(b)}}] = \sigma^2_\varepsilon, \qquad \mathbb{E}[QM_{\text{Variedade}}] = \sigma^2_\varepsilon + \frac{ra}{b-1}\sum_k \beta_k^2.$$

O termo $b\,\sigma^2_\delta$ aparece em $QM_{\text{Irrigação}}$ **e** em $QM_{\text{Erro(a)}}$, mas **não** em $QM_{\text{Erro(b)}}$: por isso o teste de irrigação precisa usar $F = QM_{\text{Irrigação}}/QM_{\text{Erro(a)}}$, nunca $QM_{\text{Erro(b)}}$ — usar o erro errado no denominador (um engano comum, fácil de cometer se o código não especificar a estrutura de erro) infla artificialmente a estatística F do fator de parcela principal, porque $QM_{\text{Erro(b)}}$ não contém a variação entre parcelas principais que também afeta $QM_{\text{Irrigação}}$. O teste de variedade (e da interação) usa corretamente $QM_{\text{Erro(b)}}$, sem σ^2_δ em nenhum dos dois lados da razão.

Consequência prática, não só teórica: como σ^2_δ tipicamente excede σ^2_ε (parcelas principais variam mais entre si do que subparcelas dentro da mesma parcela principal), o fator de parcela principal é estimado com **menos** precisão que o fator de subparcela — mesmo com o mesmo número de observações. É um trade-off deliberado do delineamento: ganha-se viabilidade logística ao custo de precisão no fator que a logística obrigou a ficar na parcela principal.

> **Uso do R** — split-plot com `aov(..., Error(bloco/irrigacao))`

```r
set.seed(48)
r <- 4; a <- 3; b <- 4
dados_sp <- expand_grid(variedade = factor(1:b), irrigacao = factor(1:a), bloco =
        factor(1:r))

efeito_irrig <- c(0, 3, 6)[dados_sp$irrigacao]
efeito_var   <- c(0, 1, 2, 4)[dados_sp$variedade]
erro_a <- rnorm(r * a, 0, 2)[interaction(dados_sp$bloco, dados_sp$irrigacao, drop =
        TRUE) %>% as.integer()]

dados_sp$producao <- 20 + efeito_irrig + efeito_var + erro_a + rnorm(nrow(dados_sp),
        0, 1)

mod_sp <- aov(producao ~ irrigacao * variedade + Error(bloco/irrigacao), data =
        dados_sp)
summary(mod_sp)
```

```
##
## Error: bloco
##           Df Sum Sq Mean Sq F value Pr(>F)
## Residuals  3  121.5   40.49
##
## Error: bloco:irrigacao
##           Df Sum Sq Mean Sq F value  Pr(>F)
## irrigacao  2  545.4  272.68   13.26 0.00628 **
## Residuals  6  123.4   20.57
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Error: Within
##                     Df Sum Sq Mean Sq F value  Pr(>F)
## variedade            3  94.19  31.398  31.329 6.1e-09 ***
## irrigacao:variedade  6   1.25   0.208   0.208   0.971
```

```
## Residuals           27  27.06   1.002
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Os graus de liberdade batem exatamente com o diagrama de Hasse acima: 3 (bloco), 2 e 6 (irrigação e seu erro, no estrato `bloco:irrigacao`), e 3, 6, 27 (variedade, interação e o erro de subparcela, no estrato `Within`) — o `Error(bloco/irrigacao)` do R **é** a declaração explícita dos dois estratos de aleatorização do diagrama, não uma opção de sintaxe arbitrária.

 Produção de sorgo por variedade, separada por método de irrigação. Retas quase paralelas entre os três painéis indicam ausência de interação irrigação-variedade -- consistente com o p-valor não significativo da interação na tabela acima.

Figura 4.5: Produção de sorgo por variedade, separada por método de irrigação. Retas quase paralelas entre os três painéis indicam ausência de interação irrigação-variedade – consistente com o p-valor não significativo da interação na tabela acima.

Neste conjunto de dados simulado, irrigação é significativa ($F_{2,6} = 13.3$, $p = 0.006$) mas testada com apenas 6 gl de erro; variedade é fortemente significativa ($F_{3,27} = 31.3$, $p < 0{,}001$), testada com 27 gl de erro — precisão bem maior, exatamente o padrão que a análise de $\mathbb{E}[QM]$ previu. A interação não é significativa ($p = 0.97$), visível no gráfico como retas aproximadamente paralelas entre os três níveis de irrigação.

4.7 Resumo do capítulo

- Sem controle algum, um fator de ruído pode ficar **completamente confundido** com o tratamento (alocação não aleatória) — falha que nenhuma quantidade de dados resolve. O DBCA evita isso agrupando unidades por uma fonte de ruído conhecida em blocos e **sorteando** os tratamentos dentro de cada bloco, generalizando o DCA ao controlar **uma** fonte de variação sistemática sem estimar interação tratamento$\times$bloco; a ANOVA separa SQ_{Total} em tratamento, bloco e erro, e a esperança dos quadrados médios mostra formalmente por que não se testa o bloco.
- Um valor perdido pode ser estimado pela fórmula de Yates, ao custo de 1 grau de liberdade do erro e de um pequeno viés (corrigível) na soma de quadrados de tratamentos.
- A eficiência relativa quantifica se a blocagem valeu a pena; ela só compensa quando os blocos de fato capturam heterogeneidade real entre unidades.
- O teste de Friedman é a alternativa não paramétrica ao DBCA, especialmente útil em desenhos de medidas repetidas (bloco = sujeito) com respostas não normais.
- Blocos incompletos balanceados (BIB) resolvem o caso em que o bloco não comporta todos os tratamentos, desde que seja possível arranjar os blocos para que todo par de tratamentos coocorra com a mesma frequência λ.
- O quadrado latino controla **duas** fontes de bloqueio cruzadas com apenas n^2 unidades, eliminando gradientes ortogonais que nenhum bloqueio de um único fator resolveria sozinho; sua aleatorização (Yates, 1933) permuta linhas, colunas e a atribuição de tratamentos de um quadrado reduzido, garantindo uma distribuição de referência válida para o teste F. A eficiência relativa se estende ao caso de duas fontes de bloqueio (quadrado latino contra DCA e contra um DBCA de uma só fonte), decompondo exatamente quanto cada gradiente contribuiu, e um segundo exemplo completo (checkout de e-commerce) fixa a mesma notação matricial $X = [\mathbf{1} \mid X_{linha} \mid X_{coluna} \mid X_{trat}]$ em um domínio de dados. Quando uma das duas dimensões de bloqueio não comporta todos os tratamentos, o **quadrado de Youden** combina a estrutura de quadrado latino (linha) com a de um BIB simétrico (coluna) em $N = rv < n^2$ unidades. O quadrado greco-latino controla **três** fontes, sobrepondo um par de quadrados latinos **mutuamente ortogonais (MOLS)** — que existe sempre

que n é potência de primo e, de fato, para toda ordem $n \geq 3$ exceto a célebre exceção de Euler, $n = 6$ (o problema dos 36 oficiais, $N(6) = 1$) — ao custo de graus de liberdade do erro, recuperáveis por replicação; a análise de poder converte "quantas réplicas?" em uma conta explícita a partir do menor efeito relevante a detectar.

- *(Além do programa do semestre)* Quando um fator só pode ser aleatorizado a **parcelas grandes** e outro a **parcelas pequenas** dentro delas, o delineamento em **parcelas subdivididas** (*split-plot*) exige **dois** erros experimentais distintos — um por estrato de aleatorização —, e não um só: o diagrama de Hasse ganha um segundo nó de erro, e a esperança dos quadrados médios mostra por que o fator de parcela principal precisa do seu próprio erro no denominador do teste F, nunca o erro (mais preciso) da subparcela.

Até aqui, cada capítulo tratou de **um único fator de tratamento** (ainda que controlado por uma ou mais fontes de bloqueio). O Capítulo 5 introduz o caso em que **dois ou mais fatores de tratamento** são cruzados deliberadamente no mesmo experimento — os arranjos fatoriais —, permitindo não só estimar o efeito de cada fator, mas também se o efeito de um depende do nível do outro.

5 Delineamentos com arranjos fatoriais

Até aqui, cada capítulo tratou de **um único fator de tratamento** — a técnica de estudo, o método de ensino, o algoritmo de recomendação — ainda que sob desenhos crescentemente sofisticados para controlar o erro experimental (blocos, quadrados latinos). Mas a maioria das perguntas de pesquisa interessantes envolve *várias* variáveis que podem afetar a resposta simultaneamente, e frequentemente o interesse não está apenas em cada uma isoladamente, mas em **como elas interagem**. Este capítulo introduz o **arranjo fatorial**: em vez de rodar um experimento por fator, cruzamos todos os níveis de todos os fatores em um único desenho.

Uma nota sobre notação. Os Capítulos 3 e 4 escreveram o efeito de tratamento como τ_i, porque havia apenas **um** fator em jogo. A partir daqui, com múltiplos fatores cruzados, trocamos essa notação por $\alpha_i, \beta_j, \gamma_k, \ldots$ — uma letra grega por fator — seguindo a convenção usual para desenhos fatoriais (Dean et al., 2017; Montgomery, 2017): τ seria ambíguo assim que há mais de um fator, porque não indicaria a qual deles o índice pertence. A mudança é só de rótulo, não de conceito — α_i desempenha, para o fator A, exatamente o mesmo papel que τ_i desempenhava no Capítulo 3 para o único fator do DCA. A sistematização completa desse arranjo — o que hoje chamamos de "delineamento fatorial" — é obra de Fisher e, sobretudo, de Yates, que formalizou a análise e a notação de sinais $(1), a, b, ab, \ldots$ que usaremos ao longo deste capítulo e do próximo (Yates, 1937).

5.1 Por que cruzar fatores?

Suponha que uma equipe queira saber se a viscosidade de um solvente e a salinidade de uma solução afetam a recuperação de um composto volátil em um processo de extração de laboratório. A estratégia ingênua — "um fator de cada vez" (*one factor at a time*, OFAT) — fixaria a salinidade em um valor de referência, variaria só a viscosidade, escolheria o "melhor" nível, e só depois variaria a salinidade mantendo fixa a viscosidade "vencedora". Essa estratégia tem dois problemas sérios (Box et al., 2005; Montgomery, 2017):

1. **Não detecta interação.** Se o efeito da viscosidade depende do nível de salinidade (e vice-versa), o OFAT pode convergir para uma combinação que está longe do ótimo real, porque nunca observa as combinações que revelariam a dependência mútua.
2. **É estatisticamente ineficiente.** Um fatorial completo com o mesmo número total de unidades experimentais estima os efeitos de **todos** os fatores com a mesma precisão que um experimento de um único fator dedicado inteiramente a cada um — sem custo adicional. Esse é, literalmente, o argumento com que Fisher introduziu o desenho fatorial: cada unidade experimental participa, ao mesmo tempo, de uma comparação de A e de uma comparação de B, de modo que o fatorial produz o equivalente a uma "réplica oculta" de cada fator dentro do experimento do outro (Fisher, 1935b).

> **Aplicação — Agricultura: irrigação e silício na altura do pepino**
> Um experimento agronômico testa dois fatores sobre a altura de plantas de pepino (*Cucumis sativus*): a lâmina de **irrigação** (`riego`, dois níveis: 0,5 e 1,0, em unidades relativas da lâmina de referência) e a **dose de silício** aplicada ao solo (`silicio`, quatro níveis: 0, 500, 1000 e 1500 mL de solução por parcela). Todas as $2 \times 4 = 8$ combinações de níveis foram testadas, com três repetições cada (24 parcelas ao todo).

5.2 O fatorial A×B: efeitos principais e interação

Sejam dois fatores, A com a níveis e B com b níveis, cruzados em um desenho balanceado com r repetições por combinação. O modelo de efeitos fixos é

$$y_{ijk} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + \varepsilon_{ijk}, \qquad \begin{array}{l} i = 1, \ldots, a, \\ j = 1, \ldots, b, \\ k = 1, \ldots, r, \end{array}$$

com $\varepsilon_{ijk} \overset{iid}{\sim} N(0, \sigma^2)$ e as restrições usuais de identificabilidade $\sum_i \alpha_i = 0$, $\sum_j \beta_j = 0$, $\sum_i (\alpha\beta)_{ij} = 0$ para todo j, e $\sum_j (\alpha\beta)_{ij} = 0$ para todo i. Os termos têm interpretação direta:

- α_i: **efeito principal** de A — o desvio médio do nível i de A em relação à média geral, calculado *marginalizando* sobre todos os níveis de B.
- β_j: efeito principal de B, analogamente.
- $(\alpha\beta)_{ij}$: **efeito de interação** — o quanto a combinação (i, j) se desvia do que se esperaria apenas somando os efeitos principais $\alpha_i + \beta_j$. Interação diferente de zero significa que **o efeito de A muda conforme o nível de B** (e vice-versa): as retas que ligam as médias de A dentro de cada nível de B deixam de ser paralelas.

Uma leitura causal. Sob a estrutura potencial-outcomes (Imbens & Rubin, 2015), e sob a restrição soma-zero $\sum_i \alpha_i = 0$, o parâmetro α_i é o **desvio** do nível i de A em relação à média sobre os níveis de A — não, por si só, um efeito causal. O objeto causal é o **contraste** entre dois níveis:

$$\mathrm{ATE}(i, i') \;=\; E\big[Y_u(i) - Y_u(i')\big] \;=\; \alpha_i - \alpha_{i'},$$

o efeito causal médio de receber o nível i em vez do nível i', *marginalizado* sobre a distribuição de níveis de B presente no experimento — uma média do efeito de A que "soma sobre" todas as condições de B observadas. A distinção importa: α_i depende de qual restrição de identificação se adotou (com casela de referência, α_i já *seria* um contraste contra o nível de referência), ao passo que $\alpha_i - \alpha_{i'}$ é invariante — é estimável no sentido da Seção 2.5 (p. 25), e é por isso que o objeto causal é ele. A interação $(\alpha\beta)_{ij}$, por sua vez, é exatamente o objeto que a literatura de inferência causal moderna chama de **heterogeneidade de efeito de tratamento** (*treatment effect heterogeneity*, ou interação trata-tratamento quando ambos A e B são manipuláveis): ela mede o quanto o efeito causal de A *difere* conforme o nível de B em que é avaliado. Um efeito principal significativo com interação nula diz "o tratamento funciona, e funciona igual em todos os subgrupos definidos por B"; um efeito principal com interação forte diz "o tratamento funciona, mas seu tamanho depende de B" — duas conclusões científicas e práticas muito diferentes, ainda que ambas comecem no mesmo modelo fatorial.

> **Uso do R** — ajustando o fatorial A×B (ignorando o bloco por ora)

```
pepino <- read_csv("data/pepino.csv", show_col_types = FALSE) %>%
  mutate(
    riego   = factor(riego, labels = c("Lâmina baixa (0,5)", "Lâmina alta (1,0)")),
    silicio = factor(silicio, levels = c("0 ml", "500 ml", "1000 ml", "1500 ml")),
    bloque  = factor(bloque)
  )
```

```
modelo_axb <- aov(altura ~ riego * silicio, data = pepino)summary(modelo_axb)
```

```
##               Df Sum Sq Mean Sq F value   Pr(>F)
## riego          1 0.2604  0.2604   5.283 0.035355 *
## silicio        3 1.3872  0.4624   9.380 0.000819 ***
## riego:silicio  3 0.3883  0.1294   2.626 0.086050 .
## Residuals     16 0.7887  0.0493
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

As retas são quase paralelas — sinal de que a interação, embora presente na tabela ($p \approx 0{,}09$), é discreta perto do nível de significância usual de 5%: o efeito da dose de silício sobre a altura parece semelhante nas duas lâminas de irrigação, e o efeito da irrigação parece semelhante nas quatro doses.

5.3 Tabela de ANOVA para o fatorial A×B balanceado

A soma de quadrados total se decompõe exatamente em quatro parcelas ortogonais:

$$SQ_{Total} = SQ_A + SQ_B + SQ_{AB} + SQ_E,$$

com

$$SQ_A = rb\sum_i (\bar{y}_{i\cdot\cdot} - \bar{y}_{\cdot\cdot\cdot})^2, \quad SQ_B = ra\sum_j (\bar{y}_{\cdot j\cdot} - \bar{y}_{\cdot\cdot\cdot})^2,$$

$$SQ_{AB} = r\sum_{i,j} (\bar{y}_{ij\cdot} - \bar{y}_{i\cdot\cdot} - \bar{y}_{\cdot j\cdot} + \bar{y}_{\cdot\cdot\cdot})^2, \quad SQ_E = \sum_{i,j,k} (y_{ijk} - \bar{y}_{ij\cdot})^2.$$

Tabela 5.1: ANOVA do fatorial A×B balanceado

Fonte de variação	Graus de liberdade	Soma de quadrados	Quadrado médio	F
Fator A	$a-1$	SQ_A	$QM_A = SQ_A/(a-1)$	QM_A/QM_E
Fator B	$b-1$	SQ_B	$QM_B = SQ_B/(b-1)$	QM_B/QM_E
Interação A×B	$(a-1)(b-1)$	SQ_{AB}	$QM_{AB} = SQ_{AB}/[(a-1)(b-1)]$	QM_{AB}/QM_E
Erro	$ab(r-1)$	SQ_E	$QM_E = SQ_E/[ab(r-1)]$	
Total	$abr-1$	SQ_{Total}		

Por que o teste F funciona: valor esperado dos quadrados médios. O Capítulo 2 (Seção 2.10 (p. 37)) mostrou que uma forma quadrática $\mathbf{Y}'\mathbf{A}\mathbf{Y}$, com $\mathbf{A}$ idempotente de posto r, é σ^2 vezes uma qui-quadrado com r graus de liberdade e parâmetro de não centralidade $\boldsymbol{\mu}'\mathbf{A}\boldsymbol{\mu}/\sigma^2$. Cada uma das quatro somas de quadrados acima ($SQ_A, SQ_B, SQ_{AB}, SQ_E$) é exatamente uma forma quadrática desse tipo — a soma de quadrados de A, por exemplo, usa a matriz idempotente que projeta sobre a direção dos efeitos de A dentro do espaço-coluna de $\mathbf{X}$ (Seção 5.4 (p. 135)). Isso permite calcular o valor esperado de cada quadrado médio sem depender de nenhuma simulação:

Tabela 5.2: Esperança dos quadrados médios do fatorial A×B (efeitos fixos)

Quadrado médio	Valor esperado
QM_A	$\sigma^2 + \dfrac{rb\sum_i \alpha_i^2}{a-1}$
QM_B	$\sigma^2 + \dfrac{ra\sum_j \beta_j^2}{b-1}$
QM_{AB}	$\sigma^2 + \dfrac{r\sum_{i,j}(\alpha\beta)_{ij}^2}{(a-1)(b-1)}$
QM_E	σ^2

Cada linha tem a mesma estrutura: σ^2 (o que QM_E estima sozinho) mais um termo não negativo que só se anula quando o efeito correspondente é identicamente zero. É exatamente essa estrutura que justifica usar QM_E como denominador comum dos três testes F: sob $H_0 : \alpha_i = 0\ \forall i$, por exemplo, $E[QM_A] = E[QM_E] = \sigma^2$ e a razão QM_A/QM_E segue uma F central; sob a alternativa, o numerador de $E[QM_A]$ cresce com a soma dos quadrados dos α_i, deslocando a distribuição de F para a direita (não centralidade) e aumentando a chance de rejeitar H_0 — a mesma lógica de poder já usada no Capítulo 3 (Seção 3.2.6 (p. 55)), agora com três parâmetros de não centralidade em jogo simultaneamente em vez de um só.

Note que, diferentemente de um DCA de um único fator, o fatorial A×B testa **três hipóteses** com um único conjunto de dados: $H_0 : \alpha_i = 0\ \forall i$ (nenhum efeito de A), $H_0 : \beta_j = 0\ \forall j$ (nenhum efeito de B) e $H_0 : (\alpha\beta)_{ij} = 0\ \forall i, j$ (nenhuma interação) — todas usando o mesmo QM_E como denominador, o que é exatamente a eficiência estatística mencionada na Seção 5.1 (p. 129). Na prática, a convenção é examinar primeiro a interação: se ela for relevante, interpretar os efeitos principais isolados pode ser enganoso, e a análise deve reportar as médias de célula (combinação i, j) diretamente.

5.3.1 Quando as células não têm o mesmo tamanho: somas de quadrados Tipo I, II e III

A decomposição exata $SQ_{Total} = SQ_A + SQ_B + SQ_{AB} + SQ_E$ da seção anterior depende de uma suposição que ficou implícita: **o mesmo número r de réplicas em toda casela** (i, j). Sob balanceamento, as colunas de $\mathbf{X}$ associadas a A, a B e à interação são ortogonais entre si (a mesma ideia da Seção 5.4 (p. 135) do fatorial 2^k, agora para um A×B geral) — SQ_A mede exatamente a mesma coisa, seja A ajustado sozinho ou na presença de B. Quando as caselas têm tamanhos diferentes — a norma, não a exceção, em dados que não vêm de um experimento de campo cuidadosamente balanceado (tráfego real de um teste A/B, perda de observações, inscrição voluntária) —, essa ortogonalidade se perde: as colunas de A e de B passam a ser correlacionadas, e "o quanto A explica" passa a depender de **o que mais já está no modelo** (Speed et al., 1978). Três convenções resolvem essa ambiguidade de formas diferentes:

- **Tipo I (sequencial):** cada termo é testado ajustado só pelos termos que entraram **antes** dele no modelo, na ordem em que foram escritos. SQ_A ignora B; SQ_B já ajusta para A; SQ_{AB} ajusta para ambos. Consequência direta: **a ordem em que os fatores são escritos na fórmula muda o resultado** — `aov(y ~ A*B)` e `aov(y ~ B*A)` dão SQ_A e SQ_B diferentes (a soma dos quatro termos continua igual a SQ_{Total} em qualquer ordem, só a divisão entre A e B muda). É o padrão de `aov()`/`anova()` no R.
- **Tipo II:** cada efeito principal é ajustado pelo **outro** efeito principal, mas não pela interação — simétrico em A e B (não depende de ordem), sob a suposição de que a interação é desprezível o bastante para não "roubar" variação dos efeitos principais.

- **Tipo III (marginal):** cada termo é ajustado por **todos** os outros, incluindo a interação — a mais conservadora e a única que testa exatamente as mesmas hipóteses $H_0 : \alpha_i = 0 \; \forall i$ etc. do caso balanceado, mesmo com interação presente. Exige **contrastes de soma zero** (`options(contrasts = c("contr.sum", "contr.poly"))` no R) — com a parametrização padrão do R (`contr.treatment`), o teste Tipo III do "efeito principal" testa uma combinação que depende de qual nível é a referência, não o que o pesquisador normalmente quer dizer por "efeito de A".

Aplicação — Ciência de dados: teste A/B/n com tráfego desigual
Uma loja testa **layout** (Lista/Grade) × **desconto exibido** (Sim/Não) sobre o tempo de permanência na página (s). Diferente de um experimento de campo, o tráfego real não se divide em partes iguais entre as quatro combinações — a tabela abaixo mostra tamanhos de casela desiguais (30 a 70 sessões), a situação típica de um teste A/B em produção.

```r
set.seed(2026)
n_celula <- c(Lista_Nao = 40, Lista_Sim = 55, Grade_Nao = 30, Grade_Sim = 70)
media_celula <- c(Lista_Nao = 42, Lista_Sim = 47, Grade_Nao = 44, Grade_Sim = 53)

dados_desbal <- map2_dfr(n_celula, media_celula, ~ tibble(tempo = rnorm(.x, .y, 8)),
                         .id = "celula") %>%
  separate(celula, into = c("layout", "desconto"), sep = "_") %>%
  mutate(layout = factor(layout, labels = c("Grade", "Lista")),
         desconto = factor(desconto, labels = c("Nao", "Sim")))

table(dados_desbal$layout, dados_desbal$desconto)
```

```
##
##         Nao Sim
##   Grade  30  70
##   Lista  40  55
```

```r
summary(aov(tempo ~ layout * desconto, data = dados_desbal))   # layout primeiro
```

```
##                  Df Sum Sq Mean Sq F value   Pr(>F)
## layout            1   2332  2332.0  37.974 4.16e-09 ***
## desconto          1   2511  2510.8  40.886 1.21e-09 ***
## layout:desconto   1    451   450.9   7.342  0.00735 **
## Residuals       191  11729    61.4
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
summary(aov(tempo ~ desconto * layout, data = dados_desbal))   # desconto primeiro
```

```
##                  Df Sum Sq Mean Sq F value   Pr(>F)
## desconto          1   3114  3113.5  50.700 2.13e-11 ***
## layout            1   1729  1729.3  28.159 3.08e-07 ***
## desconto:layout   1    451   450.9   7.342  0.00735 **
## Residuals       191  11729    61.4
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

SQ_{layout} e SQ_{desconto} mudam de fato conforme a ordem — exatamente o sintoma da falta de ortogonalidade. Nos dois casos, SQ_{AB} (a interação) é idêntico, porque a interação é sempre o último termo

a entrar, ajustado por tudo o resto em qualquer ordem.

> **Uso do R** — Tipo II e Tipo III com `car::Anova()`

```
contrastes_originais <- options("contrasts")          # preserva o default do
        capitulo
options(contrasts = c("contr.sum", "contr.poly"))     # exigido para Tipo III fazer
        sentido
modelo_desbal <- lm(tempo ~ layout * desconto, data = dados_desbal)

car::Anova(modelo_desbal, type = "II")
```

```
## Anova Table (Type II tests)
##
## Response: tempo
##                  Sum Sq  Df F value    Pr(>F)
## layout           1729.3   1 28.1595 3.079e-07 ***
## desconto         2510.8   1 40.8856 1.210e-09 ***
## layout:desconto   450.9   1  7.3418   0.00735 **
## Residuals       11729.4 191
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
car::Anova(modelo_desbal, type = "III")
```

```
## Anova Table (Type III tests)
##
## Response: tempo
##                 Sum Sq  Df   F value    Pr(>F)
## (Intercept)     380434   1 6194.9229 < 2.2e-16 ***
## layout            1143   1   18.6178 2.560e-05 ***
## desconto          2610   1   42.4968 6.153e-10 ***
## layout:desconto    451   1    7.3418   0.00735 **
## Residuals        11729 191
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
options(contrastes_originais)   # restaura imediatamente -- nao deve vazar para as
        secoes seguintes
```

O Tipo II dá exatamente $SQ_{\text{layout}} = 1729.3$ (o mesmo valor de quando `layout` entra **depois** de `desconto` no Tipo I) e $SQ_{\text{desconto}} = 2510.8$ — cada um ajustado pelo outro, nenhum pela interação, e por isso independente da ordem de escrita. O Tipo III muda de novo (ajusta também pela interação), e é o único dos três cuja soma de quadrados de `layout`/`desconto` não bate com nenhuma das duas linhas de Tipo I acima.

Recomendação prática, seguindo a literatura sobre o tema (Langsrud, 2003): olhar a interação primeiro; se ela for desprezível, o Tipo II é preferível ao III (mais poder, mesma interpretação de “efeito principal médio”); se a interação for relevante, nenhum teste de efeito principal — de nenhum tipo — costuma responder a pergunta certa, e a análise deve reportar as médias de célula diretamente (a mesma recomendação da seção anterior, agora reforçada pelo caso desbalanceado). Delineamentos de campo bem balanceados evitam esse problema por construção — mais uma razão prática para preferir balanceamento sempre que o custo do experimento permitir.

5.4 Notação matricial do fatorial A×B

O Capítulo 2 escreveu todo modelo linear como $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ e definiu a matriz de projeção $\mathbf{P}_X = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$ (Seção 2.7 (p. 30)). O fatorial A×B é um caso particular dessa estrutura geral, e vale a pena tornar explícito **como** a matriz $\mathbf{X}$ se monta a partir dos dois fatores. Usando **codificação de casela de referência** (`contr.treatment`, o padrão do R: colunas indicadoras de cada fator com um nível omitido, que passa a ser a referência — não confundir com a **codificação de efeito**, `contr.sum`, o esquema ± 1 soma-zero que corresponde às restrições de identificação da Seção 5.2 (p. 130)), sejam $\mathbf{X}_A$ (dimensão $n \times (a-1)$) e $\mathbf{X}_B$ (dimensão $n \times (b-1)$) as submatrizes que codificam os efeitos principais de A e B. A matriz completa do fatorial A×B é o bloco

$$\mathbf{X} = \left[\, \mathbf{1} \mid \mathbf{X}_A \mid \mathbf{X}_B \mid \mathbf{X}_A \odot \mathbf{X}_B \,\right],$$

em que $\mathbf{X}_A \odot \mathbf{X}_B$ denota a matriz cujas colunas são **todos os produtos elemento a elemento** (produto de Hadamard) entre uma coluna de $\mathbf{X}_A$ e uma coluna de $\mathbf{X}_B$ — exatamente $(a-1)(b-1)$ colunas, o mesmo número de graus de liberdade da interação na Seção 5.3 (p. 131). Esta não é uma analogia: é **literalmente** como `model.matrix()` constrói uma coluna de interação no R.

> **Uso do R** — a coluna de interação é o produto das colunas principais

```r
X <- model.matrix(~ riego * silicio, data = pepino)
colnames(X)
```

```
## [1] "(Intercept)"
## [2] "riegoLâmina alta (1,0)"
## [3] "silicio500 ml"
## [4] "silicio1000 ml"
## [5] "silicio1500 ml"
## [6] "riegoLâmina alta (1,0):silicio500 ml"
## [7] "riegoLâmina alta (1,0):silicio1000 ml"
## [8] "riegoLâmina alta (1,0):silicio1500 ml"
```

```r
# A coluna de interação é, por construção, o produto elemento a elemento
# das duas colunas principais correspondentes:
identical(
  X[, "riegoLâmina alta (1,0):silicio500 ml"],
  X[, "riegoLâmina alta (1,0)"] * X[, "silicio500 ml"]
)
```

```
## [1] TRUE
```

Essa forma de bloco tem uma consequência importante para a Seção 5.3 (p. 131): o teste de interação é, em termos do Capítulo 2 (Seção 2.8 (p. 33)), exatamente a comparação entre o modelo reduzido $\mathbf{X}_1 = [\mathbf{1} \mid \mathbf{X}_A \mid \mathbf{X}_B]$ (só efeitos principais) e o modelo completo $\mathbf{X} = [\mathbf{X}_1 \mid \mathbf{X}_2]$, com $\mathbf{X}_2 = \mathbf{X}_A \odot \mathbf{X}_B$ — a mesma lógica de $F = \dfrac{(SQE_{reduzido} - SQE_{completo})/p_2}{QM_{E,\,completo}}$ usada para testar qualquer bloco de colunas em um modelo linear geral, agora aplicada especificamente ao bloco de colunas de interação.

5.5 Fatoriais A×B×C: interações duplas e tripla

Com três fatores A, B, C (níveis a, b, c) e r repetições, o modelo se estende naturalmente:

$$y_{ijkl} = \mu + \alpha_i + \beta_j + \gamma_k + (\alpha\beta)_{ij} + (\alpha\gamma)_{ik} + (\beta\gamma)_{jk} + (\alpha\beta\gamma)_{ijk} + \varepsilon_{ijkl}.$$

Surge um novo tipo de termo: a **interação tripla** $(\alpha\beta\gamma)_{ijk}$. Sua interpretação é um nível acima da interação dupla — ela mede se **a interação entre dois fatores muda conforme o nível do terceiro**. Por exemplo, se a interação viscosidade×salinidade for forte quando o tempo de exposição é curto, mas quase nula quando o tempo é longo, há interação tripla. Interações triplas costumam ser mais difíceis de interpretar e, na prática, mais raras de serem grandes o suficiente para serem detectadas — mas ignorá-las sem testar é um erro de análise.

5.5.1 O cubo do 2^3: visualizando efeitos principais, duplos e triplo

Antes de tratar o fatorial $3 \times 3 \times 3$ completo da próxima aplicação, vale construir intuição geométrica com o caso mais simples possível de três fatores cruzados: um $2 \times 2 \times 2$ (2^3), em que cada fator tem só dois níveis. Cada um dos $2^3 = 8$ tratamentos corresponde a um **vértice de um cubo** — os três eixos do cubo são os três fatores, e cada aresta liga dois tratamentos que diferem em exatamente um fator. O Capítulo 6 (Seção 6.1 (p. 143)) trata fatoriais 2^k em profundidade; aqui adiantamos só a leitura geométrica, com dados reais. A representação do 2^k como um cubo (ou hipercubo, para $k > 3$) cujos vértices são os tratamentos é o dispositivo visual clássico da literatura de fatoriais (Box et al., 2005; Yates, 1937), e a notação de cada vértice — (1) para a combinação de níveis baixos, letras minúsculas para indicar quais fatores estão no nível alto — é exatamente a notação de sinais introduzida por Yates.

Em vez de simular dados fictícios, recortamos um sub-desenho real de dentro do fatorial 2^4 de biodiesel que será analisado por completo no Capítulo 6: fixamos o agente de purificação (`Agente`) no nível baixo e mantemos os outros três fatores — razão molar (A = `Relacion`), catalisador (B = `Catalizador`) e temperatura (C = `Temperatura`) — com suas duas repetições cada, totalizando 16 corridas.

Cada vértice mostra o tratamento (notação de Yates (Yates, 1937)) e o rendimento médio observado nas duas repetições. Já dá para notar, a olho, que os vértices não seguem um padrão simples: o vértice `b` (91,7) é bem mais alto que seus vizinhos `(1)` (73,5) e `ab` (66,7) — um primeiro sinal visual de que a superfície de resposta sobre o cubo não é “plana” (efeitos puramente aditivos).

Efeitos principais como faces do cubo. O efeito principal de um fator é a diferença entre a média da face “alta” e da face “baixa” desse fator — geometricamente, as duas faces retangulares opostas do cubo:

Interações duplas como planos diagonais. A interação AB compara a diferença $B_+ - B_-$ calculada dentro de A_+ com a mesma diferença dentro de A_- — geometricamente, dois planos diagonais que cruzam o cubo (cada um ligando quatro vértices alternados):

Os dois planos de cada painel se cruzam no centro do cubo — visualmente, é exatamente essa sobreposição que corresponde a um efeito de interação não nulo: se as duas faixas coloridas fossem, em vez disso, faces opostas e paralelas (como nos efeitos principais acima), a interação seria zero por construção.

A interação tripla. Não existe mais um “plano” simples de duas cores para representar ABC — em vez disso, os oito vértices se dividem em dois grupos de quatro, alternados, que formam dois tetraedros entrelaçados dentro do cubo:

Neste sub-desenho real, a interação tripla (8.91) já é **maior em magnitude** do que qualquer um dos seis efeitos principais e duplos — um preview exato do que a ANOVA completa do fatorial 2^4 vai confirmar formalmente no Capítulo 6 (Seção 6.1 (p. 143)), com os quatro fatores e teste de significância. A leitura geométrica não substitui o teste formal, mas explica *por que* uma interação tripla grande é, à primeira vista, contraintuitiva: não há uma única “direção” no cubo — como uma face ou um plano diagonal — que a represente sozinha, só a alternância entre os dois tetraedros.

> **Aplicação — Ciência de dados/Engenharia: otimizando um processo de extração como um teste A/B/n de três fatores**
> Uma equipe de laboratório trata a otimização de um processo de recuperação de um composto volátil exatamente como uma equipe de produto trataria um teste A/B/n multivariado (também chamado teste fatorial online; Kohavi, Tang & Xu, 2020): em vez de dois braços (A vs. B), há **três fatores de configuração** cruzados, cada um com três níveis — viscosidade do solvente (`baixa`/`média`/`alta`), salinidade da solução (`baixa`/`média`/`alta`) e tempo de exposição (`curto`/`médio`/`longo`) — totalizando $3 \times 3 \times 3 = 27$ combinações, cada uma executada em duas injeções independentes (repetições), 54 corridas ao todo. A resposta é a proporção do composto recuperado.

> **Uso do R** — ANOVA do fatorial 3×3×3 com repetição

```r
acuosas <- read_csv("data/acuosas.csv", show_col_types = FALSE) %>%
  transmute(
    viscosidade = factor(Viscosidad, labels = c("baixa", "média", "alta")),
    salinidade  = factor(Salinidad,  labels = c("baixa", "média", "alta")),
    tempo       = factor(Tiempo,     labels = c("curto", "médio", "longo")),
    injecao     = factor(inyeccion),
    recuperacao = recupera
  )

modelo_axbxc <- aov(recuperacao ~ viscosidade * salinidade * tempo, data = acuosas)
summary(modelo_axbxc)
```

```
##                              Df Sum Sq Mean Sq F value   Pr(>F)
## viscosidade                   2 0.4981 0.24906  34.680 3.47e-08 ***
## salinidade                    2 0.0986 0.04930   6.865  0.00389 **
## tempo                         2 0.0751 0.03757   5.231  0.01202 *
## viscosidade:salinidade        4 0.0388 0.00969   1.350  0.27736
## viscosidade:tempo             4 0.0048 0.00119   0.166  0.95404
## salinidade:tempo              4 0.0501 0.01252   1.743  0.16974
## viscosidade:salinidade:tempo  8 0.0753 0.00941   1.311  0.28001
## Residuals                    27 0.1939 0.00718
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Os três efeitos principais são estatisticamente significativos ($p < 0{,}05$ para os três), mas **nenhuma das interações — duplas ou tripla — é significativa** neste conjunto de dados. Isso é uma conclusão

substantiva importante, não um resultado “nulo” sem interesse: significa que os três fatores atuam de forma aproximadamente **aditiva** sobre a recuperação, e que otimizar cada um isoladamente (ao contrário do que a Seção 5.1 (p. 129) alertou em geral) levaria, neste caso específico, a uma conclusão muito parecida com a do fatorial completo — algo que só podemos afirmar com confiança *depois* de testar a interação, nunca antes.

Tabela 5.3: Médias marginais por fator (fatorial 3×3×3 do processo de extração)

fator	nível	recuperação_média
Viscosidade	baixa	0.712
	média	0.583
	alta	0.477
Salinidade	baixa	0.550
	média	0.572
	alta	0.650
Tempo	curto	0.543
	médio	0.595
	longo	0.634

A recuperação **diminui** com o aumento da viscosidade (0,712 → 0,477) — solventes mais viscosos dificultam a transferência de massa — e **aumenta** discretamente com salinidade e tempo de exposição. Como as interações não são relevantes, essas três tendências marginais já resumem bem o comportamento do processo.


Recuperação média marginal de cada fator do fatorial 3x3x3, com barra de erro-padrão. Como nenhuma interação é significativa, estas três tendências isoladas já descrevem quase todo o comportamento do processo.

Figura 5.1: Recuperação média marginal de cada fator do fatorial 3x3x3, com barra de erro-padrão. Como nenhuma interação é significativa, estas três tendências isoladas já descrevem quase todo o comportamento do processo.

O painel deixa visível, lado a lado, o que a tabela de médias descreveu em prosa: a reta de viscosidade cai monotonicamente, enquanto salinidade e tempo sobem de forma mais discreta e quase linear. As barras de erro-padrão são pequenas em relação às diferenças entre níveis — consistente com os três efeitos principais significativos da ANOVA — e a ausência de qualquer “dobra” abrupta dentro de cada painel é o retrato visual da aditividade: cada fator parece empurrar a recuperação na mesma direção, ao longo de toda a faixa observada, independentemente do nível dos outros dois.

5.5.2 O diagrama de Hasse do fatorial 3×3×3

A Seção 2.2 (p. 17) (Capítulo 2) introduziu o diagrama de Hasse para um DCA de um fator e para um fatorial $A \times B$ de dois fatores; o desenho de extração acima — três fatores cruzados, cada um com 3 níveis, $r = 2$ injeções por combinação, $N = 3 \times 3 \times 3 \times 2 = 54$ — é o primeiro exemplo deste livro com **três** fatores cruzados, e vale formalizar sua estrutura antes de seguir para os fatoriais 2^k do Capítulo 6, em que diagramas com quatro e mais fatores serão a norma.

> **Uso do R** — diagrama de Hasse do fatorial 3×3×3 de extração

```
nos_axbxc <- tibble(
  termo   = c("Média", "Viscosidade", "Salinidade", "Tempo",
              "Visc.×Sal.", "Visc.×Tempo", "Sal.×Tempo",
              "Visc.×Sal.×Tempo", "Erro"),
  # classes = numero de combinacoes distintas que o termo distingue
  classes = c(1, 3, 3, 3,
              3 * 3, 3 * 3, 3 * 3,
              3 * 3 * 3, 54)
)

arestas_axbxc <- tibble(
  de   = c("Média", "Média", "Média",
           "Viscosidade", "Salinidade",
           "Viscosidade", "Tempo",
           "Salinidade", "Tempo",
           "Visc.×Sal.", "Visc.×Tempo", "Sal.×Tempo",
           "Visc.×Sal.×Tempo"),
  para = c("Viscosidade", "Salinidade", "Tempo",
           "Visc.×Sal.", "Visc.×Sal.",
           "Visc.×Tempo", "Visc.×Tempo",
           "Sal.×Tempo", "Sal.×Tempo",
           "Visc.×Sal.×Tempo", "Visc.×Sal.×Tempo", "Visc.×Sal.×Tempo",
           "Erro")
)

knitr::include_graphics(
  hasse_svg(nos_axbxc, arestas_axbxc,
            arquivo = "figuras/hasse/axbxc.svg",
            titulo  = "Fatorial 3&#215;3&#215;3: viscosidade, salinidade, tempo, r=2
         (N=54)")
)
```

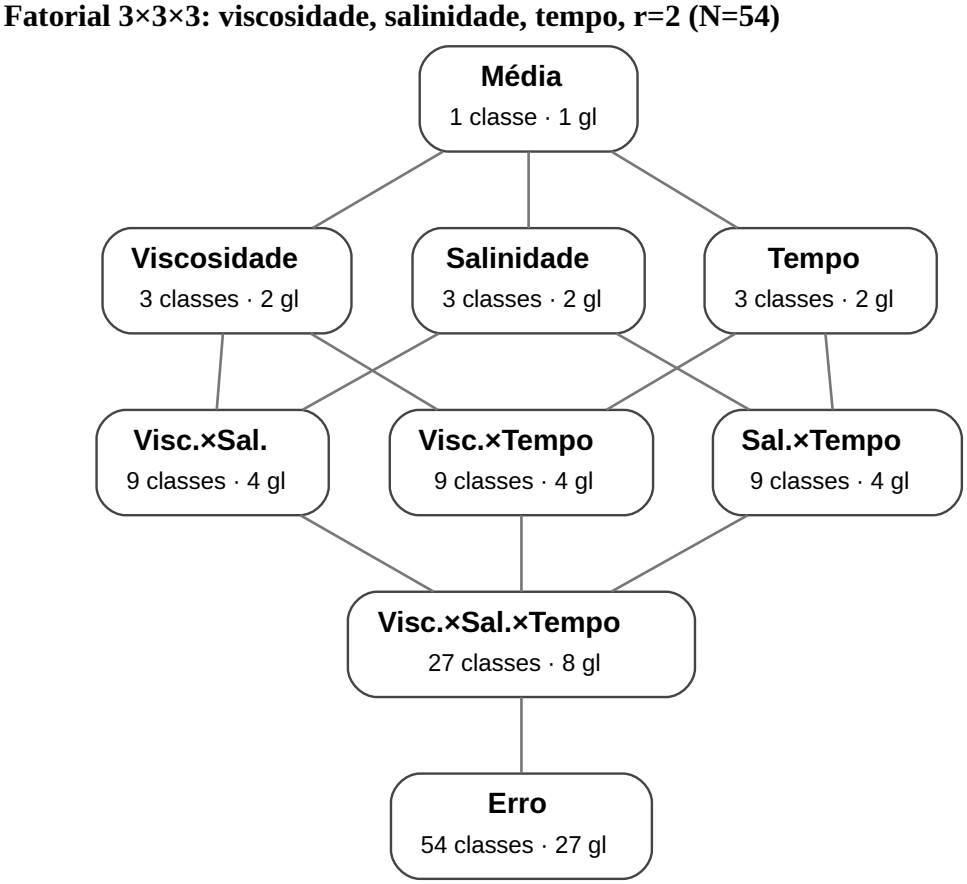


Figura 5.2: Diagrama de Hasse do fatorial 3x3x3 de extração (viscosidade, salinidade, tempo, r=2 injeções, N=54). Os três fatores ocupam o mesmo nível (cruzados entre si); as três interações duplas refinam exatamente o par de fatores que as compõe; a interação tripla refina as três duplas simultaneamente; o Erro, na base, recebe o que sobra depois de toda a estrutura de tratamento.

Os três fatores (Viscosidade, Salinidade, Tempo) aparecem lado a lado no mesmo nível do diagrama, sem aresta entre nenhum par deles — a assinatura de fatores **cruzados**, já vista no Capítulo 2 para dois fatores e agora estendida a três. Cada interação dupla refina exatamente os dois fatores que a compõem (Visc.×Sal. desce de Viscosidade *e* de Salinidade, nunca de Tempo), e a interação tripla é o único nó que desce simultaneamente das três duplas — geometricamente, o único ponto do diagrama "abaixo" de toda a estrutura de tratamento, exatamente como o cubo do 2^3 (Seção 5.5.1 (p. 136)) tampouco tem uma única face ou plano que represente ABC sozinho. Aplicando a regra de subtração da Seção 2.2 (p. 17) ao nó da tripla: ela distingue $3 \times 3 \times 3 = 27$ caselas, das quais $1 + 2 + 2 + 2 + 4 + 4 + 4 = 19$ graus de liberdade já foram "gastos" pelos termos acima dela no diagrama, sobrando $27 - 19 = 8 = (3-1)^3$ — a mesma fórmula da interação tripla escrita algebricamente na Seção 5.5 (p. 135). Somando todos os nós, $1 + 2 + 2 + 2 + 4 + 4 + 4 + 8 + 27 = 54 = N$: os graus de liberdade do diagrama esgotam exatamente as 54 observações, sem sobra e sem falta — a mesma verificação de contabilidade que a Seção 2.2 (p. 17) fez para o DCA e o fatorial $A \times B$, agora com uma estrutura de árvore em vez de uma cadeia ou um losango simples.

Para discutir

1. Se a interação viscosidade×salinidade tivesse sido significativa, por que reportar apenas as médias marginais da Tabela acima seria enganoso? O que deveria ser reportado no lugar?
2. O desenho usa duas injeções por combinação de níveis (repetição verdadeira, não submuestreo — ver a seção sobre unidades experimentais e amostrais do Capítulo 1). O que mudaria na análise, e por que ela deixaria de ser válida, se houvesse apenas uma corrida por combinação?
3. Uma equipe de produto testando cor do botão × layout × texto do CTA sobre a taxa de conversão está, estruturalmente, no mesmo desenho A×B×C. Que cuidado adicional um teste A/B/n online exige que um experimento de bancada, como este, controla mais facilmente (aleatorização, ausência de interferência entre unidades)?

5.6 Fatoriais de dois fatores em blocos completos

A Seção 5.2 (p. 130) analisou o experimento do pepino **como se** as 24 parcelas fossem completamente intercambiáveis — mas a variável `bloque` (três blocos de terreno) foi ignorada de propósito, para isolar o modelo A×B primeiro. Se os blocos capturam uma fonte real e conhecida de variação (fertilidade do solo, posição no terreno), ignorá-los desperdiça informação: a variação entre blocos permanece dentro do erro experimental, inflando QM_E e reduzindo o poder dos testes de A, B e $A\times B$ — exatamente o problema que a blocagem foi criada para resolver (Capítulo 4).

O modelo correto para um fatorial de dois fatores em **blocos completos** (cada bloco contém todas as ab combinações de tratamento, uma vez) acrescenta um termo aditivo de bloco:

$$y_{ijk} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + \rho_k + \varepsilon_{ijk}, \qquad k = 1, \ldots, r,$$

com ρ_k o efeito fixo do k-ésimo bloco ($\sum_k \rho_k = 0$) e a suposição usual de que o bloco **não interage** com os fatores de tratamento (a mesma suposição de aditividade do delineamento em blocos completos aleatorizados do Capítulo 4). Tratar cada combinação de tratamento do fatorial como uma "unidade de tratamento" única e blocá-la exatamente como no Capítulo 4 é a extensão natural do DBCA a mais de um fator (Oehlert, 2010). A soma de quadrados do erro perde $r - 1$ graus de liberdade, que passam a ser explicados pelo termo de bloco:

Uso do R — o mesmo fatorial, agora com o bloco

```
modelo_blocos <- aov(altura ~ bloque + riego * silicio, data = pepino)
summary(modelo_blocos)
```

```
##               Df Sum Sq Mean Sq F value  Pr(>F)
## bloque         2 0.0128  0.0064   0.116 0.89158
## riego          1 0.2604  0.2604   4.699 0.04791 *
## silicio        3 1.3872  0.4624   8.343 0.00199 **
## riego:silicio  3 0.3883  0.1294   2.335 0.11807
## Residuals     14 0.7759  0.0554
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Tabela 5.4: Efeito de incluir o bloco sobre o quadrado médio do erro

Modelo	QM do erro	gl do erro
Sem bloco (Seção 5.2)	0.0493	16
Com bloco (Seção 5.5)	0.0554	14

Neste conjunto de dados específico, o bloco explica muito pouco ($SQ_{bloco} \approx 0{,}013$, $p \approx 0{,}89$): os três blocos de terreno acabaram sendo bastante homogêneos entre si, então "gastar" 2 graus de liberdade com eles não trouxe ganho de precisão — o QM_E com bloco é, na verdade, ligeiramente **maior** do que sem ele. Isso ilustra um ponto importante que vale a pena enfatizar: **blocar é uma decisão que deve ser tomada a partir do conhecimento do delineamento, antes de ver os dados**, e não uma garantia automática de ganho de precisão. Quando os blocos correspondem a uma fonte real de heterogeneidade, o ganho costuma ser substancial (como visto no Capítulo 4); quando não, o custo em graus de liberdade é pequeno, mas não nulo.



Quadrado médio do erro do fatorial pepino, com e sem o termo de bloco. A diferença mínima entre as duas barras é o retrato visual de um bloco que captura pouca heterogeneidade real.

Figura 5.3: Quadrado médio do erro do fatorial pepino, com e sem o termo de bloco. A diferença mínima entre as duas barras é o retrato visual de um bloco que captura pouca heterogeneidade real.

As duas barras são quase idênticas — ao contrário do ganho de eficiência claro que a blocagem trouxe em outros exemplos do Capítulo 4, aqui incluir o bloco não reduziu (e, por este critério ingênuo, até aumentou ligeiramente) o quadrado médio do erro, confirmando numericamente, e agora visualmente, que os três blocos de terreno deste experimento específico não carregavam heterogeneidade suficiente para compensar os graus de liberdade gastos com eles.

5.7 Resumo do capítulo

- Cruzar fatores em um arranjo fatorial detecta **interação** — algo que nenhuma sequência de experimentos de um único fator (OFAT) consegue capturar — sem custo adicional de unidades experimentais.
- O modelo A×B decompõe a resposta em efeito principal de A, efeito principal de B e interação $A \times B$; a tabela de ANOVA testa as três hipóteses com o mesmo QM_E.
- Com três fatores, surgem interações duplas e uma interação **tripla**, que mede se a interação entre dois fatores muda com o nível do terceiro.
- Um fatorial em **blocos completos** soma um termo aditivo de bloco ao modelo — útil quando os blocos capturam heterogeneidade real; caso contrário, apenas consome graus de liberdade.

O Capítulo 6 aprofunda o caso especial (e extremamente comum na prática) em que todos os fatores têm exatamente dois níveis — os fatoriais 2^k — e as técnicas específicas para analisá-los sem repetição, confundi-los em blocos e fracioná-los (Finney, 1945) quando o número de fatores é grande demais para rodar o fatorial completo.

6 Fatoriais avançados: confusão, fracionamento e superfície de resposta

O Capítulo 5 tratou fatoriais com número arbitrário de níveis por fator. Este capítulo se concentra no caso particular — e de longe o mais usado na prática industrial e científica — em que **todos os fatores têm exatamente dois níveis**: os fatoriais 2^k. Sua popularidade não é acidente: com apenas duas configurações por fator (tipicamente um nível "baixo" e um "alto"), um fatorial 2^k estima todos os efeitos principais e interações com o menor número de corridas possível, e sua álgebra é simples o bastante para ser feita à mão — uma vantagem que continua relevante mesmo com software disponível, porque torna transparente *o que* está sendo estimado. O Capítulo 7 dá sequência a este, trocando a pergunta "o que importa?" pela pergunta "qual é o ótimo?" — a **metodologia de superfície de resposta**.

6.1 Fatoriais 2^k: notação e ANOVA

Com k fatores de dois níveis cada, há 2^k tratamentos distintos. Por convenção, codificamos o nível baixo como -1 e o alto como $+1$ (ou, na notação clássica de Yates, o nível baixo de um fator recebe a letra minúscula ausente e o alto a letra presente: `(1)`, `a`, `b`, `ab` para $k = 2$). Um **efeito** — principal ou de interação — é definido como a diferença média na resposta ao mover o(s) fator(es) envolvido(s) do nível baixo ao alto, e pode ser calculado diretamente como duas vezes o coeficiente de uma regressão da resposta sobre as colunas codificadas em ± 1 (e suas interações, construídas por produto de colunas):

$$\text{efeito}_A = \bar{y}(A{=}{+}1) - \bar{y}(A{=}{-}1) = 2\hat{\beta}_A, \qquad \text{efeito}_{AB} = 2\hat{\beta}_{AB}, \ \ldots$$

Com r repetições por tratamento, a ANOVA de um 2^k é um caso especial da tabela do Capítulo 5: cada efeito principal e cada interação (de ordem 2 até ordem k) tem exatamente **1 grau de liberdade** (porque cada fator só tem 2 níveis), e o erro tem $2^k(r-1)$ graus de liberdade. Isso faz a tabela de ANOVA de um 2^k replicado ser simples de ler: cada linha é uma pergunta binária sobre um único contraste.

> **Aplicação — Engenharia química: rendimento de biodiesel em um fatorial 2^4**
> Uma planta piloto de biodiesel testa quatro fatores de processo, cada um em dois níveis codificados (-1/$+1$): razão molar álcool:óleo (`Relacion`), tipo de catalisador (`Catalizador`), temperatura de reação (`Temperatura`) e agente de purificação (`Agente`). O fatorial 2^4 completo (16 tratamentos) foi executado com **duas repetições** (32 corridas), medindo o rendimento percentual de biodiesel.

> **Uso do R** — ANOVA completa do 2^4 replicado

```
# Mantemos os quatro fatores em sua codificação numérica original (-1/+1), em vez de
# convertê-los para factor(): a seção "Ortogonalidade da matriz de desenho" mostra
        que é exatamente essa
# codificação simétrica que faz X'X ser diagonal. A tabela de ANOVA abaixo não muda
        em nada
# — soma de quadrados de um fatorial 2^k balanceado não depende de como cada fator é
        codificado —
# mas as próximas seções (contraste de Yates, Lenth) dependem disso de forma
        essencial.
biodiesel <- read_csv("data/biodiesel.csv", show_col_types = FALSE)
```

```
modelo_2k <- aov(Rendimiento ~ Relacion * Catalizador * Temperatura * Agente, data =
        biodiesel)
broom::tidy(modelo_2k) %>%  filter(p.value < 0.10 | is.na(p.value)) %>%
  mutate(across(where(is.numeric), ~round(., 4))) %>%
  kable(caption = "Termos com p < 0,10 na ANOVA completa do fatorial 2⁴ (rendimento
        de biodiesel)") %>%
  kable_styling(full_width = FALSE)
```

Tabela 6.1: Termos com p < 0,10 na ANOVA completa do fatorial 2⁴ (rendimento de biodiesel)

term	df	sumsq	meansq	statistic	p.value
Temperatura	1	216.8403	216.8403	10.4857	0.0051
Relacion:Catalizador	1	63.5628	63.5628	3.0737	0.0987
Relacion:Temperatura	1	224.1903	224.1903	10.8411	0.0046
Relacion:Agente	1	137.3653	137.3653	6.6425	0.0203
Catalizador:Agente	1	94.8753	94.8753	4.5879	0.0479
Relacion:Catalizador:Temperatura	1	334.7578	334.7578	16.1878	0.0010
Relacion:Catalizador:Agente	1	71.7003	71.7003	3.4672	0.0811
Residuals	16	330.8750	20.6797	NA	NA

Com as duas repetições, cinco termos emergem como estatisticamente relevantes ($p < 0{,}05$): o efeito principal da **temperatura**, as interações duplas **razão:temperatura**, **razão:agente** e **catalisador:agente**, e — o efeito dominante — a **interação tripla razão:catalisador:temperatura** ($p \approx 0{,}001$). Voltaremos a este mesmo conjunto de dados na próxima seção, mas fingindo, por um momento, que só tínhamos rodado **uma** repetição — o cenário mais comum na prática, porque cada corrida de um fatorial 2^k completo já é cara, e dobrar o número de corridas para obter uma repetição raramente é viável quando k é grande.

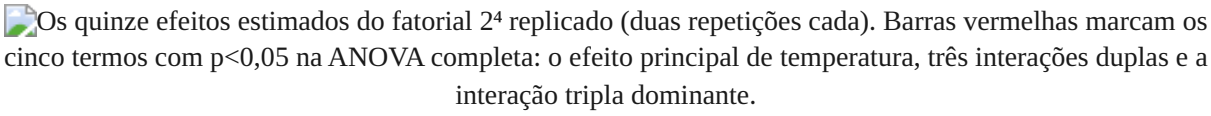

Os quinze efeitos estimados do fatorial 2⁴ replicado (duas repetições cada). Barras vermelhas marcam os cinco termos com p<0,05 na ANOVA completa: o efeito principal de temperatura, três interações duplas e a interação tripla dominante.

Figura 6.1: Os quinze efeitos estimados do fatorial 2⁴ replicado (duas repetições cada). Barras vermelhas marcam os cinco termos com p<0,05 na ANOVA completa: o efeito principal de temperatura, três interações duplas e a interação tripla dominante.

O painel deixa visível, de um só golpe, o que a tabela de p-valores só confirma termo a termo: a interação tripla razão:catalisador:temperatura não é apenas “significativa” — é, em magnitude, o maior de todos os quinze efeitos, maior até que o efeito principal da temperatura sozinho. Os outros dez efeitos não destacados (barras cinzas) se acumulam perto de zero, um padrão visual que antecipa exatamente o que a Seção 6.2 (p. 148) explora a seguir: a maioria dos efeitos de um fatorial 2^k tende a ser pequena, e só uns poucos se destacam — o princípio da esparsidade dos efeitos, aqui visto com a repetição completa disponível, antes de precisarmos de qualquer método que dispense repetição para enxergá-lo.

6.1.1 Ortogonalidade da matriz de desenho

A Seção 5.4 (p. 135) mostrou que a matriz $\mathbf{X}$ de um fatorial A×B se monta em blocos $[\mathbf{1} \mid \mathbf{X}_A \mid \mathbf{X}_B \mid \mathbf{X}_A \odot \mathbf{X}_B]$. No 2^k codificado em $\{-1, +1\}$, essa construção ganha uma propriedade extra e muito especial: **todas as colunas de $\mathbf{X}$ — incluindo o intercepto e todas as colunas de interação, de qualquer ordem — são mutuamente ortogonais**, isto é, $\mathbf{X}'\mathbf{X}$ é uma matriz **diagonal** (cada entrada fora da diagonal é o produto interno de duas colunas de ± 1’s, que se cancela exatamente quando o desenho é

balanceado). Isso não é uma coincidência do desenho — é uma consequência direta de cada coluna assumir apenas os valores ± 1 em proporções iguais e de forma cruzada.

> **Uso do R** — verificando que X'X é diagonal no 2^4

```
X <- model.matrix(~ Relacion * Catalizador * Temperatura * Agente, data = biodiesel)
XtX <- t(X) %*% X

# Todas as entradas fora da diagonal são zero?
all(XtX[upper.tri(XtX)] == 0)
```

```
## [1] TRUE
```

```
# A diagonal inteira vale n = 32 (o número de corridas)
range(diag(XtX))
```

```
## [1] 32 32
```

Quando $\mathbf{X}'\mathbf{X}$ é diagonal, sua inversa também é diagonal — basta inverter cada elemento — e as equações normais $\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}'\mathbf{Y}$ do Capítulo 2 (Seção 2.4 (p. 23)) se **desacoplam** completamente: cada coeficiente $\hat{\beta}_j$ passa a ter uma fórmula fechada que não depende de nenhum outro coeficiente,

$$\hat{\beta}_j = \frac{\mathbf{x}_j'\mathbf{Y}}{\mathbf{x}_j'\mathbf{x}_j} = \frac{\mathbf{x}_j'\mathbf{Y}}{n}, \qquad \text{efeito}_j = 2\hat{\beta}_j = \frac{2}{n}\,\mathbf{x}_j'\mathbf{Y} = \frac{2}{n}\sum_{i=1}^{n}(\pm 1)\,y_i,$$

isto é, cada efeito é (duas vezes) o **produto interno** da coluna de sinais $\mathbf{x}_j$ com a resposta, normalizado pela norma ao quadrado da coluna. Essa é exatamente a fórmula clássica do "contraste de Yates" — soma da resposta com sinal $+$ menos soma com sinal $-$, dividida pela metade do número de corridas — só que agora obtida como caso particular da álgebra de mínimos quadrados do Capítulo 2, não como uma regra memorizada à parte.

```
y  <- biodiesel$Rendimiento
xa <- X[, "Relacion"]                       # coluna de sinais ±1 do fator Relação

efeito_via_produto_interno <- 2 * sum(xa * y) / sum(xa * xa)
efeito_via_regressao <- 2 * coef(lm(Rendimiento ~ Relacion * Catalizador *
                                    Temperatura * Agente, data = biodiesel))
        ["Relacion"]

c(produto_interno = efeito_via_produto_interno,
  regressao       = unname(efeito_via_regressao))
```

```
## produto_interno       regressao
##        -1.99375         -1.99375
```

A ortogonalidade tem uma segunda consequência, agora sobre a ANOVA: como as colunas são ortogonais, a soma de quadrados de cada efeito é $SQ_j = n\,\hat{\beta}_j^2$ e a soma de quadrados total se decompõe **exatamente** na soma das SQ_j de todos os efeitos — sem nenhum termo cruzado. É por isso que, em um 2^k balanceado, é possível estimar e testar cada efeito isoladamente, um de cada vez, sem que a ordem em que os fatores entram no modelo afete o resultado (ao contrário de desenhos desbalanceados, em que $\mathbf{X}'\mathbf{X}$ deixa de ser

diagonal e a soma de quadrados de cada termo passa a depender de quais outros termos já estão no modelo — o problema das “somas de quadrados Tipo I vs. Tipo III” que volta a aparecer sempre que o balanceamento se perde).

6.1.2 O algoritmo tabular de Yates

A Seção anterior obteve cada efeito como um produto interno, $\text{efeito}_j = \frac{2}{n}\mathbf{x}_j'\mathbf{Y}$. Antes de existirem pacotes estatísticos, essa conta era feita literalmente assim, à mão: monta-se uma tabela com uma coluna de sinais ± 1 para cada efeito — principais e interações —, multiplica-se cada coluna pela resposta média do tratamento correspondente, somam-se os produtos e divide-se pelo divisor apropriado. O exemplo clássico a seguir — um 2^3 com fatores de processo T, C e K, cada um em dois níveis, com duas réplicas — é reproduzido do material de aula do curso e ilustra esse procedimento numericamente, antes de o formalizarmos como um algoritmo mais rápido e o reproduzirmos em R sobre os próprios dados do biodiesel.

Um 2³ clássico com fatores T, C e K (duas réplicas cada, I e II). As colunas de sinais (-/+) definem os oito tratamentos em ordem-padrão; as colunas à direita resumem média, amplitude e variância de cada tratamento.

Figura 6.2: Um 2³ clássico com fatores T, C e K (duas réplicas cada, I e II). As colunas de sinais (-/+) definem os oito tratamentos em ordem-padrão; as colunas à direita resumem média, amplitude e variância de cada tratamento.

A tabela de sinais e contrastes para o 2³ acima: cada coluna (T, C, K, T x C, T x K, C x K, T x C x K) é a coluna de sinais ±1 daquele efeito, multiplicada pela Produção Média de cada tratamento (última coluna) e somada; o resultado, dividido pelo divisor do rodapé, é o efeito estimado -- exatamente o produto interno da Seção 6.1.1.

Figura 6.3: A tabela de sinais e contrastes para o 2³ acima: cada coluna (T, C, K, T x C, T x K, C x K, T x C x K) é a coluna de sinais ±1 daquele efeito, multiplicada pela Produção Média de cada tratamento (última coluna) e somada; o resultado, dividido pelo divisor do rodapé, é o efeito estimado – exatamente o produto interno da Seção 6.1.1.

Cálculo manual do efeito de interação dupla T x C (temperatura x catalisador) no mesmo exemplo 2^3: as quatro combinações com sinal '+' (diagonal do cubo) contra as quatro com sinal '-' produzem a mesma conta que a coluna 'T x C' da tabela de sinais -- a leitura geométrica (planos diagonais do cubo, seção sobre o cubo do 2 ao cubo do Capítulo 5) e a leitura tabular (produto de colunas de sinais) chegam ao mesmo número.

Figura 6.4: Cálculo manual do efeito de interação dupla T x C (temperatura x catalisador) no mesmo exemplo 2^3: as quatro combinações com sinal ‘+’ (diagonal do cubo) contra as quatro com sinal ‘-’ produzem a mesma conta que a coluna ‘T x C’ da tabela de sinais – a leitura geométrica (planos diagonais do cubo, seção sobre o cubo do 2 ao cubo do Capítulo 5) e a leitura tabular (produto de colunas de sinais) chegam ao mesmo número.

Essa tabela é a versão numérica, célula a célula, da fórmula algébrica $\text{efeito}_j = \frac{2}{n}\mathbf{x}_j'\mathbf{Y}$: cada coluna de sinais é uma coluna $\mathbf{x}_j$ diferente (a de “T” é o efeito principal do fator T; a de “T×C” é o produto elemento a elemento das colunas de T e C, exatamente como a Seção 5.4 (p. 135) descreveu para o caso geral A×B); a soma dos produtos sinal×resposta é o numerador do produto interno; e o “Divisor” do rodapé — 4 para qualquer efeito neste 2^3 — é 2^{k-1}, a metade do número de tratamentos, que aparece porque a tabela já trabalha com a **produção média** de cada tratamento (a média das duas réplicas), não com o total. Montar

essa tabela inteira, coluna a coluna, é exatamente o que os pesquisadores faziam antes de qualquer software — e é exatamente o que `model.matrix()` faz por trás dos panos hoje.

Montar a tabela de sinais completa fica caro rapidamente: um 2^k tem $2^k - 1$ colunas de sinal, cada uma com 2^k entradas. Yates (1937) percebeu que **não é preciso montar a tabela inteira**: os mesmos 2^k contrastes podem ser obtidos com apenas k passadas sucessivas de somas e diferenças sobre os totais de tratamento dispostos em ordem-padrão (`(1), a, b, ab, c, ac, bc, abc, ...`, em que cada letra sucessiva repete o bloco de tratamentos já listado, acrescentando-o com o novo fator no nível alto). Em cada passada: (i) a primeira metade do novo vetor é a soma de pares consecutivos do vetor anterior; (ii) a segunda metade é a diferença (segundo menos primeiro) desses mesmos pares. Depois de k passadas, a primeira entrada do vetor final é o total geral, e cada entrada seguinte é o contraste de um efeito — na mesma ordem-padrão dos rótulos —, pronto para ser dividido por $n\,2^{k-1}$ (obtendo o efeito) ou elevado ao quadrado e dividido por $n\,2^k$ (obtendo sua soma de quadrados, a mesma $SQ_j = n\hat{\beta}_j^2$ da Seção 6.1.1 (p. 144)). O ganho é computacional, não conceitual: $k\,2^k$ somas/diferenças no total, contra a ordem $2^k(2^k - 1)$ de operações da tabela de sinais completa — uma economia que importava muito com lápis e papel, e que hoje sobrevive sobretudo por seu valor didático.

> **Uso do R** — implementando o algoritmo tabular de Yates e verificando-o contra os efeitos já calculados do biodiesel

```r
# Uma passada do algoritmo: metade inferior = somas de pares consecutivos,
# metade superior = diferencas (segundo menos primeiro) dos mesmos pares
passada_yates <- function(v) {
  n <- length(v)
  somas       <- v[seq(1, n, by = 2)] + v[seq(2, n, by = 2)]
  diferencas  <- v[seq(2, n, by = 2)] - v[seq(1, n, by = 2)]
  c(somas, diferencas)
}

algoritmo_yates <- function(totais, k) {
  v <- totais
  for (passo in seq_len(k)) v <- passada_yates(v)
  v
}

# Reaproveitando o 2^4 do biodiesel (secao "Fatoriais 2^k: notacao e ANOVA"): totais
      de tratamento
# em ordem-padrao (1, a, b, ab, c, ac, ..., abcd), construida a partir dos 4 bits do
      indice
k <- 4
ordem_padrao <- tibble(idx = 0:(2^k - 1)) %>%
  mutate(
    Relacion    = if_else(bitwAnd(idx, 1L) > 0,  1, -1),
    Catalizador = if_else(bitwAnd(idx, 2L) > 0,  1, -1),
    Temperatura = if_else(bitwAnd(idx, 4L) > 0,  1, -1),
    Agente      = if_else(bitwAnd(idx, 8L) > 0,  1, -1)
  )

totais_trat <- ordem_padrao %>%
  left_join(
    biodiesel %>% group_by(Relacion, Catalizador, Temperatura, Agente) %>%
      summarise(total = sum(Rendimiento), n = n(), .groups = "drop"),
    by = c("Relacion", "Catalizador", "Temperatura", "Agente")
  )

v_final <- algoritmo_yates(totais_trat$total, k)
```

```
r <- unique(totais_trat$n)                          # 2 replicas por tratamento
efeitos_yates <- v_final[-1] / (r * 2^(k - 1))        # descarta o total geral
        (posicao 1)

# Efeitos ja calculados via produto interno / regressao (secao "Ortogonalidade da
        matriz de desenho")
efeitos_regressao <- 2 * coef(lm(Rendimiento ~ Relacion * Catalizador * Temperatura *
        Agente,
                                 data = biodiesel))[-1]
max(abs(sort(efeitos_yates) - sort(efeitos_regressao)))
```

```
## [1] 1.676437e-14
```

A diferença máxima entre os 15 efeitos calculados pelo algoritmo tabular e os mesmos 15 efeitos obtidos por regressão é numericamente zero: as duas rotas — produto interno de colunas de sinais e somas/diferenças sucessivas — chegam exatamente ao mesmo resultado, porque são, algebricamente, a mesma conta organizada de duas formas diferentes. A vantagem do algoritmo de Yates nunca foi precisão adicional, e sim **custo computacional**: k passadas de 2^{k-1} somas e 2^{k-1} diferenças cada ($k\,2^k$ operações ao todo) contra o cálculo de $2^k - 1$ produtos internos de comprimento 2^k cada (proporcional a $2^k(2^k-1)$ operações) — uma economia que importava muito quando as contas eram feitas à mão ou em calculadoras mecânicas, e que hoje sobrevive sobretudo por seu valor didático: tornar visível, coluna a coluna, como cada efeito de ordem crescente nasce dos efeitos de ordem menor já calculados.

6.2 Análise de um fatorial 2^k não replicado

Sem repetição, não há graus de liberdade sobrando para estimar σ^2 diretamente — o modelo saturado (todos os $2^k - 1$ efeitos) consome todos os graus de liberdade disponíveis, e não sobra um "erro puro" para comparar. A saída clássica (Box et al., 2005; Daniel, 1959) explora um fato empírico: **a maioria dos efeitos de ordem alta é, de fato, próxima de zero** (o chamado *princípio da esparsidade dos efeitos*), então os efeitos verdadeiramente nulos se comportam como ruído aproximadamente normal em torno de zero, enquanto os poucos efeitos reais se destacam como discrepantes dessa distribuição.

6.2.1 Gráfico de probabilidade normal (half-normal plot)

O dispositivo gráfico proposto por Daniel (1959) para essa situação é simples e eficaz: se ordenarmos os $2^k - 1$ efeitos estimados por valor absoluto e os colocarmos contra os quantis teóricos de uma normal-meio (half-normal, já que só nos importa a magnitude), os efeitos nulos devem cair aproximadamente sobre uma reta que passa pela origem; efeitos reais se afastam dela, tipicamente no canto superior direito do gráfico.

6.2.2 Gráfico de Pareto dos efeitos

Uma alternativa mais direta é ordenar as magnitudes dos efeitos do maior para o menor em um gráfico de barras — o "gráfico de Pareto dos efeitos" — sobrepondo uma linha de referência (a margem de erro de Lenth, descrita a seguir) para separar visualmente o que é "grande demais para ser ruído" do que não é.

6.2.3 Margem de erro pelo método de Lenth

O método de Lenth (1989) fornece uma margem de erro formal sem exigir repetição, usando a **mediana** dos efeitos como uma estimativa robusta de escala (pouco sensível aos próprios efeitos grandes que queremos detectar):

$$s_0 = 1{,}5 \cdot \text{mediana}_i |c_i|, \qquad \text{PSE} = 1{,}5 \cdot \text{mediana}_{\{i:\, |c_i| < 2{,}5 s_0\}} |c_i|,$$

onde c_i percorre os $m = 2^k - 1$ efeitos estimados. O primeiro passo (s_0) dá uma estimativa inicial e grosseira de escala; o segundo passo refina essa estimativa — batizada de **erro-padrão pseudo** (PSE) — usando só os efeitos que já parecem “pequenos” segundo s_0, descartando os candidatos a efeito real. A margem de erro (ME) usa esse PSE como se fosse um erro-padrão comum, com $d = m/3$ graus de liberdade (uma aproximação heurística validada por simulação no artigo original):

$$\text{ME} = t_{0{,}975;\, d} \cdot \text{PSE}.$$

Um efeito é declarado “grande” se $|c_i| > \text{ME}$.

> **Uso do R** — método de Lenth, half-normal e Pareto em uma única repetição do 2^4

```
# Simulando o cenário mais comum: apenas UMA repetição por tratamento
rep_unica <- biodiesel %>%
  distinct(Relacion, Catalizador, Temperatura, Agente, .keep_all = TRUE)

modelo_saturado <- lm(Rendimiento ~ Relacion * Catalizador * Temperatura * Agente,
                      data = rep_unica)
efeitos <- 2 * coef(modelo_saturado)[-1]   # exclui o intercepto
efeitos <- sort(efeitos, decreasing = TRUE)

# --- Método de Lenth ---
s0  <- 1.5 * median(abs(efeitos))
pse <- 1.5 * median(abs(efeitos)[abs(efeitos) < 2.5 * s0])
m   <- length(efeitos)
d   <- m / 3
me  <- qt(0.975, d) * pse

cat("PSE =", round(pse, 3), " | graus de liberdade efetivos =", d,
    " | margem de erro (ME) =", round(me, 3), "\n")
```

```
## PSE = 2.588  | graus de liberdade efetivos = 5  | margem de erro (ME) = 6.651
```

```
efeitos[abs(efeitos) > me]
```

```
## Relacion:Catalizador:Temperatura
##                           8.2875
```

O gráfico de Pareto mostra a mesma informação do half-normal em outra forma: uma única barra ultrapassa a linha tracejada da margem de erro de Lenth. A segunda maior barra (a interação de quarta ordem razão:catalisador:temperatura:agente, $|c| \approx 3{,}0$) já fica a menos da metade da margem de erro ($\text{ME} \approx 6{,}7$) — um contraste nítido que deixa claro, visualmente, por que só um efeito é sinalizado como “grande demais para ser ruído”.

Com uma única repetição, o único efeito que ultrapassa a margem de erro de Lenth é a **interação tripla razão:catalisador:temperatura** — que é, coincidentemente, o efeito de maior magnitude também na análise completa com duas repetições da Seção 6.1 (p. 143). O método acerta o efeito dominante, mas — de forma esperada e didaticamente importante — é conservador demais para sinalizar os outros quatro

dispensar a repetição: ganha-se em economia de corridas, perde-se em poder para detectar efeitos de magnitude intermediária.

Para discutir

1. Por que a mediana, e não o desvio-padrão amostral, é a escolha certa para estimar a escala dos efeitos no método de Lenth? O que aconteceria se um dos poucos efeitos realmente grandes entrasse no cálculo de s_0 sem qualquer proteção?
2. Se um fatorial 2^5 não replicado (31 efeitos) tivesse, por acaso, um único efeito verdadeiramente grande e os outros 30 exatamente nulos, o que você esperaria ver no gráfico de probabilidade normal? E se dois terços dos 31 efeitos fossem moderadamente grandes?

6.3 Confusão em 2^k: designação de tratamentos a blocos

Fatoriais 2^k crescem rápido: um 2^6 já tem 64 tratamentos. Se uma única unidade de bloqueio (um lote de matéria-prima, um turno de operação, um dia) só comporta metade das corridas, o fatorial completo precisa ser dividido em blocos — e queremos que a divisão **não contamine** os efeitos que nos interessam. A técnica de **confusão** (do inglês *confounding*) escolhe deliberadamente um efeito de interação — normalmente de ordem alta, o que consideramos menos provável de ser grande e mais fácil de "sacrificar" — para ficar indistinguível do efeito de bloco.

6.3.1 Esquema de designação: o contraste definidor

Para dividir um 2^k em 2 blocos de 2^{k-1} corridas, escolhemos um efeito — o **contraste definidor** — e calculamos seu sinal (produto dos níveis codificados ± 1 dos fatores envolvidos) para cada tratamento. Tratamentos com sinal $+1$ vão para um bloco; com sinal -1, para o outro.

Uso do R — confundindo ABCD com o bloco no 2^4 do biodiesel (construção didática)

```
# Suponha que as 16 combinações do 2^4 só coubessem em 2 lotes de solvente (bloco),
# de 8 corridas cada, e que quiséssemos "sacrificar" a interação de quarta ordem
        ABCD.
# rep_unica já está na codificação numérica -1/+1 (seção "Ortogonalidade da matriz de
        desenho"), então o
# sinal de ABCD é só o produto direto das quatro colunas.
combinacoes <- rep_unica %>%
  mutate(ABCD = Relacion * Catalizador * Temperatura * Agente,
         bloco = if_else(ABCD > 0, "Bloco 1", "Bloco 2"))

count(combinacoes, bloco)
```

```
## # A tibble: 2 × 2
##   bloco       n
##   <chr>   <int>
## 1 Bloco 1     8
## 2 Bloco 2     8
```

Como o sinal de $ABCD$ é constante *dentro* de cada bloco e varia *entre* blocos, a diferença entre as médias dos dois blocos é algebricamente idêntica à estimativa do efeito $ABCD$ — os dois ficam **totalmente**

confundidos: é impossível, a partir dos dados, separar “efeito do lote de solvente” de “interação de quarta ordem entre os quatro fatores”. Isso é aceitável precisamente porque escolhemos confundir um efeito que, a priori, julgamos pouco provável de ser grande (efeitos de ordem 3 ou 4 raramente dominam, pelo princípio da esparsidade da Seção 6.2 (p. 148)) — mas seria um erro grave confundir um efeito principal ou uma interação dupla dessa forma.

6.3.2 Confusão como colinearidade em $\mathbf{X}$

A Seção 6.1.1 (p. 144) mostrou que a força do 2^k vem de $\mathbf{X}'\mathbf{X}$ ser diagonal — cada efeito, incluindo $ABCD$, ocupa sua própria coluna, ortogonal a todas as outras. Confundir $ABCD$ com o bloco é, em termos exatamente matriciais, **construir a coluna de bloco $\mathbf{x}_{bloco}$ para ser idêntica à coluna $\mathbf{x}_{ABCD}$** (a menos de uma reescala/sinal): ambas separam as mesmas 8 corridas do mesmo lado. O efeito é que, se tentássemos colocar as duas colunas simultaneamente na matriz de desenho, $\mathbf{X}$ deixaria de ter posto coluna completo — exatamente a situação de deficiência de posto do Capítulo 2 (Seção 2.5 (p. 25)) — e $(\mathbf{X}'\mathbf{X})^{-1}$ deixaria de existir.

> **Uso do R** — a colinearidade exata entre bloco e ABCD

```
combinacoes <- combinacoes %>%
  mutate(bloco_num = if_else(bloco == "Bloco 1", 1, -1))

# A coluna de bloco é, literalmente, a coluna ABCD (correlação perfeita)
cor(combinacoes$ABCD, combinacoes$bloco_num)
```

```
## [1] 1
```

```
# Ao incluir as duas no mesmo modelo, R %>% lm() detecta a colinearidade exata
# e descarta uma delas, reportando coeficiente NA:
dados_conf <- rep_unica %>% bind_cols(bloco = factor(combinacoes$bloco))
mod_confundido <- lm(Rendimiento ~ Relacion * Catalizador * Temperatura * Agente +
        bloco,
                     data = dados_conf)
coef(mod_confundido)[c("blocoBloco 2", "Relacion:Catalizador:Temperatura:Agente")]
```

```
##                          blocoBloco 2 Relacion:Catalizador:Temperatura:Agente
##                                3.0375                                     NA
```

O `NA` no coeficiente da interação de quarta ordem não é um erro numérico — é o R relatando, da única forma possível, que **não existe informação nos dados capaz de distinguir** “efeito de bloco” de “interação $ABCD$”: as duas colunas de $\mathbf{X}$ apontam exatamente na mesma direção do espaço-coluna, e $\mathbf{P}_X$ (Seção 2.7 (p. 30)) não consegue projetar separadamente sobre duas direções que coincidem. Esta é a face matricial, concreta, de uma ideia que de outra forma permanece abstrata: **confundir é, literalmente, fazer duas colunas do modelo colidirem**, e a escolha de qual efeito confundir é a escolha de qual coluna estamos dispostos a sacrificar.

6.3.3 Confusão total vs. confusão parcial

O esquema acima é **confusão total**: o mesmo efeito é sacrificado em *todas* as repetições do experimento. Quando há mais de uma repetição (como no biodiesel, com 2 réplicas), uma alternativa melhor é a **confusão parcial**: usar um contraste definidor diferente em cada repetição (por exemplo, $ABCD$ na repetição 1 e ABC na repetição 2). Cada efeito confundido perde informação apenas na repetição em que

foi sacrificado — nas demais, permanece estimável a partir das comparações intra-bloco — de modo que **nenhum efeito é totalmente perdido**, ao custo de uma análise ligeiramente mais elaborada (a informação de cada efeito parcialmente confundido é recuperada combinando as repetições em que ele não foi sacrificado, com peso proporcional à informação disponível). A confusão parcial é preferível sempre que o número de repetições permite, justamente porque nenhuma pergunta de pesquisa fica inteiramente sem resposta.

6.3.4 Visualizando a confusão com um diagrama de Hasse

A Seção 2.2 (p. 17) (Capítulo 2) definiu o diagrama de Hasse pela regra de que os graus de liberdade de todos os termos, somados, esgotam exatamente N — nenhum termo novo pode entrar no diagrama sem "tomar" seus graus de liberdade de algum lugar. É exatamente essa contabilidade rígida que torna a confusão visualmente clara: o desenho de réplica única do 2^4 (`rep_unica`, $N = 16$) é **saturado** — a Seção 6.2 (p. 148) já observou que os $2^4 - 1 = 15$ efeitos mais a média esgotam os 16 graus de liberdade disponíveis, sem sobrar nenhum para um termo de erro. Um diagrama de Hasse desse desenho (agrupando, por clareza visual, os quatro efeitos principais em um só nó, as seis interações duplas em outro, e as quatro triplas em um terceiro — mantendo apenas $ABCD$ em destaque, o termo que a próxima figura vai confundir) tem exatamente esta forma:

> **Uso do R** — Hasse do 2⁴ saturado, sem e com bloco confundido com ABCD

Sem bloco: 2^4 saturado (N=16)

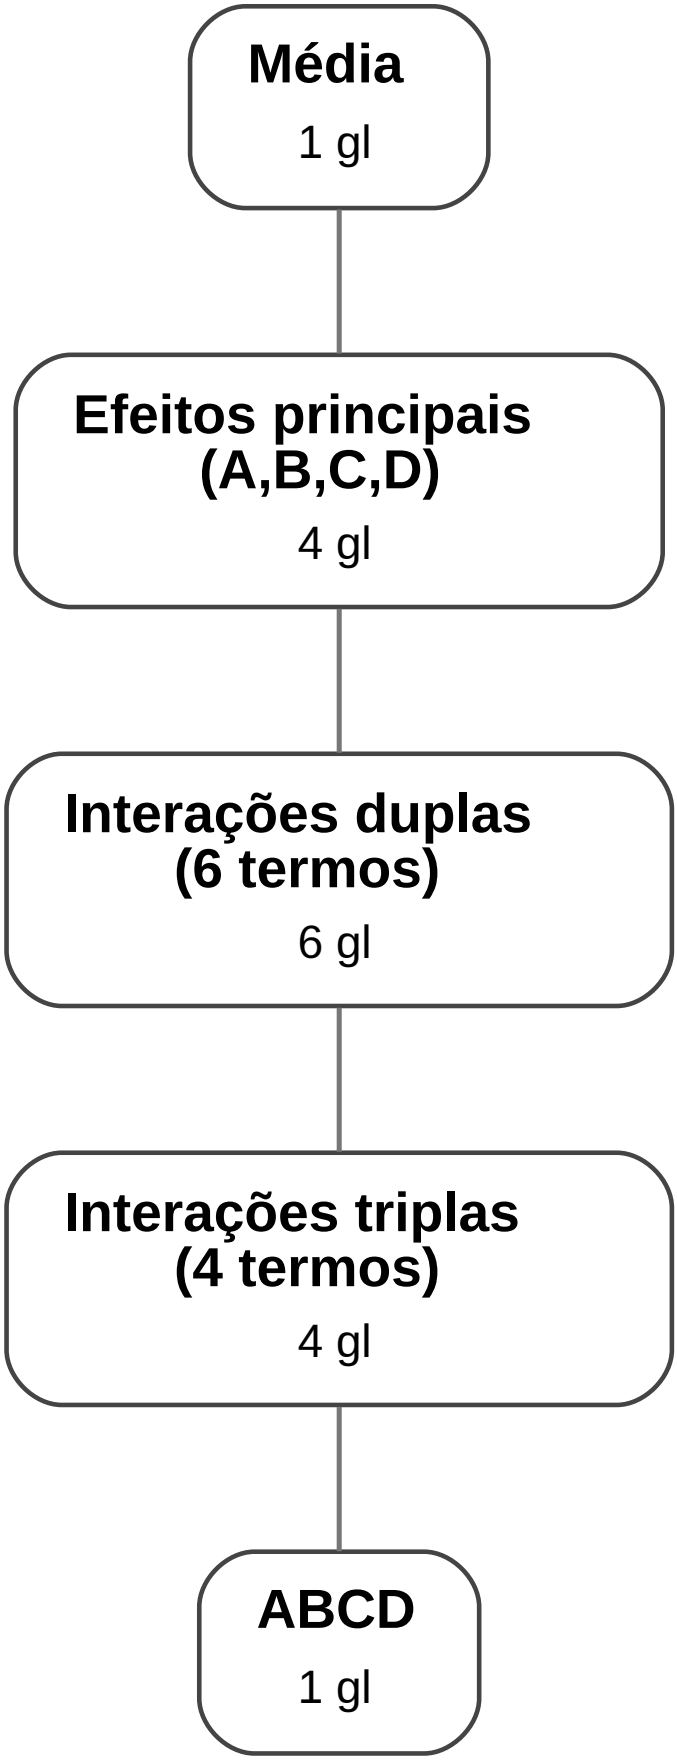


Figura 6.5: Esquerda: diagrama de Hasse do 2^4 de réplica única (N=16), saturado – todos os 16 graus de liberdade já estão ocupados por Média, efeitos principais, duplas, triplas e ABCD, sem sobra para Erro nem para Bloco. Direita: para incluir um termo de Bloco (2 blocos de 8 corridas), a confusão faz Bloco e ABCD ocuparem a mesma posição relativa na estrutura – o mesmo único grau de liberdade, com dois rótulos possíveis, em vez de um grau de liberdade roubado de outro termo.

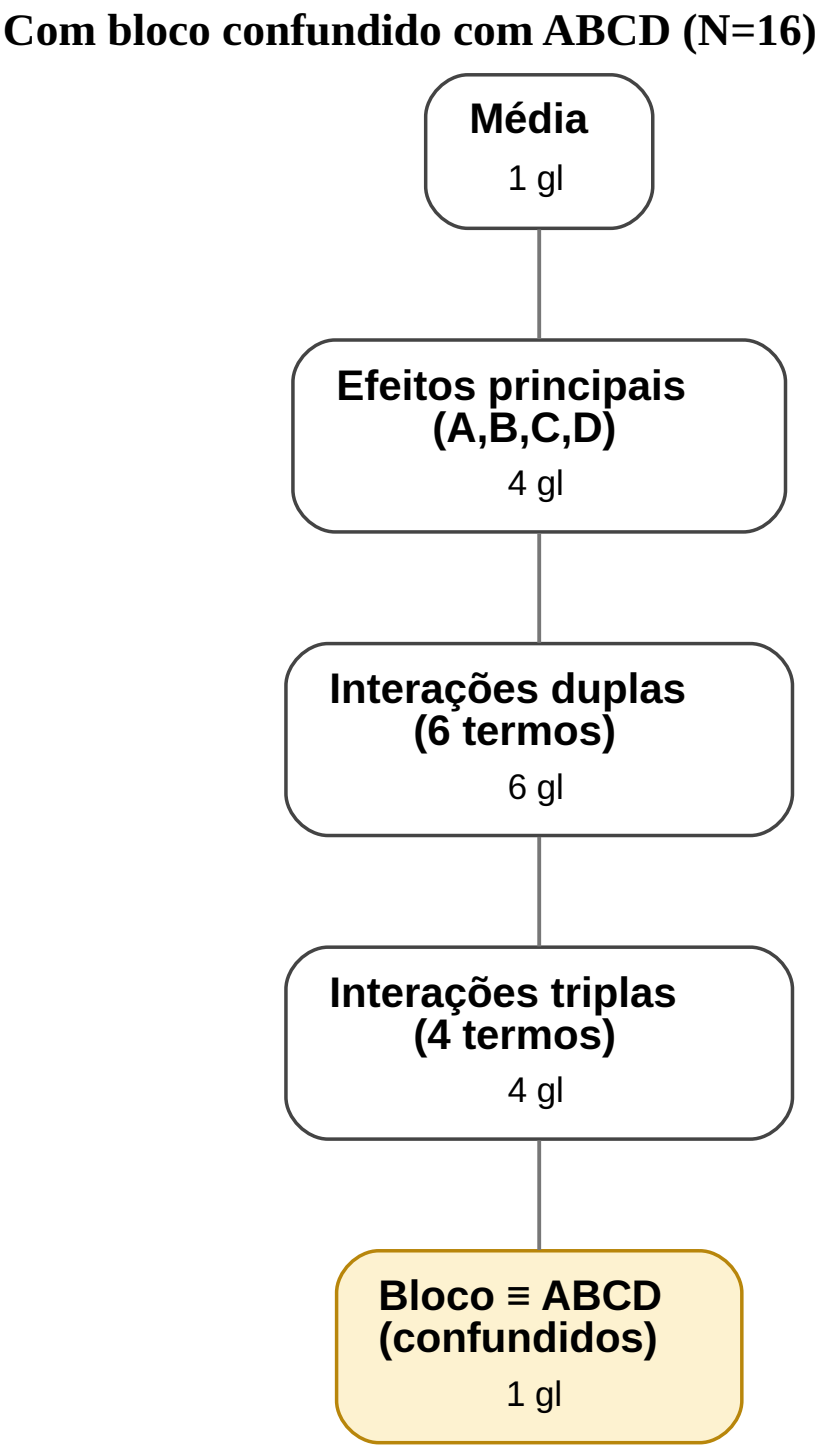


Figura 6.6: Esquerda: diagrama de Hasse do 2^4 de réplica única (N=16), saturado – todos os 16 graus de liberdade já estão ocupados por Média, efeitos principais, duplas, triplas e ABCD, sem sobra para Erro nem para Bloco. Direita: para incluir um termo de Bloco (2 blocos de 8 corridas), a confusão faz Bloco e ABCD ocuparem a mesma posição relativa na estrutura – o mesmo único grau de liberdade, com dois rótulos possíveis, em vez de um grau de liberdade roubado de outro termo.

O painel esquerdo é o retrato do problema: com réplica única, todo grau de liberdade do desenho já tem dono, incluindo o próprio $ABCD$ — não existe espaço “livre” para um termo de Bloco entrar sem que algum outro termo perca graus de liberdade. O painel direito mostra a solução da confusão, e é aqui que o

diagrama de Hasse ganha um significado que a tabela de ANOVA sozinha não deixa tão explícito: **Bloco** e **ABCD** aparecem lado a lado, no mesmo nível, ambos descendo do mesmo nó de interações triplas — não porque sejam dois termos novos de 1 grau de liberdade cada (o que somaria 17, estourando $N = 16$), mas porque são **o mesmo** grau de liberdade, com dois rótulos possíveis para a mesma coluna de $\mathbf{X}$ (exatamente a colinearidade exata demonstrada algebricamente acima, Seção 6.3.2 (p. 151)). Somando o diagrama corretamente — contando o par Bloco/ABCD como um único grau de liberdade compartilhado, não dois —, a contabilidade volta a fechar: $1 + 4 + 6 + 4 + 1 = 16 = N$, a mesma soma do painel sem bloco, só que agora um dos 16 "lugares" tem duas etiquetas em vez de uma. É essa disputa por espaço no diagrama — não uma analogia, mas a mesma regra de contagem de graus de liberdade da Seção 2.2 (p. 17) aplicada literalmente — que explica por que confusão sempre sacrifica *algum* termo: adicionar uma fonte de variação a um desenho saturado nunca é gratuito, e a única escolha real é *qual* termo aceita dividir sua coluna com o novo bloco.

6.4 Fatoriais 3^k: ideia geral e confusão com AB^2

Quando um fator tem três níveis igualmente espaçados (por exemplo, para permitir a estimação de curvatura, não só de tendência linear), o fatorial correspondente é um 3^k: 3^k tratamentos, cada efeito principal com $3 - 1 = 2$ graus de liberdade (que podem, por sua vez, ser decompostos em componentes linear e quadrático — ver polinômios ortogonais, Capítulo 3), e interações com graus de liberdade multiplicativos — por exemplo, $2 \times 2 = 4$ graus de liberdade para uma interação dupla $A \times B$ em um 3^2.

> **Aplicação — Usinagem: velocidade de corte e ângulo em um 3^2**
> Um experimento de usinagem mede a energia de corte consumida em função da **velocidade de corte** (três níveis: 2,3, 3,4 e 4,5 m/s) e do **ângulo de saída da ferramenta** (três níveis: 20°, 40° e 60°) — um 3^2 completo, com quatro repetições por combinação (36 corridas). Retomaremos este mesmo conjunto de dados no capítulo sobre superfície de resposta.

Assim como no 2^k, dividir um 3^k em blocos exige confundir algum efeito com o bloco. A construção decompõe a interação em **componentes ortogonais de dois graus de liberdade cada**, AB e AB^2 (ou, equivalentemente, A^2B), em vez de tratar $A \times B$ como um bloco único: a interação dupla de um 3^2 tem $2 \times 2 = 4$ graus de liberdade, que se repartem exatamente nesses dois componentes ($2 + 2 = 4$). Como o bloco consome $3 - 1 = 2$ graus de liberdade, é preciso escolher *um* componente específico para confundir, e a notação AB^2 indica o contraste $L = i + 2j \pmod 3$, onde i e j são os níveis (codificados $0, 1, 2$) de A e B. Valores de L iguais a 0, 1 e 2 definem três blocos de tamanho 3^{k-1}:

Tabela 6.2: Designação de blocos por AB² em um 3² (ilustração conceitual)

A	B	L	Bloco
0	0	0	Bloco 1
1	1	0	Bloco 1
2	2	0	Bloco 1
0	2	1	Bloco 2
1	0	1	Bloco 2
2	1	1	Bloco 2
0	1	2	Bloco 3
1	2	2	Bloco 3
2	0	2	Bloco 3

A lógica é a mesma do 2^k: o contraste AB^2 (que mistura um componente da interação $A\times B$) fica confundido com o bloco, e o custo é aceitável se julgarmos, a priori, que esse componente específico da interação é o menos relevante para a pergunta de pesquisa. Fatoriais 3^k com $k \geq 3$ seguem a mesma lógica, usando geradores da forma AB^2C, e são discutidos em detalhe por Montgomery (2017) (Cap. 9) e Box et al. (2005).

6.5 Fatoriais fracionados de dois níveis: a ideia geral

Quando k é grande (a partir de aproximadamente $k = 5$ ou 6), mesmo um 2^k completo pode ter mais corridas do que o orçamento do experimento permite — e, pelo princípio da esparsidade dos efeitos, grande parte dessas corridas está sendo "gasta" para estimar interações de ordem alta que provavelmente são desprezíveis. Um **fatorial fracionado** 2^{k-p} roda apenas uma fração $1/2^p$ do fatorial completo, escolhida deliberadamente por meio de p **relações geradoras** — a ideia, introduzida por Finney (1945) para desenhos agrícolas com muitos fatores, tornou-se décadas depois o pilar das aplicações industriais de controle de qualidade associadas aos **arranjos ortogonais de Taguchi** (Taguchi, 1986), que nada mais são, em essência, do que fatoriais fracionados (ou fatoriais 3^{k-p} e desenhos mistos) escolhidos para robustez do processo a fontes de ruído não controláveis.

A ideia central é a mesma da confusão: ao usar só uma fração das corridas, alguns efeitos deixam de ser estimáveis separadamente — ficam **aliasados** (confundidos) uns com os outros. A diferença é que, na confusão, sacrificamos a distinção entre um efeito e o *bloco*; no fracionamento, sacrificamos a distinção entre **dois efeitos de tratamento**. A **relação definidora** ($I =$ produto de letras) determina exatamente quais efeitos ficam aliasados a quais — por exemplo, com geradora $D = ABC$ (equivalente a $I = ABCD$) em um 2^{4-1} de 8 corridas, o efeito principal A fica aliasado com a interação tripla BCD: o que estimamos como "A" é, na verdade, a soma $A + BCD$, indistinguível a partir dos dados.

A **resolução** de um fracionado resume a "qualidade" desse aliasamento:

- **Resolução III**: efeitos principais aliasados com interações duplas.
- **Resolução IV**: efeitos principais limpos de interações duplas (aliasados só com triplas ou mais); mas interações duplas aliasadas entre si.
- **Resolução V**: efeitos principais e interações duplas todos limpos entre si; aliasamento só aparece em interações de ordem 3 ou mais.

Quanto maior a resolução, mais informação útil o fracionado preserva — ao custo de exigir mais corridas (isto é, uma fração *maior*: $1/2$ exige mais corridas que $1/4$, que exige mais que $1/8$) para o mesmo k. Na prática, escolher a fração certa é uma decisão de compromisso entre orçamento experimental e quais interações o pesquisador está disposto a assumir, a priori, como desprezíveis — a mesma lógica de custo-benefício da confusão, aplicada aos próprios efeitos de tratamento em vez de ao bloco. O leitor interessado em construir geradores para k maiores e tabelas de resolução encontra o tratamento completo em Montgomery (2017) (Cap. 8) e Box et al. (2005) (Cap. 6).

6.6 Rumo à otimização: superfície de resposta

Tudo até aqui respondeu “quais fatores importam, e há interação?”. O Capítulo 7 muda a pergunta para “qual combinação de níveis **otimiza** a resposta?” — a metodologia de superfície de resposta, que estende os fatoriais 2^k deste capítulo com um modelo polinomial de segunda ordem capaz de representar curvatura e localizar um ótimo.

6.7 Resumo do capítulo

- Fatoriais 2^k estimam todos os efeitos com o menor número de corridas possível; cada efeito tem 1 grau de liberdade, e sua magnitude é o dobro do coeficiente de regressão correspondente.
- Sem repetição, o princípio da esparsidade dos efeitos permite separar sinal de ruído por meios gráficos (half-normal, Pareto) e formais (margem de erro de Lenth), ainda que com menos poder do que uma análise replicada.
- Confusão sacrifica deliberadamente um efeito de interação (idealmente de ordem alta) para viabilizar blocos menores; confusão parcial, usando geradores diferentes por repetição, evita perder qualquer efeito por completo.
- 3^k generaliza a lógica de 2^k para fatores de três níveis, com confusão via contrastes de grau único como AB^2; fracionados 2^{k-p} generalizam a lógica de confusão para os próprios efeitos de tratamento, classificados por resolução (III, IV, V) segundo a “qualidade” do aliasamento resultante.
- O Capítulo 7 retoma esses mesmos fatoriais para responder a uma pergunta diferente: não “o que importa?”, mas “qual é o ótimo?”.

7 Metodologia de superfície de resposta

Os Capítulos 5 e 6 trataram fatoriais desenhados para **detectar e estimar efeitos** — a pergunta era “quais fatores importam, e há interação?”. Este capítulo muda a pergunta para “qual combinação de níveis **otimiza** a resposta?” — a metodologia de superfície de resposta (MSR), um dos usos mais comuns de delineamento de experimentos na indústria e na ciência de dados hoje em dia (ajuste de hiperparâmetros, otimização de processos químicos e de manufatura, desenho de produtos).

7.1 Introdução à superfície de resposta

Fatoriais 2^k e 3^k são desenhados para **detectar e estimar efeitos** — a pergunta é “quais fatores importam, e há interação?”. A **metodologia de superfície de resposta** (MSR), formalizada por Box e Wilson (1951) como uma sequência de fatoriais e desenhos aumentados que “escala” a superfície na direção de maior melhoria (Box et al., 2005; Montgomery, 2017), muda a pergunta para “qual combinação de níveis **otimiza** a resposta?”, tipicamente ajustando um modelo polinomial de segunda ordem que permite representar curvatura:

$$y = \beta_0 + \sum_{i=1}^{k} \beta_i x_i + \sum_{i=1}^{k} \beta_{ii} x_i^2 + \sum_{i<j} \beta_{ij} x_i x_j + \varepsilon.$$

Os termos quadráticos β_{ii} são o que distingue este modelo do fatorial 2^k (que só estima efeitos lineares e de interação): eles permitem capturar um máximo, mínimo ou ponto de sela dentro da região experimental, em vez de apenas uma tendência linear.

> **Uso do R** — ajustando e visualizando a superfície de resposta da energia de corte

```
energia <- read_csv("data/energia.csv", show_col_types = FALSE)

modelo_rsm <- lm(
  energia ~ Velocidad + angulo + I(Velocidad^2) + I(angulo^2) + Velocidad:angulo,
  data = energia
)
summary(modelo_rsm)$coefficients %>%
  round(4) %>%
  kable(caption = "Modelo de segunda ordem para energia de corte") %>%
  kable_styling(full_width = FALSE)
```

Tabela 7.1: Modelo de segunda ordem para energia de corte

	Estimate	Std. Error	t value	Pr(>|t|)
(Intercept)	0.0768	0.0479	1.6035	0.1193
Velocidad	0.0448	0.0260	1.7261	0.0946
angulo	-0.0041	0.0010	-3.9442	0.0004
I(Velocidad^2)	-0.0055	0.0037	-1.4864	0.1476
I(angulo^2)	0.0000	0.0000	3.6139	0.0011
Velocidad:angulo	-0.0002	0.0001	-1.0642	0.2957

O termo quadrático de $\hat{\beta}_{\text{ângulo}^2}$ é altamente significativo ($p < 0{,}01$), e o R^2 ajustado do modelo (0.773) confirma que a superfície de segunda ordem descreve bem os dados — evidência de curvatura real, que um fatorial 2^k nesses mesmos dois fatores nunca teria detectado, porque um desenho de apenas dois níveis por fator é algebricamente cego a termos quadráticos.

A perspectiva 3D e o gráfico de contorno são duas janelas para o mesmo objeto matemático: a primeira dá intuição sobre a forma geral da superfície (aqui, a energia sobe em algumas direções e desce em outras — um sinal visual de que a curvatura não é simplesmente "uma tigela"); a segunda é mais útil para leitura precisa, e para localizar exatamente onde a superfície para de subir ou descer.

7.1.1 Classificando o ponto estacionário: gradiente e Hessiana

Derivando o modelo de segunda ordem em relação a cada regressor e igualando a zero, o **ponto estacionário** $\mathbf{x}_0$ resolve o sistema linear

$$\nabla y(\mathbf{x}_0) = \mathbf{b} + 2\mathbf{B}\mathbf{x}_0 = \mathbf{0} \quad \Longrightarrow \quad \mathbf{x}_0 = -\tfrac{1}{2}\mathbf{B}^{-1}\mathbf{b},$$

em que $\mathbf{b} = (\hat{\beta}_{\text{Velocidad}}, \hat{\beta}_{\text{ângulo}})'$ é o vetor de coeficientes lineares e $\mathbf{B}$ é a matriz **simétrica dos coeficientes de segunda ordem** (quadráticos na diagonal, de interação fora dela),

$$\mathbf{B} = \begin{pmatrix} \hat{\beta}_{\text{Velocidad}^2} & \hat{\beta}_{\text{Velocidad·ângulo}}/2 \\ \hat{\beta}_{\text{Velocidad·ângulo}}/2 & \hat{\beta}_{\text{ângulo}^2} \end{pmatrix}.$$

Note que $\mathbf{B}$ **não** é a Hessiana: do gradiente $\nabla\hat{y} = \mathbf{b} + 2\mathbf{B}\mathbf{x}$ segue $\nabla^2\hat{y} = 2\mathbf{B}$. As duas matrizes têm os mesmos sinais de autovalores — por isso a classificação do ponto estacionário é a mesma —, mas são os autovalores de $\mathbf{B}$, e não os da Hessiana, que aparecem como as **taxas** λ_i da forma canônica adiante.

A **natureza** do ponto estacionário — máximo, mínimo ou sela — é decidida pelos autovalores de $\mathbf{B}$: ambos negativos indicam máximo, ambos positivos indicam mínimo, e **sinais opostos indicam ponto de sela** (a superfície sobe em uma direção do espaço dos regressores e desce em outra, exatamente o padrão sugerido pelo gráfico anterior).

```
b_rsm <- coef(modelo_rsm)
B_hess <- matrix(
  c(2 * b_rsm["I(Velocidad^2)"],     b_rsm["Velocidad:angulo"],
    b_rsm["Velocidad:angulo"],       2 * b_rsm["I(angulo^2)"]),
  nrow = 2
) / 2   # B tem beta_ii na diagonal e beta_ij/2 fora: o 2*.../2 da diagonal devolve
    # o proprio beta_ii, e o termo de interacao fica dividido por 2

ponto_estacionario <- -0.5 * solve(B_hess) %*% c(b_rsm["Velocidad"], b_rsm["angulo"])
rownames(ponto_estacionario) <- c("Velocidade", "Ângulo")
ponto_estacionario
```

```
##                 [,1]
## Velocidade  3.282264
## Ângulo     56.358108
```

```
eigen(B_hess)$values   # sinais dos autovalores classificam o ponto
```

```
## [1]  4.158071e-05 -5.510702e-03
```

Os dois autovalores têm **sinais opostos** — o ponto estacionário ($V \approx 3{,}28$, ângulo$\approx 56{,}4^\circ$) é uma **sela**, não um mínimo nem um máximo. Isso significa que, dentro da região experimental, o menor valor de energia predito não está nesse ponto interior, mas em algum ponto da **fronteira** da região — a varredura da grade confirma que o mínimo prático fica no canto $V = 4{,}5$, ângulo$\approx 59{,}0^\circ$ (energia $\approx 0{,}027$). Esse é exatamente o tipo de situação em que o gráfico de contorno é indispensável: sem ele, seria fácil confundir "a superfície tem curvatura" com "a superfície tem um ótimo interior", quando na verdade tem as duas coisas ao mesmo tempo, mas não no mesmo ponto.

7.1.2 Análise canônica: além de classificar, descrever a forma da superfície

A classificação do ponto estacionário acima (máximo, mínimo ou sela) usa só os **sinais** dos autovalores de $\mathbf{B}$. A **análise canônica** usa os autovalores *e* autovetores completos para reescrever o modelo ajustado numa base em que a curvatura fica diagonal — revelando não só *que tipo* de ponto estacionário existe, mas *quão rápido* a resposta muda em cada direção principal da superfície. Partindo do modelo centrado no ponto estacionário $\mathbf{x}_0$, $\hat{y} - \hat{y}_0 = (\mathbf{x} - \mathbf{x}_0)'\mathbf{B}(\mathbf{x} - \mathbf{x}_0)$, e da decomposição espectral $\mathbf{B} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}'$ ($\mathbf{V}$ ortogonal, colunas = autovetores; $\mathbf{\Lambda} = \text{diag}(\lambda_1, \lambda_2)$), a mudança de variável $\mathbf{w} = \mathbf{V}'(\mathbf{x} - \mathbf{x}_0)$ (uma rotação de eixos, não uma translação arbitrária) elimina o termo cruzado:

$$\hat{y} = \hat{y}_0 + \lambda_1 w_1^2 + \lambda_2 w_2^2.$$

> **Uso do R** — forma canônica da superfície da energia de corte

```
decomp <- eigen(B_hess)
V_rot <- decomp$vectors
lambda_canonico <- decomp$values

y0_chapeu <- predict(modelo_rsm, newdata = as.data.frame(t(ponto_estacionario)) %>%
                       setNames(c("Velocidad", "angulo")))

list(y0 = unname(y0_chapeu), lambda = lambda_canonico, eixos_w = V_rot)
```

```
## $y0
## [1] 0.03579915
##
## $lambda
## [1]  4.158071e-05 -5.510702e-03
##
## $eixos_w
##             [,1]        [,2]
## [1,]  0.01381628 -0.99990455
## [2,] -0.99990455 -0.01381628
```

Os eixos canônicos w_1, w_2 são combinações lineares (rotacionadas) de velocidade e ângulo — não correspondem a nenhum dos dois fatores originais isoladamente. O sinal oposto de $\lambda_1 \approx 4.16$^{-5} e $\lambda_2 \approx$ -0.00551 é a mesma informação da Seção 7.1.1 (p. 160) (sela), mas agora quantificada. A leitura dos sinais é direta: ao longo de w_i a superfície **sobe** se $\lambda_i > 0$ e **desce** se $\lambda_i < 0$, a uma taxa dada por $|\lambda_i|$. Aqui $\lambda_1 > 0$ e $\lambda_2 < 0$: a superfície sobe ao longo de w_1 e cai ao longo de w_2.

O que a análise canônica acrescenta à simples classificação do ponto estacionário é a **escala relativa** das duas curvaturas. Como $|\lambda_2|/|\lambda_1| \approx 133$, a sela é fortemente **alongada**: ao longo de w_1 a superfície é quase

plana, enquanto ao longo de w_2 ela muda duas ordens de grandeza mais rápido. É w_2 — a direção de **maior** $|\lambda|$ — que domina o comportamento local da resposta, e é nela que vale a pena mover o processo. Uma crista quase plana como a de w_1 é, na prática, uma faixa de combinações velocidade/ângulo praticamente equivalentes em energia: liberdade para otimizar *outro* critério (custo, desgaste de ferramenta) sem perda mensurável nesta resposta (Myers et al., 2016).

7.1.3 Análise de ridge: otimizando dentro de um raio fixo da região experimental

Dois problemas distintos tornam o ponto estacionário um alvo insuficiente. O primeiro é ele cair **fora** da região onde os dados foram coletados: aí segui-lo é extrapolar, e o modelo de segunda ordem só é confiável *dentro* da nuvem de pontos observados. O segundo — o caso **deste** exemplo, em que $\mathbf{x}_0 = (3.28\ \text{m/s};\ 56.4^\circ)$ está confortavelmente dentro dos dados — é o ponto estacionário ser uma **sela**: ele não é nem máximo nem mínimo, de modo que "ir até $\mathbf{x}_0$" simplesmente não responde à pergunta de otimização.

A **análise de ridge** (Myers et al., 2016) contorna os dois casos com uma pergunta mais modesta: para cada raio fixo ρ (distância ao centro do desenho), qual é o melhor ponto sobre o círculo (ou esfera, em mais dimensões) de raio ρ? Isso é otimização restrita — otimizar $\hat{y}(\mathbf{x})$ sujeito a $\mathbf{x}'\mathbf{x} = \rho^2$ —, cuja condição de estacionariedade de Lagrange é

$$\mathbf{b} + 2\mathbf{B}\mathbf{x} = 2\mu\,\mathbf{x} \quad \Longleftrightarrow \quad \mathbf{x}(\mu) = \tfrac{1}{2}(\mu\mathbf{I} - \mathbf{B})^{-1}\mathbf{b},$$

em que o multiplicador de Lagrange μ é ajustado até que $\|\mathbf{x}(\mu)\| = \rho$.

A condição de estacionariedade sozinha **não basta**: para um mesmo ρ ela admite várias raízes μ, e cada uma corresponde a um ponto crítico diferente sobre o círculo. A escolha do ramo é o que decide qual delas é a resposta procurada (Draper, 1963; Myers et al., 2016):

$$\mu > \lambda_{\max}(\mathbf{B}) \ \Rightarrow\ \textbf{máximo restrito}, \qquad \mu < \lambda_{\min}(\mathbf{B}) \ \Rightarrow\ \textbf{mínimo restrito},$$

e dentro de cada ramo $\|\mathbf{x}(\mu)\|$ é monótona em μ, o que torna o ajuste de μ a um ρ desejado um problema unidimensional bem posto. Fora desses dois ramos obtêm-se pontos de sela da função restrita — críticos, mas nem máximo nem mínimo. Varrendo ρ de 0 até a borda da região experimental, obtém-se o **caminho de ridge**: a sequência de pontos ótimos-restritos, um para cada raio.

Velocidade e ângulo estão em escalas e unidades muito diferentes ($2{,}3$–$4{,}5\ \text{m/s}$ contra 20°–60°) — um "raio" euclidiano só faz sentido depois de **codificar** as duas variáveis para uma escala comum, a mesma convenção de ± 1 já usada em todo o livro para fatoriais.

```
c_vel <- mean(range(energia$Velocidad)); s_vel <- diff(range(energia$Velocidad)) / 2
c_ang <- mean(range(energia$angulo));    s_ang <- diff(range(energia$angulo)) / 2

energia_cod <- energia %>%
  mutate(z1 = (Velocidad - c_vel) / s_vel, z2 = (angulo - c_ang) / s_ang)

modelo_rsm_cod <- lm(energia ~ z1 + z2 + I(z1^2) + I(z2^2) + z1:z2, data =
        energia_cod)
b_cod <- coef(modelo_rsm_cod)[c("z1", "z2")]
B_cod <- matrix(
  c(2 * coef(modelo_rsm_cod)["I(z1^2)"], coef(modelo_rsm_cod)["z1:z2"],
    coef(modelo_rsm_cod)["z1:z2"],       2 * coef(modelo_rsm_cod)["I(z2^2)"]),
  nrow = 2
```

```
) / 2     y0_cod <- coef(modelo_rsm_cod)["(Intercept)"]
```

```
# Ate onde o raio pode ir sem extrapolar? A regiao experimental e a CAIXA
# [-1,1]^2 (grade 3x3 em unidades codificadas). O circulo de raio rho so fica
# inteiramente dentro da caixa ate rho = 1 (circulo INSCRITO); a partir dai ele
# escapa pelos lados, tocando o desenho apenas nos quatro vertices, que estao a
# raio sqrt(2). Paramos em 1: e o maior raio para o qual NENHUMA direcao theta
# leva para fora dos dados.
raio_max <- 1
raios <- seq(0.2, raio_max, by = 0.1)

y_no_circulo <- function(theta, rho) {
  z_theta <- rho * c(cos(theta), sin(theta))
  as.numeric(y0_cod) + as.numeric(t(z_theta) %*% b_cod) + as.numeric(t(z_theta) %*%
        B_cod %*% z_theta)
}

caminho_ridge <- map_dfr(raios, function(rho) {
  # y_no_circulo(theta) tem em geral DOIS mínimos e DOIS máximos em [0,2pi) (forma
        quadrática
  # indefinida sobre um círculo) -- optimize() assume unimodalidade e pode convergir
        para um
  # mínimo local errado; uma busca em grade fina, seguida de refinamento local, é
        mais confiável.
  grade_theta <- seq(0, 2 * pi, length.out = 721)[-721]
  th0 <- grade_theta[which.min(sapply(grade_theta, y_no_circulo, rho = rho))]
  opt <- optimize(function(th) y_no_circulo(th, rho),
                  interval = c(th0 - 2 * pi / 360, th0 + 2 * pi / 360), maximum =
        FALSE)
  z_theta <- rho * c(cos(opt$minimum), sin(opt$minimum))
  tibble(raio = rho, Velocidad = c_vel + s_vel * z_theta[1], angulo = c_ang + s_ang *
        z_theta[2],
         y_predito = opt$objective)
})

# Fronteira da regiao experimental, para deixar visivel que o caminho fica dentro
        dela.
fronteira <- tibble(theta = seq(0, 2 * pi, length.out = 361)) %>%
  mutate(Velocidade = c_vel + s_vel * raio_max * cos(theta),
         `Ângulo`   = c_ang + s_ang * raio_max * sin(theta))

caminho_ridge %>%
  rename(Velocidade = Velocidad, `Ângulo` = angulo) %>%
  ggplot(aes(Velocidade, `Ângulo`)) +
  geom_path(data = fronteira, linetype = "dashed", color = "grey55") +
  geom_path(aes(color = y_predito), linewidth = 1) +
  geom_point(aes(color = y_predito), size = 2) +
  scale_color_viridis_c(name = "Energia\npredita") +
  labs(title = "Caminho de ridge: melhor ponto para cada\nraio ao centro do desenho",
       subtitle = paste0("Tracejado: maior circulo inteiramente contido na
        regiao\nexperimental ",
                         "(raio codificado ", round(raio_max, 2), "). O caminho nao o
        ultrapassa."),
       x = "Velocidade de corte (m/s)", y = "Ângulo de saída (graus)") +
  theme_minimal(base_size = 12)
```

O caminho de ridge sai do centro do desenho e se afasta em direção à combinação de velocidade/ângulo que **minimiza** a energia predita a cada raio — aqui o objetivo é minimizar, porque energia de corte é custo; o problema de máximo é o mesmo com o sinal trocado, e corresponde ao ramo $\mu > \lambda_{\max}(\mathbf{B})$ da condição de Lagrange. O raio só é bem definido porque as duas variáveis foram trazidas à mesma escala.

Duas observações sobre o que a figura mostra. Primeira: o caminho **para no círculo tracejado**. Vale explicitar por que o limite é $\rho = 1$ e não $\rho = \sqrt{2}$. A região experimental aqui é a *caixa* $[-1, 1]^2$ — uma grade 3×3 —, enquanto o caminho de ridge percorre *círculos*. O maior círculo inteiramente contido na caixa é o **inscrito**, de raio 1; o círculo de raio $\sqrt{2} \approx 1{,}41$ toca o desenho apenas nos quatro vértices e, em todas as demais direções, já está fora dos dados. Como a direção ótima θ é escolhida pelo próprio procedimento, e não por nós, só $\rho \leq 1$ garante que *nenhuma* direção escolhida seja extrapolação — que é a disciplina que esta seção prega e precisa praticar. (Em desenhos cuja região é esférica por construção, como o CCD rotacionável da próxima seção, essa distinção desaparece: lá a região *é* um círculo, e o raio axial α é o limite natural.) Segunda: em vez de relatar apenas "o mínimo fica na fronteira", como fizemos antes, o caminho mostra *toda a trajetória* de pontos ótimos-restritos, permitindo ao engenheiro escolher conscientemente um raio que equilibre ganho na resposta e proximidade da região onde o modelo foi de fato estimado — quanto maior o raio, maior o ganho predito e maior a incerteza sobre ele.

7.2 O caminho de máxima inclinação: de um fatorial inicial até a região do ótimo

A energia de corte partiu de um modelo de segunda ordem já ajustado — mas, na prática, raramente se começa perto do ótimo. A estratégia sequencial clássica da MSR (Box & Hunter, 1957; Box & Wilson, 1951) tem duas fases: (1) longe do ótimo, um modelo de **primeira ordem** (fatorial 2^k, sem termos quadráticos) é suficiente para apontar uma *direção* de melhoria — o **caminho de máxima inclinação** (*steepest ascent*); (2) perto do ótimo, a curvatura passa a importar, e um desenho de segunda ordem (como o CCD da próxima seção) é necessário.

> **Aplicação — Engenharia de alimentos: secagem de fatias de fruta**
> Uma planta de desidratação de frutas quer encontrar a combinação de **temperatura** (30–70 °C) e **tempo de secagem** (2–8 h) que maximiza a retenção de vitamina C. Um fatorial 2^2 inicial, rodado numa região exploratória de baixa temperatura/tempo curto (onde a equipe suspeitava, sem certeza, que a retenção seria baixa), estima um modelo de primeira ordem.

```
set.seed(2026)
codif_para_natural <- function(x1, x2) tibble(temperatura = 45 + 10 * x1, tempo = 4 +
        1.5 * x2)

fatorial_inicial <- expand_grid(x1 = c(-1, 1), x2 = c(-1, 1), rep = 1:3) %>%
  bind_cols(codif_para_natural(.$x1, .$x2)) %>%
  mutate(retencao = 55 + 4 * x1 + 6 * x2 - 1.5 * x1 * x2 + rnorm(n(), 0, 1.5))

modelo_1a_ordem <- lm(retencao ~ x1 + x2, data = fatorial_inicial)
coef(modelo_1a_ordem)
```

```
## (Intercept)          x1          x2
##   54.132313    4.054148    5.647708
```

O gradiente estimado $(\hat{\beta}_{x_1}, \hat{\beta}_{x_2})$ aponta a direção de subida mais rápida em **unidades codificadas**; convertendo para as unidades naturais originais (multiplicando cada componente pela meia-amplitude codificada de cada fator, 10 °C e 1,5 h) dá o **passo** a cada movimento ao longo do caminho:

```
grad_codificado <- coef(modelo_1a_ordem)[c("x1", "x2")]
passo_unitario <- grad_codificado / sqrt(sum(grad_codificado^2))  # direção unitária
```

```
        caminho_subida <- tibble(passo = 0:6) %>%  mutate(
    x1 = passo * passo_unitario["x1"],    x2 = passo * passo_unitario["x2"],
    temperatura = 45 + 10 * x1,    tempo       = 4 + 1.5 * x2,
    # retencao "verdadeira" simulada ao longo do caminho, com um maximo por volta de
        x1=2.5,x2=3.2
    # -- ruido pequeno (sd=0.3) para que o pico fique visível apesar de uma única
        corrida por passo
    retencao_verdadeira = 75 - 3 * (x1 - 2.5)^2 - 2.5 * (x2 - 3.2)^2 + rnorm(n(), 0,
        0.3)
  )
caminho_subida %>% select(passo, temperatura, tempo, retencao_verdadeira) %>%
  kable(digits = 1, caption = "Caminho de máxima inclinação: um novo experimento a
        cada passo") %>%
  kable_styling(full_width = FALSE)
```

Tabela 7.2: Caminho de máxima inclinação: um novo experimento a cada passo

passo	temperatura	tempo	retencao_verdadeira
0	45.0	4.0	30.6
1	50.8	5.2	49.7
2	56.7	6.4	62.7
3	62.5	7.7	72.3
4	68.3	8.9	75.1
5	74.2	10.1	72.7
6	80.0	11.3	64.8

Cada passo ao longo do caminho é uma **corrida experimental real** (não uma predição): a equipe segue na direção do gradiente até que a resposta pare de melhorar. O painel da direita deixa isso inequívoco — a retenção sobe até o passo 4 e cai nos passos 5–6 — enquanto o painel da esquerda mostra que essa mesma informação é quase imperceptível só pela cor ao longo do caminho espacial, porque a escala de cor é dominada pela subida grande dos primeiros passos. É esse declínio, visível no painel da direita, que sinaliza que a região passou por perto do ótimo e que a curvatura, ignorada pelo modelo de primeira ordem, começou a importar. É exatamente esse o sinal para trocar de estratégia: parar de subir e desenhar um experimento de segunda ordem — tipicamente um CCD — centrado na vizinhança onde o caminho parou de melhorar.

7.3 Delineamento composto central (CCD)

Um fatorial 2^k sozinho não estima termos quadráticos β_{ii} (só tem dois níveis por fator). O **delineamento composto central** (Box & Hunter, 1957; Box & Wilson, 1951) aumenta um fatorial 2^k com dois tipos de corrida extra, mantendo a estrutura fatorial como núcleo:

- 2^k pontos **fatoriais** (nível ± 1 em todos os fatores) — estimam efeitos principais e interações, como antes;
- $2k$ pontos **axiais** (**"em estrela"**): cada um varia **um único** fator para $\pm\alpha$, com os demais fixos em 0 — são esses pontos que tornam os termos quadráticos β_{ii} estimáveis;
- n_c pontos **centrais** ($\mathbf{x} = \mathbf{0}$, repetidos n_c vezes) — estimam o erro puro e checam curvatura pura antes mesmo de ajustar o modelo completo.

> **Uso do R** — construindo um CCD rotacionável para a secagem de fruta

```
k_ccd <- 2
alpha_rot <- (2^k_ccd)^(1/4)   # alpha que torna o desenho rotacionavel (Var(y-
        chapeu) so depende do raio)
nc <- 5                         # pontos centrais (regra pratica: 4-6 para k=2)

ccd_codificado <- bind_rows(
  expand_grid(x1 = c(-1, 1), x2 = c(-1, 1)) %>% mutate(tipo = "fatorial"),
  tibble(x1 = c(-alpha_rot, alpha_rot, 0, 0), x2 = c(0, 0, -alpha_rot, alpha_rot),
         tipo = "axial"),
  tibble(x1 = rep(0, nc), x2 = rep(0, nc), tipo = "central")
)
nrow(ccd_codificado)   # N = 4 + 4 + 5 = 13 corridas
```

```
## [1] 13
```

A **rotabilidade** — a propriedade de que $\mathrm{Var}(\hat{y}(\mathbf{x}))$ depende só da distância $\|\mathbf{x}\|$ ao centro, não da direção — é obtida escolhendo $\alpha = (2^k)^{1/4}$ (para $k = 2$, $\alpha = 1.414$); um desenho rotacionável garante que a precisão da predição não privilegia nenhuma direção do espaço de fatores, desejável quando não se sabe de antemão em que direção o ótimo vai estar.

```
set.seed(2026)
ccd_dados <- ccd_codificado %>%
  mutate(
    temperatura = 65 + 10 * x1,   # CCD centrado onde o caminho de subida parou de
        melhorar
    tempo       = 6 + 1.5 * x2,
    retencao = 78 - 3 * x1^2 - 2.5 * x2^2 + 0.8 * x1 - 0.5 * x2 - 1.2 * x1 * x2 +
        rnorm(n(), 0, 1),
    atividade_agua = 0.42 + 0.03 * x1 + 0.025 * x2 + 0.015 * x1^2 + 0.01 * x2^2 -
      0.008 * x1 * x2 + rnorm(n(), 0, 0.01)
  )

ggplot(ccd_dados, aes(x1, x2, color = tipo)) +
  geom_point(size = 3) +
  coord_equal() +
  labs(title = "Estrutura do CCD: núcleo fatorial + pontos axiais + centrais",
       x = expression(x[1]~"(temperatura codificada)"), y = expression(x[2]~"(tempo
        codificado)")) +
  theme_minimal(base_size = 12)
```

O gráfico mostra a assinatura geométrica de um CCD: um quadrado (núcleo fatorial), quatro pontos sobre os eixos além do quadrado (axiais, a distância $\alpha > 1$ do centro) e uma pilha de pontos na origem (centrais) — nenhum desses três grupos, sozinho, estimaria a superfície completa de segunda ordem; juntos, com $N = 13$ corridas, estimam os 6 parâmetros do modelo ($\beta_0, \beta_1, \beta_2, \beta_{11}, \beta_{22}, \beta_{12}$) com graus de liberdade sobrando para estimar o erro puro a partir só dos pontos centrais.

7.4 Otimização de múltiplas respostas: funções de desejabilidade

A planta de secagem tem duas respostas em jogo — **retenção de vitamina C** (maximizar) e **atividade de água residual** (minimizar, por segurança microbiológica) — e o ponto que maximiza uma pode não ser o que minimiza a outra. A abordagem de **desejabilidade** (Derringer & Suich, 1980) converte cada resposta $\hat{y}_j(\mathbf{x})$ numa escala comum $d_j(\mathbf{x}) \in [0, 1]$ (0 = inaceitável, 1 = ideal) e combina as m desejabilidades

individuais pela **média geométrica**,

$$D(\mathbf{x}) = \Big(\prod_{j=1}^{m} d_j(\mathbf{x}) \Big)^{1/m},$$

de modo que $D = 0$ se **qualquer** resposta for inaceitável (a média geométrica penaliza um único $d_j = 0$ derrubando o produto inteiro — uma média aritmética não teria essa propriedade). Para uma resposta a **maximizar** entre um mínimo aceitável L e um alvo T, $d_j = \big[(\hat{y}_j - L)/(T - L)\big]^{s}$ (truncado em $[0, 1]$); para **minimizar** entre um alvo T e um máximo aceitável U, $d_j = \big[(U - \hat{y}_j)/(U - T)\big]^{s}$; o expoente s controla quão rígida é a aproximação à meta ($s = 1$: linear).

```
modelo_retencao <- lm(retencao ~ x1 + x2 + I(x1^2) + I(x2^2) + x1:x2, data =
        ccd_dados)
modelo_atividade <- lm(atividade_agua ~ x1 + x2 + I(x1^2) + I(x2^2) + x1:x2, data =
        ccd_dados)
```

```
desej_maximizar <- function(y, L, T_alvo) pmin(pmax((y - L) / (T_alvo - L), 0), 1)
desej_minimizar <- function(y, T_alvo, U) pmin(pmax((U - y) / (U - T_alvo), 0), 1)

grade_ccd <- expand_grid(x1 = seq(-alpha_rot, alpha_rot, length.out = 60),
                         x2 = seq(-alpha_rot, alpha_rot, length.out = 60)) %>%
  mutate(
    retencao_pred  = predict(modelo_retencao, newdata = .),
    atividade_pred = predict(modelo_atividade, newdata = .),
    d_retencao  = desej_maximizar(retencao_pred, L = 65, T_alvo = 78),
    d_atividade = desej_minimizar(atividade_pred, T_alvo = 0.35, U = 0.55),
    D = sqrt(d_retencao * d_atividade)   # media geometrica, m=2
  )

melhor_ponto <- grade_ccd %>% slice_max(D, n = 1)

ggplot(grade_ccd, aes(x1, x2, fill = D)) +
  geom_raster() +
  geom_contour(aes(z = D), color = "white", alpha = 0.4) +
  geom_point(data = melhor_ponto, aes(x1, x2), color = "red", size = 3) +
  scale_fill_viridis_c(name = "Desejabilidade\nglobal D") +
  coord_equal() +
  labs(title = "Desejabilidade global: retenção de vitamina C (max)\ne atividade de
        água (min)",
       x = expression(x[1]), y = expression(x[2])) +
  theme_minimal(base_size = 12)
```

O ponto vermelho — o máximo de $D(\mathbf{x})$ na grade — não coincide nem com o máximo isolado da retenção nem com o mínimo isolado da atividade de água; é o **compromisso** que a média geométrica das duas desejabilidades encontra, exatamente o problema que motivou a técnica. Na escala natural, esse ponto corresponde a temperatura $\approx$ 62.4°C e tempo $\approx$ 5.5 h, com desejabilidade global $D \approx 0.81$.

7.5 Desenho robusto: otimizando a média e a variância ao mesmo tempo

Toda a metodologia deste capítulo, até aqui, otimiza uma **média** — o ponto estacionário, a análise de ridge, a desejabilidade combinam previsões de $E[y \mid \mathbf{x}]$. Genichi Taguchi (1986) levantou, na engenharia da qualidade japonesa dos anos 1980, uma pergunta diferente: além de acertar um alvo, um processo de

manufatura precisa ser **robusto** — pouco sensível a fatores de ruído (variação de matéria-prima, desgaste de equipamento, condições ambientais) que o engenheiro não controla em produção, mesmo que os controle perfeitamente durante o experimento. Dois processos podem ter a mesma média e diferir enormemente em quão essa média se mantém estável quando o ruído de produção entra em cena — e MSR clássica, focada só na média, não enxerga essa diferença.

> **Aplicação — Engenharia: espessura de um revestimento por deposição**
> Um processo de deposição controla dois fatores — **temperatura** e **pressão** da câmara — para produzir um revestimento de espessura alvo 15 µm. Além de acertar a média, a fábrica quer **variância mínima** em torno do alvo: um lote com espessura média 15 mas desvio-padrão alto tem mais peças fora da tolerância do que um lote com a mesma média e desvio-padrão baixo.

7.5.1 A proposta original de Taguchi, e por que ela foi revista

Taguchi propôs cruzar um **arranjo interno** de fatores de controle com um **arranjo externo** de fatores de ruído (simulados deliberadamente no experimento, por exemplo variando a matéria-prima entre lotes conhecidos de qualidade diferente), calculando para cada combinação de controle uma **razão sinal-ruído** agregada sobre todas as réplicas de ruído, e escolhendo os níveis de controle que maximizam essa razão. A ideia — otimizar robustez, não só média — foi influente e genuinamente nova; o **método** teve, porém, duas críticas estatísticas que se consolidaram nas décadas seguintes (Vining & Myers, 1990): (i) arranjos internos $\times$ externos cruzados exigem muito mais corridas do que uma única superfície de resposta bem desenhada; e (ii) a razão sinal-ruído comprime média e variância numa única estatística, perdendo informação sobre como cada uma responde separadamente aos fatores de controle — informação que a própria maquinaria deste capítulo (modelo de segunda ordem, ponto estacionário, análise canônica) já sabe extrair.

7.5.2 A alternativa: duas superfícies de resposta, uma única maquinaria

Vining e Myers (1990) propuseram tratar o problema de Taguchi com as ferramentas já construídas neste capítulo: em vez de um arranjo externo separado, usa-se um único delineamento com **réplicas genuínas** em cada ponto (o CCD da Seção 7.3 (p. 165) serve para isso sem alteração nenhuma) e ajustam-se **duas** superfícies de segunda ordem a partir dos mesmos dados — uma para a média $\hat{y}(\mathbf{x})$ em cada ponto, outra para o logaritmo da variância $\ln \widehat{\sigma^2}(\mathbf{x})$ (o log estabiliza a variância da própria estimativa de variância, pela mesma razão da transformação de Box-Cox da Seção 3.5.3 (p. 69)). O problema de otimização vira: minimizar $\widehat{\sigma^2}(\mathbf{x})$ sujeito a $\hat{y}(\mathbf{x})$ ficar dentro de uma faixa aceitável ao redor do alvo — exatamente o tipo de otimização restrita que a Seção 7.4 (p. 166) já resolveu por busca em grade, agora com uma restrição em vez de uma segunda desejabilidade.

> **Uso do R** — duas superfícies de resposta (média e log-variância) a partir de um único CCD replicado

```
set.seed(2026)
pontos_robusto <- bind_rows(
  expand_grid(x1 = c(-1, 1), x2 = c(-1, 1)),
  tibble(x1 = c(-alpha_rot, alpha_rot, 0, 0), x2 = c(0, 0, -alpha_rot, alpha_rot)),
  tibble(x1 = 0, x2 = 0)
)
r_robusto <- 8   # replicas genuinas por ponto do desenho -- e o que permite estimar
        variancia local
```

```
dados_robusto <- pontos_robusto %>%  slice(rep(1:n(), each = r_robusto)) %>%  mutate(
    temperatura = 180 + 10 * x1,    pressao     = 40 + 5 * x2,
    mu_true    = 15 + 0.3*x1 - 0.2*x2 - 0.15*x1^2 - 0.1*x2^2 + 0.05*x1*x2,
    sigma_true = exp(0.35 + 0.30*x1 + 0.25*x2^2),   # variancia sobe com temperatura,
        e com |pressao| fora do centro
    espessura  = rnorm(n(), mu_true, sigma_true)  )
resumo_robusto <- dados_robusto %>%  group_by(x1, x2) %>%
  summarise(media = mean(espessura), variancia = var(espessura), .groups = "drop")
        resumo_robusto %>%
  kable(digits = 2, caption = "Média e variância amostrais (8 réplicas) em cada um
        dos 9 pontos do CCD") %>%
  kable_styling(full_width = FALSE)
```

Tabela 7.3: Média e variância amostrais (8 réplicas) em cada um dos 9 pontos do CCD

x1	x2	media	variancia
-1.41	0.00	14.38	0.45
-1.00	-1.00	13.78	1.59
-1.00	1.00	13.67	2.11
0.00	-1.41	14.64	2.73
0.00	0.00	14.47	2.25
0.00	1.41	13.49	1.63
1.00	-1.00	15.29	4.98
1.00	1.00	16.67	5.36
1.41	0.00	15.02	4.60

```
modelo_media_r  <- lm(media ~ x1 + x2 + I(x1^2) + I(x2^2) + x1:x2, data =
        resumo_robusto)
modelo_logvar_r <- lm(log(variancia) ~ x1 + x2 + I(x1^2) + I(x2^2) + x1:x2, data =
        resumo_robusto)
```

```
grade_robusto <- expand_grid(x1 = seq(-alpha_rot, alpha_rot, length.out = 80),
                             x2 = seq(-alpha_rot, alpha_rot, length.out = 80)) %>%
  mutate(
    media_pred = predict(modelo_media_r, newdata = .),
    var_pred   = exp(predict(modelo_logvar_r, newdata = .)),
    viavel     = abs(media_pred - 15) < 0.5   # faixa aceitavel ao redor do alvo de
        15 um
  )

ponto_robusto <- grade_robusto %>% filter(viavel) %>% slice_min(var_pred, n = 1)

ggplot(grade_robusto, aes(x1, x2)) +
  geom_raster(aes(fill = var_pred)) +
  geom_contour(aes(z = media_pred), breaks = c(14.5, 15, 15.5), color = "white",
        linewidth = 0.6) +
  geom_point(data = ponto_robusto, aes(x1, x2), color = "red", size = 3) +
  scale_fill_viridis_c(name = expression(hat(sigma)^2), option = "magma") +
  coord_equal() +
  labs(title = "Variância prevista (cor) e média prevista\n(contornos brancos,
        14,5/15/15,5 µm)",
       x = expression(x[1]~"(temperatura codificada)"), y = expression(x[2]~"(pressão
        codificada)")) +
  theme_minimal(base_size = 12)
```

O contorno branco central marca onde a média prevista cruza exatamente o alvo de 15 µm; a cor de fundo mostra que a variância prevista **cresce com a temperatura** (x_1 alto) e **cresce nas duas direções conforme a pressão se afasta do centro** (x_2^2) — duas conclusões que a razão sinal-ruído de Taguchi, agregada num único número, jamais teria separado uma da outra. O ponto vermelho — o de menor variância prevista dentre os que ficam a $\pm 0{,}5$ µm do alvo — fica em temperatura ≈ 165.9°C (baixa) e pressão ≈ 34.5 (próxima do centro), com variância prevista $\hat{\sigma}^2 \approx 0.82$ — bem abaixo da variância observada em qualquer ponto de temperatura alta da Tabela acima. A recomendação final para a fábrica: **não** é o ponto de temperatura mais alta (ainda que ele também passe perto do alvo), porque ali a variância prevista é ordens de grandeza maior — o mesmo tipo de compromisso média-variância que motivou Taguchi, resolvido aqui com duas superfícies de resposta interpretáveis separadamente, em vez de uma razão sinal-ruído que as mistura.

7.6 Resumo do capítulo

- A metodologia de superfície de resposta troca a pergunta “o que importa?” (típica dos fatoriais) pela pergunta “qual é o ótimo?”, ajustando um modelo de segunda ordem que captura curvatura — algo que nenhum fatorial de dois níveis consegue estimar.
- O ponto estacionário resolve $\mathbf{b} + 2\mathbf{B}\mathbf{x}_0 = \mathbf{0}$; os autovalores da Hessiana $\mathbf{B}$ classificam-no como máximo, mínimo ou sela — no exemplo da energia de corte, uma sela, o que desloca a busca pelo ótimo prático para a fronteira da região experimental.
- A análise canônica (autovetores, não só autovalores, de $\mathbf{B}$) reescreve o modelo numa base rotacionada onde a curvatura fica diagonal, revelando a direção em que a superfície muda mais rápido — informação que a classificação simples do ponto estacionário não dá.
- A análise de ridge otimiza dentro de um raio fixo do centro do desenho (em unidades codificadas), produzindo um caminho de pontos ótimos-restritos — uma alternativa disciplinada a extrapolar até um ponto estacionário fora da região onde os dados foram coletados.
- O caminho de máxima inclinação usa um modelo de primeira ordem, longe do ótimo, para apontar uma direção de melhoria com corridas reais sequenciais; quando a resposta para de melhorar (a curvatura passa a importar), é hora de desenhar um experimento de segunda ordem.
- O delineamento composto central (CCD) — núcleo fatorial 2^k + pontos axiais + pontos centrais — é o desenho de segunda ordem padrão; a escolha $\alpha = (2^k)^{1/4}$ o torna rotacionável.
- Quando há mais de uma resposta em jogo, funções de desejabilidade combinam metas individuais (maximizar, minimizar ou mirar um alvo) numa única escala $[0, 1]$ via média geométrica, que penaliza qualquer resposta inaceitável isoladamente.
- *(Além do programa do semestre)* Desenho robusto pergunta não só “qual ponto acerta o alvo?” mas “qual ponto é **insensível** a ruído de produção?”: réplicas genuínas num único CCD alimentam **duas** superfícies de segunda ordem — uma para a média, outra para a log-variância —, que Vining e Myers mostraram serem estatisticamente mais eficientes e mais interpretáveis do que a razão sinal-ruído original de Taguchi.

7.7 Fim do programa do semestre

Este capítulo fecha os sete capítulos alinhados ao cronograma de MATD48 — a jornada que começou no Capítulo 1 com uma distinção aparentemente simples, unidade experimental versus unidade amostral, e terminou aqui ajustando superfícies de segunda ordem sobre fatoriais completos de múltiplos fatores. A própria MSR tem, hoje, uma contraparte para respostas obtidas por simulação computacional em vez de experimento físico — os **desenhos de experimentos computacionais**, que substituem réplicas e erro aleatório por desenhos “preenchedores de espaço” (*space-filling*, como hipercubos latinos) e modelos de

processo gaussiano no lugar do polinômio de segunda ordem (Sacks et al., 1989; Santner et al., 2003), uma direção que foge do escopo deste curso mas que compartilha o mesmo objetivo de mapear uma superfície de resposta com o menor número de corridas possível. O Capítulo 8 estende o livro (não o semestre) para o domínio de experimentação onde o delineamento clássico encontrou, nas últimas duas décadas, sua aplicação mais numerosa: testes A/B e bandits em produtos digitais — o mesmo arcabouço causal do Capítulo 1, a mesma lógica de aleatorização e controle de confusão, aplicados a um contexto em que os experimentos são sequenciais, numerosos e frequentemente automatizados.

8 Experimentação em produtos digitais: testes A/B e bandits

Sobre este capítulo
Os sete capítulos anteriores acompanham, aula a aula, o programa do semestre de MATD48 (ver cronograma na home do curso). Este capítulo não tem aula correspondente — é material que expande o livro além do que cabe em um semestre, cobrindo como os mesmos princípios de delineamento (repetição, aleatorização, controle de confusão) aparecem na forma mais comum de experimentação do século XXI: testes A/B e bandits em produtos digitais. A referência principal é @owen2020experimental (Stanford Stat 263/363), cujo capítulo de abertura trata exatamente dessa ponte entre delineamento clássico e experimentação online.

Um teste A/B é, ao mesmo tempo, o experimento mais executado no mundo hoje — plataformas grandes de tecnologia rodam milhares deles simultaneamente — e, estruturalmente, o delineamento mais simples que este livro estuda: dois tratamentos, unidades atribuídas ao acaso, sem blocos, sem fatores cruzados. A dificuldade não está na álgebra (é a mesma do Capítulo 3), mas no *contexto* em que ele roda: tráfego contínuo em vez de uma amostra fixa coletada de uma vez, efeitos minúsculos em relação à variância natural do comportamento humano online, e a tentação constante de olhar o resultado antes da hora. A Parte I deste capítulo formaliza o teste A/B como um caso particular do delineamento completamente aleatorizado (Capítulo 3) e cataloga os problemas estatísticos que essa combinação de "experimento simples, mas contínuo e de alto volume" produz na prática. A Parte II introduz uma alternativa: em vez de dividir o tráfego 50/50 até o fim de um horizonte fixo, um **bandit** realoca tráfego adaptativamente para o que parece estar funcionando melhor, ao custo de uma pergunta causal mais difícil de responder depois que o experimento termina.

8.1 Parte I — Testes A/B como delineamento completamente aleatorizado

8.1.1 Um teste A/B é um delineamento completamente aleatorizado

Tire o vocabulário de produto — "variante", "conversão", "tráfego" — e o que resta é exatamente o delineamento completamente aleatorizado (DCA) de dois tratamentos do Capítulo 3, na notação de resultados potenciais estabelecida na Seção 1.4.3 (p. 9) do Capítulo 1. A unidade experimental i é o **usuário** (ou, mais precisamente, a sessão ou o dispositivo, dependendo de como o sistema de experimentação identifica "quem" está sendo tratado — voltaremos a essa sutileza). O tratamento $Z_i \in \{0, 1\}$ indica se o usuário i foi alocado para o controle ("A", a versão atual do produto) ou para a variante ("B", a mudança proposta). Cada usuário tem dois resultados potenciais, $Y_i(0)$ e $Y_i(1)$ — por exemplo, um indicador binário de conversão (comprou ou não, em uma sessão), o tempo gasto na página, ou a receita gerada — mas o sistema só observa um deles, $Y_i = Z_i Y_i(1) + (1 - Z_i) Y_i(0)$, exatamente como na equação ((8.1)) abaixo, que repete a estrutura da Seção 1.4.3 (p. 9):

$$Y_i = Z_i\, Y_i(1) + (1 - Z_i)\, Y_i(0), \qquad Z_i \sim \text{Bernoulli}(1/2) \text{ (tipicamente)}, \tag{8.1}$$

com Z_i sorteado independentemente entre usuários. O estimando de interesse é o efeito médio do tratamento,

$$\text{ATE} = E[Y_i(1) - Y_i(0)],$$

que no caso mais comum de uma métrica binária de conversão se reduz a uma diferença de proporções, $\text{ATE} = p_1 - p_0$, com $p_1 = P(Y_i(1) = 1)$ e $p_0 = P(Y_i(0) = 1)$. O estimador natural,

$$\widehat{\text{ATE}} = \bar{Y}_1^{\,obs} - \bar{Y}_0^{\,obs} = \hat{p}_1 - \hat{p}_0,$$

é exatamente a diferença de médias amostrais do Capítulo 3, e a demonstração de $E[\widehat{\text{ATE}}] = \text{ATE}$ da Seção 1.4.3 (p. 9) se aplica sem alteração alguma: não depende do contexto (parcela agrícola, estudante ou usuário de site), só do mecanismo de aleatorização. Em notação de modelo linear (Capítulo 2), o mesmo problema se escreve

$$Y_i = \beta_0 + \beta_1 Z_i + \varepsilon_i, \qquad i = 1, \ldots, N,$$

com $\hat{\beta}_1$ (o coeficiente de Z_i em uma regressão OLS de Y contra o indicador de tratamento) numericamente idêntico a $\hat{p}_1 - \hat{p}_0$ — a regressão com um único regressor binário *é* o teste de duas amostras, um fato que já usamos implicitamente no Capítulo 3 e que aqui simplesmente reaparece com outro nome de aplicação.

O que muda de fato, em relação ao DCA de laboratório do Capítulo 3, é a **mecânica de aleatorização**. Um pesquisador de psicologia sorteia 36 voluntários e anota manualmente quem recebeu qual condição; uma plataforma digital recebe milhões de requisições por segundo e precisa decidir, em tempo real e sem consultar um banco de dados central, se um usuário específico vê a versão A ou B — e precisa que a *mesma* pessoa continue vendo a mesma versão em visitas subsequentes (senão a "unidade experimental" se confunde com a "unidade de observação", o mesmo problema de submuestreo da Seção 1.2 (p. 5), só que ao contrário: aqui queremos *evitar* múltiplas atribuições da mesma unidade). A solução industrial padrão é a **aleatorização por hash**: aplica-se uma função hash determinística (por exemplo, MD5 ou MurmurHash) ao identificador do usuário concatenado com um identificador do experimento, e o resultado — um número pseudoaleatório, mas *reprodutível* para o mesmo par (usuário, experimento) — decide o grupo. Isso tem duas propriedades cruciais: (1) a mesma pessoa sempre cai no mesmo grupo dentro de um mesmo experimento, preservando a unidade experimental como o usuário e não a visita; e (2) usada com "seeds" (sementes de hash) diferentes por experimento, a mesma pessoa pode estar em experimentos *diferentes e não correlacionados* ao mesmo tempo, o que viabiliza rodar milhares de testes A/B simultâneos sem que a alocação de um contamine a de outro (Kohavi et al., 2020).

> **Aplicação — Ciência de dados: cor do botão de checkout**
> Uma loja online quer saber se trocar a cor do botão "Finalizar compra" de cinza para verde aumenta a taxa de conversão. O sistema de experimentação faz o hash do `user_id` de cada visitante e atribui metade a cada grupo — grupo A (cinza, controle) e grupo B (verde, variante). Cada visitante i tem um resultado potencial binário $Y_i(0)$ (converteria vendo cinza?) e $Y_i(1)$ (converteria vendo verde?), mas o hash decide qual dos dois é revelado. Ao final de duas semanas de tráfego, o time compara $\hat{p}_1$ (conversão observada no grupo B) com $\hat{p}_0$ (conversão observada no grupo A).

Do ponto de vista puramente algébrico, portanto, não há nada de novo aqui — e é exatamente por isso que testes A/B se popularizaram tão rápido: qualquer time de produto, sem treinamento formal em delineamento de experimentos, consegue programar um teste de duas amostras. O que a Seção seguinte argumenta é que a *facilidade de implementar* um teste A/B tecnicamente correto é enganosa — o contexto de alto volume, métricas ruidosas e pressão para decidir rápido introduz uma família de armadilhas estatísticas que raramente aparecem no experimento de bancada clássico.

8.1.2 Por que testes A/B em produtos digitais são estatisticamente difíceis

Se a matemática é a mesma do Capítulo 3, por que Kohavi, Tang e Xu dedicam um livro inteiro (2020) só às dificuldades práticas de rodar testes A/B "à escala"? Quatro razões concentram a maior parte do problema.

Efeitos pequenos, variância grande. Uma mudança de layout raramente move a taxa de conversão de um site em mais do que uma fração de ponto percentual — de $p_0 = 10{,}0\%$ para $p_1 = 10{,}3\%$, digamos. Para uma proporção, a variância do estimador $\hat{p}$ é $p(1-p)/n$, que para $p \approx 0{,}1$ não é pequena em termos relativos: detectar uma diferença de $0{,}3$ pontos percentuais com poder razoável ($1-\beta = 0{,}8$, $\alpha = 0{,}05$) exige, pela fórmula de tamanho amostral para duas proporções análoga à da Seção de poder do Capítulo 3,

$$n \approx \frac{\left(z_{\alpha/2} + z_{\beta}\right)^2 \left[p_0(1-p_0) + p_1(1-p_1)\right]}{(p_1 - p_0)^2},$$

algo da ordem de **centenas de milhares** de usuários por grupo — perfeitamente viável para uma plataforma grande, impossível para a maioria dos experimentos de laboratório do resto deste livro. Métricas de receita são ainda piores: distribuições fortemente assimétricas, com uma minoria de usuários de alto gasto dominando a variância, de modo que o fator $p_1(1-p_1)$ no numerador acima subestima muito a dificuldade real de detectar efeitos em métricas monetárias.

Múltiplas métricas e múltiplos testes simultâneos. Um teste A/B raramente monitora uma única métrica. Times de produto acompanham um **OEC** (*Overall Evaluation Criterion*, a métrica de decisão primária) junto de dezenas de métricas secundárias e de "guarda-corpo" (*guardrail metrics* — métricas que não deveriam piorar, como tempo de carregamento ou taxa de erro). Ver dezenas de métricas simultaneamente é, estruturalmente, o mesmo problema do 3.7 (p. 76): sob $\alpha = 0{,}05$ por métrica, a chance de pelo menos um falso positivo entre 20 métricas independentes já passa de 64% ($1 - (1-0{,}05)^{20} \approx 0{,}64$). A prática recomendada por Kohavi et al. (2020) — escolher o OEC *antes* de rodar o teste e tratá-lo com o rigor de uma hipótese pré-registrada, deixando as métricas secundárias para geração de hipóteses, não confirmação — é uma aplicação direta do princípio contra *data snooping* já discutido na Seção 3.7.1 (p. 76).

Efeito de novidade (e o oposto, efeito de primazia). Uma mudança de interface pode gerar uma reação inicial que não reflete o efeito de longo prazo: usuários clicam em um botão só porque ele é diferente (efeito de novidade, que infla o efeito estimado nos primeiros dias e desaparece depois), ou resistem a uma mudança só por ser mudança, mesmo que objetivamente melhor (efeito de primazia, que faz o teste subestimar o efeito real até os usuários se acostumarem). Isso viola implicitamente uma suposição que o Capítulo 1 deixou implícita ao tratar $Y_i(t)$ como fixo: aqui, o resultado potencial de um usuário que permanece exposto ao tratamento por semanas não é constante no tempo, e o "ATE médio nas primeiras 48 horas" pode ser um estimando diferente do "ATE médio de longo prazo" que o time de produto realmente quer.

Dependência temporal dentro do mesmo usuário. O mesmo usuário volta ao site várias vezes ao longo do período do teste, e cada visita gera uma observação — mas, exatamente como no problema de submuestreo formalizado na Seção 1.2 (p. 5), essas observações repetidas **não são réplicas independentes**: são correlacionadas dentro do usuário (alguém propenso a comprar tende a comprar em várias visitas; alguém que nunca compra continua não comprando). Tratar cada visita como uma unidade experimental independente — em vez de agregar por usuário antes de testar, como manda o princípio de submuestreo do Capítulo 1 — infla artificialmente o tamanho amostral efetivo e produz erros-padrão anticonservadores, exatamente o mesmo erro de pseudorreplicação identificado naquela seção, só que reaparecendo aqui sob um nome de produto diferente.

Uso do R — poder de um teste A/B para efeitos pequenos

```
p0 <- 0.10
p1 <- 0.103    # lift de 0,3 ponto percentual — típico de um teste de UI em e-
        commerce

poder_ab <- power.prop.test(p1 = p0, p2 = p1, sig.level = 0.05, power = 0.80)
poder_ab$n
```

```
## [1] 159065.5
```

Tabela 8.1: Tamanho amostral necessário por grupo para detectar diferentes lifts, partindo de p0 = 10%, alpha = 0,05, poder = 80%

Cenário	n por grupo
Lift de 0,3 p.p. (UI)	159066
Lift de 1,0 p.p. (feature nova)	14751
Lift de 3,0 p.p. (mudança grande)	1774

O contraste é gritante: para detectar um efeito realista de UI (0,3 ponto percentual) são necessários mais de 159,066 usuários **por grupo** — um volume que só faz sentido em contexto de alto tráfego, e que explica por que testes A/B de produto digital são projetados de forma tão diferente de um experimento de bancada com 30 ou 40 sujeitos.

8.1.3 O problema do “peeking”

A teoria do teste t/F clássica pressupõe que o tamanho amostral n é **fixo antes da coleta** e a decisão de rejeitar ou não H_0 é tomada **uma única vez**, depois que todos os n dados foram coletados. É essa suposição — não nenhuma outra — que garante que $P(\text{rejeitar } H_0 \mid H_0 \text{ verdadeira}) = \alpha$ exatamente. Em um ambiente de produto, porém, é natural (e tentador) olhar o painel de resultados do teste todos os dias, calcular o valor-p a cada olhada, e parar assim que ele cruza $0{,}05$ — prática conhecida como ***peeking*** (“espiar”). O problema é que essa prática transforma silenciosamente o procedimento em outro completamente diferente: em vez de “um teste com $\alpha = 0{,}05$”, o que se está executando é “uma sequência de testes, parando no primeiro que rejeitar” — e a probabilidade de que *pelo menos um* desses testes rejeite, mesmo sob H_0 verdadeira, é muito maior que $0{,}05$ (Johari et al., 2017).

A intuição por trás da inflação vem de um argumento de passeio aleatório: sob H_0, a estatística de teste acumulada ao longo do tempo (por exemplo, a diferença de proporções observadas até o instante t) evolui como um processo estocástico que oscila em torno de zero, com variância crescente. Um resultado clássico de teoria de sequências (relacionado à lei do logaritmo iterado) garante que, se o processo é observado continuamente e o pesquisador para assim que ele cruza *qualquer* limiar fixo, o cruzamento acontece **quase certamente**, mesmo que a média do processo seja exatamente zero — basta esperar o tempo suficiente. Checar o valor-p repetidamente e parar no primeiro cruzamento de $0{,}05$ é uma versão discreta exatamente desse fenômeno: quanto mais vezes se olha, maior a chance de que, só por acaso, uma das checagens caia abaixo do limiar.

A forma matematicamente correta de testar sequencialmente — permitindo checagens repetidas *sem* inflar α — não é simplesmente “não olhar”, mas usar um procedimento desenhado para isso. O **teste sequencial de razão de verossimilhança** (SPRT, *sequential probability ratio test*) de Wald (1945) formaliza a ideia: em vez de um limiar fixo de significância aplicado a um n fixo, o SPRT define dois limiares A e B para a

razão de verossimilhanças acumulada $\Lambda_n = \prod_{i=1}^{n} f_1(Y_i)/f_0(Y_i)$ entre a hipótese alternativa e a nula, e continua coletando dados enquanto $B < \Lambda_n < A$, parando para rejeitar H_0 assim que $\Lambda_n \geq A$ e para não rejeitar assim que $\Lambda_n \leq B$. Escolhendo A e B em função dos erros tipo I e II desejados ($A \approx (1-\beta)/\alpha$, $B \approx \beta/(1-\alpha)$), o SPRT garante as mesmas taxas de erro nominal do teste de tamanho fixo, *mesmo permitindo parar a qualquer momento* — a diferença crucial é que os limiares de decisão do SPRT são derivados especificamente para controlar o erro acumulado de múltiplas checagens, ao passo que reaplicar ingenuamente o limiar $p < 0{,}05$ do teste de tamanho fixo a cada checagem não tem essa propriedade. Ferramentas modernas de teste sequencial em produto (testes de razão de verossimilhança sempre válidos, *always-valid p-values*) generalizam essa ideia para o contexto de testes A/B contínuos (Johari et al., 2017), mas o princípio já está inteiro no SPRT de 1945.

> **Uso do R** — simulando a inflação do erro tipo I sob peeking

A simulação a seguir gera dados sob H_0 verdadeira (as duas variantes têm exatamente a mesma taxa de conversão, $p = 0{,}10$) e compara duas formas de decidir: (i) checar o valor-p a cada 100 usuários acumulados, até um máximo de 2.000 por grupo, e parar assim que $p < 0{,}05$ (“peeking”); e (ii) checar uma única vez, ao final dos 2.000 usuários. Sob H_0, ambas deveriam rejeitar cerca de 5% das vezes — a pergunta é se de fato rejeitam.

```
set.seed(2026)

n_max      <- 2000                       # tamanho amostral maximo por braco
checagens  <- seq(100, n_max, by = 100)  # instantes de checagem (a cada 100
        usuarios)
n_sim      <- 3000                       # replicas Monte Carlo
alpha      <- 0.05
p_H0       <- 0.10                       # mesma taxa de conversao nos dois bracos
        (H0 verdadeira)

simula_uma_replica <- function() {
  grupo_a <- rbinom(n_max, 1, p_H0)
  grupo_b <- rbinom(n_max, 1, p_H0)

  rejeitou_com_peeking <- FALSE
  for (n in checagens) {
    xa <- sum(grupo_a[1:n]); xb <- sum(grupo_b[1:n])
    pval <- suppressWarnings(prop.test(c(xa, xb), c(n, n), correct = FALSE)$p.value)
    if (!is.na(pval) && pval < alpha) { rejeitou_com_peeking <- TRUE; break }
  }

  pval_tamanho_fixo <- suppressWarnings(
    prop.test(c(sum(grupo_a), sum(grupo_b)), c(n_max, n_max), correct =
        FALSE)$p.value
  )

  c(peeking = rejeitou_com_peeking, fixo = pval_tamanho_fixo < alpha)
}

resultado_peeking <- replicate(n_sim, simula_uma_replica())
taxa_peeking <- mean(as.logical(resultado_peeking["peeking", ]))
taxa_fixo    <- mean(as.logical(resultado_peeking["fixo", ]))

tibble(
  Procedimento = c("Checagem única (n fixo = 2.000)", "Peeking a cada 100 (até n =
        2.000)"),
  `Taxa de rejeição sob H0` = c(taxa_fixo, taxa_peeking)
) %>%
```

```
  kable(digits = 3, caption = "Taxa de falso positivo observada em 3.000 réplicas
        Monte Carlo sob H0 verdadeira") %>%
  kable_styling(full_width = FALSE)
```

Tabela 8.2: Taxa de falso positivo observada em 3.000 réplicas Monte Carlo sob H0 verdadeira

Procedimento	Taxa de rejeição sob H0
Checagem única (n fixo = 2.000)	0.051
Peeking a cada 100 (até n = 2.000)	0.251

A checagem única fica, como esperado, muito próxima do α nominal de 0.05 (5.1% observado). Com peeking a cada 100 usuários — só 20 checagens ao longo de todo o experimento, uma frequência bem menor do que o "olhar o painel todo dia" que de fato acontece em produto — a taxa de falso positivo salta para 25.1%, quase 4.9 vezes o valor nominal. Nenhuma das duas variantes tinha qualquer efeito real: a diferença inteira vem do procedimento de parada. Esse é o argumento numérico por trás da recomendação, universal em times de experimentação de produto, de nunca decidir "parar porque ficou significativo" sem um procedimento sequencial formal (SPRT ou equivalente) desenhado para isso.

8.1.4 Vício do vencedor (*winner's curse*)

Um problema relacionado, mas distinto, aparece quando várias variantes são testadas ao mesmo tempo contra o controle (um teste "A/B/n") e a decisão final é lançar a variante com a **maior** diferença estimada. Mesmo que todas as variantes tenham, na verdade, o mesmo efeito verdadeiro — inclusive nulo —, a variante escolhida por ter a maior estimativa amostral tende a ter sua estimativa **viesada para cima**, simplesmente por ter sido selecionada por ser a maior entre várias estimativas ruidosas. Esse fenômeno, batizado de **vício do vencedor** (por analogia a leilões, em que o lance vencedor tende a superestimar o valor real do item), é uma consequência direta de estatística de ordem: entre k estimativas não-viesadas mas ruidosas de um mesmo parâmetro, o *máximo* delas tem expectativa maior do que o parâmetro verdadeiro, e a diferença cresce com k (mais variantes testadas) e com a variância de cada estimativa individual.

Formalmente, sejam $\hat{\delta}_1, \ldots, \hat{\delta}_k$ as diferenças estimadas de k variantes contra o controle, cada uma com $\hat{\delta}_j \sim N(\delta, \sigma^2)$ sob a suposição (deliberada, para isolar o fenômeno) de que o efeito verdadeiro δ é o mesmo para todas. A variante escolhida é $j^\star = \arg\max_j \hat{\delta}_j$, e o vício do vencedor é a quantidade

$$E\big[\hat{\delta}_{j^\star}\big] - \delta = E\Big[\max_j \hat{\delta}_j\Big] - \delta > 0,$$

estritamente positiva sempre que $k > 1$ e $\sigma^2 > 0$ — uma consequência do fato de que o máximo de variáveis aleatórias tem expectativa maior ou igual à expectativa comum de cada uma (com igualdade só no caso degenerado $\sigma^2 = 0$). É o mesmo fenômeno estatístico, com sinal trocado, por trás da "regressão à média": medições extremas tendem a ser seguidas por medições mais próximas da média, porque parte do que as tornou extremas foi ruído, não sinal persistente.

> **Uso do R** — simulando o vício do vencedor

```
set.seed(2026)

n_variantes    <- 10    # variantes testadas simultaneamente contra o controle
n_por_variante <- 500   # usuarios por variante
efeito_real    <- 0     # todas as variantes tem, de fato, o MESMO efeito verdadeiro
```

```
sigma          <- 1     # desvio-padrao da metrica (escala padronizada)
n_sim          <- 5000  # replicas Monte Carlo
simula_vencedora <- function() {
  estimativas <- rnorm(n_variantes, mean = efeito_real, sd = sigma /
        sqrt(n_por_variante))
  estimativas[which.max(estimativas)]}
estimativas_vencedoras <- replicate(n_sim, simula_vencedora())
vies_vencedor <- mean(estimativas_vencedoras) - efeito_real        tibble(
  Quantidade = c("Efeito verdadeiro (idêntico em todas as variantes)",
                 "Média das estimativas da variante vencedora (5.000 réplicas)",
                 "Vício do vencedor"),
  Valor = c(efeito_real, mean(estimativas_vencedoras), vies_vencedor)) %>%
  kable(digits = 4, caption = "Vício do vencedor: efeito estimado da melhor entre 10
        variantes idênticas") %>%
  kable_styling(full_width = FALSE)
```

Tabela 8.3: Vício do vencedor: efeito estimado da melhor entre 10 variantes idênticas

Quantidade	Valor
Efeito verdadeiro (idêntico em todas as variantes)	0.0000
Média das estimativas da variante vencedora (5.000 réplicas)	0.0691
Vício do vencedor	0.0691



Distribuição, sobre 5.000 réplicas Monte Carlo, do efeito estimado da variante vencedora (a de maior estimativa entre 10 variantes com efeito verdadeiro idêntico), com o efeito verdadeiro (zero) marcado pela linha tracejada.

Figura 8.1: Distribuição, sobre 5.000 réplicas Monte Carlo, do efeito estimado da variante vencedora (a de maior estimativa entre 10 variantes com efeito verdadeiro idêntico), com o efeito verdadeiro (zero) marcado pela linha tracejada.

Com efeito verdadeiro igual a zero em todas as 10 variantes, a variante escolhida por ter a maior estimativa amostral aparenta, em média, um efeito de 0.069 — inteiramente espúrio, produto só da seleção pelo máximo entre `r n_variantes` estimativas ruidosas. A linha tracejada verde no gráfico marca o efeito verdadeiro (zero); a linha sólida azul marca a média das estimativas vencedoras — a distância entre as duas é o vício do vencedor. Isso não é um argumento contra testar várias variantes (testar várias ideias ao mesmo tempo é eficiente), mas um argumento contra **lançar uma variante com base só na estimativa do próprio teste que a selecionou**: a prática recomendada em times de experimentação maduros é re-testar a variante vencedora isoladamente, contra o controle, em uma segunda rodada com tráfego novo — um procedimento de validação *fora da amostra* que quebra exatamente o mecanismo de seleção que produz o vício, análogo em espírito à separação treino/validação usada para evitar sobreajuste em modelos preditivos.

Para discutir

1. A seção sobre validade interna e externa do Capítulo 1 distingue validade interna (a estimativa é não-viesada para o ATE *da amostra estudada*) de validade externa (o resultado generaliza para além dela). Usuários que efetivamente participam de um teste A/B — em geral uma fração do tráfego total, às vezes restrita a uma região, uma versão de aplicativo ou um segmento de usuários "elegíveis" para o experimento — são uma amostra aleatória de *todos* os usuários da plataforma, ou apenas do subconjunto elegível? Que diferença prática isso faz para decidir se o resultado se generaliza quando a mudança for lançada para 100% da base?
2. Se um teste A/B roda só durante uma semana de dezembro (alta temporada de compras), que tipo de ameaça à validade externa isso introduz, além da amostragem de usuários em si?
3. Uma plataforma com efeitos de rede (por exemplo, uma rede social, ou um marketplace de duas pontas) testa uma mudança que afeta a visibilidade de conteúdo. Por que a suposição SUTVA (seção sobre o modelo de resultados potenciais, no Capítulo 1) — o resultado potencial de um usuário depende só do *seu* tratamento, não do tratamento dos demais — é particularmente frágil nesse tipo de produto? O que pode dar errado ao interpretar o teste como se SUTVA valesse?

8.2 Parte II — Bandits: quando explorar e quando explotar

8.2.1 Exploração, explotação e a definição de arrependimento (*regret*)

Um teste A/B de horizonte fixo, como formalizado na Parte I, tem uma ineficiência estrutural: se a variante B é de fato melhor, metade do tráfego continua sendo enviada para a variante A (pior) até o experimento terminar, porque a divisão 50/50 foi decidida antes de qualquer dado ser observado, e não muda com o que se aprende ao longo do caminho. Em um contexto de decisão sequencial — em que a mesma decisão (qual variante mostrar) é tomada repetidamente, uma vez por usuário, e o objetivo inclui maximizar o resultado *durante* o próprio experimento, não só aprender o efeito para decidir depois — essa rigidez tem um custo real: usuários “gastos” no braço pior enquanto o time já suspeita, com razoável confiança, que ele é pior.

Um **bandit de múltiplos braços** (*multi-armed bandit*) formaliza esse problema de decisão sequencial. Há K “braços” (variantes), cada um com uma distribuição de recompensa desconhecida de média μ_k; a cada rodada $t = 1, \dots, T$, uma política escolhe um braço $A_t \in \{1, \dots, K\}$, observa uma recompensa X_t amostrada da distribuição do braço escolhido, e usa essa observação para informar a escolha da próxima rodada. O objetivo é maximizar a soma das recompensas ao longo de T rodadas — equivalentemente, minimizar o **arrependimento acumulado** (*regret*), definido como a diferença entre a recompensa que se teria obtido sempre jogando o melhor braço (o oráculo, que conhece $\mu^\star = \max_k \mu_k$ desde o início) e a recompensa efetivamente obtida:

$$R_T = \sum_{t=1}^{T} \left(\mu^\star - \mu_{A_t} \right). \tag{8.2}$$

R_T cresce sempre que a política joga um braço subótimo; uma política “boa” é aquela cujo regret cresce devagar (idealmente, sublinearmente em T) — o que exige resolver o **trade-off entre exploração e explotação**: jogar demais nos braços que já parecem bons demasiado cedo (*explotação* pura, sem testar o suficiente) arrisca convergir prematuramente para um braço subótimo, por má sorte nas primeiras

observações; jogar demais em busca de mais informação (*exploração* pura, tipo alocação uniforme, que é exatamente o que um teste A/B de horizonte fixo faz até o fim) desperdiça recompensa em braços já suficientemente conhecidos como inferiores. Duas famílias de políticas resolvem esse trade-off de formas distintas, mas com a mesma ideia de fundo: usar a **incerteza** sobre cada braço, e não só sua média estimada, para decidir o que jogar a seguir.

8.2.2 Upper Confidence Bound (UCB1): otimismo perante a incerteza

A política **UCB1** (Auer et al., 2002), com raízes na teoria assintótica de alocação adaptativa de Lai & Robbins (1985) e no problema originalmente formulado por Robbins (1952), resolve o trade-off por um princípio simples de enunciar: **seja otimista sob incerteza**. Em vez de jogar o braço de maior média estimada $\bar{X}_k(t)$ (o que seria explotação pura), UCB1 joga o braço que maximiza um **limite superior de confiança** para a média verdadeira,

$$\mathrm{UCB}_k(t) = \bar{X}_k(t) + \sqrt{\frac{2\log t}{n_k(t)}}, \tag{8.3}$$

em que $\bar{X}_k(t)$ é a média das recompensas observadas do braço k até a rodada t e $n_k(t)$ é o número de vezes que o braço k já foi jogado até então. O primeiro termo é a explotação (o melhor palpite atual sobre μ_k); o segundo é um **bônus de exploração** que cresce quando o braço foi jogado poucas vezes ($n_k(t)$ pequeno no denominador) e encolhe conforme mais evidência é acumulada sobre ele — refletindo que a incerteza sobre μ_k diminui com $n_k(t)$, na mesma lógica de um intervalo de confiança que estreita com o tamanho amostral (Capítulo 2). Braços pouco testados recebem um bônus grande mesmo com média estimada modesta, garantindo que nenhum braço fique permanentemente "esquecido" só por má sorte nas primeiras jogadas — e é exatamente esse mecanismo que dá a Auer et al. (2002) uma prova de que o regret de UCB1 cresce apenas na ordem de $O(\log T)$, a mesma taxa assintoticamente ótima estabelecida por Lai & Robbins (1985).

8.2.3 Thompson sampling: uma solução bayesiana

A segunda política, **Thompson sampling**, resolve o mesmo trade-off por um caminho bayesiano — e é notavelmente mais antiga do que o nome "bandit" (cunhado só décadas depois, por Robbins (1952)): Thompson (1933) propôs o método já em 1933, no contexto de decidir qual de dois tratamentos clínicos usar em pacientes sucessivos, décadas antes de existir a teoria formal de arrependimento da Equação (8.2).

A ideia: mantenha, para cada braço k, uma distribuição a posteriori sobre μ_k, atualizada bayesianamente a cada observação. Para uma métrica de conversão (Bernoulli), o par conjugado Beta-Binomial é a escolha natural: comece com um prior $\mu_k \sim \mathrm{Beta}(1,1)$ (uniforme, não-informativo) para cada braço, e a cada recompensa binária $X_t \in \{0,1\}$ observada do braço A_t, atualize

$$\mathrm{Beta}(\alpha_k, \beta_k) \;\longrightarrow\; \mathrm{Beta}\big(\alpha_k + X_t,\; \beta_k + (1 - X_t)\big),$$

que é a mesma atualização conjugada Beta-Binomial de qualquer curso de inferência bayesiana. A regra de decisão de Thompson sampling é: a cada rodada t, **amostre** um valor $\tilde{\mu}_k \sim \mathrm{Beta}(\alpha_k, \beta_k)$ de cada posteriori (não use a média da posteriori — amostre dela) e jogue o braço $A_t = \arg\max_k \tilde{\mu}_k$. A aleatoriedade da amostragem é o próprio mecanismo de exploração: um braço com posteriori ainda muito dispersa (pouco testado) tem chance razoável de produzir uma amostra alta mesmo com média posterior modesta, levando a política a experimentá-lo; conforme a posteriori se concentra em torno do valor verdadeiro (mais dados acumulados), as amostras ficam cada vez mais próximas da média, e a política converge para explotação quase pura do melhor braço. Resultados teóricos modernos — fora do escopo de prova completa aqui, mas que valem a pena citar como ponteiro — mostram que Thompson sampling

também atinge a taxa ótima $O(\log T)$ de regret assintótico, e costuma superar UCB1 em termos práticos para T finito, como a simulação a seguir ilustra numericamente.

> **Uso do R** — três políticas de bandit, implementadas do zero

O código abaixo implementa, sem nenhum pacote especializado de bandit, três políticas sobre um cenário de 4 braços com taxas de conversão fixas e conhecidas apenas pelo simulador — nunca pelas políticas, que só observam recompensas binárias realizadas: alocação **aleatória** (baseline, a mesma lógica de um A/B/C/D de horizonte fixo com tráfego dividido igualmente por toda a duração), **UCB1** e **Thompson sampling**. Cada política roda por $T = 3.000$ rodadas, repetida em 300 réplicas Monte Carlo independentes para obter o regret acumulado médio esperado — não o de uma única simulação, que seria ruidosa demais para comparação confiável.

```
set.seed(2026)

p_verdadeiro <- c(0.10, 0.12, 0.15, 0.11)   # taxas de conversao reais dos 4 bracos
        (desconhecidas p/ as politicas)
K        <- length(p_verdadeiro)
T_rounds <- 3000
n_mc     <- 300
mu_star  <- max(p_verdadeiro)

politica_aleatoria <- function() {
  regret <- numeric(T_rounds)
  for (t in 1:T_rounds) {
    a <- sample(K, 1)
    regret[t] <- mu_star - p_verdadeiro[a]
  }
  cumsum(regret)
}

politica_ucb1 <- function() {
  contagens <- rep(0, K); somas <- rep(0, K)
  regret <- numeric(T_rounds)

  # inicializacao: joga cada braco uma vez, para nunca dividir por zero
  for (a in 1:K) {
    r <- rbinom(1, 1, p_verdadeiro[a])
    contagens[a] <- 1; somas[a] <- r
    regret[a] <- mu_star - p_verdadeiro[a]
  }
  for (t in (K + 1):T_rounds) {
    medias <- somas / contagens
    ucb <- medias + sqrt(2 * log(t) / contagens)
    a <- which.max(ucb)
    r <- rbinom(1, 1, p_verdadeiro[a])
    contagens[a] <- contagens[a] + 1
    somas[a]     <- somas[a] + r
    regret[t]    <- mu_star - p_verdadeiro[a]
  }
  cumsum(regret)
}

politica_thompson <- function() {
  alpha_post <- rep(1, K); beta_post <- rep(1, K)   # prior Beta(1,1) em cada braco
  regret <- numeric(T_rounds)
  for (t in 1:T_rounds) {
    theta_amostrado <- rbeta(K, alpha_post, beta_post)
```

```
    a <- which.max(theta_amostrado)    r <- rbinom(1, 1, p_verdadeiro[a])
    alpha_post[a] <- alpha_post[a] + r    beta_post[a]  <- beta_post[a] + (1 - r)
    regret[t] <- mu_star - p_verdadeiro[a]  }        cumsum(regret)}
regret_aleatoria <- replicate(n_mc, politica_aleatoria())
regret_ucb1      <- replicate(n_mc, politica_ucb1())
regret_thompson  <- replicate(n_mc, politica_thompson())
regret_medio <- tibble(  rodada     = rep(1:T_rounds, times = 3),
  politica   = rep(c("Aleatória", "UCB1", "Thompson sampling"), each = T_rounds),
  regret_acumulado = c(rowMeans(regret_aleatoria), rowMeans(regret_ucb1),
        rowMeans(regret_thompson))
)
```

Tabela 8.4: Regret acumulado médio ao final de 3.000 rodadas, 300 réplicas Monte Carlo

Política	Regret acumulado médio (T = 3.000)
Thompson sampling	36.46
UCB1	74.14
Aleatória	90.01



Regret acumulado médio (300 réplicas Monte Carlo) das três políticas ao longo de 3.000 rodadas, em um cenário de 4 braços com taxas de conversão 10%, 12%, 15% e 11%.

Figura 8.2: Regret acumulado médio (300 réplicas Monte Carlo) das três políticas ao longo de 3.000 rodadas, em um cenário de 4 braços com taxas de conversão 10%, 12%, 15% e 11%.

Os números confirmam a intuição teórica. A política aleatória, que nunca aprende com os dados observados, termina com regret acumulado de 90 — crescendo **linearmente** em T (a reta quase perfeita no gráfico), porque continua jogando o braço 15% só $1/4$ das vezes até a última rodada, exatamente a mesma ineficiência estrutural do teste A/B/n de horizonte fixo discutida na Seção 8.2.1 (p. 180). UCB1 reduz o regret final para 74.1 (18% menor que a aleatória), com a curva visivelmente **desacelerando** (côncava) conforme o algoritmo converge para o braço de 15% — a assinatura visual do regret sublinear $O(\log T)$ previsto pela teoria. Thompson sampling vai além, terminando em 36.5, a menor das três — um resultado empírico conhecido na literatura de bandits (Thompson sampling costuma superar UCB1 na prática em problemas de Bernoulli, mesmo com garantias teóricas de pior caso comparáveis) e que a simulação reproduz sem qualquer ajuste fino de parâmetros: nenhuma das três políticas tem hiperparâmetro algum para calibrar, a diferença inteira vem de *como* cada uma converte incerteza em decisão de exploração.

8.2.4 Horizonte fixo ou bandit?

A simulação da seção anterior pode sugerir que bandits deveriam substituir testes A/B em toda situação — afinal, por que “desperdiçar” tráfego em um braço pior por um horizonte inteiro, se um bandit realoca tráfego automaticamente para o que funciona melhor? A resposta depende do que se quer da experimentação, e não é unânime.

O teste A/B de horizonte fixo tem uma vantagem que nenhum bandit reproduz de graça: a **simplicidade da inferência causal pós-hoc**. Como a atribuição Z_i é decidida de uma vez, com probabilidade fixa e conhecida, independente de qualquer dado já observado, a demonstração de não-viés de $\widehat{\mathrm{ATE}}$ da Seção 1.4.3 (p. 9) se aplica diretamente, os intervalos de confiança clássicos (Capítulo 2) têm cobertura correta, e a pergunta “qual foi o efeito causal da variante B?” tem uma resposta estatisticamente limpa. Em um bandit, a alocação de cada rodada **depende dos dados observados até ali** — o próprio mecanismo que faz o bandit ser eficiente (jogar mais o que parece melhor) introduz uma dependência entre a decisão de alocação e a recompensa observada que quebra a independência simples entre Z_i e $(Y_i(0), Y_i(1))$ pressuposta na Seção 1.4.3 (p. 9). Estimar o efeito causal *depois* de uma coleta adaptativa exige métodos estatísticos mais delicados (fora do escopo deste capítulo) para corrigir o viés introduzido pela própria

adaptação — o braço que "pareceu" melhor cedo tende a ser jogado mais, o que retroalimenta sua própria média estimada de forma sutilmente enviesada, um primo próximo do vício do vencedor da Seção 8.1.4 (p. 178).

Como regra prática: prefira um **teste A/B de horizonte fixo** quando o objetivo principal é **aprender** o efeito causal de forma limpa e reportável (uma decisão de produto de alto risco, uma mudança que precisa de aprovação com base em um número defensável, um resultado que será citado depois) — o custo de oportunidade do tráfego "desperdiçado" no braço pior é aceitável em troca de uma resposta estatisticamente inequívoca. Prefira um **bandit** quando o objetivo principal é **maximizar o resultado durante o próprio processo de decisão**, a pergunta causal exata importa menos do que o desempenho acumulado, e há muitos braços ou mudanças frequentes (recomendação de conteúdo, otimização de preço em tempo real, alocação de criativos de anúncio) — contextos em que rodar dezenas de testes A/B sequenciais e formais seria impraticável. Muitas plataformas grandes usam os dois em conjunto: bandits para decisões operacionais de alta frequência e baixo risco individual, testes A/B de horizonte fixo reservados para mudanças que exigem uma resposta causal limpa e defensável.

8.2.5 Outros tópicos modernos

Este capítulo — e o livro — não esgota o território além do delineamento clássico. Dois ponteiros merecem menção, mesmo sem desenvolvimento completo. Quando as "unidades experimentais" não são pessoas nem parcelas, mas **execuções de um simulador computacional determinístico** (um modelo de elementos finitos, uma simulação climática, um pipeline de aprendizado de máquina caro de treinar), a lógica de repetição do Capítulo 1 deixa de fazer sentido — rodar o mesmo simulador duas vezes com os mesmos parâmetros de entrada produz exatamente a mesma saída, sem ruído algum a estimar. O campo de **desenho e análise de experimentos computacionais** (Sacks et al., 1989; Santner et al., 2003) responde a esse problema com desenhos **"space-filling"** (preenchedores de espaço, como hipercubos latinos), que cobrem o espaço de entradas de forma uniforme em vez de replicar pontos, e com modelos substitutos (processos gaussianos) para interpolar a superfície de resposta entre as corridas simuladas — uma lógica de vizinhança espacial que estende, mas não substitui, a metodologia de superfície de resposta do Capítulo 7.

Um segundo ponteiro: os **métodos de Taguchi** (Taguchi, 1986) para desenho robusto abordam uma pergunta ligeiramente diferente da deste livro — não "qual combinação de fatores maximiza a resposta média?" (a pergunta do Capítulo 7), mas "qual combinação de fatores de controle torna a resposta **menos sensível** a fatores de ruído que o pesquisador não consegue controlar em produção?" (temperatura ambiente, variação de matéria-prima, desgaste de equipamento). Diferente do ponteiro anterior, este **é** desenvolvido neste livro — a Seção 7.5 (p. 167) do Capítulo 7 mostra a proposta original de Taguchi (arranjos cruzados de controle e ruído, razão sinal-ruído) e a alternativa de Vining e Myers (1990), que resolve o mesmo problema com duas superfícies de resposta (média e log-variância) a partir de um único delineamento replicado — estatisticamente mais eficiente e mais interpretável.

8.3 Resumo do capítulo

- Um teste A/B é, estruturalmente, o delineamento completamente aleatorizado de dois tratamentos do Capítulo 3, com o usuário como unidade experimental e a aleatorização implementada por hash determinístico do identificador do usuário, garantindo atribuição persistente e SUTVA sob suposições razoáveis.
- O que torna testes A/B de produto digital difíceis na prática não é a álgebra, mas o contexto: efeitos pequenos relativos à variância exigem amostras enormes, múltiplas métricas monitoradas simultaneamente reintroduzem o problema de comparações múltiplas do Capítulo 3, efeitos de

novidade/primazia violam a suposição de resultado potencial estável no tempo, e visitas repetidas do mesmo usuário reintroduzem o problema de submuestreo do Capítulo 1.
- *Peeking* (checar o resultado repetidamente e parar no primeiro cruzamento de significância) infla drasticamente a taxa de falso positivo em relação ao α nominal — confirmado numericamente por simulação — porque viola a suposição de tamanho amostral fixo do teste clássico; o SPRT de Wald é a forma matematicamente correta de testar sequencialmente sem essa inflação.
- O vício do vencedor faz com que a estimativa da variante escolhida entre várias, por ter a maior média amostral, seja viesada para cima mesmo quando todas têm o mesmo efeito verdadeiro — motivo para sempre revalidar a variante vencedora com tráfego novo antes de generalizar a conclusão.
- Bandits (UCB1, Thompson sampling) resolvem o trade-off exploração/explotação realocando tráfego adaptativamente, com regret sublinear comprovado teórica e numericamente — ao custo de uma inferência causal pós-hoc mais delicada do que a de um teste A/B de horizonte fixo, porque a alocação passa a depender dos dados já observados.
- A escolha entre horizonte fixo e bandit depende do objetivo: aprendizado causal limpo e reportável favorece o primeiro; maximização do resultado durante a própria coleta favorece o segundo.

8.4 Encerrando o livro

Este livro começou, no Capítulo 1, com uma distinção que parece quase trivial — unidade experimental versus unidade amostral — e uma pergunta que não é trivial: por que, exatamente, sortear um tratamento permite chamar uma diferença observada de *efeito causal*? A resposta, formalizada com a notação de resultados potenciais de Neyman e Rubin na Seção 1.4.3 (p. 9), é o fio que atravessa todos os sete capítulos, sem exceção. O Capítulo 2 deu a esse fio uma maquinaria algébrica — o modelo linear, a matriz de projeção, a decomposição de somas de quadrados — que os Capítulos 3 a 6 aplicaram a delineamentos progressivamente mais ricos: um único fator (DCA), fontes de variação conhecidas removidas por blocagem, múltiplos fatores cruzados e suas interações, superfícies de resposta com curvatura. Este último capítulo mostrou que o mesmo fio causal — o mesmo $Y_i(0)$, $Y_i(1)$, a mesma prova de não-viés sob aleatorização — atravessa também o domínio de experimentação mais numeroso do século XXI, testes A/B e bandits em produtos digitais, ainda que ali surjam problemas práticos (peeking, vício do vencedor, o trade-off exploração/explotação) que um experimento de bancada raramente expõe com a mesma urgência.

Se há uma ideia única que vale a pena levar deste livro inteiro, é esta: a análise estatística de um experimento é, na melhor das hipóteses, tão boa quanto o delineamento que gerou os dados — nenhuma técnica de estimação, por mais sofisticada, salva um experimento confundido, sem repetição genuína ou sem aleatorização legítima. Repetição, aleatorização e controle local não são um capítulo introdutório a ser esquecido assim que a álgebra do modelo linear aparece; são a razão pela qual a álgebra significa o que significa. Um estudante que termina este livro capaz de olhar para qualquer questão comparativa — em psicologia, agricultura, engenharia ou produto digital — e perguntar primeiro “qual é a unidade experimental, e como o tratamento foi atribuído a ela?” já aprendeu o essencial da disciplina; o resto é, como os últimos seis capítulos tentaram mostrar, elaboração técnica sobre essa mesma pergunta.

Referências

Aitken, A. C. (1936). On Least Squares and Linear Combination of Observations. *Proceedings of the Royal Society of Edinburgh*, *55*, 42–48.

Auer, P., Cesa-Bianchi, N., & Fischer, P. (2002). Finite-time Analysis of the Multiarmed Bandit Problem. *Machine Learning*, *47*(2–3), 235–256.

Bailey, R. A. (2008). *Design of Comparative Experiments*. Cambridge University Press.

Bartlett, M. S. (1937). Properties of Sufficiency and Statistical Tests. *Proceedings of the Royal Society of London. Series A*, *160*(901), 268–282.

Bonferroni, C. E. (1936). Teoria statistica delle classi e calcolo delle probabilità. *Pubblicazioni del R Istituto Superiore di Scienze Economiche e Commerciali di Firenze*, *8*, 3–62.

Bose, R. C., Shrikhande, S. S., & Parker, E. T. (1960). Further Results on the Construction of Mutually Orthogonal Latin Squares and the Falsity of Euler's Conjecture. *Canadian Journal of Mathematics*, *12*, 189–203.

Box, G. E. P., & Cox, D. R. (1964). An Analysis of Transformations. *Journal of the Royal Statistical Society, Series B*, *26*(2), 211–252.

Box, G. E. P., & Hunter, J. S. (1957). Multi-Factor Experimental Designs for Exploring Response Surfaces. *The Annals of Mathematical Statistics*, *28*(1), 195–241.

Box, G. E. P., Hunter, J. S., & Hunter, W. G. (2005). *Statistics for Experimenters: Design, Innovation, and Discovery* (2º ed). John Wiley & Sons.

Box, G. E. P., & Wilson, K. B. (1951). On the Experimental Attainment of Optimum Conditions. *Journal of the Royal Statistical Society, Series B*, *13*(1), 1–45.

Cochran, W. G., & Cox, G. M. (1957). *Experimental Designs* (2º ed). John Wiley & Sons.

Cornfield, J. (1944). On Samples from Finite Populations. *Journal of the American Statistical Association*, *39*(226), 236–239. https://doi.org/10.1080/01621459.1944.10500675

Daniel, C. (1959). Use of Half-Normal Plots in Interpreting Factorial Two-Level Experiments. *Technometrics*, *1*(4), 311–341.

Dean, A., Voss, D., & Draguljić, D. (2017). *Design and Analysis of Experiments* (2º ed). Springer.

Derringer, G., & Suich, R. (1980). Simultaneous Optimization of Several Response Variables. *Journal of Quality Technology*, *12*(4), 214–219.

Draper, N. R. (1963). Ridge Analysis of Response Surfaces. *Technometrics*, *5*(4), 469–479. https://doi.org/10.1080/00401706.1963.10490122

Duncan, D. B. (1955). Multiple Range and Multiple F Tests. *Biometrics*, *11*(1), 1–42.

Dunnett, C. W. (1955). A Multiple Comparison Procedure for Comparing Several Treatments with a Control. *Journal of the American Statistical Association*, *50*(272), 1096–1121.

Edgington, E. S., & Onghena, P. (2007). *Randomization Tests* (4º ed). Chapman & Hall/CRC.

Finney, D. J. (1945). The Fractional Replication of Factorial Arrangements. *Annals of Eugenics*, *12*(1), 291–301.

Fisher, R. A. (1935a). *Statistical Methods for Research Workers* (5º ed). Oliver; Boyd.

Fisher, R. A. (1935b). *The Design of Experiments*. Oliver; Boyd.

Friedman, M. (1937). The use of ranks to avoid the assumption of normality implicit in the analysis of variance. *Journal of the American Statistical Association*, *32*(200), 675–701.

Frisch, R., & Waugh, F. V. (1933). Partial Time Regressions as Compared with Individual Trends. *Econometrica*, *1*(4), 387–401.

Golub, G. H., & Van Loan, C. F. (2013). *Matrix Computations* (4º ed). Johns Hopkins University Press.

Hinkelmann, K., & Kempthorne, O. (2008). *Design and Analysis of Experiments, Volume 1: Introduction to Experimental Design* (2º ed). John Wiley & Sons.

Imbens, G. W., & Rubin, D. B. (2015). *Causal Inference for Statistics, Social, and Biomedical Sciences: An Introduction*. Cambridge University Press.
Johari, R., Koomen, P., Pekelis, L., & Walsh, D. (2017). Peeking at A/B Tests: Why it Matters, and What to Do About It. *Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 1517–1525.
Kempthorne, O. (1952). *The Design and Analysis of Experiments*. John Wiley & Sons.
Kirk, R. E. (2012). *Experimental Design: Procedures for the Behavioral Sciences* (4º ed). Sage Publications.
Kish, L. (1965). *Survey Sampling*. John Wiley & Sons.
Kohavi, R., Tang, D., & Xu, Y. (2020). *Trustworthy Online Controlled Experiments: A Practical Guide to A/B Testing*. Cambridge University Press.
Kruskal, W. H., & Wallis, W. A. (1952). Use of Ranks in One-Criterion Variance Analysis. *Journal of the American Statistical Association*, *47*(260), 583–621.
Kutner, M. H., Nachtsheim, C. J., Neter, J., & Li, W. (2005). *Applied Linear Statistical Models* (5º ed). McGraw-Hill Irwin.
Lai, T. L., & Robbins, H. (1985). Asymptotically Efficient Adaptive Allocation Rules. *Advances in Applied Mathematics*, *6*(1), 4–22.
Langsrud, Ø. (2003). ANOVA for Unbalanced Data: Use Type II Instead of Type III Sums of Squares. *Statistics and Computing*, *13*(2), 163–167.
Lenth, R. V. (1989). Quick and Easy Analysis of Unreplicated Factorials. *Technometrics*, *31*(4), 469–473.
Levene, H. (1960). Robust Tests for Equality of Variances. Em I. Olkin et al. (Orgs.), *Contributions to Probability and Statistics: Essays in Honor of Harold Hotelling* (p. 278–292). Stanford University Press.
Lovell, M. C. (1963). Seasonal Adjustment of Economic Time Series and Multiple Regression Analysis. *Journal of the American Statistical Association*, *58*(304), 993–1010.
Montgomery, D. C. (2017). *Design and Analysis of Experiments* (9º ed). John Wiley & Sons.
Myers, R. H., Montgomery, D. C., & Anderson-Cook, C. M. (2016). *Response Surface Methodology: Process and Product Optimization Using Designed Experiments* (4º ed). John Wiley & Sons.
Oehlert, G. W. (2010). *A First Course in Design and Analysis of Experiments*. W. H. Freeman.
Owen, A. B. (2020). *A First Course in Experimental Design: Notes from Stat 263/363*. Stanford University.
Penrose, R. (1955). A Generalized Inverse for Matrices. *Mathematical Proceedings of the Cambridge Philosophical Society*, *51*(3), 406–413.
Plackett, R. L. (1950). Some Theorems in Least Squares. *Biometrika*, *37*(1/2), 149–157.
Popper, K. R. (1959). *The Logic of Scientific Discovery*. Hutchinson & Co.
Rao, C. R. (1973). *Linear Statistical Inference and Its Applications* (2º ed). John Wiley & Sons.
Robbins, H. (1952). Some Aspects of the Sequential Design of Experiments. *Bulletin of the American Mathematical Society*, *58*(5), 527–535.
Rubin, D. B. (1974). Estimating Causal Effects of Treatments in Randomized and Nonrandomized Studies. *Journal of Educational Psychology*, *66*(5), 688–701.
Sacks, J., Welch, W. J., Mitchell, T. J., & Wynn, H. P. (1989). Design and Analysis of Computer Experiments. *Statistical Science*, *4*(4), 409–423.
Santner, T. J., Williams, B. J., & Notz, W. I. (2003). *The Design and Analysis of Computer Experiments*. Springer.
Scheffé, H. (1959). *The Analysis of Variance*. John Wiley & Sons.
Searle, S. R. (1971). *Linear Models*. John Wiley & Sons.
Shapiro, S. S., & Wilk, M. B. (1965). An Analysis of Variance Test for Normality (Complete Samples). *Biometrika*, *52*(3/4), 591–611.
Speed, F. M., Hocking, R. R., & Hackney, O. P. (1978). Methods of Analysis of Linear Models with Unbalanced Data. *Journal of the American Statistical Association*, *73*(361), 105–112.
Splawa-Neyman, J. (1990). On the Application of Probability Theory to Agricultural Experiments. Essay on Principles. Section 9. *Statistical Science*, *5*(4), 465–472.

Taguchi, G. (1986). *Introduction to Quality Engineering: Designing Quality into Products and Processes*. Asian Productivity Organization.
Tarry, G. (1900). Le problème de 36 officiers. *Compte Rendu de l'Association Française pour l'Avancement des Sciences*, *1*, 122–123.
Thompson, W. R. (1933). On the Likelihood that One Unknown Probability Exceeds Another in View of the Evidence of Two Samples. *Biometrika*, *25*(3/4), 285–294.
Throckmorton, T. (1961). *Structures of classification data* [Tese de doutorado]. Iowa State University.
Tukey, J. W. (1949a). Comparing Individual Means in the Analysis of Variance. *Biometrics*, *5*(2), 99–114.
Tukey, J. W. (1949b). One Degree of Freedom for Non-Additivity. *Biometrics*, *5*(3), 232–242. https://doi.org/10.2307/3001938
Vining, G. G., & Myers, R. H. (1990). Combining Taguchi and Response Surface Philosophies: A Dual Response Approach. *Journal of Quality Technology*, *22*(1), 38–45.
Wald, A. (1945). Sequential Tests of Statistical Hypotheses. *The Annals of Mathematical Statistics*, *16*(2), 117–186.
Yates, F. (1933). The Formation of Latin Squares for Use in Field Experiments. *Empire Journal of Experimental Agriculture*, *1*(3), 235–244.
Yates, F. (1936). Incomplete randomized blocks. *Annals of Eugenics*, *7*(2), 121–140.
Yates, F. (1937). *The Design and Analysis of Factorial Experiments*. Imperial Bureau of Soil Science.
Zyskind, G. (1967). On Canonical Forms, Non-Negative Covariance Matrices and Best and Simple Least Squares Linear Estimators in Linear Models. *The Annals of Mathematical Statistics*, *38*(4), 1092–1109. https://doi.org/10.1214/aoms/1177698779